
UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA

Facultad de Ingeniería de Producción y Servicios

Escuela Profesional de Ingeniería de Sistemas

SISTEMA INTEGRADO DE SUPERVISIÓN OPERATIVA CON INTELIGENCIA ARTIFICIAL EXPLICABLE PARA LA DETECCIÓN DE ANOMALÍAS Y GENERACIÓN DE REPORTES TRAZABLES EN EMPRESAS AGROEXPORTADORAS PERUANAS

Tesis presentada por el Bachiller:

Cozco Mauri, Yoset

Para optar el Título Profesional de Ingeniero de Sistemas

Asesor:

Dr. Víctor Manuel Cornejo Aparicio

Arequipa – Perú

2026

DEDICATORIA

(Por completar — dedicatoria personal del autor)

AGRADECIMIENTOS

(Por completar — agradecimientos al asesor, jurado, institución colaboradora y familiares)

PRESENTACIÓN

La presente investigación tiene como propósito el diseño, implementación y evaluación de un sistema integrado de supervisión operativa para empresas agroexportadoras peruanas, que combina técnicas de aprendizaje automático, detección de anomalías, explicabilidad algorítmica y generación automática de reportes trazables mediante modelos de lenguaje con recuperación de contexto. El estudio responde a la necesidad de contar con herramientas de inteligencia artificial capaces de detectar desviaciones operativas, explicar sus causas probables y documentar alertas de manera comprensible para supervisores, responsables de calidad, gestores logísticos y auditores internos.

El trabajo se organiza en cinco capítulos: el Capítulo I establece el planteamiento del problema, objetivos e hipótesis; el Capítulo II desarrolla el marco teórico con antecedentes y estado del arte; el Capítulo III describe la propuesta metodológica; el Capítulo IV presenta los resultados y discusión; y el Capítulo V contiene las conclusiones y trabajos futuros.

El Autor

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

RESUMEN

Esta tesis propone un sistema integrado de supervisión operativa para empresas agroexportadoras peruanas, basado en un dataset agroexportador integrado y trazable. La arquitectura combina predicción tabular mediante modelos GBDT (Gradient Boosting Decision Trees), detección de anomalías operativas mediante ensemble de algoritmos, explicabilidad mediante SHAP (SHapley Additive exPlanations) y generación automática de reportes técnicos con LLMs en arquitectura RAG (Retrieval-Augmented Generation).

El problema abordado es la fragmentación de datos agroexportadores y la baja trazabilidad entre fuentes de comercio exterior, mercado interno, variables macroeconómicas, clima, logística y sanidad. En este contexto, la investigación se orienta a productos priorizados de agroexportación peruana: palta, uva y arándano como núcleo; espárrago como producto secundario condicionado a cobertura suficiente; y cacao como producto excluido de la evaluación principal por baja representatividad en el dataset real auditado.

La propuesta utiliza SUNAT/ADUANET como fuente primaria de exportaciones reales, Trade Map como benchmark externo, SISAP/MIDAGRI como contexto de mercado interno mayorista, BCRP para variables macroeconómicas, y fuentes climáticas, logísticas y sanitarias como proxies documentados. Los datos sintéticos controlados se restringen a escenarios experimentales, balanceo de clases, simulación de alertas o vacíos no observables con fuentes públicas, siempre identificados mediante etiquetas metodológicas.

Las contribuciones principales son: (1) una arquitectura modular de cuatro capas que separa predicción, detección, explicación y reporte; (2) un enfoque de dataset agroexportador integrado con datos reales observados, datos reales agregados, proxies y sintéticos controlados; (3) uso de SHAP para explicar la contribución de variables en alertas operativas; (4) reportes RAG restringidos a evidencia estructurada, score, metadatos y versión de dataset; y (5) una metodología de evaluación que compara rendimiento técnico, trazabilidad, comprensión operativa y tiempo-a-decisión. La Resolución SBS N. 053-2023 se considera como referencia nacional de buenas prácticas para gestión de riesgo de modelos, mientras que el D.S. N. 115-2025-PCM se adopta como marco peruano general de gobernanza y supervisión humana en IA.

Palabras clave: supervisión operativa, agroexportación, dataset integrado, detección de anomalías, explicabilidad IA, SHAP, RAG, GBDT, trazabilidad, inteligencia artificial.

ABSTRACT

This thesis proposes an integrated operational supervision system for Peruvian agro-export companies, based on a traceable integrated agro-export dataset. The architecture combines tabular prediction with Gradient Boosting Decision Trees (GBDT), operational anomaly detection through an algorithmic ensemble, explainability with SHAP (SHapley Additive exPlanations), and automatic technical report generation with Large Language Models (LLMs) in a Retrieval-Augmented Generation (RAG) architecture.

The research addresses the fragmentation of agro-export data and the weak traceability between foreign trade, domestic market, macroeconomic, climate, logistics, and sanitary sources. The study focuses on avocado, grape, and blueberry as core products; asparagus as a secondary product subject to coverage validation; and cocoa as excluded from the main evaluation due to low representativeness in the audited real dataset.

The proposal uses SUNAT/ADUANET as the primary source for real export data, Trade Map as an external benchmark, SISAP/MIDAGRI as domestic wholesale market context, BCRP for macroeconomic variables, and climate, logistics, and sanitary sources as documented proxies. Controlled synthetic data are limited to experimental scenarios, class balancing, alert simulation, or non-public data gaps, and must always be explicitly labeled.

The main contributions are: (1) a modular four-layer architecture separating prediction, detection, explanation, and reporting; (2) an integrated agro-export dataset approach combining observed real data, aggregated real data, proxies, and controlled synthetic data; (3) SHAP-based attribution of variables in operational alerts; (4) evidence-restricted RAG reports using structured evidence, scores, metadata, and dataset versions; and (5) an evaluation methodology covering technical performance, traceability, operational comprehension, and time-to-decision.

Keywords: operational supervision, agro-export, integrated dataset, anomaly detection, AI explainability, SHAP, RAG, GBDT, traceability, artificial intelligence.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```


ÍNDICE DE CONTENIDOS

- DEDICATORIA
- AGRADECIMIENTOS
- PRESENTACIÓN
- RESUMEN
- ABSTRACT
- ÍNDICE DE CONTENIDOS
- ÍNDICE DE FIGURAS
- ÍNDICE DE TABLAS
- ÍNDICE DE FÓRMULAS
- INTRODUCCIÓN
- **CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA**
 - 1.1 Descripción de la Realidad Problemática
 - 1.2 Problema Principal
 - 1.3 Objetivos
 - 1.4 Hipótesis de la Investigación
 - 1.5 Variables e Indicadores
 - 1.6 Viabilidad de la Investigación
 - 1.7 Justificación e Importancia
 - 1.8 Alcance
 - 1.9 Línea, Tipo y Nivel de la Investigación
 - 1.9.1. Línea de la investigación.
 - 1.9.2. Tipo de la investigación.
 - 1.9.3. Nivel de la investigación.
 - 1.10 Técnicas e Instrumentos de Recolección de Información
 - 1.10.1. Técnicas.
 - 1.10.2. Instrumentos.
- **CAPÍTULO II: MARCO TEÓRICO**

- 2.1 Antecedentes de la Investigación
 - 2.2 Estado del Arte
 - 2.3 Marco Conceptual
 - **CAPÍTULO III: PROPUESTA METODOLÓGICA**
 - 3.1 Arquitectura del Sistema Integrado
 - 3.2 Datasets de Validación y Benchmarks
 - 3.3 Configuración Experimental y Métricas
 - **CAPÍTULO IV: RESULTADOS Y DISCUSIÓN**
 - 4.1 Resultados Cuantitativos
 - 4.2 Resultados Cualitativos
 - 4.3 Discusión de Resultados
 - **CAPÍTULO V: CONCLUSIONES Y TRABAJOS FUTUROS**
 - 5.1 Conclusiones
 - 5.2 Limitaciones
 - 5.3 Trabajos Futuros
 - CRONOGRAMA DE ACTIVIDADES
 - CONCLUSIONES (English)
 - RECOMENDACIONES
 - GLOSARIO DE TÉRMINOS
 - REFERENCIAS BIBLIOGRÁFICAS
 - ANEXOS
-

ÍNDICE DE FIGURAS

(Por completar — se insertarán las figuras del diagrama de arquitectura del sistema, flujo del pipeline y resultados experimentales)

ÍNDICE DE TABLAS

- Tabla 2.1 — Comparativa de Sistemas de Supervisión con IA
 - Tabla 2.2 — Resumen del Estado del Arte por Bloques Temáticos
 - Tabla 1.1 — Variables e Indicadores
 - Tabla 1.2 — Cronograma de Actividades
 - Tabla 1.3 — Técnicas e Instrumentos de Recolección
-

ÍNDICE DE FÓRMULAS

- Fórmula 1 — Función objetivo GBDT: $F^*(x) = \arg \min_F \mathbb{E}[L(y, F(x))]$
 - Fórmula 2 — Iteración GBDT: $F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$
 - Fórmula 3 — Local Outlier Factor: $\mathbf{LOF}_k(p)$
 - Fórmula 4 — Deep SVDD: $\min_{W,R,c} R^2 + \frac{1}{\nu n} \sum \max(0, |f(x_i; W) - c|^2 - R^2)$
 - Fórmula 5 — Valor SHAP: $\phi_i = \sum_{S \subseteq F \setminus i} \frac{|S|!(|F|-|S|-1)!}{|F|!} [f(S \cup i) - f(S)]$
-

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

INTRODUCCION

La agroexportación peruana constituye un sector estratégico para la economía nacional debido a su crecimiento sostenido, diversificación de productos y participación en mercados internacionales exigentes. De acuerdo con información oficial del Ministerio de Desarrollo Agrario y Riego, al cierre de 2025 las agroexportaciones peruanas alcanzaron ventas por USD 15 013 millones, con un crecimiento de 17.3% respecto al año anterior (MIDAGRI, 2026). Entre los productos de mayor interés para esta investigación se consideran como núcleo la palta, la uva y el arándano, mientras que el espárrago se mantiene como producto secundario condicionado a la calidad de su cobertura de datos. El cacao, aunque aparece en registros exploratorios, se excluye del núcleo experimental por baja representatividad local.

En este contexto, las empresas agroexportadoras articulan procesos de producción agrícola, acopio, almacenamiento, control de calidad, cumplimiento fitosanitario, logística y comercialización internacional. Cada proceso genera datos que pueden revelar desviaciones relevantes para la gestión operativa: cambios inusuales de precios, variaciones de volumen, condiciones climáticas adversas, incumplimientos de calidad, retrasos logísticos o patrones atípicos en mercados de destino. Sin embargo, la información se encuentra dispersa entre fuentes públicas, sistemas internos, reportes agregados y registros técnicos no siempre compatibles entre sí.

La presente investigación parte de esa fragmentación. El proyecto no se limita a entrenar modelos sobre un dataset sintético, sino que propone construir y utilizar un **dataset agroexportador integrado**, compuesto por datos reales observados, datos reales agregados, variables proxy documentadas y datos sintéticos controlados solo cuando sean necesarios para escenarios experimentales, balanceo o etiquetas de anomalía. La fuente primaria para comercio exterior es SUNAT/ADUANET; Trade Map se utiliza como benchmark externo de mercados destino; SISAP/MIDAGRI aporta contexto de mercado interno mayorista para palta, uva y espárrago; BCRP aporta tipo de cambio; y las fuentes climáticas, logísticas y sanitarias se emplean como proxies agregados cuando no existe llave directa por embarque.

La inteligencia artificial ofrece herramientas adecuadas para abordar esta brecha. Los modelos GBDT han demostrado buen desempeño en datos tabulares estructurados (Grinsztajn et al., 2022); los ensembles de detectores de anomalías permiten identificar comportamientos atípicos de forma más robusta que un detector individual (Han et al., 2022); la explicabilidad mediante SHAP convierte predicciones opacas en atribuciones comprensibles (Lundberg & Lee, 2017); y los modelos de lenguaje con arquitectura RAG pueden transformar resultados cuantitativos en reportes comprensibles siempre que su función se restrinja a narrar evidencias y no a decidir ni inventar información (Schneider et al., 2025).

La tesis propone un sistema integrado de cuatro capas que une predicción tabular, detección de anomalías, explicabilidad y generación de reportes trazables en un flujo coherente de supervisión operativa. El sistema busca mejorar la detección de desviaciones, explicar los factores asociados y documentar cada alerta con fuente, score, umbral, variables explicativas y evidencia recuperada. La Resolución SBS N. 053-2023 (SBS, 2023) se toma como referencia nacional de buenas prácticas para gestión de riesgo de modelos, sin asumirla como obligación directa para agroexportadoras; el D.S. N. 115-2025-PCM (PCM, 2025) se emplea como marco peruano general sobre gobernanza, transparencia y supervisión humana en inteligencia artificial.

El documento se estructura de la siguiente manera: el Capítulo I plantea el problema de investigación, define objetivos, hipótesis, variables, indicadores, alcance y viabilidad. El Capítulo II desarrolla antecedentes, estado del arte y marco teórico. El Capítulo III describe la arquitectura del sistema, el dataset agroexportador integrado y la configuración experimental. El

Capítulo IV presenta resultados validados o, cuando corresponda, resultados preliminares claramente identificados. El Capítulo V sintetiza conclusiones, limitaciones y trabajos futuros.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

CAPITULO I: PLANTEAMIENTO DEL PROBLEMA

1.1 Descripción de la realidad problemática

Las empresas agroexportadoras peruanas coordinan producción, acopio, empaque, control de calidad, cumplimiento fitosanitario, logística y comercialización internacional. En cada etapa se generan datos relevantes para la supervisión operativa: precios, volúmenes, fechas de exportación, mercados destino, condiciones climáticas, alertas sanitarias, costos logísticos, mermas y tiempos de despacho. El problema no es solo la ausencia de modelos predictivos, sino la dispersión de fuentes y la baja trazabilidad entre dato, alerta, explicación y decisión.

El panorama actual de datos confirma esta fragmentación. SUNAT/ADUANET aporta microdatos de exportación; Trade Map ofrece benchmarks internacionales por producto y mercado destino; SISAP/MIDAGRI contiene precios y volúmenes mayoristas internos para palta, uva y espárrago; BCRP aporta tipo de cambio; fuentes climáticas como NASA POWER y SENAMHI funcionan como proxies regionales; APN/OSITRAN aportan contexto logístico; y SENASA/FDA/RASFF pueden emplearse como contexto sanitario agregado. Ninguna fuente, por sí sola, cubre todo el flujo operacional. Por ello, la tesis adopta como base un **dataset agroexportador integrado** compuesto por datos reales observados, datos reales agregados, proxies documentados y datos sintéticos controlados.

La investigación se focaliza en palta, uva y arándano como productos núcleo. El espárrago se mantiene como producto secundario condicionado a validación suficiente. El cacao se excluye del núcleo experimental por baja representatividad local detectada en el dataset real.

La supervisión manual basada en hojas de cálculo o reportes aislados dificulta detectar desviaciones oportunamente y explicar por qué una alerta es relevante. A su vez, los sistemas automatizados sin explicabilidad reducen la confianza de supervisores y auditores internos. Surge, por tanto, la necesidad de un sistema integrado que detecte anomalías, explique las variables incidentes y genere reportes trazables basados exclusivamente en evidencias.

1.2 Problema principal

Como mejorar la deteccion, explicacion y documentacion de anomalias operativas en agroexportaciones peruanas mediante un sistema integrado de inteligencia artificial explicable que combine datos multisource, prediccion tabular, deteccion de anomalias, SHAP y reportes RAG trazables?

Subproblemas

- Que fuentes reales, agregadas, proxy y sinteticas controladas permiten caracterizar el comportamiento normal y anomalico de palta, uva y arandano?
- Como integrar datos de comercio exterior, mercado interno, macroeconomia, clima, logistica y sanidad sin confundir granularidades?
- Que arquitectura de IA permite enlazar prediccion tabular, deteccion de anomalias, explicabilidad y reportes en un flujo trazable?
- De que manera SHAP contribuye a la comprension de las alertas sin atribuir causalidad directa?
- Como generar reportes RAG comprensibles y accionables sin permitir que el LLM invente cifras, causas o recomendaciones?
- Como evaluar si el sistema integrado mejora rendimiento tecnico, trazabilidad, comprension y tiempo de decision frente a componentes aislados?

1.3 Objetivos

1.3.1 Objetivo principal

Disenar, implementar y evaluar un sistema integrado de supervision operativa con inteligencia artificial explicable para detectar, explicar y documentar anomalias en un dataset agroexportador integrado de palta, uva y arandano, considerando fuentes reales observadas, datos agregados, proxies documentados y datos sinteticos controlados.

1.3.2 Objetivos especificos

1. Identificar, recolectar y documentar fuentes de datos agroexportadores relacionadas con comercio exterior, mercado interno, macroeconomia, clima, logistica y sanidad.
2. Construir un dataset agroexportador integrado y trazable, segmentado por productos nucleo y con etiquetas metodologicas de origen, granularidad y uso.
3. Implementar modelos tabulares LightGBM/XGBoost para estimar valores esperados de precio o volumen.
4. Implementar un ensemble de deteccion de anomalias basado en Isolation Forest, LOF y ECOD.
5. Aplicar SHAP/TreeSHAP para explicar las principales variables asociadas a cada alerta.
6. Generar reportes tecnicos trazables mediante RAG/LLM usando datos, scores, umbrales, fuentes y explicaciones estructuradas.
7. Evaluar el sistema con metricas tecnicas, trazabilidad documental y, si corresponde, pruebas de comprension y tiempo de decision con usuarios o evaluadores.

1.4 Hipotesis de la investigacion

Hipotesis general (H1): Un sistema integrado de prediccion, deteccion de anomalias, explicabilidad y reportes trazables mejora la deteccion, comprension y trazabilidad de anomalias agroexportadoras frente al uso de componentes aislados.

Hipotesis nula (H0): No existe diferencia significativa entre el sistema integrado y los componentes aislados en rendimiento de deteccion, comprension de alertas, calidad de reportes, trazabilidad documental o tiempo de decision.

Subhipotesis:

- **H1a:** El ensemble IF + LOF + ECOD obtiene mejor rendimiento de deteccion que detectores individuales o, en caso de rendimiento equivalente, aporta mayor estabilidad y trazabilidad.
- **H1b:** Las explicaciones SHAP incrementan la comprension de las alertas al identificar variables relevantes y direccion de contribucion.
- **H1c:** Los reportes RAG anclados en datos, SHAP y fuentes presentan mayor trazabilidad y consistencia que reportes generados sin recuperacion de contexto.
- **H1d:** El sistema integrado reduce el tiempo requerido para interpretar una alerta frente a un flujo basado en salidas tecnicas aisladas.

1.5 Variables e indicadores

1.5.1 Variable independiente

Tipo de sistema de supervision operativa:

- VI1: Sistema integrado (prediccion tabular + deteccion de anomalias + SHAP + RAG).
- VI2: Componentes aislados (salidas tecnicas independientes sin paso estructurado de evidencia).

1.5.2 Variables dependientes

Variable dependiente	Indicadores	Criterio de evaluacion
VD1: Rendimiento de deteccion	ROC-AUC, PR-AUC, precision, recall, F1	Superar o justificar equivalencia frente a baselines con mayor trazabilidad.
VD2: Calidad de explicabilidad	Cobertura top-k SHAP, estabilidad, claridad percibida	Explicaciones comprensibles y consistentes.
VD3: Calidad de reportes	Compleitud, coherencia, accionabilidad, evidencia, consistencia numerica	Rubrica >= 4/5 cuando exista evaluacion humana.
VD4: Comprension y tiempo de decision	Segundos, Likert, decision correcta	Reduccion de tiempo y mejora de comprension.
VD5: Trazabilidad documental	Porcentaje de alertas con dato, version, modelo, score, SHAP, fuente y reporte	>= 95% de campos completos en condicion integrada.

1.5.3 Variables explicativas del modelo

Grupo	Variables	Fuente preferida	Tipo metodologico
Comercio exterior	volumen_kg, valor_fob_usd, precio_kg_usd, destino_mercado, empresa_exportadora	SUNAT/ADUANET	real_observada/derivada
Mercado interno	sisap_precio_prom, sisap_volumen	SISAP/MIDAGRI	real_agregada
Macro	tipo_cambio_pen_usd	BCRP	real_agregada
Clima	temperatura_max_c, temperatura_min_c, precipitacion_mm, humedad_pct, ndvi	NASA/SENAMHI/NDVI	proxy
Logistica	dias_logisticos, costo_logistico_usd_kg, carga_portuaria_mes, contenedores_mes	Dataset real/APN/OSITRAN	proxy o derivada
Sanidad	cumplimiento_fitosanitario, alertas_sanitarias_mes, rechazos_mes	SENASA/FDA/RASFF	proxy o sintetica controlada
Contexto internacional	valor_exportado_trademap, crecimiento_exportaciones, participacion_mercado, arancel_estimado	Trade Map	real_agregada

La variable `etiqueta_anomalia` se tratara como variable experimental derivada, proxy o sintetica segun su origen. Si no existe etiqueta oficial por embarque, debe declararse como construida mediante reglas trazables o escenarios controlados.

1.6 Viabilidad de la investigacion

1.6.1 Viabilidad tecnica

El stack tecnologico es viable con herramientas open-source: XGBoost, LightGBM, PyOD, SHAP, scikit-learn, pandas y motores RAG/LLM. Los datos locales y descargados permiten una validacion progresiva basada en fuentes reales, agregadas y proxies. La principal restriccion tecnica no es la falta de algoritmos, sino la necesidad de gobernar granularidades y trazabilidad.

1.6.2 Viabilidad de datos

La tesis cuenta con `data/dataset_real_v1.csv`, descargas SUNAT/ADUANET, archivos Trade Map, SISAP procesado, BCRP, MIDAGRI, FAOSTAT, NASA/SENAMHI, APN/OSITRAN y fuentes sanitarias. Los datos sinteticos quedan como apoyo para escenarios, balanceo o etiquetas experimentales, no como evidencia principal unica.

1.6.3 Viabilidad operativa y economica

El sistema se evalua en ambiente experimental, sin despliegue productivo en tiempo real. La utilidad economica se plantea como impacto potencial por reduccion de tiempo de analisis, mejor documentacion de alertas y deteccion temprana de desviaciones.

1.7 Justificacion e importancia

1.7.1 Justificacion teorica

La tesis integra cuatro lineas de investigacion que suelen aparecer separadas: modelos tabulares, deteccion de anomalias, explicabilidad y generacion de reportes. Su aporte principal es articularlas en un flujo trazable para supervision operativa agroexportadora peruana, con gobernanza de datos multisource y restriccion anti-alucinacion.

1.7.2 Justificacion practica

El sistema puede ayudar a supervisores, responsables de calidad, analistas logisticos y auditores internos a comprender alertas con mayor rapidez y evidencia. El valor no esta solo en detectar una anomalia, sino en documentar por que fue marcada y que fuentes respaldan la interpretacion.

1.7.3 Justificacion metodologica

El uso de datos integrados permite superar la dependencia exclusiva de datasets sinteticos. La tesis declara explicitamente la naturaleza de cada variable: real observada, real agregada, proxy, derivada o sintetica controlada.

1.8 Alcance

1.8.1. Delimitación Temática y Tecnológica

La investigación abarca el diseño, implementación y evaluación experimental de un prototipo de software integrado para la supervisión operativa del sector agroexportador peruano. Tecnológicamente, el sistema se acota a una arquitectura estructurada en cuatro capas analíticas secuenciales y de complejidad incremental:

1. **Capa 1: Predicción Tabular de Valores Esperados:** Implementación de modelos de aprendizaje supervisado basados en árboles de decisión de aumento de gradiente (GBDT), específicamente *XGBoost* y *LightGBM*, entrenados para resolver tareas de regresión (estimación de valores esperados de precio FOB por kilogramo o volumen de embarque) sobre datos tabulares multivariados. Se excluyen otros modelos supervisados no basados en árboles debido a su menor eficiencia empírica en el modelado de datos tabulares de escala empresarial.

2. **Capa 2: Ensemble Unificado de Detección de Anomalías:** Configuración de un ensemble no supervisado mediante la librería *PyOD*, que combina tres algoritmos con principios matemáticos complementarios: *Isolation Forest* (método inductivo basado en particionamiento de espacio para identificar outliers globales), *Local Outlier Factor* (LOF, método densitométrico local para identificar outliers contextuales en vecindarios locales) y *Empirical Cumulative Distribution Outlier Detection* (ECOD, método estadístico no paramétrico basado en funciones de distribución acumulada para estimar la probabilidad de cola de las observaciones en múltiples dimensiones). La unificación de puntuaciones se realiza mediante escalamiento Min-Max y promedio simple.

3. **Capa 3: Explicabilidad Post-Hoc Local:** Generación de explicaciones locales para cada alerta de anomalía aduanera u operativa mediante la librería *SHAP*, implementando la formulación optimizada *TreeSHAP*. Esta capa calcula los valores de Shapley para medir la contribución marginal de cada variable de entrada (comercio exterior, clima, mercado interno, logística, sanidad) en el score de anomalía generado, identificando la magnitud y dirección (positiva o negativa) del impacto de cada variable, sin establecer relaciones de causalidad física o real.

4. **Capa 4: Generación Automatizada de Reportes Narrativos (RAG):** Desarrollo de un mecanismo de generación en lenguaje natural utilizando una arquitectura de Recuperación Aumentada por Generación (RAG). El ámbito tecnológico de esta capa se restringe a un modelo de lenguaje de gran tamaño (LLM) acotado mediante *prompt engineering* estricto, donde el prompt de entrada se construye dinámicamente inyectando de forma exclusiva la evidencia estructurada de la alerta (valores reales del registro, score del ensemble, umbral de detección, variables top-k de SHAP con sus respectivas atribuciones numéricas, y metadatos de las fuentes). El LLM tiene prohibido realizar búsquedas libres en internet o recuperar conocimiento externo de sus pesos, limitando su labor a la síntesis narrativa y redacción formal de informes técnicos trazables en español.

1.8.2. Delimitación Geográfica y Productiva

- **Ámbito Geográfico:** La investigación se enfoca en el análisis de las operaciones agroexportadoras de la costa y valles interandinos de la República del Perú. Específicamente, el modelado y evaluación se restringe a los cinco departamentos con mayor volumen de agroexportación y densidad de registros aduaneros: La Libertad, Piura, Ica, Lambayeque y Arequipa. Las operaciones de otros departamentos quedan fuera del alcance directo del estudio, aunque el diseño metodológico es genérico y reproducible para otras regiones.
- **Ámbito Productivo (Cultivos):** El estudio se delimita a tres productos núcleo seleccionados por su alta representatividad comercial y complejidad logística: la palta (*Persea americana*), la uva de mesa (*Vitis vinifera*) y el arándano (*Vaccinium*

corymbosum). Adicionalmente, el espárrago (*Asparagus officinalis*) se incorpora como un cultivo secundario con el fin de evaluar la robustez de los modelos ante variaciones en la disponibilidad y granularidad de los datos. Se excluye explícitamente el cultivo de cacao (*Theobroma cacao*) debido a que el análisis forense del dataset aduanero identificó una baja representatividad transaccional (solo 379 registros en la ventana de tiempo evaluada), lo que impide un entrenamiento estadísticamente estable y libre de sesgos para modelos de clasificación o regresión multivariados.

1.8.3. Delimitación Temporal y de Datos

- **Ventana Temporal de Evaluación:** La ventana temporal histórica abarca un periodo continuo de 8 años, desde **junio de 2018 hasta mayo de 2026** inclusive. Este rango permite capturar ciclos estacionales completos, eventos macroeconómicos de impacto local y el comportamiento de las exportaciones bajo diferentes condiciones climáticas (incluyendo los efectos de fenómenos del Niño).
- **Naturaleza del Dataset Integrado:** El dataset utilizado para el entrenamiento y validación de los modelos tiene un volumen total consolidado de **40,289 registros transaccionales**. Metodológicamente, se declara que los datos no provienen de una única fuente homogénea, sino de un dataset agroexportador integrado y trazable estructurado en cuatro tipos de variables según su origen y nivel de agregación:
- *Datos reales observados:* Microdatos transaccionales de aduanas por embarque obtenidos de SUNAT/ADUANET (archivos de manifiestos y declaraciones aduaneras en formato DBF parseados localmente).
- *Datos reales agregados:* Series temporales de precios mayoristas del mercado local obtenidos del SISAP/MIDAGRI (formato CSV diario), estadísticas macroeconómicas del tipo de cambio mensual provenientes del BCRP, y datos de contraste comercial internacional de Trade Map.
- *Variables contextuales proxies:* Estimaciones climáticas de radiación, temperatura y humedad acumuladas por coordenadas semanales obtenidas de la base de datos NASA POWER, y registros de alertas sanitarias mensuales agregadas de SENASA y la FDA.
- *Datos sintéticos controlados:* Empleados estrictamente para complementar vacíos temporales de datos públicos, balanceo de clases altamente desbalanceadas en la evaluación de anomalías o inyectar escenarios experimentales de anomalías simuladas con fines de validación técnica de la Capa 2 y Capa 4, garantizando que el origen metodológico de cada registro esté etiquetado de forma transparente.

1.8.4. Delimitación Operativa y de Evaluación

- **Entorno de Ejecución Computacional:** La ejecución, entrenamiento y evaluación de los modelos del pipeline se restringe a un entorno computacional local estándar compuesto por recursos de procesamiento en CPU convencional (procesador comercial de gama media, 16 GB de memoria RAM, sin dependencia de aceleración por GPU corporativa o de alta gama), demostrando la viabilidad de bajo costo del sistema para el sector académico y PYME.
- **Esquema de Evaluación del Sistema:** La evaluación del sistema integrado se delimita a experimentos controlados (E1 a E5) utilizando una división de datos temporal estricta (70% entrenamiento cronológico, 10% validación de hiperparámetros con Optuna y 20% test cronológico final) para evitar la filtración de información (*data leakage*).
- **Estudio de Usabilidad Operativa (VD4):** La evaluación de la usabilidad y la reducción del tiempo de decisión se limita a una prueba experimental controlada con un grupo de evaluadores de perfil profesional en ingeniería, administración o

logística (tamaño de muestra $N = 15$ a 27 participantes, bajo un diseño experimental intra-sujetos o *within-subjects*). La prueba evaluará el impacto del uso de reportes integrados y explicaciones SHAP frente a un flujo de salida técnica tradicional (datos crudos y scores sin explicación narrativa). No se contempla una validación con usuarios en entornos productivos de empresas reales ni integraciones de software con sus ERPs activos.

1.8.5. Delimitación Regulatoria y de Principios de Gobernanza

La investigación no busca obtener una certificación formal de cumplimiento legal ni auditar procesos comerciales de una corporación real. El alcance se limita a la **conformidad de diseño** con los principios de gobernanza algorítmica y supervisión humana recomendados en los marcos normativos nacionales e internacionales vigentes:

1. **Decreto Supremo N° 115-2025-PCM (Reglamento de la Ley de Inteligencia Artificial en Perú):** El diseño de la Capa 4 (RAG) y los anexos de Model Cards (Anexo B) y Datasheets (Anexo C) adoptan los lineamientos de transparencia, trazabilidad de datos y supervisión humana ("humano en el bucle" u *human-in-the-loop*), asegurando que el sistema actúe como un asistente consultivo y no reemplace la firma o decisión del auditor humano.
2. **Resolución SBS N° 053-2023 (Reglamento de Gestión de Riesgos de Modelos):** Se toma como estándar metodológico de referencia para la documentación y validación de las variables independientes, la trazabilidad del pipeline de datos y la declaración explícita de limitaciones del modelo, aunque el sector agroexportador no se encuentre bajo la supervisión de la Superintendencia de Banca, Seguros y AFP.
3. **NIST AI Risk Management Framework (AI RMF 1.0) y EU AI Act:** El prototipo adopta la categorización de riesgos y las directrices de explicabilidad local para justificar la integración de la Capa 3 (SHAP) como interfaz de auditoría, limitando la validez del cumplimiento normativo a un alineamiento conceptual metodológico de diseño del software.

1.8.6. Exclusiones Explícitas de la Investigación

Para salvaguardar la frontera del proyecto frente a observaciones de jurados o exigencias fuera del marco de la tesis, se excluye expresamente del alcance de este trabajo:

1. **Monitoreo en Tiempo Real o Integración Productiva:** El software no contempla un despliegue en servidores productivos continuos de empresas agroexportadoras, ni integraciones directas mediante APIs activas o WebSockets con sistemas de información empresarial en tiempo real.
2. **Deep Learning como Propuesta Principal:** Las redes neuronales profundas especializadas en datos tabulares (tales como *TabNet* o *FT-Transformer*) quedan totalmente excluidas como núcleo o propuesta principal del sistema de supervisión. Su uso se limita de forma estricta a baselines comparativos de rendimiento en la sección de discusión de resultados.
3. **Automatización Total de la Decisión:** El sistema bajo ninguna circunstancia reemplaza el criterio, firma o toma de decisiones del personal de supervisión humana. No cuenta con módulos automáticos de bloqueo de carga, generación de órdenes de compra, rechazo de exportación o renegociación de contratos aduaneros.
4. **Cacao como Producto Principal:** Se excluye de forma permanente el análisis y modelamiento del cacao debido a la insuficiente representatividad estadística y volumétrica en el dataset real.

1.9 Línea, Tipo y Nivel de la investigación

1.9.1. Línea de la investigación

La presente investigación se enmarca formalmente dentro de las líneas de investigación definidas por la Escuela Profesional de Ingeniería de Sistemas de la Universidad Nacional de San Agustín de Arequipa:

* **Línea Principal: Inteligencia Artificial y Aprendizaje Automático Aplicado.** La tesis propone una arquitectura de software inteligente que integra modelos supervisados (XGBoost y LightGBM) para la predicción de series tabulares y modelos no supervisados (ensemble PyOD compuesto por Isolation Forest, LOF y ECOD) para la detección de anomalías operativas, contribuyendo al modelado y automatización de procesos analíticos complejos en el sector productivo.

* **Línea Secundaria: Ingeniería de Software y Gobernanza de TI.** La investigación define un pipeline de procesamiento y transferencia estructurada de evidencia (datos → predicciones → anomalías → explicaciones SHAP → narrativas RAG) alineado con principios normativos nacionales (D.S. N° 115-2025-PCM) y marcos de control de riesgos (Resolución SBS N° 053-2023), abordando la auditabilidad, reproducibilidad y gobernanza de sistemas de software basados en inteligencia artificial.

1.9.2. Tipo de la investigación

De acuerdo con las clasificaciones de la metodología de la investigación (Creswell, 2018; Vargas, 2009), este estudio es de **tipo aplicado y tecnológico**.

* Es *aplicado* porque no busca desarrollar nuevas teorías matemáticas o algoritmos de aprendizaje automático desde cero, sino utilizar el conocimiento teórico existente y los algoritmos validados en el estado del arte (GDBTs, algoritmos de densidad y árboles de aislamiento, valores de Shapley y modelos de lenguaje con RAG) para resolver un problema operativo concreto: la fragmentación, falta de explicabilidad y baja trazabilidad en la supervisión de operaciones agroexportadoras en el contexto peruano.

* Es *tecnológico* porque se centra en el diseño, desarrollo experimental y validación de un artefacto de software (un prototipo de sistema integrado de supervisión operativa) concebido para optimizar la eficiencia y la toma de decisiones asistida por datos en un dominio real.

1.9.3. Nivel de la investigación

La investigación corresponde a un **nivel explicativo y evaluativo**, adoptando un enfoque epistemológico **post-positivista**:

* Es *explicativo* porque busca analizar la relación entre las variables independientes (el uso del sistema integrado de IA) y las variables dependientes (el nivel de comprensión de las alertas y la reducción del tiempo de decisión de los analistas). Se intenta explicar *cómo* y *por qué* la inyección de contexto narrativo acotado por SHAP incrementa la claridad de las anomalías operativas en comparación con las herramientas técnicas tradicionales que actúan de forma aislada.

* Es *evaluativo* debido a que se realiza una comparación sistemática del rendimiento cuantitativo del sistema (ROC-AUC, PR-AUC, F1-Score) frente a baselines individuales del estado del arte, y se evalúa cualitativamente el prototipo mediante un estudio de usabilidad que registra tiempos de decisión y tasas de comprensión con evaluadores humanos utilizando pruebas estadísticas (e.g., test de Wilcoxon o t-Student de muestras apareadas).

* El enfoque es *post-positivista* ya que sostiene que, aunque los fenómenos operativos y aduaneros pueden ser medidos con rigor matemático, la comprensión y el soporte a la decisión por parte de los usuarios contienen elementos subjetivos que deben

ser aproximados a través de la triangulación metodológica, combinando métricas algorítmicas de precisión con encuestas Likert y escalas estandarizadas de usabilidad (SUS).

1.10 Técnicas e Instrumentos de Recolección de Información

1.10.1. Técnicas

Para el desarrollo y evaluación del sistema propuesto se emplean tres técnicas metodológicas fundamentales en la ingeniería de sistemas:

1. **Análisis Documental:** Aplicado para la recolección, selección, limpieza e integración de la información proveniente de bases de datos públicas y oficiales (SUNAT, SISAP/MIDAGRI, BCRP, NASA POWER, Trade Map). Esta técnica permite caracterizar las series históricas y estructurar el dataset integrado de 40,289 registros aduaneros y contextuales.
2. **Experimentación Tecnológica Controlada:** Técnica por la cual se configuran y ejecutan pruebas de software en un entorno de desarrollo para evaluar el rendimiento predictivo y la capacidad de detección de anomalías del pipeline en diferentes condiciones de entrenamiento (E1 a E5), incluyendo análisis de varianza con múltiples semillas y estudios de ablación.
3. **Encuesta:** Técnica empleada en el estudio de usabilidad (Anexo A) para recopilar las valoraciones de los evaluadores respecto a la comprensión de las alertas explicadas con SHAP y RAG, y su percepción general sobre la usabilidad del prototipo en comparación con la interfaz de control aislada.

1.10.2. Instrumentos

Los instrumentos utilizados son herramientas técnicas y métricas diseñadas para registrar la evidencia y evaluar los indicadores de efectividad del sistema:

1. **Ficha de Registro y Normalización de Datos (Análisis Documental):** Estructura lógica y esquema de base de datos relacional que define el origen, la unidad de medida, la granularidad y la naturaleza metodológica (real, derivada, proxy o sintética) de cada una de las variables que componen el dataset integrado.
2. **Consola de Experimentación y Scripts de Pruebas (Experimentación):** Programas en lenguaje Python para entrenar los modelos, guardar checkpoints, ejecutar validación cruzada y registrar de forma automatizada las métricas de error (RMSE, SMAPE) y rendimiento (ROC-AUC, PR-AUC, F1-Score).
3. **Cuestionario de Usabilidad Estructurado (Encuesta):** Cuestionario adaptado basado en la escala estándar SUS (System Usability Scale) y preguntas específicas tipo Likert (escala del 1 al 5) para registrar el nivel de comprensión percibida, utilidad práctica y confianza de los usuarios en los reportes generados.
4. **Logs de Decisión Temporal (Encuesta):** Cronómetros lógicos automatizados dentro de la interfaz experimental que registran con precisión el tiempo (en segundos) que le toma a cada evaluador analizar una alerta aduanera y responder de forma correcta bajo diferentes condiciones experimentales.

Técnica	Instrumento	Propósito
Análisis Documental	Ficha de registro de datos estructurados (CSV/DBF)	Recolección e integración de microdatos de comercio exterior (SUNAT/ADUANET), mercado interno (SISAP/MIDAGRI), indicadores macroeconómicos (BCRP) y datos climáticos (NASA POWER).
Experimentación Controlled	Entorno de desarrollo (Python/VS Code) y Scripts de pruebas	Medición del rendimiento predictivo tabular (XGBoost/LightGBM) y de la precisión del ensemble de anomalías operativas (Isolation Forest, LOF, ECOD).
Encuesta	Cuestionario Tipo Likert, Escala SUS y Logs de decisión temporal	Evaluación cualitativa de la usabilidad del sistema, tiempo de decisión de los analistas, y nivel de confianza y comprensión de las alertas explicadas frente a reportes convencionales.

1.11 Cronograma de actividades

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5
Revision bibliografica y marco teorico	X				
Normalizacion e integracion de fuentes	X	X			
Construccion del dataset integrado		X			
Implementacion Capa 1 y Capa 2		X	X		
Implementacion SHAP y RAG			X		
Experimentos y baselines				X	
Evaluacion de trazabilidad/usabilidad				X	
Analisis, redaccion y defensa					X

1.12 Limitaciones

- Algunas variables operativas no existen como dato publico por embarque y deben tratarse como proxies o sinteticas controladas.
 - SISAP no mide exportaciones; solo aporta mercado interno mayorista.
 - SHAP explica contribuciones del modelo, no causalidad real.
 - Las alertas sanitarias agregadas no equivalen a cumplimiento fitosanitario por embarque si no existe llave directa.
 - Los resultados basados solo en datos sinteticos deben reportarse como preliminares o auxiliares.
 - La generalizacion a empresas especificas requiere validacion con datos privados o convenios de acceso.
-

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

CAPÍTULO II: MARCO TEÓRICO

2.1 Antecedentes de la Investigación

Los antecedentes de esta investigación se organizan desde dos perspectivas. La primera corresponde a trabajos técnicos sobre datos tabulares, detección de anomalías, explicabilidad y generación de reportes, incluso cuando fueron desarrollados en dominios financieros o contables. Estos trabajos se utilizan como soporte metodológico. La segunda corresponde al dominio de aplicación de esta tesis: supervisión operativa agroexportadora, donde la contribución principal consiste en adaptar e integrar dichas técnicas para detectar, explicar y documentar desviaciones en procesos agroexportadores peruanos.

El desarrollo de sistemas de predicción, detección de anomalías y generación de reportes en datos empresariales ha seguido una trayectoria de especialización creciente, marcada por tres tendencias paralelas: el auge de los modelos basados en árboles para datos tabulares, la proliferación de benchmarks sistemáticos y la emergencia de los modelos de lenguaje como capa de interpretación. Los siguientes antecedentes fueron seleccionados por su proximidad metodológica con la propuesta de esta investigación, aunque varios provienen de dominios financieros o contables y se emplean aquí solo como soporte técnico transferible.

2.1.1 Kadir et al. (2025) — AuditCopilot: LLMs (Large Language Models - Modelos de Lenguaje de Gran Tamaño) para Reportes de Anomalías

Kadir et al. (2025) desarrollaron AuditCopilot (Kadir et al., 2025), un sistema de auditoría contable que integra LLMs con detección de anomalías en asientos de doble entrada para generar explicaciones automáticas en lenguaje natural. El sistema implementa un pipeline de tres etapas —detección de irregularidades, interpretación contextual con LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño) ajustado y generación de narrativas— evaluado sobre un corpus de asientos contables sintéticos y reales. Los resultados reportan mejoras en la tasa de detección y reducción del tiempo de revisión, con valoración positiva de auditores en pruebas de aceptabilidad.

La relevancia de este antecedente para la presente tesis es metodológica: confirma la viabilidad de combinar detección de anomalías con generación de reportes LLM. No obstante, su dominio es contable, por lo que no se adopta como evidencia agroexportadora. Esta tesis traslada el principio de generación narrativa a un contexto operativo, separando estrictamente la detección de la redacción mediante RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación) sobre scores y vectores SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley).

2.1.2 Park (2024) — Framework Multi-Agente LLM para Anomalías Financieras

Park (2024) propuso un framework de múltiples agentes LLM especializados para validar alertas de anomalías en el mercado bursátil (S&P 500) (Park, 2024). La arquitectura organiza cuatro agentes —conversión de datos, análisis estadístico, verificación cruzada y consolidación— que se comunican mediante prompts estructurados y alcanzan mejores tasas de verdaderos positivos que un LLM único. La especialización de agentes demuestra ser superior a la generalización en la validación de señales financieras.

Este trabajo aporta a la literatura evidencia de que los LLMs en arquitecturas especializadas pueden mejorar la calidad del análisis automatizado. Sin embargo, opera en mercados de alta frecuencia, un dominio alejado del contexto agroexportador. Esta tesis aplica únicamente el principio de especialización de roles —LLM como intérprete, no como detector— en un sistema de supervisión operativa con trazabilidad y generación restringida a datos verificados (Schneider et al., 2025).

2.1.3 Almalki & Masud (2025) y Autores varios (2025) — Ensemble GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente)+SHAP en Datos Críticos

Almalki y Masud (2025) y trabajos paralelos publicados en el *Journal of Risk and Financial Management* (2025), diseñaron frameworks integrados de detección de fraude financiero combinando Stacking Ensemble de GBDTs (XGBoost y LightGBM) con explicabilidad SHAP (Almalki & Masud, 2025; JRFM, 2025). El ensemble alcanza PR-AUC (Precision-Recall Area Under the Curve - Área Bajo la Curva de Precisión y Exhaustividad) > 0.90 y F1-Score (Medida Armónica de Precisión y Exhaustividad) > 0.80 , superando a arquitecturas complejas de Deep Learning, con un SHAP Stability Index alto que certifica la coherencia forense de las explicaciones —requisito indispensable en auditoría.

Este antecedente respalda la decisión arquitectónica de combinar GBDT y SHAP en datos tabulares críticos. La diferencia clave es que dichos trabajos se limitan a detección de fraude en estados financieros; la presente investigación adapta la lógica de modelos tabulares explicables al contexto agroexportador, incorporando un dataset agroexportador integrado con fuentes públicas, proxies documentados, datos sintéticos controlados y generación de reportes LLM+RAG para supervisión operativa.

2.1.4 Han et al. (2022) — ADBench: Benchmark para Detección de Anomalías

Han et al. (2022) publicaron ADBench (Han et al., 2022), un benchmark sistemático que evalúa 30 algoritmos de detección de anomalías en 57 datasets reales y sintéticos bajo tres niveles de supervisión —no supervisado, semisupervisado y supervisado. El hallazgo central es que no existe un algoritmo universalmente superior: el rendimiento depende del tipo de anomalía, la distribución de datos y el nivel de etiquetado. Isolation Forest y ECOD (Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica) muestran consistencia en escenarios no supervisados, y los ensembles de múltiples detectores superan sistemáticamente a los detectores individuales en escenarios de alta variabilidad distribucional.

ADBench justifica formalmente la estrategia de ensemble adoptada en esta tesis y proporciona la metodología experimental de referencia para el Capítulo III. La librería PyOD (Zhao et al., 2019), compatible con todos los algoritmos evaluados en ADBench, asegura la reproducibilidad directa de los resultados.

2.1.5 Grinsztajn et al. (2022) — GBDT vs. Deep Learning en Datos Tabulares

Grinsztajn et al. (2022) realizaron un benchmark sistemático en 45 datasets tabulares comparando GBDT contra FT-Transformer, TabNet y MLP (Grinsztajn et al., 2022). El resultado es contundente: en datasets con menos de 50,000 muestras, los GBDT superan a cualquier modelo de Deep Learning en el 95% de los casos. Los autores identifican tres propiedades estructurales de los datos tabulares que favorecen a los árboles: robustez ante features no informativas, orientación no invariante a rotaciones e irregularidades en la función objetivo.

Este trabajo cierra el debate GBDT versus Deep Learning para el tamaño de dataset típico en entornos empresariales medianos y justifica de manera irrefutable la elección de XGBoost y LightGBM como backbone del módulo de predicción de esta tesis. Es el argumento bibliográfico central de la primera batalla del estado del arte (§2.2.1).

2.1.6 Zhao et al. (2019) — PyOD: Librería Estándar para Detección de Outliers

Zhao et al. (2019) desarrollaron PyOD (Zhao et al., 2019), una librería unificada en Python que implementa más de 40 algoritmos de detección de outliers con una API compatible con scikit-learn. Cubre métodos basados en proximidad (LOF

(Local Outlier Factor - Factor de Anomalía Local)), proyección (PCA), ensembles (Isolation Forest) y distribuciones empíricas (ECOD). Con más de 7,000 estrellas en GitHub y adopción en publicaciones de NeurIPS, ICDM e ICML, PyOD es la infraestructura técnica de referencia para implementar el ensemble de detección de anomalías de esta tesis, garantizando reproducibilidad directa con los 30 algoritmos de ADBench (Han et al., 2022).

2.1.7 Mendoza & Huamán (2024) — Modelos GBDT y Clima para Predicción Agroexportadora Peruana

Mendoza y Huamán (2024) investigaron el uso de algoritmos basados en árboles de decisión (XGBoost y LightGBM) para predecir el rendimiento y calidad de cultivos de arándanos y uva de mesa en la región La Libertad y Piura, utilizando variables climáticas locales de estaciones del SENAMHI y registros históricos de exportación. Su modelo demostró que los GBDT manejan con éxito la no-linealidad, el ruido estacional y la escasez de datos característicos de la agricultura peruana, superando a modelos autorregresivos clásicos y a redes neuronales densas en precisión de pronóstico a corto plazo.

Este trabajo es sumamente relevante porque valida la robustez de XGBoost y LightGBM en el dominio agroexportador nacional con datos altamente dependientes del clima y la estacionalidad, justificando su elección como backbone de la Capa 1 de esta tesis. Sin embargo, Mendoza y Huamán se limitaron a la predicción puntual, sin abordar la detección integrada de anomalías transaccionales ni el cumplimiento regulatorio de trazabilidad.

2.1.8 Chávez & Díaz (2023) — Detección de Anomalías IoT en Cadenas de Frío de Perecederos

Chávez y Díaz (2023) propusieron un sistema de detección de anomalías no supervisado para contenedores de uva de mesa peruana de exportación en tránsito marítimo utilizando sensores IoT de temperatura, humedad relativa y CO2. Empleando Isolation Forest y LOF de forma aislada, el sistema identificó de manera oportuna desviaciones críticas en la cadena de frío (*cold chain failures*) y eventos de descalibración de gases, logrando reducir hasta en un 15% las pérdidas por sobre-maduración del producto en destino.

El antecedente respalda empíricamente la viabilidad de Isolation Forest y LOF en el dominio logístico agrícola peruano. No obstante, los autores reportaron que los supervisores operativos mostraron desconfianza y dificultades para tomar decisiones rápidas ante las alertas porque los algoritmos generaban únicamente puntajes numéricos de anomalía ("cajas negras") sin explicaciones del por qué. Esta limitación justifica la inyección de la Capa 3 (SHAP) y la Capa 4 (LLM+RAG) propuestas en la presente tesis para resolver la brecha de explicabilidad y accionabilidad operativa.


```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

2.2 Estado del Arte

El estado del arte se organiza en torno a cinco debates fundamentales de la literatura que la presente propuesta debe resolver o posicionarse explícitamente. Cada sub-sección presenta el debate, los trabajos relevantes y la posición de esta tesis. La Tabla 2.1 sintetiza todas las referencias relevantes al final de la sección.

2.2.1 GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente) versus Deep Learning para Datos Tabulares Empresariales y Agroexportadores

El desarrollo de modelos para datos tabulares ha seguido una trayectoria diferente a la de visión computacional y procesamiento de lenguaje natural: el Deep Learning no ha conseguido desplazar a los modelos basados en árboles como estándar de facto en datos estructurados. Chen y Guestrin (2016) introdujeron XGBoost como sistema escalable de gradient boosting con regularización L1/L2, manejo nativo de valores faltantes y paralelización por columnas, estableciéndolo como el baseline universal con más de 45,000 citas en la literatura científica. Ke et al. (2017) lo extendieron con LightGBM, que incorpora Gradient-based One-Side Sampling (GOSS) e histogramas para lograr velocidades de entrenamiento hasta 20 veces superiores con rendimiento comparable. Prokhorenkova et al. (2018) resolvieron el problema de target leakage en variables categóricas con Ordered Boosting, siendo especialmente relevante en datos contables con alta cardinalidad (cuentas, departamentos, centros de costo).

El auge del Deep Learning motivó intentos de adaptar estas arquitecturas a datos tabulares. Gorishniy et al. (2021) propusieron FT-Transformer, el primer Transformer robusto para tablas mediante feature embeddings, que en algunos benchmarks iguala pero raramente supera a los GBDT. Arik y Pfister (2021) desarrollaron TabNet, que combina selección secuencial de features con atención interpretable, argumentando que puede ofrecer tanto rendimiento como interpretabilidad en un solo modelo. Sin embargo, el estudio seminal de Grinsztajn et al. (2022) zanjó empíricamente este debate: en datasets tabulares de hasta 50,000 muestras, los GBDT superan a los modelos de Deep Learning en la inmensa mayoría de los escenarios empíricos. Esta evidencia respalda la decisión arquitectónica de la presente tesis, cuyo dataset agroexportador integrado se sitúa en una escala tabular adecuada para modelos basados en árboles. Los autores identifican tres propiedades estructurales de los datos tabulares que favorecen a los árboles: robustez ante features no informativas, orientación no invariante a rotaciones y presencia de irregularidades en la función objetivo, características presentes en registros comerciales, logísticos y contextuales de agroexportación.

En dominios empresariales con datos tabulares heterogéneos, esta evidencia respalda el uso de GBDT como primera opción antes de recurrir a arquitecturas neuronales complejas. En el caso agroexportador, los registros combinan variables numéricas, categóricas, temporales y contextuales —producto, zona, volumen, precio, clima, destino, cumplimiento y logística—, por lo que los modelos basados en árboles son una base técnica adecuada para capturar relaciones no lineales y manejar variables de distinta naturaleza.

Posición de esta tesis: XGBoost y LightGBM constituyen el backbone del módulo de predicción tabular. TabNet y FT-Transformer se evalúan como baselines comparativos, no como propuesta principal, dado que la evidencia empírica no justifica su adopción en el contexto de tamaño del dataset empresarial analizado.

2.2.2 Detector Único versus Ensemble para Detección de Anomalías

El campo de la detección de anomalías cuenta con una historia de más de dos décadas de métodos en competencia. Breunig et al. (2000) establecieron el Local Outlier Factor (LOF (Local Outlier Factor - Factor de Anomalía Local)) como referencia para detectar anomalías locales mediante densidad relativa al vecindario k-NN, un enfoque sensible a variaciones locales que permite identificar transacciones con patrones de comportamiento heterogéneos. Liu et al. (2008) revolucionaron el campo con Isolation Forest, que aísla anomalías por particionamiento aleatorio sin necesidad de definir perfiles de normalidad, con complejidad $O(n)$ que lo hace viable en millones de transacciones diarias. Ruff et al. (2018) extendieron la detección a espacios de representación profundos con Deep SVDD, capturando patrones no lineales en los datos mediante redes neuronales. Li et al. (2022) propusieron ECOD (Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica), un detector moderno libre de parámetros basado en distribución empírica acumulada que supera a 11 baselines en datasets no supervisados, eliminando el riesgo de sobreajuste al proceso de calibración.

El hallazgo central de Han et al. (2022) en ADBench —57 datasets, 30 algoritmos, tres niveles de supervisión— establece que no existe un algoritmo universalmente superior: el rendimiento depende fuertemente del tipo de anomalía, la distribución de los datos y el nivel de etiquetado disponible. Esta conclusión teórica valida la estrategia de ensemble como la opción más robusta para entornos de producción donde la distribución de anomalías es desconocida a priori. La librería PyOD (Zhao et al., 2019) proporciona la infraestructura técnica para implementar este ensemble de manera estandarizada y reproducible.

Posición de esta tesis: El ensemble Isolation Forest + LOF + ECOD (coordinado mediante PyOD) es más robusto que cualquier detector individual, priorizando ECOD sobre Deep SVDD por su interpretabilidad estadística y ausencia de hiperparámetros.

Asimismo, frente a arquitecturas complejas de Deep Learning para series temporales (como LSTM-Autoencoders o redes recurrentes profundas aplicadas a la detección de anomalías), esta tesis justifica la elección de un ensemble no supervisado tabular de baja complejidad en base a la viabilidad de infraestructura y costo operativo real del sector agroindustrial peruano. Las empresas agroexportadoras de tamaño medio en el Perú raramente disponen en sus centros de control locales de servidores equipados con tarjetas de procesamiento gráfico (GPU) dedicadas, lo que haría económicamente inviable el entrenamiento y mantenimiento continuo de modelos neuronales profundos ante el cambio en la distribución de datos (*concept drift*) propio de la estacionalidad de las campañas agrícolas. En contraste, el ensemble tabular propuesto se ejecuta y reentrena en pocos segundos en CPU comercial estándar sin requerir hardware de alta gama, garantizando viabilidad operativa real, bajo consumo de recursos y total transferencia tecnológica. Esta decisión está respaldada por ADBench (Han et al., 2022) como fundamento teórico.

2.2.3 LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño) como Detector versus LLM como Generador de Reportes

El surgimiento de los LLMs (Large Language Models - Modelos de Lenguaje de Gran Tamaño) ha generado propuestas de integración en sistemas empresariales con distintos roles. Hegselmann et al. (2023) demostraron con TabLLM que los LLMs pueden clasificar datos tabulares en configuración zero/few-shot mediante serialización a texto, con rendimiento no trivial incluso sin ajuste fino. Park (2024) llevó esta lógica más lejos con un framework multi-agente donde LLMs especializados validan alertas de anomalías. Estos antecedentes muestran potencial metodológico, aunque no resuelven por sí mismos el problema de trazabilidad operativa agroexportadora.

Sin embargo, existe evidencia sustancial de que usar LLMs como detectores o tomadores de decisiones introduce riesgos inaceptables. El survey sobre alucinaciones en LLMs (Maynez et al., 2026) documenta que los modelos pueden generar razonamiento coherente en forma pero incorrecto en contenido, con alta confianza aparente. Este riesgo es especialmente importante en reportes operativos, donde una cifra o causa inventada puede inducir decisiones equivocadas.

La arquitectura RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación) (Schneider et al., 2025 (Schneider et al., 2025)) ofrece una solución al anclar las respuestas del LLM a bases de conocimiento verificadas —en este caso, scores, umbrales, vectores SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) y fuentes agroexportadoras recuperadas— reduciendo el espacio de alucinación al forzar al modelo a narrar únicamente lo que los datos cuantitativos establecen. El LLM no infiere anomalías; las narra con evidencias como fundamento.

Posición de esta tesis: El LLM se restringe estrictamente a la capa de generación de reportes mediante RAG. La detección, cuantificación y explicación son realizadas por modelos y evidencias estructuradas (GBDT + ensemble + SHAP). Esta separación se alinea con principios de transparencia, supervisión humana y trazabilidad promovidos por marcos como el D.S. N° 115-2025-PCM (PCM, 2025), el EU AI Act (Parlamento Europeo y Consejo, 2024) y el NIST AI RMF (NIST, 2023).

2.2.4 Sistemas Aislados versus Sistema Integrado de Supervisión Operativa Continua

La revisión de la literatura evidencia una fragmentación sistemática en los sistemas de supervisión asistida por IA. Los trabajos pueden agruparse en cuatro categorías según el módulo que abordan: (1) sistemas de predicción tabular (Chen & Guestrin, 2016; Ke et al., 2017; Prokhorenkova et al., 2018); (2) sistemas de forecasting y series temporales (Lim et al., 2021; Challu et al., 2022); (3) sistemas de detección de anomalías (Liu et al., 2008; Han et al., 2022); y (4) sistemas de generación de reportes con LLMs (Kadir et al., 2025; Park, 2024).

Trabajos como AuditCopilot (Kadir et al., 2025) logran una integración parcial al combinar detección de anomalías con generación de reportes LLM, pero operan en dominio contable y no abordan supervisión agroexportadora. El framework de Park (2024) integra múltiples LLMs pero opera en mercados financieros de alta frecuencia. AuditMAI (Waltersdorfer et al., 2024) propone una infraestructura conceptual para auditoría continua de sistemas de IA. La Tabla 2.2 resume comparativamente los sistemas más cercanos a la propuesta de esta tesis desde una perspectiva metodológica.

Posición de esta tesis: Esta investigación cierra la brecha de integración al proponer y evaluar una arquitectura modular de cuatro capas que combina predicción tabular, detección de anomalías, explicabilidad SHAP y generación de reportes LLM-RAG con restricción anti-alucinación, aplicada a supervisión operativa agroexportadora. BAF (Jesus et al., 2022) se utiliza solo como benchmark metodológico complementario; la validación principal se orienta a un dataset agroexportador integrado con datos reales observados, datos agregados, proxies y datos sintéticos controlados.

2.2.5 Contexto Regulatorio Internacional versus Perú

La mayoría de marcos de gobernanza de IA de la literatura operan en contextos regulatorios de EE.UU. (NIST AI RMF (NIST, 2023)), Europa (EU AI Act (Parlamento Europeo y Consejo, 2024), GDPR) o Asia. Estos marcos coinciden en principios relevantes para esta tesis: documentación, transparencia, supervisión humana, gestión de riesgos y trazabilidad.

En el contexto peruano, el marco regulatorio ha madurado significativamente en 2023–2025. La Resolución SBS N° 053-2023 establece lineamientos de gobernanza, trazabilidad y explicabilidad para modelos de riesgo en entidades supervisadas por la SBS (SBS, 2023), por lo que se adopta aquí solo como referencia de buenas prácticas. El Decreto Supremo N° 115-

2025-PCM, reglamento de la Ley N° 31814, proporciona un marco nacional general para promover el uso responsable de la inteligencia artificial (PCM, 2025). A nivel internacional, el EU AI Act (Parlamento Europeo y Consejo, 2024) refuerza obligaciones de transparencia y documentación para sistemas de IA.

Posición de esta tesis: Esta investigación diseña un sistema de supervisión operativa agroexportadora que incorpora principios de gobernanza, trazabilidad, documentación y supervisión humana. El D.S. N° 115-2025-PCM se adopta como marco peruano general de IA responsable, mientras que la Resolución SBS N° 053-2023 se utiliza solo como referencia nacional de gestión de riesgo de modelos.

2.2.6 Síntesis y Tabla del Estado del Arte

La revisión sistemática de los bloques temáticos permite identificar la brecha de investigación central: **no existe en la literatura revisada un sistema orientado al contexto agroexportador peruano que integre de manera modular, con evaluación reproducible y trazabilidad explícita, los cuatro componentes:** predicción tabular, detección de anomalías, explicabilidad SHAP y generación de reportes LLM-RAG basada en evidencias. Esta tesis propone y evalúa dicha integración para supervisión operativa agroexportadora.

Tabla 2.1 — Comparativa de Sistemas de Supervisión con IA

Característica	Esta tesis	AuditCopilot (Kadir et al., 2025)	Park 2024 (Park, 2024)	AuditMAI (Waltersdorfer et al., 2024)	Almalki & Masud (2025) / JRFM (2025)
Predicción tabular GBDT	✅ XGBoost+LightGBM	❌	❌ Solo LLMs	❌	✅ Stacking
Benchmark público reproducible	✅ Dataset agroexportador integrado; BAF complementario	❌ Dataset propio	❌ S&P 500	❌ Conceptual	⚠️ Dataset propio
Forecasting DL (ej. TFT)	❌ (Solo tabular GBDT)	❌	❌	❌	❌
Ensemble de anomalías (ADBench)	✅ IF (Isolation Forest - Bosque de Aislamiento)+LOF+ECOD	⚠️ Parcial	❌	❌	❌
Explicabilidad SHAP	✅ TreeSHAP	❌	❌	❌	✅ SHAP+Anchor
Generación LLM de reportes	✅ RAG determinista	✅ LLM narrativo	✅ Multi-agente	❌	❌
Restricción anti-alucinación (RAG+SHAP)	✅	❌	❌	—	—
Marco de gobernanza explícito	✅ DS115+NIST+EU AI Act; SBS como referencia	❌	❌	❌	❌
Contexto peruano	✅ Agroexportación peruana	❌	❌	❌	❌
Evaluación con supervisores/evaluadores	✅	❌	❌	❌	❌
Dominio	Supervisión operativa agroexportadora	Asientos contables	Mercados bursátiles	Auditoría de IA	Fraude en EEFF

Tabla 2.2 — Resumen del Estado del Arte

N°	Autor(es)	Año	Aporte principal
1	Chen & Guestrin (Chen & Guestrin, 2016)	2016	XGBoost: gradient boosting escalable con regularización L1/L2, benchmark universal para datos tabulares
2	Ke et al. (Ke et al., 2017)	2017	LightGBM: GOSS + histogramas, 20× más rápido que XGBoost con precisión comparable
3	Prokhorenkova et al. (Prokhorenkova et al., 2018)	2018	CatBoost: Ordered Boosting elimina target leakage en variables categóricas de alta cardinalidad
4	Gorishniy et al. (Gorishniy et al., 2021)	2021	FT-Transformer: primer Transformer robusto para datos tabulares mediante feature embeddings
5	Arik & Pfister (Arik & Pfister, 2021)	2021	TabNet: atención secuencial interpretable para tablas, combina rendimiento e interpretabilidad
6	Grinsztajn et al. (Grinsztajn et al., 2022)	2022	GBDT supera a DL en el 95% de datasets ≤50K muestras; cierra el debate en contexto empresarial
7	Li et al. (Li et al., 2022)	2022	ECOD: detección no supervisada basada en distribución empírica acumulada, sin hiperparámetros
8	Liu et al. (Liu et al., 2008)	2008	Isolation Forest: aislamiento aleatorio O(n), sin perfil de normalidad, escalable a millones de registros
9	Breunig et al. (Breunig et al., 2000)	2000	LOF: densidad local relativa k-NN, detecta anomalías locales heterogéneas
10	Almalki & Masud (Almalki & Masud, 2025)	2025	Stacking ensemble de GBDT con explicabilidad SHAP para detección en datos críticos
11	Han et al. (Han et al., 2022)	2022	ADBBench: benchmark de 30 algoritmos en 57 datasets; ensembles son más robustos que detectores únicos
12	Lundberg & Lee (Lundberg & Lee, 2017)	2017	SHAP: valores Shapley con consistencia axiomática; TreeSHAP exacto para GBDT
13	Kadir et al. (Kadir et al., 2025)	2025	AuditCopilot: LLM+detección en asientos contables; antecedente metodológico para reportes automáticos
14	Park (Park, 2024)	2024	Framework multi-agente LLM para validar anomalías en mercados bursátiles
15	Schneider et al. (Schneider et al., 2025)	2025	RAG avanzado para BI organizacional; arquitectura anti-alucinación base de esta tesis
16	SBS Perú (SBS, 2023)	2023	Resolución N° 053-2023: referencia nacional de buenas prácticas para gestión de riesgo de modelos

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```


2.3 Marco Conceptual

2.3.1 Reconocimiento de Patrones y Aprendizaje Automático

El reconocimiento de patrones es la disciplina de la inteligencia artificial que busca identificar regularidades, estructuras o relaciones en datos a partir de ejemplos históricos. En el aprendizaje automático, este proceso se formaliza mediante modelos que aprenden una función $f: X \rightarrow Y$ a partir de un conjunto de entrenamiento $(x_i, y_i)_{i=1}^n$, con el objetivo de generalizar hacia instancias no observadas.

Se distinguen tres paradigmas principales: **aprendizaje supervisado**, donde el modelo aprende de etiquetas explícitas (e.g., operación normal / operación anómala); **aprendizaje no supervisado**, que identifica patrones sin etiquetas y es fundamental en la detección de anomalías; y **aprendizaje semi-supervisado**, que combina ambos cuando el etiquetado es costoso o escaso, escenario habitual en procesos agroexportadores donde no todas las desviaciones quedan registradas formalmente.

En el contexto de esta investigación, el reconocimiento de patrones opera en dos dimensiones complementarias: la detección de registros operativos anómalos (patrones puntuales) y la identificación de secuencias temporales de comportamiento irregular (patrones colectivos), requiriendo tanto modelos de clasificación supervisada como detectores de anomalías no supervisados.

2.3.2 Datos Tabulares en Sistemas Agroexportadores Empresariales

Los datos tabulares son la forma predominante de almacenamiento en los sistemas de información empresarial: cada fila representa una instancia operativa y cada columna una variable. En agroexportación, una instancia puede describir un lote, día, producto, zona, envío o registro de mercado; las columnas pueden incluir precio, volumen, temperatura, precipitación, humedad, destino, cumplimiento fitosanitario, días logísticos, merma y etiqueta de anomalía.

Estas propiedades estructurales explican por qué los GBDT son adecuados para este dominio (Grinsztajn et al., 2022): manejan variables numéricas y categóricas heterogéneas, toleran valores faltantes, capturan relaciones no lineales y requieren menor ingeniería de features que arquitecturas neuronales complejas. Cuando las etiquetas de anomalía son escasas o desbalanceadas, el rendimiento debe evaluarse con métricas orientadas a precisión-recall (PR-AUC (Precision-Recall Area Under the Curve - Área Bajo la Curva de Precisión y Exhaustividad)), F1-Score (Medida Armónica de Precisión y Exhaustividad) y análisis de falsos positivos.

2.3.3 GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente)

Los Gradient Boosting Decision Trees (GBDT) son una familia de algoritmos de aprendizaje supervisado que construyen modelos predictivos mediante la combinación secuencial de múltiples árboles de decisión débiles. El enfoque fue formalizado por Friedman (2001) como "Greedy Function Approximation", donde cada árbol nuevo se ajusta para corregir los errores residuales del conjunto de árboles previos mediante descenso de gradiente en el espacio funcional de la función de pérdida.

La formulación matemática central de GBDT busca encontrar una función $F(x)$ que minimice la pérdida esperada:

$$F^*(x) = \arg \min_F \mathbb{E}_{y,x} [L(y, F(x))]$$

donde L es la función de pérdida (e.g., entropía cruzada para clasificación, MSE para regresión) y la minimización se realiza iterativamente añadiendo árboles de regresión $h_m(x)$ con pesos de aprendizaje ν :

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

XGBoost (Chen & Guestrin, 2016) introduce mejoras clave sobre el GBDT estándar: regularización L1 y L2 en la función objetivo para controlar la complejidad del modelo, manejo nativo de valores faltantes mediante aprendizaje automático de la dirección de ramificación, y paralelización por columnas en lugar de por filas, lo que habilita el procesamiento en datasets de alta dimensión.

LightGBM (Ke et al., 2017) acelera el entrenamiento mediante dos innovaciones: Gradient-based One-Side Sampling (GOSS), que retiene las muestras con mayor gradiente y descarta aleatoriamente las de menor gradiente, preservando la distribución sin pérdida estadística significativa; y Exclusive Feature Bundling (EFB), que agrupa features mutuamente excluyentes para reducir dimensionalidad efectiva. El resultado es una aceleración de hasta 20× sobre XGBoost con precisión comparable.

CatBoost (Prokhorenkova et al., 2018) resuelve el problema del target leakage en variables categóricas mediante Ordered Boosting: calcula las estadísticas de objetivo para cada categoría usando únicamente las observaciones previas en un orden aleatorio permutado, evitando que la información del objetivo filtre hacia las features de entrada durante el entrenamiento. Esta propiedad es especialmente relevante en datos contables, donde variables como "código de cuenta" o "centro de costo" tienen alta cardinalidad.

La justificación empírica para elegir GBDT sobre Deep Learning en datos tabulares empresariales está sólidamente documentada por (Grinsztajn et al., 2022): en 45 datasets con hasta 50,000 muestras, los GBDT superan a arquitecturas neuronales complejas (como FT-Transformer o TabNet) en la inmensa mayoría de los casos. Dado que el dataset operativo de esta tesis se define como un dataset agroexportador integrado de escala tabular, con datos reales observados, datos agregados, proxies y datos sintéticos controlados, se sitúa en el rango donde los modelos basados en árboles maximizan su ventaja comparativa. Esta superioridad es atribuible a tres propiedades estructurales de los datos tabulares que los árboles aprovechan mejor que las redes neuronales.

2.3.4 Detección de Anomalías y Estrategia de Ensemble

La detección de anomalías es el problema de identificar observaciones que se desvían significativamente del comportamiento esperado del conjunto de datos. La literatura distingue tres tipos fundamentales de anomalías (Han et al., 2022): (a) **puntuales** — instancias individuales anómalas (e.g., una transacción de monto atípico); (b) **contextuales** — instancias que son anómalas en un contexto particular pero no en general (e.g., un cargo nocturno inusual para un perfil de usuario); y (c) **colectivas** — secuencias de instancias que son anómalas en conjunto aunque cada una individualmente no lo sea (e.g., un patrón de micro-transacciones).

Isolation Forest (Liu et al., 2008) se basa en el principio de que las anomalías son "pocas y diferentes": son más fáciles de aislar que los puntos normales mediante particionamiento aleatorio del espacio. Un árbol de aislamiento selecciona aleatoriamente una feature y un valor de corte; la anomalía será aislada en pocas particiones (camino corto), mientras que los puntos normales requieren muchas particiones (camino largo). El score de anomalía es el inverso de la longitud promedio del camino de aislamiento, normalizada según la longitud esperada para un punto normal en un conjunto de tamaño n . La complejidad es $O(n \log n)$ en entrenamiento y $O(n)$ en inferencia.

Local Outlier Factor (LOF (Local Outlier Factor - Factor de Anomalía Local)) (Breunig et al., 2000) cuantifica el grado de anomalía de cada punto en función de la densidad de su vecindario local respecto a la densidad de sus vecinos. El score LOF para el punto p se define como:

$$\text{LOF}(p) = \frac{\text{Lrd}_k(o)}{\text{Lrd}_k(p)} \cdot \frac{|N_k(p)|}{|N_k(o)|}$$

donde Lrd_k es la densidad de alcanzabilidad local. Un valor $\text{LOF} \gg 1$ indica que p tiene densidad local mucho menor que sus vecinos, lo que lo caracteriza como anomalía. LOF es sensible a variaciones locales de densidad, lo que lo hace complementario a Isolation Forest en datasets heterogéneos.

Deep SVDD (Ruff et al., 2018) extiende el Support Vector Data Description al espacio de representación de redes neuronales: entrena una red para mapear los datos normales hacia el interior de una hipersfera mínima en el espacio latente. Las anomalías se detectan como puntos que caen fuera o lejos de esta hipersfera. La función objetivo minimiza el volumen de la hipersfera:

$$\min_{W, R, c} R^2 + \frac{1}{n} \sum_{i=1}^n \max(0, |f(x_i; W) - c|^2 - R^2)$$

donde $f(x_i; W)$ es la representación de la red neuronal, c es el centro de la hipersfera y R es su radio.

ECOD (Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica) (Li et al., 2022) calcula el score de anomalía como la probabilidad acumulada de observar un punto tan extremo como x bajo la distribución empírica del dataset, estimada mediante funciones de distribución acumulada (ECDF) multivariadas. Su ventaja principal es que no tiene hiperparámetros que calibrar, eliminando el riesgo de sobreajuste y simplificando el despliegue en producción.

La estrategia de **ensemble** consolida las puntuaciones de múltiples detectores para reducir la varianza del estimador agregando perspectivas de densidad local (LOF), aislamiento espacial (IF) y probabilidad empírica acumulada (ECOD). Sin embargo, un desafío matemático fundamental radica en que los algoritmos marginales producen puntuaciones en escalas y naturalezas numéricas completamente incompatibles:

1. **Isolation Forest** genera puntuaciones acotadas $S_{IF}(x) \in [0, 1]$.
2. **Local Outlier Factor** genera puntuaciones $S_{LOF}(x) \in [1, \infty)$, donde valores cercanos a 1 indican normalidad y valores superiores representan el grado local de desviación.
3. **ECOD** genera puntuaciones acumuladas inversas $S_{ECOD}(x) \in [0, \infty)$ en escalas de log-probabilidad.

Sumar o promediar estos valores en bruto anularía la influencia de IF y ECOD debido a que LOF dominaría la agregación por magnitud. Para resolver esta incompatibilidad, esta tesis implementa la unificación probabilística de puntuaciones basada en el escalamiento Min-Max lineal calibrado sobre el conjunto de entrenamiento (Kriegel et al., 2011). Las puntuaciones brutas de cada detector se transforman en puntuaciones probabilísticas de anomalía acotadas $P_m(a|x) \in [0, 1]$ mediante la función de mapeo:

$$P_m(a|x) = \max \left(0, \min \left(1, \frac{S_m(x) - \min_{x' \in D_{\text{train}}} (S_m(x'))}{\max_{x' \in D_{\text{train}}} (S_m(x')) - \min_{x' \in D_{\text{train}}} (S_m(x'))} \right) \right)$$

donde $\min_{D_{\text{train}}}$ y $\max_{D_{\text{train}}}$ son los valores extremos de score observados en el conjunto de calibración histórica del detector m . La puntuación consolidada de anomalía del ensemble $S_{\text{Ensemble}}(x) \in [0, 1]$ se calcula entonces como el promedio simple de estas probabilidades unificadas:

$$S_{Ensemble}(x) = \frac{P_{IF}(a|x) + P_{LOF}(a|x) + P_{ECOD}(a|x)}{3}$$

Una instancia operativa x se clasifica finalmente como alerta anómala si y solo si $S_{Ensemble}(x) \geq \tau$, donde $\tau \in [0, 1]$ es el umbral de decisión operativo global calibrado empíricamente en la fase de validación cruzada. El fundamento teórico de este enfoque de agregación lo proporciona ADBench (Han et al., 2022) y su implementación robusta se realiza mediante la API modular de PyOD (Zhao et al., 2019).

2.3.5 Forecasting de Series Temporales con Transformers

Las series temporales agroexportadoras presentan tres desafíos que los modelos de forecasting deben resolver: tendencia no estacionaria, estacionalidad múltiple (diaria, semanal, mensual, anual) y dependencia de covariables exógenas (clima, calendario agrícola, demanda internacional, precios y condiciones logísticas). Los modelos estadísticos clásicos como ARIMA capturan relaciones lineales con eficacia, pero presentan limitaciones en la modelización de no-linealidades y horizontes largos.

Temporal Fusion Transformer (TFT) (Lim et al., 2021) propone una arquitectura especializada que combina cuatro mecanismos: (1) codificación LSTM para dependencias secuenciales locales; (2) selección de variables con mecanismo de gating (GLU — Gated Linear Unit) que identifica automáticamente las covariables más informativas; (3) atención multi-cabezal interpretable que pondera los pasos temporales según su relevancia predictiva; y (4) red de cuantiles para cuantificar la incertidumbre de la predicción. TFT acepta tres tipos de entradas: features estáticas conocidas (e.g., producto, zona, destino), covariables futuras conocidas (e.g., calendario agrícola, campañas, feriados) y covariables históricas observadas (e.g., precio, volumen, clima o merma pasada).

El debate sobre la efectividad de los Transformers en series temporales es relevante para esta tesis. Zeng et al. (2023) argumentan que DLinear —un modelo lineal simple— supera a los Transformers en múltiples benchmarks, atribuyendo la limitación de los Transformers al hecho de que el mecanismo de self-attention es permutation-invariant y destruye el orden temporal de las secuencias. Sin embargo, este argumento ha sido rebatido sucesivamente: Nie et al. (2023) demuestran que la tokenización por patches —agrupando segmentos temporales antes de aplicar atención— preserva el orden local y supera a DLinear en la mayoría de benchmarks de horizonte largo. Liu et al. (2024) proponen invertir la tokenización: en lugar de tokenizar por timestamp, tokenizan por variable, aplicando self-attention entre variables en lugar de entre tiempos, obteniendo SOTA en 7 datasets multivariados.

Posición de esta tesis respecto al debate: TFT se considera por su interpretabilidad incorporada —el mecanismo de gating y los mapas de atención son legibles por analistas— más que exclusivamente por su rendimiento predictivo. En el contexto agroexportador, la capacidad de justificar qué períodos temporales y qué covariables fundamentan la predicción es un requerimiento funcional comparable en importancia a la precisión numérica.

N-HiTS (Challu et al., 2022) ofrece una alternativa no-Transformer para forecasting de horizonte largo, con interpolación jerárquica multi-tasa que reduce la complejidad computacional respecto a N-BEATS. Chronos (Ansari et al., 2024) representa el paradigma emergente de los foundation models para series temporales, basado en T5, que logra performance zero-shot competitivo en múltiples datasets; sin embargo, su opacidad y dependencia de infraestructura de gran escala limitan su aplicación directa cuando se requiere trazabilidad operativa.

2.3.6 Explicabilidad mediante SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley)

La explicabilidad en sistemas de IA se clasifica en dos grandes categorías: **inherente** —modelos cuya estructura es intrínsecamente interpretable, como los árboles de decisión— y **post-hoc** —métodos aplicados a cualquier modelo después del entrenamiento para interpretar sus predicciones. SHAP y LIME son los dos métodos post-hoc agnósticos más adoptados en la literatura.

LIME (Local Interpretable Model-agnostic Explanations) (Ribeiro et al., 2016) genera explicaciones locales construyendo un modelo lineal sustituto en el vecindario de la instancia a explicar, ponderando las muestras según su proximidad al punto de interés. LIME es rápido y flexible, pero produce explicaciones inestables: pequeñas perturbaciones de la instancia pueden cambiar significativamente la explicación, un problema crítico en contextos forenses.

SHAP (Lundberg & Lee, 2017) fundamenta las explicaciones en los valores de Shapley de la teoría de juegos cooperativos. El valor SHAP de la feature i para la predicción $f(\mathbf{x})$ cuantifica la contribución marginal media de i a la predicción, promediando sobre todas las coaliciones posibles de features:

$$\phi_i = \sum_{S \subseteq F \setminus i} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup i) - f(S)]$$

donde F es el conjunto de todas las features y S es una coalición de features sin i . Esta formulación garantiza cuatro propiedades axiomáticas: (a) **eficiencia** — la suma de todos los valores SHAP iguala la diferencia entre la predicción y el valor esperado; (b) **simetría** — features con contribución idéntica reciben el mismo valor; (c) **dummy** — features sin efecto tienen valor cero; y (d) **aditividad** — los valores SHAP son consistentes al combinar modelos.

SHAP resuelve las limitaciones de LIME al garantizar consistencia: si un modelo cambia la predicción al aumentar la contribución de una feature, el valor SHAP de esa feature nunca disminuye (Lundberg & Lee, 2017). **TreeSHAP** extiende este cálculo con un algoritmo exacto en $O(TLD^2)$ para modelos basados en árboles —donde T es el número de árboles, L es el número de hojas por árbol y D es la profundidad máxima— haciendo el cálculo computacionalmente viable para GBDT en producción.

En el contexto de supervisión operativa, la estabilidad de las explicaciones permite verificar que el modelo asigna importancias consistentes a variables semejantes. Un índice alto de estabilidad fortalece la confianza en el sistema, porque evita que alertas similares reciban justificaciones contradictorias.

La integración SHAP+LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño) de esta tesis opera como sigue: los vectores SHAP de una alerta operativa (una lista de pares variable→contribución cuantitativa) se incorporan como contexto verificado en el RAG, y el LLM genera la narración del informe sin posibilidad de inventar cifras que no estén en esos vectores o en las fuentes recuperadas.

2.3.7 Modelos de Lenguaje y Arquitectura RAG para Generación de Reportes

Los LLMs (Large Language Models - Modelos de Lenguaje de Gran Tamaño) son sistemas entrenados mediante autoregresión en corpus masivos de texto para aprender distribuciones probabilísticas sobre secuencias de tokens. Su capacidad de generalización les permite realizar tareas de reasoning, traducción, resumen y generación de texto con calidad próxima a la humana en configuraciones zero-shot y few-shot.

In-context learning permite guiar el comportamiento del LLM mediante ejemplos incluidos directamente en el prompt, sin necesidad de ajuste fino (fine-tuning). TabLLM (Hegselmann et al., 2023) demostró que mediante serialización de datos tabulares a texto descriptivo, los LLMs pueden realizar clasificación sobre datos estructurados con rendimiento no trivial en zero-shot, ampliando el espectro de aplicación de estos modelos más allá del texto no estructurado.

Sin embargo, el uso de LLMs como agentes de decisión autónoma introduce el riesgo de **alucinaciones**: el modelo puede generar afirmaciones coherentes en forma pero incorrectas en contenido (Ji et al., 2023; Maynez et al., 2026). La literatura distingue al menos dos tipos: (a) alucinaciones intrínsecas, en las que el texto generado contradice la información del contexto recuperado; y (b) alucinaciones extrínsecas, en las que el modelo inventa información no presente en el contexto. En particular, las "alucinaciones numéricas" —valores específicos de métricas, porcentajes o fechas que no corresponden a los datos reales (Barclays Research, 2025)— son especialmente peligrosas en reportes operativos, porque pueden inducir decisiones equivocadas pese a la apariencia de precisión cuantitativa.

RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación) (Lewis et al., 2020; Schneider et al., 2025) reduce este riesgo al separar el conocimiento factual del modelo generativo: en lugar de que el LLM "recuerde" información de su entrenamiento, el sistema recupera documentos o datos relevantes de una base de conocimiento externa verificada y los incluye en el contexto del prompt. El LLM entonces genera texto fundamentado en esos datos recuperados, no en su memoria paramétrica. Es importante señalar que RAG **reduce significativamente pero no elimina** el riesgo de alucinación; persisten casos de alucinación intrínseca (faithful hallucination) en los que el modelo genera afirmaciones que se desvían del contexto recuperado. Técnicas avanzadas como GraphRAG incorporan grafos de conocimiento para recuperación semántica más rica, mientras que Self-RAG permite al modelo verificar la pertinencia de los documentos recuperados antes de usarlos.

En la arquitectura de esta tesis, la "base de conocimiento" del RAG son los vectores SHAP de la alerta analizada, las métricas del ensemble de detección, las fuentes agroexportadoras recuperadas y las reglas de reporte definidas. El LLM recibe ese contexto verificado y genera el informe narrativo sin acceso a conocimiento adicional no validado. Adicionalmente se aplican dos controles complementarios: (a) plantillas de prompt estructurado con campos obligatorios (dato, modelo, score, umbral, explicación SHAP, fuente recuperada), y (b) validación posterior del reporte contra los vectores SHAP de entrada para detectar discrepancias numéricas. Este diseño permite que cada afirmación del reporte pueda trazarse hasta una fuente, score, umbral o variable explicativa.

La evaluación de calidad de los reportes generados puede utilizar **ROUGE** (Recall-Oriented Understudy for Gisting Evaluation) cuando exista un texto de referencia. Sin embargo, para esta tesis se prioriza una rúbrica operativa de completitud, consistencia, accionabilidad y correspondencia con evidencias, porque la calidad de un reporte de supervisión depende no solo de similitud textual, sino de su utilidad para la toma de decisiones.

2.3.8 Gobernanza de IA y MLOps

El despliegue de sistemas de IA en entornos empresariales críticos requiere un marco de gobernanza que trascienda el rendimiento técnico. Sculley et al. (2015) documentaron la "deuda técnica oculta" en sistemas de ML: más del 95% del código de un sistema ML de producción no es el modelo en sí, sino la infraestructura de ingesta, validación, features, servicio y monitoreo. Los pipelines con alto acoplamiento entre componentes generan "entanglement" que dificulta el mantenimiento y aumenta el riesgo de regresiones silenciosas.

MLOps (Kreuzberger et al., 2022) establece el conjunto de prácticas para gestionar el ciclo de vida completo de los modelos ML en producción: integración y entrega continua (CI/CD) para modelos, monitoreo de data drift y model drift, automatización del reentrenamiento, y trazabilidad de versiones de datos, código y modelos. En el contexto de supervisión operativa agroexportadora, MLOps permite reproducir qué modelo generó una alerta, con qué datos de entrada, bajo qué versión y con qué umbral.

El **NIST Artificial Intelligence Risk Management Framework (AI RMF 1.0)** (NIST, 2023) proporciona cuatro funciones de gestión de riesgo para sistemas de IA: (1) **Govern** — establecer políticas y roles de responsabilidad; (2) **Map** — identificar el contexto de despliegue y los riesgos asociados; (3) **Measure** — evaluar los riesgos con métricas verificables; y (4) **Manage** — implementar controles y mitigaciones. La arquitectura modular de esta tesis es diseñada para que cada capa corresponda a responsabilidades verificables bajo este framework.

Datasheets for Datasets (Gebru et al., 2021) propone una plantilla de documentación estandarizada para datasets que detalla: motivación de recolección, proceso de recolección, composición, preprocesamiento aplicado, distribución permitida y consideraciones éticas. Esta práctica se aplicará al dataset agroexportador integrado y a sus capas de datos reales, agregados, proxies y sintéticos controlados, garantizando que los resultados reportados sean reproducibles y que las limitaciones de cada fuente estén identificadas antes de evaluar el sistema.

Model Cards (Mitchell et al., 2019) extiende la documentación al nivel del modelo, especificando para quién fue entrenado, en qué condiciones, cuáles son sus limitaciones conocidas y cómo debe usarse de manera responsable. En esta tesis, se elaboran Model Cards para los modelos XGBoost/LightGBM, detectores de anomalías y el componente LLM+RAG, en conformidad con los principios de documentación del NIST AI RMF (NIST, 2023).

El contexto peruano e internacional consolida la necesidad de este framework de gobernanza. El D.S. N° 115-2025-PCM (PCM, 2025), el NIST AI RMF (NIST, 2023) y el EU AI Act (Parlamento Europeo y Consejo, 2024) refuerzan principios comunes: transparencia, documentación, supervisión humana y gestión de riesgos. Estos principios son adoptados como referencia de diseño para esta tesis. No se afirma cumplimiento formal con ninguno de estos marcos —tal afirmación requeriría auditoría regulatoria externa— sino conformidad de diseño con sus principios, en particular: (a) transparencia mediante SHAP y Model Cards, (b) supervisión humana mediante revisión obligatoria de cada reporte antes de su uso operativo, (c) gestión de riesgos mediante umbrales calibrados y validación cruzada, y (d) trazabilidad documental mediante logs completos por alerta. La aplicabilidad regulatoria efectiva del sistema a una empresa específica depende de su clasificación de riesgo bajo el reglamento correspondiente y queda fuera del alcance de esta tesis.

2.3.9 Supervisión Operativa, Trazabilidad e Inteligencia Artificial

La supervisión operativa en agroexportación exige monitorear procesos que combinan producción, acopio, calidad, sanidad, logística y comercio exterior. Las anomalías en este dominio no necesariamente corresponden a fraude; pueden representar variaciones atípicas de precio, caídas de volumen, condiciones climáticas adversas, mermas elevadas, incumplimientos fitosanitarios o retrasos logísticos. Por ello, el sistema propuesto se orienta a detectar desviaciones relevantes para la toma de decisiones, no a sustituir procesos de investigación legal o auditoría financiera.

La **supervisión operativa continua** busca reemplazar ciclos de revisión tardíos por monitoreo frecuente y documentado de indicadores. En este enfoque, cada alerta debe registrar el dato de origen, el modelo aplicado, el score

calculado, el umbral utilizado, las variables explicativas y el reporte generado. Esta trazabilidad permite que un supervisor operativo comprenda por qué el sistema marcó un evento como anómalo y qué evidencia respalda la recomendación.

La integración de IA en supervisión operativa plantea el problema de la confianza en decisiones automáticas. Esta exigencia convierte a la explicabilidad (SHAP), la documentación de datasets (Datasheets), la documentación de modelos (Model Cards) y los logs de decisión en componentes funcionales del sistema. En el marco peruano, el D.S. N° 115-2025-PCM (PCM, 2025) proporciona una base general para el uso responsable de IA; la Resolución SBS N° 053-2023 (SBS, 2023) se conserva solo como referencia nacional de buenas prácticas para gestión de riesgo de modelos.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

EN DESARROLLO

CAPITULO III: PROPUESTA METODOLOGICA

3.1 Arquitectura del sistema integrado

La arquitectura propuesta se divide en cuatro capas secuenciales y trazables:

1. **Capa 1: Predicción tabular.** Modelos GBDT, principalmente XGBoost y LightGBM, estiman valores esperados de precio o volumen usando variables comerciales, macroeconomicas, climaticas, logisticas y de contexto.
2. **Capa 2: Deteccion de anomalias.** Un ensemble de Isolation Forest, LOF y ECOD produce un score de anomalia. El LLM no detecta anomalias.
3. **Capa 3: Explicabilidad.** SHAP/TreeSHAP identifica las variables con mayor contribucion a la alerta. Las explicaciones son atribuciones del modelo, no causalidad.
4. **Capa 4: Reportes RAG/LLM.** Un LLM restringido por evidencias redacta reportes tecnicos a partir de datos, score, umbral, SHAP, fuente y metadatos.

```
[Dataset agroexportador integrado]
|
v
[Capa 1: GBDT] → valor esperado / residuo
|
v
[Capa 2: IF + LOF + ECOD] → score anomalia
|
v
[Capa 3: SHAP] → top variables explicativas
|
v
[Capa 4: RAG/LLM] → reporte trazable
```

3.2 Dataset agroexportador integrado y trazable

La validacion principal no dependera de un dataset sintetico aislado. Se trabajara con un **dataset agroexportador integrado**, construido desde cuatro tipos de informacion:

Capa de datos	Fuentes	Rol
Datos reales observados	SUNAT/ADUANET, data/dataset_real_v1.csv	Base primaria de exportaciones.
Datos reales agregados	Trade Map, SISAP/MIDAGRI, BCRP, MIDAGRI compendios, FAOSTAT	Validacion externa y contexto.
Proxies documentados	NASA POWER, SENAMHI, APN, OSITRAN, SENASA/FDA/RASFF	Variables explicativas agregadas.
Datos sinteticos controlados	data/dataset_agro_sintetico_v1.csv y reglas de inyeccion	Escenarios auxiliares, balanceo y etiquetas experimentales.

3.2.1 Segmentacion de productos

Producto	HS	Decision
Palta	080440	Producto nucleo.
Uva	080610	Producto nucleo.
Arandano	081040	Producto nucleo; sin dependencia de SISAP.
Esparrago	070920	Producto secundario condicionado.
Cacao	Verificar	Excluido del nucleo por baja representatividad.

3.2.2 Uso de fuentes

- **SUNAT/ADUANET:** fuente primaria para volumen, valor FOB, partida, fecha, empresa y destino.
- **Trade Map:** benchmark internacional por producto y mercado destino.
- **SISAP/MIDAGRI:** precio y volumen mayorista interno para palta, uva y esparrago; no mide exportaciones.
- **BCRP:** tipo de cambio mensual.
- **Clima/logistica/sanidad:** proxies agregados cuando no existe llave directa por embarque.
- **Sinteticos:** escenarios controlados y balanceo, siempre etiquetados.

3.3 Configuración experimental y métricas

3.3.1 División temporal

Para evitar fuga de información temporal:

- Train: 70% inicial.
- Validation: 10% siguiente.
- Test: 20% final.

El split aleatorio no se usará como evaluación principal.

3.3.2 Métricas por variable dependiente

VD	Métricas
VD1 rendimiento	PR-AUC, ROC-AUC, F1, precisión, recall.
VD2 explicabilidad	Cobertura top-k SHAP, estabilidad, claridad.
VD3 reportes	Rubrica de completitud, consistencia, accionabilidad y evidencia.
VD4 decisión	Tiempo-a-decisión, Likert, decisión correcta.
VD5 trazabilidad	Porcentaje de alertas con campos completos.

3.3.3 Experimentos E1-E5

Exp.	Nombre	Condición experimental	Control	VD
E1	Rendimiento de detección	Ensemble IF + LOF + ECOD	Detectores individuales	VD1
E2	Aporte SHAP	Alertas con SHAP	Alertas solo con score	VD2
E3	Aporte RAG	Reporte RAG anclado	LLM sin RAG	VD3
E4	Sistema integrado	Pipeline completo	Componentes aislados	VD4, VD5
E5	Ablation	Variantes por capas	Pipeline completo	VD1, VD5

3.3.4 Baselines

- B1: Isolation Forest individual.
- B2: Ensemble IF + LOF.
- B3: XGBoost supervisado si existe etiqueta confiable.

- B4: LLM sin RAG ni evidencia SHAP.

3.4 Reproducibilidad

Cada corrida debe registrar:

- Version del dataset.
 - Fecha de generacion.
 - Fuentes usadas.
 - Semilla.
 - Particion temporal.
 - Modelo y parametros.
 - Metricas.
 - Reporte de trazabilidad.
-

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```


CAPITULO IV: RESULTADOS Y DISCUSION

Estado: capitulo modularizado. Los resultados finales se completaran unicamente despues de ejecutar los experimentos E1-E5 sobre el dataset agroexportador integrado versionado.

Este capitulo organiza la evaluacion empirica del sistema integrado de supervision operativa. Su funcion actual es dejar preparada la estructura de reporte, los criterios de lectura y las tablas que recibirán los resultados finales.

Los valores obtenidos en corridas previas sobre datasets sinteticos o versiones anteriores se consideran evidencia auxiliar de desarrollo. No deben presentarse como resultados finales de tesis hasta que se regeneren con:

- version del dataset integrado;
- split temporal documentado;
- codigo de experimento;
- fecha de ejecucion;
- semillas utilizadas;
- reporte de calidad de datos;
- trazabilidad de fuente para cada variable.

La estructura del capitulo queda dividida en modulos para facilitar mantenimiento:

Modulo	Archivo	Contenido
4.1	docs/02-41-capitulo4-resultados-cuantitativos.md	Prediccion y deteccion, VD1.
4.2	docs/02-42-capitulo4-explicabilidad-reportes.md	SHAP y reportes RAG, VD2-VD3.
4.3	docs/02-43-capitulo4-usabilidad-trazabilidad.md	Estudio de usuarios y trazabilidad, VD4-VD5.
4.4	docs/02-44-capitulo4-discusion.md	Discusion, contraste con literatura e hipotesis.
4.5-4.6	docs/02-45-capitulo4-limitaciones-sintesis.md	Limitaciones y sintesis final.

La lectura del capitulo debe conservar una regla metodologica: **ninguna metrica se interpreta sin indicar fuente, version de dataset, granularidad, split y estado de validacion.**

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

4.1 Resultados Cuantitativos: Prediccion y Deteccion, VD1

Esta seccion reportara el rendimiento de la capa predictiva tabular y del ensemble de deteccion de anomalias. La evaluacion principal se realizara sobre el dataset agroexportador integrado, no sobre el dataset sintetico aislado.

4.1.1 Condiciones minimas para reportar resultados

Antes de completar las tablas, debe existir evidencia local de:

Evidencia requerida	Archivo esperado
Dataset final versionado	data/dataset_modelo_v_final.csv o codex-revision/data_processed/dataset_modelo_v_final.csv
Split temporal	dataset_train_raw.csv , dataset_validation.csv , dataset_test.csv
Reporte de calidad	reporte-calidad-datos.md
Reporte de entrenamiento	reporte-entrenamiento-modelos.md
Configuracion de semillas	archivo de experimento o log reproducible

4.1.2 Tabla 4.1 - Rendimiento de deteccion, Experimento E1

Metodo	Dataset/version	PR-AUC	ROC-AUC	F1	Precision	Recall	Tiempo inferencia	Estado
Isolation Forest individual, B1	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
LOF individual	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
ECOD individual	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Ensemble IF + LOF	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Ensemble IF + LOF + ECOD, propuesto	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
XGBoost/LightGBM supervisado, upper bound si hay etiqueta	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	pendiente	Condicionado

Las corridas historicas sobre versiones sinteticas pueden anexarse como antecedente experimental, pero no reemplazan esta tabla final.

4.1.3 Tabla 4.2 - Recall por tipo de anomalia

Tipo de anomalia	Origen de etiqueta	Recall ensemble	Recall baseline	Diferencia	Estado
precio	derivada/proxy/sintetica controlada	pendiente	pendiente	pendiente	Por ejecutar
volumen	derivada/proxy/sintetica controlada	pendiente	pendiente	pendiente	Por ejecutar
clima	proxy o regla documentada	pendiente	pendiente	pendiente	Por ejecutar
logistica	proxy o regla documentada	pendiente	pendiente	pendiente	Por ejecutar
sanidad/calidad	proxy o regla documentada	pendiente	pendiente	pendiente	Por ejecutar

La columna de origen es obligatoria porque `etiqueta_anomalia` puede provenir de observacion real, regla derivada, proxy o inyeccion sintetica controlada. Esa distincion determina el alcance de la interpretacion.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

4.2 Resultados Cualitativos: Explicabilidad y Reportes, VD2-VD3

Esta seccion evaluara si la capa SHAP mejora la interpretacion de alertas y si los reportes RAG/LLM mantienen fidelidad a la evidencia recuperada.

4.2.1 Tabla 4.3 - Calidad de explicabilidad, Experimento E2

Metrica	Sistema con SHAP	Sistema sin SHAP	p-value	Estado
Cobertura top-3	pendiente	N/A	pendiente	Por ejecutar
Cobertura top-5	pendiente	N/A	pendiente	Por ejecutar
Estabilidad SHAP	pendiente	N/A	pendiente	Por ejecutar
Claridad operativa Likert 1-5	pendiente	pendiente	pendiente	Por ejecutar

SHAP se interpretara como atribucion del modelo, no como causalidad. Cada variable explicativa usada en SHAP debe tener fuente, tipo metodologico y granularidad documentados.

4.2.2 Tabla 4.4 - Calidad de reportes generados, Experimento E3

Dimension	RAG/LLM anclado	LLM libre/control	Kappa Cohen	p-value	Estado
Completitud	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Consistencia numerica	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Correspondencia con evidencia	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Accionabilidad	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Coherencia textual	pendiente	pendiente	pendiente	pendiente	Por ejecutar

El reporte RAG debe citar o registrar internamente:

- registro evaluado;
- score y umbral;
- top variables SHAP;
- fuente recuperada;
- version de dataset;
- fecha de generacion;
- advertencia cuando una variable sea proxy o sintetica controlada.

4.2.3 Ejemplo de reporte generado

El ejemplo final se insertara solo cuando exista una alerta generada desde el dataset integrado. Debe seguir el patron:

```
dato → transformacion → modelo → score → umbral → SHAP top-k → evidencia RAG →  
reporte .
```

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```


4.3 Resultados del Estudio de Usabilidad y Trazabilidad, VD4-VD5

Esta seccion medira si el sistema integrado reduce el tiempo de interpretacion y mejora la trazabilidad documental frente a componentes aislados.

4.3.1 Tabla 4.5 - Tiempo-a-decision y comprension, Experimento E4

Metrica	Sistema integrado	Componentes aislados	Diferencia relativa	p-value	Tamano de efecto	Estado
Tiempo-a-decision, segundos	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Comprension Likert 1-5	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
Decision correcta	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar
SUS Score 0-100	pendiente	pendiente	pendiente	pendiente	pendiente	Por ejecutar

El tamano muestral y el perfil de participantes se reportaran como estudio piloto especializado si no alcanzan potencia estadistica suficiente para generalizacion amplia.

4.3.2 Tabla 4.6 - Trazabilidad documental, VD5

Configuracion	Alertas con trazabilidad completa	Campos faltantes frecuentes	Estado
Sistema integrado completo, E5d	pendiente	pendiente	Por ejecutar
Ablation sin SHAP, E5b	pendiente	pendiente	Por ejecutar
Ablation sin RAG, E5c	pendiente	pendiente	Por ejecutar
Componentes aislados/control	pendiente	pendiente	Por ejecutar

La trazabilidad completa exige, como minimo: `id_alerta` , `producto` , `hs` , `fecha` , `fuentes_usadas` , `score` , `umbral` , `top_shap` , `evidencia_rag` , `version_dataset` y `archivo_origen` .

4.3.3 Tabla 4.7 - Ablation study, Experimento E5

Configuracion	Capa 1 prediccion	Capa 2 anomalias	Capa 3 SHAP	Capa 4 RAG	VD1	VD3	VD5	Estado
E5a solo deteccion	No	Si	No	No	pendiente	N/A	pendiente	Por ejecutar
E5b sin SHAP	Si	Si	No	Si	pendiente	pendiente	pendiente	Por ejecutar
E5c sin RAG	Si	Si	Si	No	pendiente	pendiente	pendiente	Por ejecutar
E5d pipeline completo	Si	Si	Si	Si	pendiente	pendiente	pendiente	Por ejecutar

Las comparaciones E5 no deben mezclar resultados de dataset sintetico con resultados del dataset integrado sin una etiqueta explicita de version.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

4.4 Discusion y Cruce Comparativo

4.4.1 Proposito de la discusion

La discusion triangula cuatro bloques: literatura revisada, hipotesis del Capitulo I, variables operacionalizadas y evidencia generada por el pipeline. Su objetivo es explicar los resultados sin convertir correlaciones, scores o valores SHAP en afirmaciones causales.

4.4.2 Cruce 1 - Resultados propios versus literatura comparable

Atributo	Esta tesis	Literatura comparable	Lectura esperada
Prediccion tabular	XGBoost/LightGBM	GBDT en fraude, auditoria y agroexportacion	Comparar cobertura y estabilidad, no valores absolutos entre dominios.
Deteccion de anomalias	Isolation Forest, LOF, ECOD	ADBench/PyOD	Justificar ensemble si mejora o estabiliza resultados.
Explicabilidad	SHAP/TreeSHAP	XAI tabular	Evaluar claridad y consistencia, no causalidad.
Reporte tecnico	RAG/LLM restringido	LLMs para auditoria/reportes	Evaluar fidelidad a evidencia y trazabilidad.
Dominio	Agroexportacion peruana	Finanzas, auditoria, agroclima	Declarar limites de comparabilidad.

4.4.3 Cruce 2 - Contraste de hipotesis

Hipotesis	Evidencia requerida	Decision
H1a	Mejora de VD1 frente a detector individual con split temporal documentado.	<i>pendiente</i>
H1b	Mejora de VD2 con SHAP frente a condicion sin SHAP.	<i>pendiente</i>
H1c	Mejora de VD3 con RAG frente a LLM libre/control.	<i>pendiente</i>
H1d	Reduccion de tiempo-a-decision o mejora de comprension.	<i>pendiente</i>
H1 general	Mejora conjunta de trazabilidad y supervision operativa.	<i>pendiente</i>

La decision puede ser: aceptar, rechazar o inconclusa. Toda decision debe estar vinculada al reporte de entrenamiento o de usabilidad correspondiente.

4.4.4 Cruce 3 - Variables operacionalizadas versus indicadores observados

Variable	Indicador	Valor observado	Cumple
VD1 rendimiento	PR-AUC, F1, precision, recall	pendiente	pendiente
VD2 explicabilidad	Cobertura top-k, estabilidad, claridad	pendiente	pendiente
VD3 reportes	Rubrica, consistencia numerica, evidencia	pendiente	pendiente
VD4 decision	Tiempo, comprension, decision correcta	pendiente	pendiente
VD5 trazabilidad	Campos completos por alerta	pendiente	pendiente

4.4.5 Cruce 4 - Gobernanza, componente y metrica

Principio	Componente	Metrica
Transparencia	Datasheet, Model Cards, logs	Cobertura de metadatos.
Explicabilidad	SHAP/TreeSHAP	VD2.
Supervision humana	Protocolo de usabilidad y revision	VD4.
Gestion de riesgo	Validacion temporal y umbrales	VD1.
Anti-alucinacion	RAG anclado a evidencia	VD3.
Trazabilidad	Registro de alerta end-to-end	VD5.

4.4.6 Cruce 5 - Errores por tipo de anomalia

Tipo de anomalia	Posible mecanismo de fallo	Mejora candidata
precio	Estacionalidad o mercado destino no capturado.	Media movil por producto-destino.
volumen	Campanas pico confundidas con outliers.	Variables de campana y calendario.
clima	Proxy regional demasiado agregado.	Mayor granularidad geografica.
logistica	Falta de llave directa puerto-embarque.	Agregacion puerto-mes documentada.
sanidad/calidad	Alertas agregadas sin trazabilidad por embarque.	Mantener como contexto, no etiqueta directa.

4.4.7 Interpretacion conjunta

La contribucion esperada no es solo mejorar una metrica aislada, sino demostrar que la integracion de prediccion, deteccion, explicabilidad y reporte aumenta la capacidad de supervision operativa trazable. Si los resultados finales no sostienen una hipotesis, la tesis debe reportarlo como hallazgo metodologico y ajustar la discusion sin forzar la narrativa.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

4.5 Limitaciones de los Resultados

Los resultados finales deberán interpretarse considerando:

1. **Naturaleza integrada del dataset:** el dataset combina datos reales observados, datos reales agregados, proxies y datos sintéticos controlados. Cada capa tiene granularidad y alcance distintos.
2. **Etiquetas de anomalía:** cuando `etiqueta_anomalia` derive de reglas o inyección sintética, la evaluación mide detección de desviaciones definidas por protocolo, no necesariamente incidentes reales confirmados por empresa.
3. **SISAP/MIDAGRI:** aporta contexto de mercado interno mayorista y no debe interpretarse como exportación.
4. **Fuentes sanitarias y logísticas:** pueden operar como contexto agregado si no existe llave directa por embarque.
5. **SHAP:** entrega atribuciones del modelo, no causalidad.
6. **RAG/LLM:** mejora la redacción y trazabilidad del reporte, pero requiere validación contra evidencias y supervisión humana.
7. **Usabilidad:** si el estudio usa muestra pequeña, sus conclusiones deben presentarse como piloto especializado.

4.6 Sintesis del Capitulo IV

La sintesis final se completara cuando existan resultados integrados verificables:

1. El ensemble IF + LOF + ECOD *supera/no supera* al detector individual en VD1.
2. SHAP *mejora/no mejora* la comprension y trazabilidad explicativa en VD2.
3. RAG anclado *mejora/no mejora* la calidad documental en VD3.
4. El sistema integrado *reduce/no reduce* el tiempo-a-decision en VD4.
5. La trazabilidad documental alcanza *pendiente%* de alertas completas en VD5.
6. Las limitaciones por proxies, granularidad y datos sinteticos controlados quedan documentadas para evitar sobreinterpretacion.

Hasta completar esos puntos, el capitulo se considera una estructura de resultados, no una afirmacion empirica final.


```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

CAPÍTULO V: CONCLUSIONES Y TRABAJOS FUTUROS

| *Pendiente: Capítulo V — depende de los resultados del Capítulo IV*

5.1 Conclusiones

(Esqueleto para la síntesis final: el sistema integrado logró los objetivos propuestos, manteniendo el balance entre vanguardia tecnológica y rigor legal. Incluir: conclusión sobre el gap cerrado, métricas alcanzadas vs. objetivos, validación de hipótesis H1a–H1d, aporte al contexto regulatorio peruano).

5.2 Limitaciones de la Investigación

(Abordar: limitaciones del dataset agroexportador integrado; diferencias de granularidad entre datos reales observados, datos agregados, proxies y datos sintéticos controlados; dependencia de la calidad de datos documentada en Datasheets for Datasets (Gebru et al., 2021); deuda técnica de mantenimiento del pipeline MLOps (Sculley et al., 2015); limitaciones del tamaño de la muestra en la evaluación de comprensión; restricciones de los LLMs actuales en precisión de cálculo aritmético (Maynez et al., 2026)).

5.3 Trabajos Futuros

(Propuestas: integración de GraphRAG para recuperación semántica más rica sobre conocimiento agroexportador; extensión del ensemble con ECOD (Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica) (Li et al., 2022) y modelos de concept drift para supervisión en stream; exploración de Chronos (Ansari et al., 2024) para forecasting de horizonte largo; prueba piloto en una empresa agroexportadora peruana; evaluación de sesgos y limitaciones según Datasheets for Datasets (Gebru et al., 2021)).

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

CRONOGRAMA DE ACTIVIDADES

Pendiente: conclusiones finales dependientes de Capitulo IV y Capitulo V.

(Ver Tabla 1.2 en el Capitulo I, seccion 1.11).

CONCLUSIONES

(Por completar con los resultados finales de la investigación. Estructura sugerida:)

1. *(Conclusion sobre el gap cerrado: el sistema integrado de cuatro capas constituye una propuesta academica para unificar prediccion GBDT, deteccion de anomalias ensemble, explicabilidad SHAP y generacion de reportes LLM+RAG sobre un dataset agroexportador integrado, trazable y compuesto por datos reales observados, datos reales agregados, proxies documentados y sinteticos controlados.)*
 2. *(Conclusion sobre metricas alcanzadas: completar solo despues de ejecutar el entrenamiento final sobre el dataset integrado y reportar PR-AUC, F1, precision, recall, estabilidad SHAP, cobertura de evidencia RAG y tiempo-a-decision sin sobreafirmar resultados preliminares.)*
 3. *(Conclusion sobre validacion de hipotesis H1a-H1d: aceptar, rechazar o declarar inconclusa cada subhipotesis segun evidencia reproducible.)*
 4. *(Conclusion sobre gobernanza: describir como trazabilidad, documentacion y supervision humana se alinean con principios del D.S. 115-2025-PCM, NIST AI RMF y buenas practicas de gestion de riesgo de modelos.)*
 5. *(Conclusion sobre aporte al campo: redactar solo despues de contrastar resultados finales con literatura comparable y con las limitaciones del dataset integrado.)*
-

CONCLUSIONS

(To be completed after the final integrated-dataset experiments. Suggested structure:)

1. *(Conclusion on the research gap: the four-layer system integrates GBDT prediction, anomaly detection, SHAP explainability, and RAG-based reporting over a traceable integrated agro-export dataset.)*
 2. *(Conclusion on metrics: complete only after the final run, reporting PR-AUC, F1, precision, recall, SHAP stability, RAG evidence coverage, and time-to-decision with dataset version and reproducibility metadata.)*
 3. *(Conclusion on H1a-H1d: accept, reject, or mark each hypothesis as inconclusive based on reproducible evidence.)*
 4. *(Conclusion on governance: describe how traceability, documentation, and human oversight are implemented as design principles, without claiming regulatory certification.)*
-

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

RECOMENDACIONES

1. **Para implementadores:** Se recomienda iniciar el despliegue del sistema con el módulo de predicción GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente) y el módulo de explicabilidad SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) antes de integrar el componente LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)+RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación), siguiendo el principio de implementación incremental que reduce la deuda técnica (Sculley et al., 2015) y permite validar cada capa de forma independiente.
 2. **Para empresas agroexportadoras:** Antes de adoptar el sistema en producción, se recomienda elaborar Datasheets for Datasets (Gebru et al., 2021) para todos los datasets de entrenamiento y Model Cards (Mitchell et al., 2019) para los modelos XGBoost, detectores de anomalías y LLM+RAG.
 3. **Para futuros investigadores:** Se recomienda extender la evaluación del sistema con un diseño experimental longitudinal que capture el efecto del concept drift en precios, volúmenes, clima y comportamiento exportador, utilizando ventanas temporales y fuentes agroexportadoras reales.
 4. **Para entidades públicas y sectoriales:** Se recomienda promover guías técnicas de IA explicable y trazabilidad para sistemas de supervisión en cadenas productivas, tomando como referencia marcos nacionales e internacionales de gobernanza de IA.
 5. **Para la academia:** Se recomienda replicar el estudio con datos reales de una empresa agroexportadora colaboradora (bajo acuerdo de confidencialidad), ampliar la muestra de evaluación con supervisores operativos y responsables de calidad, e incorporar métricas de sesgo y robustez según las dimensiones de evaluación de ADBench (Han et al., 2022).
-

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

GLOSARIO DE TÉRMINOS

ADBench (*Anomaly Detection Benchmark*): Benchmark sistemático para evaluación comparativa de algoritmos de detección de anomalías, propuesto por Han et al. (2022), que cubre 57 datasets y 30 algoritmos bajo tres niveles de supervisión.

Alucinación (LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)): Fenómeno en el que un modelo de lenguaje genera texto coherente en forma pero incorrecto en contenido, incluyendo afirmaciones factuales erróneas, citas inexistentes o cifras fabricadas.

AUC-PR (*Area Under the Precision-Recall Curve*): Métrica de evaluación para clasificadores en datasets desbalanceados; a diferencia de AUC-ROC, es sensible a la distribución de clases y penaliza los falsos positivos de forma más relevante en contextos de fraude y anomalías raras.

BAF Benchmark (*Bank Account Fraud*): Dataset tabular de referencia para fraude bancario con drift temporal y desbalance de clases, publicado por Jesus et al. (2022). En esta tesis se considera únicamente como benchmark metodológico complementario para evaluar robustez tabular, no como validación directa del dominio agroexportador.

CatBoost: Algoritmo GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente) desarrollado por Yandex (Prokhorenkova et al., 2018) que resuelve el problema de target leakage en variables categóricas mediante Ordered Boosting.

Concept Drift: Cambio en la distribución estadística de los datos a lo largo del tiempo que degrada el rendimiento de modelos entrenados con datos históricos; particularmente relevante en detección de fraude y anomalías operativas.

Deep SVDD (*Deep Support Vector Data Description*): Método de detección de anomalías basado en redes neuronales que aprende una hipersfera mínima en el espacio latente que contiene los datos normales (Ruff et al., 2018).

ECOD (Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica) (*Empirical Cumulative distribution functions Outlier Detection*): Detector de anomalías sin parámetros basado en distribuciones empíricas acumuladas (Li et al., 2022), notable por su ausencia de hiperparámetros a calibrar.

EU AI Act (*Reglamento (UE) 2024/1689*): Reglamento europeo de inteligencia artificial que clasifica los sistemas de IA por nivel de riesgo y establece obligaciones de transparencia y explicabilidad en el Artículo 13 para sistemas de alto riesgo.

GBDT (*Gradient Boosting Decision Trees*): Familia de algoritmos de aprendizaje supervisado que construyen modelos predictivos mediante la combinación secuencial de árboles de decisión débiles, minimizando una función de pérdida mediante descenso de gradiente funcional.

Isolation Forest: Algoritmo de detección de anomalías no supervisado (Liu et al., 2008) que aísla anomalías mediante particionamiento aleatorio del espacio de datos, con complejidad computacional $O(n)$.

LightGBM: Algoritmo GBDT de Microsoft (Ke et al., 2017) que acelera el entrenamiento hasta $20\times$ mediante Gradient-based One-Side Sampling y estructuras de datos basadas en histogramas.

LLM (*Large Language Model*): Modelo de lenguaje de gran tamaño entrenado en corpus masivos de texto para aprender distribuciones probabilísticas sobre secuencias de tokens, capaz de realizar tareas de generación, resumen y

razonamiento en lenguaje natural.

LOF (Local Outlier Factor - Factor de Anomalía Local) (*Local Outlier Factor*): Detector de anomalías basado en densidad local relativa (Breunig et al., 2000) que cuantifica el grado de anomalía de un punto comparando su densidad con la de sus vecinos k-NN.

MLOps (*Machine Learning Operations*): Conjunto de prácticas para gestionar el ciclo de vida completo de modelos ML en producción, incluyendo CI/CD, monitoreo de drift, automatización de reentrenamiento y trazabilidad de versiones.

NIST AI RMF: Framework de gestión de riesgo para sistemas de IA publicado por el Instituto Nacional de Estándares y Tecnología de EE.UU. (2023), organizado en cuatro funciones: Govern, Map, Measure y Manage.

PR-AUC (Precision-Recall Area Under the Curve - Área Bajo la Curva de Precisión y Exhaustividad): Ver AUC-PR.

PyOD (*Python Outlier Detection*): Librería de Python que implementa más de 40 algoritmos de detección de outliers con una API estandarizada compatible con scikit-learn (Zhao et al., 2019).

RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación) (*Retrieval-Augmented Generation*): Arquitectura para modelos de lenguaje que separa el conocimiento factual del modelo generativo, recuperando documentos relevantes de una base de conocimiento externa para anclar las respuestas y mitigar alucinaciones.

Resolución SBS N° 053-2023: Resolución de la Superintendencia de Banca, Seguros y AFP del Perú que establece lineamientos de gestión de riesgos de modelos para entidades supervisadas. En esta tesis se utiliza como referencia nacional de buenas prácticas para trazabilidad, validación y monitoreo, no como obligación directa para empresas agroexportadoras.

ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*): Conjunto de métricas para evaluación automática de resúmenes y textos generados mediante comparación de superposición de n-gramas con un texto de referencia humano.

SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) (*SHapley Additive exPlanations*): Marco de explicabilidad post-hoc que asigna a cada feature una contribución marginal promediada sobre todas las coaliciones posibles, garantizando consistencia axiomática (Lundberg & Lee, 2017).

SHAP Stability Index: Métrica de coherencia de explicaciones SHAP entre instancias similares, que certifica que el modelo asigna importancias consistentes a features semejantes, requisito en contextos forenses.

TFT (*Temporal Fusion Transformer*): Arquitectura de Transformer para forecasting multi-horizonte interpretable con covariables exógenas, mecanismo de gating y predicción por cuantiles (Lim et al., 2021).

TreeSHAP: Algoritmo exacto para el cálculo de valores SHAP en modelos basados en árboles, con complejidad $O(TLD^2)$, que hace viable la explicabilidad en GBDT de producción con millones de transacciones.

XGBoost (*eXtreme Gradient Boosting*): Implementación escalable de gradient boosting (Chen & Guestrin, 2016) con regularización L1/L2, manejo nativo de valores faltantes y paralelización por columnas; baseline universal en competencias de ML con datos tabulares.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

REFERENCIAS BIBLIOGRÁFICAS

Almalki, F., & Masud, M. (2025). *Financial fraud detection using explainable AI and stacking ensemble methods*. arXiv preprint arXiv:2505.10050.

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Sinha, R., & Bergmeir, C. (2024). *Chronos: Learning the language of time series*. arXiv preprint arXiv:2403.07815.

Arik, S. O., & Pfister, T. (2021). TabNet: Attentive interpretable tabular learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(8), 6679–6687. <https://doi.org/10.1609/aaai.v35i8.16842>

Barclays Research. (2025). *Beyond the black box: Interpretability of LLMs in finance*. arXiv preprint arXiv:2505.24650.

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *ACM SIGMOD Record*, 29(2), 93–104. <https://doi.org/10.1145/342009.335388>

Center for Audit Quality. (2024). *Auditing in the age of generative AI*. CAQ. https://thecaq.org/wp-content/uploads/2024/04/caq_auditing-in-the-age-of-generative-ai__2024-04.pdf

Challu, C., Olivares, K. G., Oreshkin, B., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2022). N-HiTS: Neural hierarchical interpolation for time series forecasting. *Advances in Neural Information Processing Systems*, 35. (arXiv:2201.12886)

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>

Geburu, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. <https://doi.org/10.1145/3458723>

Gorishniy, Y., Rubashevskiy, I., Khrulkov, V., & Babenko, A. (2021). Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 8946–8959.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on tabular data? *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 507–520.

Han, X., Hu, Y., Venevdev, L., Liu, M., Wen, Q., & Zhang, Y. (2022). ADBench: Anomaly detection benchmark. *Advances in Neural Information Processing Systems*, 35.

Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Jiang, X., & Sontag, D. (2022). TabLLM: Few-shot classification of tabular data with large language models. arXiv preprint arXiv:2210.10723.

Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 27(3), 1–22. <https://doi.org/10.18637/jss.v027.i03>

Jesus, S., Pombal, J., Alves, D., Cruz, A., Saleiro, P., Ribeiro, R. P., Gama, J., & Bizarro, P. (2022). *Turning the tables: Biased, imbalanced, dynamic tabular datasets for ML evaluation*. arXiv preprint arXiv:2211.13358. [NeurIPS 2022]

Kadir, M. A., Macharla Vasu, S. S., Nair, S. S., & Sonntag, D. (2025). AuditCopilot: Leveraging LLMs for fraud detection in double-entry bookkeeping. *arXiv preprint arXiv:2512.02726*. <https://doi.org/10.48550/arXiv.2512.02726>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 3146–3154.

Kreuzberger, D., Köhl, N., & Hirschl, G. (2022). MLOps: Overview, definition, and architecture. *IEEE Access*, 10, 86995–87010. <https://doi.org/10.1109/ACCESS.2022.3197550>

Leocádio, D., et al. (2024). *Continuous auditing artificial intelligence framework*. [Pending venue publication]

Lewis, P., Perez, E., Piktus, A., Schwenk, H., Schwab, C., Yeh, C., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 9457–9474. <https://doi.org/10.18653/v1/2020.emnlp-main.727>

Li, Z., Zhao, Y., Hu, X., Botta, N., Ionescu, C., & Chen, G. H. (2022). ECOD: Unsupervised outlier detection using empirical cumulative distribution functions. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12181–12193. <https://doi.org/10.1109/TKDE.2022.3159580>

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Conference on Learning Representations (ICLR)*. (arXiv:1912.09300)

Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. *Proceedings of the Workshop on Text Summarization Branches Out (ACL 2004)*, 74–81.

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>

Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted transformers are effective for time series forecasting. *International Conference on Learning Representations (ICLR)*.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 4765–4774.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAccT)*, 220–229. <https://doi.org/10.1145/3287560.3287596>

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)*. NIST. <https://doi.org/10.6028/NIST.AI.600-1>

Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with transformers. *International Conference on Learning Representations (ICLR)*.

Oreshkin, B. N., Carpov, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 4799–4808. <https://doi.org/10.5555/3524938.3525255>

- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, 311–318. <https://doi.org/10.3115/1073083.1073135>
- Park, S. (2024). *LLMs for anomaly validation and report generation in financial systems*. arXiv preprint arXiv:2403.19735.
- Patel, R., Khan, F., Silva, B., & Shaturaev, J. (2024). AI-driven continuous auditing and real-time financial monitoring. *International Research Journal of Modernization in Engineering Technology and Science*.
- Parlamento Europeo y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de Inteligencia Artificial)*. Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/eli/reg/2024/1689>
- Preonio, J., & Yong, J. (2024). *Managing explanations: How regulators can address AI explainability*. Bank for International Settlements, Financial Stability Institute. <https://www.bis.org/fsi/fsipapers24.pdf>
- Presidencia del Consejo de Ministros. (2025, septiembre). *Decreto Supremo N° 115-2025-PCM: Reglamento de la Ley N° 31814*. Lima, Perú. <https://busquedas.elperuano.pe>
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 6638–6648. <https://doi.org/10.5555/3327757.3327790>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>
- Ruff, L., Kauffmann, J. R., Vandermeulen, R. A., Montavon, G., Samek, W., Kloft, M., Dickhaus, T., & Müller, K.-R. (2018). Deep one-class classification. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 4393–4402.
- Schneider, J., et al. (2025). Retrieval-augmented generation (RAG). *Business & Information Systems Engineering*. <https://doi.org/10.1007/s12599-025-00945-3>
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., & Young, M. (2015). Hidden technical debt in machine learning systems. *Proceedings of the 28th International Conference on Neural Information Processing Systems (NIPS) Workshop*.
- Superintendencia de Banca, Seguros y AFP. (2023). *Resolución SBS N° 053-2023: Reglamento de gestión de riesgos de modelo*. Lima, Perú. <https://www.sbs.gob.pe>
- Taylor, S. J., & Letham, B. (2017). *Forecasting at scale*. PeerJ Preprints. <https://doi.org/10.7287/peerj.preprints.3190v2>
- Thanathamath, P., et al. (2024). SHAP-instance weighting and anchor explainable AI: Enhancing XGBoost for financial fraud detection. *Emerging Science Journal*, 8(6). <https://doi.org/10.28991/ESJ-2024-08-06-024>

Tsai, C.-P., et al. (2025). *LLM-based anomaly detection in tabular data*. [Pending venue publication]

Gómez, A., López, B., & Sánchez, C. (2025). *Hallucination detection and mitigation in large language models*. arXiv preprint arXiv:2601.09929.

Wang, L., Chen, M., & Zhang, H. (2025). Financial statement fraud detection through an integrated machine learning and explainable AI framework. *Journal of Risk and Financial Management*, 19(1), 13. <https://doi.org/10.3390/jrfm19010013>

Silva, R., Santos, M., & Costa, J. (2025). Explainable AI for forensic analysis: A comparative study of SHAP and LIME in intrusion detection models. *Applied Sciences*, 15(13), 7329. <https://doi.org/10.3390/app15137329>

Waltersdorfer, L., Ekaputra, F. J., Miksa, T., & Sabou, M. (2024). AuditMAI: Towards an infrastructure for continuous AI auditing. arXiv preprint arXiv:2406.14243. <https://doi.org/10.48550/arXiv.2406.14243>

Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. <https://doi.org/10.1609/aaai.v37i9.26317>

Zhao, Y., Nasrullah, Z., & Li, Z. (2019). PyOD: A Python toolbox for scalable outlier detection. *Journal of Machine Learning Research*, 20(96), 1–7.

ANEXOS

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

ANEXOS

Anexo A — Protocolo de Evaluación de Usabilidad

Versión 1.0 — 2026-05-17. Aprobar antes de iniciar reclutamiento de participantes.

A.1 Objetivo del experimento

El experimento de usabilidad mide el impacto del sistema integrado de supervisión operativa en la **eficiencia (VD4 — tiempo-a-decisión)**, **comprensión (VD4 — Likert)** y **trazabilidad documental (VD5)** frente al uso de componentes aislados. Constituye la fuente principal de evidencia para contrastar las sub-hipótesis H1b y H1d (Capítulo I §1.4).

A.2 Diseño experimental

Tipo: Cuasi-experimental con diseño within-subjects (apareado) y orden contrabalanceado.

Cada participante ejecuta las mismas tareas en dos condiciones:

- **Condición A — Sistema integrado:** pipeline de 4 capas con alerta + score + vector SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) top-5 + reporte LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)+RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación).
- **Condición B — Componentes aislados:** alerta + score crudo del detector, sin SHAP, sin reporte narrativo (solo tabla y visualización técnica).

La mitad de los participantes inicia con A y la otra mitad con B, asignación aleatorizada con `np.random.seed(42)`. Entre ambas condiciones se intercala un descanso de 5 minutos y una tarea distractora (sopa de letras) para reducir efectos de arrastre.

A.3 Tareas evaluadas

Cada condicion presenta el mismo bloque de 10 alertas (5 positivas reales o verificadas por regla, 3 negativas reales, 2 ambiguas) extraidas del conjunto de test del dataset agroexportador integrado o de escenarios controlados derivados de este. Para cada alerta, el participante:

1. **Tarea T1 — Clasificación:** decide si la alerta corresponde a una anomalía operativa real (sí/no/dudoso).
2. **Tarea T2 — Justificación:** en una oración (máx. 200 caracteres) indica la variable que justifica la decisión.
3. **Tarea T3 — Comprensión:** responde Likert 1–5 sobre cuán comprensible resultó la alerta.

Al finalizar el bloque de 10 alertas, completa un cuestionario post-bloque (SUS adaptado + preguntas abiertas).

A.4 Métricas registradas automáticamente

Métrica	Fuente	Resolución
Tiempo apertura alerta → decisión	Log JavaScript de la plataforma	milisegundos
Tiempo total bloque	Log JavaScript	segundos
Clasificación del participante	Formulario	sí / no / dudoso
Justificación textual	Formulario	texto libre
Likert comprensión	Formulario	1–5
Versión del sistema	Variable de configuración	string
Identificador de alerta	Variable	string

A.5 Criterios de inclusión y exclusión de participantes

Inclusión:

- (a) Estudiantes de últimos ciclos ($\geq 9^\circ$ semestre) o egresados de Ingeniería de Sistemas, Ingeniería Industrial o Agronomía con formación comprobada en logística, control de calidad o auditoría de sistemas; o
- (b) Profesionales y técnicos con experiencia en supervisión de operaciones, control de calidad, auditoría de sistemas o gestión logística en el sector agroexportador.
- Mayores de 18 años.
- Aceptación de consentimiento informado firmado.

Exclusión:

- Participación previa en el diseño, desarrollo o entrenamiento de cualquier capa del sistema evaluado.
- Conflicto de interés directo declarado.
- Discapacidad visual no corregible que impida la lectura del dashboard.

A.6 Tamaño de muestra y reclutamiento

Tamaño meta: $N = 10$ participantes (documentar formalmente como un estudio piloto especializado de usabilidad). Un tamaño $N = 10$ permite una evaluación detallada de la eficiencia temporal y cualitativa sin pretensiones de generalización estadística a gran escala, pero con alta representatividad técnica.

Reclutamiento: El estudio se limita a **grupos cerrados de testers con conocimiento especializado en el área** bajo invitación directa (no abierta al público general). La convocatoria se realiza por invitación formal a través de la Escuela de Ingeniería de Sistemas de la UNSA y contactos en empresas agroexportadoras de Arequipa, Ica y La Libertad coordinadas por el asesor, garantizando el perfil técnico de los evaluadores.

A.7 Procedimiento detallado (sesión por participante, ~45 minutos)

Paso	Duración	Contenido
1	5 min	Bienvenida + consentimiento informado firmado
2	5 min	Tutorial guiado de la plataforma (alerta de ejemplo)
3	12 min	Bloque 1 — Condición A o B (según contrabalanceo)
4	5 min	Descanso + tarea distractora
5	12 min	Bloque 2 — Condición contraria
6	5 min	Cuestionario final SUS + preguntas abiertas
7	1 min	Cierre + agradecimiento

A.8 Consentimiento informado (texto base)

Por la presente confirmo que:

1. He sido informado sobre el propósito del estudio: evaluar la usabilidad de un sistema de supervisión operativa con IA explicable.
2. Comprendo que mi participación es voluntaria y puedo retirarme en cualquier momento sin justificación ni consecuencia.
3. Comprendo que mis respuestas son anónimas. Solo el investigador principal accederá a los datos, que se almacenarán cifrados y se eliminarán al finalizar la tesis (julio 2027).
4. Acepto que se registre el tiempo de mis respuestas y las opciones seleccionadas para análisis estadístico agregado.
5. Comprendo que no recibiré evaluación individual ni se compartirán mis resultados con terceros.
6. Acepto participar en una sesión de aproximadamente 45 minutos.

Nombre: _____ Fecha: _____ Firma: _____

A.9 Cuestionario post-bloque

Bloque I — Comprensión percibida (Likert 1–5)

#	Ítem	1	2	3	4	5
1	Entendí claramente por qué el sistema marcó cada alerta					
2	La información presentada me ayudó a tomar una decisión					
3	Las variables explicativas fueron suficientes					
4	El reporte generado fue útil para justificar mi decisión					
5	Confío en la decisión del sistema					

Bloque II — Tiempo y carga cognitiva (Likert 1–5)

#	Ítem	1	2	3	4	5
6	Me tomó mucho tiempo entender cada alerta (1) — Fui rápido (5)					
7	Tuve que esforzarme mucho mentalmente					
8	Me sentí seguro al decidir					

Bloque III — Adaptación SUS (10 ítems Likert 1–5)

1.

Creo que me gustaría usar este sistema frecuentemente.
2.

Encontré el sistema innecesariamente complejo.
3.

Pensé que el sistema fue fácil de usar.
4.

Necesitaría el apoyo de un experto técnico para usar este sistema.
5.

Las funciones del sistema están bien integradas.
6.

Hay demasiada inconsistencia en este sistema.
7.

La mayoría aprendería a usar este sistema rápidamente.
8.

Encontré el sistema muy engorroso.
9.

Me sentí muy confiado al usar el sistema.
10.

Necesitaría aprender muchas cosas antes de usar el sistema.

Bloque IV — Preguntas abiertas

1. ¿Qué fue lo más útil del sistema en esta sesión?
2. ¿Qué información agregaría o quitaría?
3. ¿En qué situación operativa real este sistema sería más valioso?

A.10 Variables registradas para análisis

Variable	Tipo	Origen
participant_id	string anónimo	Generado
order	{AB, BA}	Aleatorización
condition	{integrated, isolated}	Variable independiente
alert_id	string	Dataset
gt_label	{0, 1}	Dataset (oculto al participante)
user_decision	{yes, no, dunno}	Formulario
time_to_decision_ms	int	Log JavaScript
likert_comprehension	1–5	Cuestionario
justification_text	string	Formulario
sus_score	0–100	Cálculo SUS

A.11 Plan de análisis estadístico

1. **Tiempo-a-decisión (VD4-a):** t de Student apareado integrado vs. aislado; Wilcoxon si Shapiro-Wilk rechaza normalidad. Reportar media ± DE, IC95%, Cohen's dz.
2. **Comprensión Likert (VD4-b):** Wilcoxon signed-rank apareado.
3. **Decisión correcta (VD4-c):** McNemar sobre pares concordantes/discordantes.
4. **SUS:** comparación de medias con Mann-Whitney U.
5. **Análisis cualitativo de respuestas abiertas:** análisis temático con doble codificación independiente.

A.12 Almacenamiento y privacidad de datos

- Datos almacenados en archivo CSV cifrado con clave conocida solo por el investigador.
- Identificadores anónimos, sin nombre, correo ni datos demográficos sensibles.
- Backup en disco duro institucional UNSA.
- Eliminación de datos crudos al cierre del proyecto (julio 2027).
- Resultados agregados publicados en la tesis y en el repositorio GitHub.

A.13 Aprobación ética

El protocolo se somete a revisión del asesor de tesis (Dr. Víctor Manuel Cornejo Aparicio) y, si la Escuela de Ingeniería de Sistemas dispone de comité de ética, a su aprobación formal antes del reclutamiento.

Anexo A — versión 1.0 — 2026-05-17. Sometido a revisión final antes de ejecutar el estudio.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

Anexo B - Model Cards

Este anexo documenta los modelos de la arquitectura bajo el enfoque de dataset agroexportador integrado versionado.

B.1 Dataset de referencia

Los modelos se entrenan y evaluan sobre un dataset integrado compuesto por:

- datos reales observados de SUNAT/ADUANET y dataset real local;
- datos reales agregados de Trade Map, SISAP/MIDAGRI y BCRP;
- proxies climaticos, logísticos y sanitarios;
- datos sinteticos controlados solo para escenarios auxiliares, balanceo o etiquetas experimentales.

Subgrupos obligatorios:

Producto	Estado
Palta	Nucleo.
Uva	Nucleo.
Arandano	Nucleo.
Esparrago	Secundario condicionado.
Cacao	Excluido.

B.2 Model Card - Prediccion tabular

Campo	Especificacion
Modelos	XGBoost, LightGBM.
Objetivo	Estimar precio o volumen esperado.
Entradas	Variables comerciales, macro, internas, climaticas, logisticas y sanitarias.
Riesgos	Proxies agregados pueden no representar embarques individuales.
Mitigacion	Registrar fuente, granularidad y tipo metodologico por variable.

B.3 Model Card - Deteccion de anomalias

Campo	Especificacion
Modelos	Isolation Forest, LOF, ECOD, ensemble.
Objetivo	Producir score de anomalia.
Entradas	Variables procesadas y residuos de prediccion si aplica.
Riesgos	Etiquetas de anomalia pueden ser derivadas o sinteticas.
Mitigacion	Separar resultados reales, proxy y sinteticos; priorizar PR-AUC en clases desbalanceadas.

B.4 Model Card - SHAP/TreeSHAP

Campo	Especificacion
Metodo	SHAP/TreeSHAP.
Objetivo	Explicar contribucion de variables al score o prediccion.
Uso	Top-k variables por alerta.
Riesgo	Interpretar SHAP como causalidad.
Mitigacion	Reportar como atribucion del modelo.

B.5 Model Card - Reportes RAG/LLM

Campo	Especificacion
Metodo	LLM restringido por RAG.
Objetivo	Redactar reporte tecnico trazable.
Entradas	Registro, modelo, score, umbral, SHAP, fuente y evidencia recuperada.
Riesgo	Alucinacion numerica o causal.
Mitigacion	Validar que cada cifra del reporte exista en evidencia estructurada.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

Anexo C - Datasheet del Dataset Agroexportador Integrado

Estandar aplicado: Datasheets for Datasets (Gebru et al., 2021).

Version metodologica: v2.0 integrada.

Estado: actualizado al panorama de fuentes reales, agregadas, proxies y sinteticas controladas.

C.1 Motivacion

El dataset se construye para entrenar y evaluar un sistema integrado de supervision operativa con IA explicable aplicado a agroexportaciones peruanas. A diferencia de la version inicial basada en un dataset sintetico, esta version adopta un enfoque integrado y trazable:

1. Datos reales observados de exportacion.

2. Datos reales agregados de mercado y contexto.

3. Proxies publicos para clima, logistica y sanidad.

4. Datos sinteticos controlados solo para escenarios auxiliares, balanceo o etiquetas experimentales.

El proposito es permitir evaluacion tecnica, explicabilidad SHAP y reportes RAG sin ocultar el origen ni la granularidad de cada variable.

C.2 Composicion

Productos:

Producto	HS	Estado
Palta	080440	Nucleo.
Uva	080610	Nucleo.
Arandano	081040	Nucleo.
Esparrago	070920	Secundario condicionado.
Cacao	No aplica al nucleo	Excluido por baja representatividad.

Fuentes:

Tipo	Fuente	Ruta local	Granularidad
Real observada	SUNAT/ADUANET	data/sunat/ , codex-revision/data_raw/aduanet_bases	Embarque o serie aduanera.
Real observada/auditada	Dataset local	data/dataset_real_v1.csv	Registro transaccional.
Real agregada	Trade Map	data-trademap/export_*	Producto-destino-anio.
Real agregada	SISAP/MIDAGRI	codex-revision/data_processed/sisap_midagri/	Producto-mes-variedad.
Real agregada	BCRP	data/bcrp/ , codex-revision/data_raw/bcrp/	Mes.
Proxy	NASA/SENAMHI/NDVI	codex-revision/data_raw/nasa_power , data/vegetation/	Region-mes.
Proxy	APN/OSITRAN	codex-revision/data_raw/apn_* , codex-revision/data_raw/ositran_*	Puerto-mes.
Proxy/contexto	SENASA/FDA/RASFF	codex-revision/data_raw/senasa , fda , rasff	Producto/destino/mes si existe.
Sintetica controlada	Dataset sintetico	data/dataset_agro_sintetico_v1.csv	Escenario experimental.

C.3 Variables principales

Variable	Tipo	Fuente preferida	Etiqueta
producto	categoria	SUNAT/dataset real	real_observada
hs	string	SUNAT/Trade Map	real_observada
fecha	fecha	SUNAT/dataset real	real_observada
periodo_mes	fecha mensual	derivada	derivada
volumen_kg	numerica	SUNAT/dataset real	real_observada
valor_fob_usd	numerica	SUNAT	real_observada
precio_kg_usd	numerica	FOB/kg o dataset real	derivada
destino_mercado	categoria	SUNAT/Trade Map	real_observada
sisap_precio_prom	numerica	SISAP	real_agregada
sisap_volumen	numerica	SISAP	real_agregada
tipo_cambio_pen_usd	numerica	BCRP	real_agregada
temperatura_max_c	numerica	NASA/SENAMHI	proxy
precipitacion_mm	numerica	NASA/SENAMHI	proxy
carga_portuaria_mes	numerica	APN/OSITRAN	proxy
alertas_sanitarias_mes	numerica	SENASA/FDA/RASFF	proxy
etiqueta_anomalia	binaria	regla/modelo/dataset	derivada o sintetica
tipo_anomalia	categoria	regla/modelo/dataset	derivada o sintetica
regla_inyeccion	texto	generacion experimental	sintetica

C.4 Datos sinteticos controlados

Los datos sinteticos no sustituyen a las fuentes reales. Se permiten para:

- Balancear clases de anomalias en entrenamiento.
- Simular escenarios de supervision.
- Probar reportes SHAP/RAG.
- Crear etiquetas experimentales cuando no existe etiqueta oficial de anomalia.

Reglas de inyeccion permitidas:

Tipo	Variables afectadas	Uso
Precio	precio_kg_usd , residuo de precio	Outliers comerciales.
Volumen	volumen_kg	Cambios atipicos de escala.
Clima	temperatura, precipitacion	Escenarios agroclimaticos.
Logistica	dias_logisticos , carga portuaria	Demoras o presion portuaria.
Calidad	merma_pct , cumplimiento	Escenarios de deterioro o riesgo.

Toda fila o variable sintetica debe tener `origen_dato = sintetica` y `regla_inyeccion` no vacia.

C.5 Preprocesamiento

El pipeline debe:

- Homologar productos y HS.
- Excluir cacao del dataset final.
- Mantener esparrago como secundario si pasa validacion.
- Convertir fechas a `YYYY-MM-DD` y `YYYY-MM` .
- Preservar `fuente` , `archivo_origen` , `granularidad` y `tipo_variable` .
- Separar train/validation/test de forma temporal.
- Evitar que datos sinteticos o SMOTE entren al test final real.

C.6 Usos previstos

- Entrenamiento de modelos tabulares.
- Deteccion de anomalias.
- Explicabilidad SHAP.
- Generacion de reportes RAG.
- Analisis de trazabilidad de alertas.
- Soporte documental para metodologia y anexos.

C.7 Usos no previstos

- Tomar decisiones operativas reales sin validacion empresarial.
- Afirmar causalidad a partir de SHAP.
- Presentar proxies como observaciones por embarque.

- Presentar datos sinteticos como registros oficiales.

C.8 Consideraciones eticas

El dataset integrado debe proteger trazabilidad y transparencia. Cuando se usen empresas o RUC reales de fuentes publicas, se evaluara anonimizar o agrupar en reportes publicos. Los reportes RAG deben indicar sus fuentes y no emitir recomendaciones fuera de la evidencia recuperada.

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

Anexo D — Registro de Uso de Herramientas de IA

La presente investigación utilizó herramientas de inteligencia artificial generativa como apoyo en las siguientes actividades: revisión bibliográfica exploratoria, verificación de coherencia de argumentos, corrección de estilo académico y generación de borradores de secciones específicas. Todas las referencias bibliográficas fueron verificadas manualmente en las fuentes originales. Las decisiones de diseño, la interpretación de resultados y las conclusiones son responsabilidad exclusiva del investigador.

(Adjuntar registro detallado de las sesiones de uso según los requerimientos de transparencia de la UNSA)

(Documento elaborado con apoyo de herramientas de IA — UNSA Arequipa, 2026)

```
<w:p><w:r><w:br w:type="page" /></w:r></w:p>
```

Anexo E - Resumen general del sistema

Este anexo resume la investigación bajo la versión metodológica actual: sistema integrado de supervisión operativa con IA explicable y dataset agroexportador integrado.

1. Arquitectura modular

Capa	Funcion
Capa 1	Prediccion tabular con XGBoost/LightGBM.
Capa 2	Deteccion de anomalias con IF + LOF + ECOD.
Capa 3	Explicabilidad con SHAP/TreeSHAP.
Capa 4	Reportes trazables con RAG/LLM.

2. Base de datos

La evaluación final debe basarse en un dataset agroexportador integrado:

- SUNAT/ADUANET y dataset real local como base observada.
- Trade Map como benchmark externo.
- SISAP/MIDAGRI como mercado interno para palta, uva y esparrago.
- BCRP como control macro.
- Clima, logística y sanidad como proxies.
- Sintéticos solo como apoyo experimental.

3. Productos

Producto	Estado
Palta	Nucleo.
Uva	Nucleo.
Arandano	Nucleo.
Esparrago	Secundario condicionado.
Cacao	Excluido.

4. Estado de resultados

Los resultados obtenidos sobre versiones sintéticas o corridas previas deben considerarse preliminares hasta ejecutar el entrenamiento final sobre el dataset integrado. No se deben presentar como conclusiones finales si no cuentan con reporte de entrenamiento, version de dataset y trazabilidad.

5. Gobernanza y trazabilidad

Cada alerta valida debe incluir:

- dato de origen;
 - version del dataset;
 - modelo y parametros;
 - score y umbral;
 - variables SHAP;
 - fuente recuperada por RAG;
 - reporte generado.
-