

Índice

DEDICATORIA

AGRADECIMIENTOS

PRESENTACIÓN

RESUMEN

ABSTRACT

ÍNDICE DE CONTENIDOS

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

ÍNDICE DE FÓRMULAS

INTRODUCCION

CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA

1.1 Descripción de la realidad problemática

Contexto

Problema de datos

Problema analítico

Problema explicativo

Problema documental

Síntesis

1.2 Problema principal

Subproblemas

1.3 Objetivos

1.3.1 Objetivo principal

1.3.2 Objetivos específicos

1.4 Hipótesis de la investigación

1.4.1 Hipótesis general

1.4.2 Hipótesis nula (H0)

1.4.3 Hipótesis específicas

1.5 Variables e indicadores

1.5.1 Variable independiente

1.5.2 Variable dependiente

1.6 Viabilidad de la investigación

1.6.1 Viabilidad técnica

1.6.2 Viabilidad operativa

1.6.3 Viabilidad económica

1.7 Justificación e importancia

1.7.1 Justificación teórica

1.7.2 Justificación metodológica

1.7.3 Justificación práctica

1.8 Alcance

1.9 Línea, tipo y nivel de investigación

1.10 Técnicas e instrumentos de recolección de información

1.10.1 Técnicas

1.10.2 Instrumentos

1.10.3 Criterios de uso de instrumentos

1.11 Cronograma de actividades

CAPÍTULO II: MARCO TEÓRICO

2.1 Antecedentes de la Investigación

2.1.1 Antecedentes Internacionales

2.1.2 Antecedentes nacionales y evidencia sectorial verificable

2.1.3 Antecedentes Metodológicos

2.1.4 Síntesis crítica

ESTADO DEL ARTE

2.2 Estado del Arte

2.2.1 Modelos GBDT frente a Aprendizaje Profundo Tabular

2.2.2 Detector Único frente a Ensemble de Anomalías

2.2.3 Predicción Esperada y Residuos

2.2.4 SHAP y Explicabilidad

2.2.5 LLM como Detector frente a LLM como Redactor

2.2.6 RAG y Control Factual

2.2.7 Arquitecturas Aisladas frente a Integradas

2.2.8 Gobernanza de IA y Trazabilidad

2.2.9 Brecha específica que aborda la tesis

2.2.10 Implicancia para el diseño metodológico

MARCO CONCEPTUAL

2.3 Marco Conceptual

2.3.1 Operación Agroexportadora

2.3.2 Supervisión Analítica

2.3.3 Valor Unitario FOB de Exportación

2.3.4 Granularidad Temporal Semanal

2.3.5 Data Leakage (Fuga de Información)

2.3.6 Gradient Boosting Decision Trees (GBDT)

2.3.7 Residuo Predictivo Robust-Z

2.3.8 Ensemble no Supervisado PyOD

2.3.9 Explicabilidad Local Post-Hoc con SHAP

2.3.10 Retrieval-Augmented Generation (RAG)

2.3.11 Trazabilidad de Modelos y Linaje de Datos

2.3.12 Dato real observado, dato agregado, proxy y dato sintético

2.3.13 Resultado preliminar y resultado definitivo

2.3.14 Placeholder de figura o evidencia visual

2.3.15 Supervisión analítica frente a supervisión operativa causal

CAPÍTULO III: ELABORACIÓN DE LA PROPUESTA

3.1 Generalidades

3.1.1 Propósito

3.1.2 Usuarios del Sistema

3.1.3 Entradas

3.1.4 Salidas

3.1.5 Requisitos Funcionales

3.1.6 Requisitos No Funcionales

3.1.7 Restricciones

3.1.8 Principios de Diseño

3.1.9 Tecnologías Implementadas

3.1.10 Arquitectura de Componentes

3.2 Esquema de la Propuesta

3.2.1 Flujo General de Datos

3.2.2 Esquema y Capas de Datos

3.2.3 Unidad de Análisis

3.2.4 Variables Objetivo

3.2.5 Integración de Fuentes Exógenas

3.2.6 Ingeniería de Características (Prevención de Data Leakage)

3.2.7 Modelamiento Predictivo Global

3.2.8 Cálculo de Residuos Robustos

3.2.9 Ensemble de Anomalías y Percentiles

3.2.10 Explicabilidad SHAP y Atribución local

3.2.11 RAG con Validador Factual

3.2.12 Trazabilidad de Auditoría

3.2.13 Seguridad y Privacidad

3.2.14 Esquema de Despliegue Local

3.3 Obtención y Preparación de Datos

3.3.1 Fuentes de datos y estado de uso

3.3.2 Inventario reproducible de archivos principales

3.3.3 Capas de procesamiento

3.3.4 Caracterización del dataset semanal gold

3.3.5 Calidad, registros eliminados y límites de datos

3.3.6 Controles de calidad temporal

3.3.7 Registro de artefactos experimentales

3.4 Diseño e Implementación del Prototipo

3.4.1 Estructura técnica del prototipo

3.4.2 Vistas funcionales del prototipo

3.4.3 Placeholders de capturas del prototipo

3.4.4 Algoritmos propuestos e implementación vinculada

3.5 Diseño Experimental y Validación

3.5.1 Validación de predicción y anomalías

3.5.1.1 Partición temporal propuesta

3.5.1.2 Estrategia walk-forward

3.5.1.3 Baselines predictivos

3.5.1.4 Modelos propuestos e hiperparámetros

3.5.1.5 Métricas por objetivo

3.5.1.6 Protocolo de anomalías sintéticas

3.5.2 Validación de explicabilidad

3.5.3 Validación de reportes automáticos

3.5.4 Evaluación controlada con usuarios

3.5.5 Puertas de control

3.5.6 Checklist verificable de cierre del Capítulo III

CAPÍTULO IV — RESULTADOS Y DISCUSIÓN

4.1 Estado de Implementación del Prototipo

4.1.1 Alcance verificable

4.1.2 Reglas de interpretación

4.1.3 Algoritmos integrados en el avance actual

4.1.4 Estado frente a las puertas de control

4.2 Resultados Cuantitativos: Predicción y Detección — VD1

4.2.1 Condiciones de reproducibilidad

4.2.2 Tabla 4.1 — Rendimiento de detección en validación semilla

4.2.3 Tabla 4.2 — Recall por tipo de anomalía

4.2.4 Tabla 4.3 — Predicción FOB en validación semilla

4.2.5 Evidencia faltante para resultado definitivo

4.3 Explicabilidad Local y Reportes Automáticos — VD2, VD3

4.3.1 Explicabilidad local con SHAP — VD2

4.3.2 Reportes RAG — VD3

4.3.3 Tabla 4.6 — Documentos recuperados en muestras semilla

4.3.4 Evidencia faltante para cierre de VD2 y VD3

4.4 Usabilidad y Trazabilidad — VD4, VD5

4.4.1 Diseño del estudio de usabilidad — VD4

4.4.2 Telemetría semilla

4.4.3 Trazabilidad — VD5

4.4.4 Evidencia faltante

4.5 Discusion y Cruce Comparativo

4.5.1 Proposito de la discusion

4.5.2 Cruce 1 - Resultados propios versus literatura comparable

4.5.3 Cruce 2 - Contraste de hipotesis

4.5.4 Cruce 3 - Variables operacionalizadas versus indicadores observados

4.5.5 Cruce 4 - Gobernanza, componente y metrica

4.5.6 Cruce 5 - Errores por tipo de anomalia

4.5.7 Interpretación conjunta

4.6 Limitaciones de los Resultados

4.7 Síntesis del Capítulo IV

CAPÍTULO V: CONCLUSIONES Y TRABAJOS FUTUROS

5.1 Conclusiones

5.2 Limitaciones de la Investigación

5.3 Trabajos Futuros

CRONOGRAMA DE ACTIVIDADES

CONCLUSIONES

CONCLUSIONS

RECOMENDACIONES

GLOSARIO DE TÉRMINOS

REFERENCIAS BIBLIOGRÁFICAS

ANEXOS

ANEXOS

Anexo A — Protocolo de Evaluación de Usabilidad

A.1 Objetivo del experimento

A.2 Diseño experimental

A.3 Tareas evaluadas

A.4 Métricas registradas automáticamente

A.5 Criterios de inclusión y exclusión de participantes

A.6 Tamaño de muestra y reclutamiento

A.7 Procedimiento detallado (sesión por participante, ~45 minutos)

A.8 Consentimiento informado (texto base)

A.9 Cuestionario post-bloque

A.10 Variables registradas para análisis

A.11 Plan de análisis estadístico

A.12 Almacenamiento y privacidad de datos

A.13 Aprobación ética

Anexo B - Model Cards

B.1 Dataset de referencia

B.2 Model Card - Predicción tabular

B.3 Model Card - Detección de anomalías

B.4 Model Card - SHAP/TreeSHAP

B.5 Model Card - Reportes RAG/LLM

Anexo C - Datasheet del Dataset Agroexportador Integrado

C.1 Motivacion

C.2 Composicion

C.3 Variables principales

C.4 Datos sinteticos controlados

C.5 Preprocesamiento

C.6 Usos previstos

C.7 Usos no previstos

C.8 Consideraciones eticas

Anexo D — Registro de Uso de Herramientas de IA

Anexo E - Resumen general del sistema

1. Arquitectura modular

2. Base de datos

3. Productos

4. Estado de resultados

5. Gobernanza y trazabilidad

Tesis Completa — Sistema Integrado Agroexportador

Autor: Yoset Cozco Mauri | Generado: 2026-06-22 09:03

title: "Sistema Integrado de Supervisión Operativa con Inteligencia Artificial Explicable para Empresas Agroexportadoras Peruanas"

author: "Yoset Cozco Mauri"

date: "2026"

bibliography: refs.bib

csl: apa.csl

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA

Facultad de Ingeniería de Producción y Servicios

Escuela Profesional de Ingeniería de Sistemas

SISTEMA INTEGRADO DE SUPERVISIÓN OPERATIVA CON INTELIGENCIA ARTIFICIAL EXPLICABLE PARA LA DETECCIÓN DE ANOMALÍAS Y GENI REPORTES TRAZABLES EN EMPRESAS AGROEXPORTADORAS PERUANAS

Tesis presentada por el Bachiller:

Cozco Mauri, Yoset

Para optar el Título Profesional de Ingeniero de Sistemas

Asesor:

Dr. Víctor Manuel Cornejo Aparicio

Arequipa – Perú

2026

DEDICATORIA

(Por completar — dedicatoria personal del autor)

AGRADECIMIENTOS

(Por completar — agradecimientos al asesor, jurado, institución colaboradora y familiares)

PRESENTACIÓN

La presente investigación tiene como propósito el diseño, implementación y evaluación de un sistema integrado de supervisión operativa para agroexportadoras peruanas, que combina técnicas de aprendizaje automático, detección de anomalías, explicabilidad algorítmica y generación de reportes trazables mediante modelos de lenguaje con recuperación de contexto. El estudio responde a la necesidad de contar con herramientas de inteligencia artificial capaces de detectar desviaciones operativas, explicar sus causas probables y documentar alertas de manera comprensible para supervisores, gerentes de calidad, gestores logísticos y auditores internos.

El trabajo se organiza en cinco capítulos: el Capítulo I establece el planteamiento del problema, objetivos e hipótesis; el Capítulo II desarrolla el marco teórico, antecedentes y estado del arte; el Capítulo III describe la propuesta metodológica; el Capítulo IV presenta los resultados y discusión; y el Capítulo V presenta las conclusiones y trabajos futuros.

El Autor

RESUMEN

Esta tesis propone un sistema integrado de supervisión operativa para empresas agroexportadoras peruanas, basado en un dataset agroexportador peruano trazable. La arquitectura combina predicción tabular mediante modelos GBDT (Gradient Boosting Decision Trees), detección de anomalías operativas mediante ensemble de algoritmos, explicabilidad mediante SHAP (SHapley Additive exPlanations) y generación automática de reportes técnicos con LLMs en arquitectura RAG (Retrieval-Augmented Generation).

El problema abordado es la fragmentación de datos agroexportadores y la baja trazabilidad entre fuentes de comercio exterior, mercado interno, macroeconomics, clima, logística y sanidad. En este contexto, la investigación se orienta a productos priorizados de agroexportación peruana: palta, uva como núcleo; espárrago como producto secundario condicionado a cobertura suficiente; y cacao como producto excluido de la evaluación por falta de representatividad en el dataset real auditado.

La propuesta utiliza SUNAT/ADUANET como fuente primaria de exportaciones reales, Trade Map como benchmark externo, SISAP/MIDAGRI como mercado interno mayorista, BCRP para variables macroeconómicas, y fuentes climáticas, logísticas y sanitarias como proxies documentados. Los datos controlados se restringen a escenarios experimentales, balanceo de clases, simulación de alertas o vacíos no observables con fuentes públicas, siempre mediante etiquetas metodológicas.

Las contribuciones principales son: (1) una arquitectura modular de cuatro capas que separa predicción, detección, explicación y reporte; (2) un enfoque de agroexportador integrado con datos reales observados, datos reales agregados, proxies y sintéticos controlados; (3) uso de SHAP para explicar la contribución de variables en alertas operativas; (4) reportes RAG restringidos a evidencia estructurada, score, metadatos y versión de dataset; y (5) una metodología de comparación que compara rendimiento técnico, trazabilidad, comprensión operativa y tiempo-a-decisión. La Resolución SBS N. 053-2023 se considera como referente de buenas prácticas para gestión de riesgo de modelos, mientras que el D.S. N. 115-2025-PCM se adopta como marco peruano general de gobernanza humana en IA.

Palabras clave: supervisión operativa, agroexportación, dataset integrado, detección de anomalías, explicabilidad IA, SHAP, RAG, GBDT, trazabilidad artificial.

ABSTRACT

This thesis proposes an integrated operational supervision system for Peruvian agro-export companies, based on a traceable integrated agro-export architecture that combines tabular prediction with Gradient Boosting Decision Trees (GBDT), operational anomaly detection through an algorithmic ensemble, and automatic generation of technical reports with LLMs in a RAG (Retrieval-Augmented Generation) architecture.

explainability with SHAP (SHapley Additive exPlanations), and automatic technical report generation with Large Language Models (LLMs) in a Retrieval Generation (RAG) architecture.

The research addresses the fragmentation of agro-export data and the weak traceability between foreign trade, domestic market, macroeconomic, climate and sanitary sources. The study focuses on avocado, grape, and blueberry as core products; asparagus as a secondary product subject to coverage verification; and cocoa as excluded from the main evaluation due to low representativeness in the audited real dataset.

The proposal uses SUNAT/ADUANET as the primary source for real export data, Trade Map as an external benchmark, SISAP/MIDAGRI as domestic market context, BCRP for macroeconomic variables, and climate, logistics, and sanitary sources as documented proxies. Controlled synthetic data are limited to specific scenarios, class balancing, alert simulation, or non-public data gaps, and must always be explicitly labeled.

The main contributions are: (1) a modular four-layer architecture separating prediction, detection, explanation, and reporting; (2) an integrated agro-export approach combining observed real data, aggregated real data, proxies, and controlled synthetic data; (3) SHAP-based attribution of variables in operational evidence-restricted RAG reports using structured evidence, scores, metadata, and dataset versions; and (5) an evaluation methodology covering performance, traceability, operational comprehension, and time-to-decision.

Keywords: operational supervision, agro-export, integrated dataset, anomaly detection, AI explainability, SHAP, RAG, GBDT, traceability, artificial intelligence

ÍNDICE DE CONTENIDOS

- DEDICATORIA
- AGRADECIMIENTOS
- PRESENTACIÓN
- RESUMEN
- ABSTRACT
- ÍNDICE DE CONTENIDOS
- ÍNDICE DE FIGURAS
- ÍNDICE DE TABLAS
- ÍNDICE DE FÓRMULAS
- INTRODUCCIÓN
- **CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA**
 - 1.1 Descripción de la Realidad Problemática
 - 1.2 Problema Principal
 - 1.3 Objetivos
 - 1.4 Hipótesis de la Investigación
 - 1.5 Variables e Indicadores
 - 1.6 Viabilidad de la Investigación
 - 1.7 Justificación e Importancia
 - 1.8 Alcance
 - 1.9 Línea, Tipo y Nivel de la Investigación
 - 1.10 Técnicas e Instrumentos de Recolección de Información
 - 1.11 Cronograma de Actividades
- **CAPÍTULO II: MARCO TEÓRICO**
 - 2.1 Antecedentes de la Investigación
 - 2.2 Estado del Arte
 - 2.3 Marco Conceptual
- **CAPÍTULO III: ELABORACIÓN DE LA PROPUESTA**
 - 3.1 Generalidades de la Propuesta
 - 3.2 Esquema de la Propuesta

- 3.3 Obtención y Preparación de Datos
- 3.4 Diseño e Implementación del Prototipo
- 3.5 Diseño Experimental y Validación
- **CAPÍTULO IV: RESULTADOS Y DISCUSIÓN**
- 4.1 Estado de Implementación del Prototipo
- 4.2 Resultados Cuantitativos: Predicción y Detección
- 4.3 Explicabilidad Local y Reportes Automáticos
- 4.4 Usabilidad y Trazabilidad
- 4.5 Discusión y Cruce Comparativo
- 4.6 Limitaciones de los Resultados
- 4.7 Síntesis del Capítulo IV
- **CAPÍTULO V: CONCLUSIONES Y TRABAJOS FUTUROS**
- 5.1 Conclusiones
- 5.2 Limitaciones
- 5.3 Trabajos Futuros
- CRONOGRAMA DE ACTIVIDADES
- CONCLUSIONES
- RECOMENDACIONES
- GLOSARIO DE TÉRMINOS
- REFERENCIAS BIBLIOGRÁFICAS
- ANEXOS

ÍNDICE DE FIGURAS

- Figura 3.1 — Arquitectura lógica del sistema integrado
- Figura 3.2 — Flujo temporal de datos, predicción, alerta y reporte
- Figura 3.3 — Modelo lógico de trazabilidad de alerta, explicación y reporte
- Figura 4.1 — Vista de detalle de alerta del prototipo funcional
- Figura 4.2 — Consola de telemetría experimental del prototipo
- Figura 4.3 — Bandeja de gestión de alertas
- Figura 4.4 — Configuración de modelo y umbrales
- Figura 4.5 — Explorador de datos y biblioteca RAG
- Figura 4.6 — Importancia global SHAP para FOB
- Figura 4.7 — Importancia global SHAP para volumen
- Figura 4.8 — Distribución SHAP para FOB
- Figura 4.9 — Distribución SHAP para volumen

ÍNDICE DE TABLAS

- Tabla 1.1 — Variables e Indicadores
- Tabla 1.2 — Cronograma de Actividades
- Tabla 1.3 — Técnicas e Instrumentos de Recolección
- Tabla 2.1 — Comparativa de Sistemas de Supervisión con IA
- Tabla 2.2 — Resumen del Estado del Arte por Bloques Temáticos
- Tabla 3.1 — Mapeo de módulos, rutas, entradas, salidas y evidencia

- Tabla 3.2 — Inventario reproducible de archivos principales
- Tabla 3.3 — Caracterización del dataset semanal gold
- Tabla 3.4 — Controles de calidad temporal y prevención de fuga de información
- Tabla 3.5 — Checklist verificable de cierre del Capítulo III
- Tabla 4.1 — Rendimiento de detección en experimento preliminar
- Tabla 4.2 — Recall por tipo de anomalía
- Tabla 4.3 — Rendimiento predictivo de XGBoost
- Tabla 4.4 — Atribuciones SHAP promedio por variable
- Tabla 4.5 — Rúbrica de calidad de reportes RAG
- Tabla 4.6 — Documentos recuperados por tipo de alerta
- Tabla 4.7 — Telemetría de usabilidad
- Tabla 4.8 — Campos de trazabilidad completos

ÍNDICE DE FÓRMULAS

- Fórmula 1 — Función objetivo GBDT: $F^*(x) = \arg\min_F \mathbb{E}[L(y, F(x))]$
- Fórmula 2 — Iteración GBDT: $F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$
- Fórmula 3 — Local Outlier Factor: $\text{LOF}_k(p)$
- Fórmula 4 — Score robusto de residuo: $z_r(t) = \frac{r(t) - \text{mediana}(r_{t-13:t-1})}{\text{MAD}(r_{t-13:t-1})}$
- Fórmula 5 — Score ensemble de anomalía: $s = \sum_i w_i p_i$
- Fórmula 6 — Valor SHAP: $\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{1}{|S|(|F|-|S|-1)!} [f(S \cup \{i\}) - f(S)]$

INTRODUCCION

La agroexportacion peruana constituye un sector estrategico para la economia nacional debido a su crecimiento sostenido, diversificacion de participacion en mercados internacionales exigentes. De acuerdo con informacion oficial del Ministerio de Desarrollo Agrario y Riego, al cierre agroexportaciones peruanas alcanzaron ventas por USD 15 013 millones, con un crecimiento de 17.3% respecto al anio anterior (MIDAGRI, 2026). Entre l de mayor interes para esta investigacion se consideran como nucleo la palta, la uva y el arandano, mientras que el esparrago se mantiene como product condicionado a la calidad de su cobertura de datos. El cacao, aunque aparece en registros exploratorios, se excluye del nucleo experimen representatividad local.

En este contexto, las empresas agroexportadoras articulan procesos de produccion agricola, acopio, almacenamiento, control de calidad, cumplimiento logistica y comercializacion internacional. Cada proceso genera datos que pueden revelar desviaciones relevantes para la gestion operativa: cambios precios, variaciones de volumen, condiciones climaticas adversas, incumplimientos de calidad, retrasos logisticos o patrones atipicos en mercados de embargo, la informacion se encuentra dispersa entre fuentes publicas, sistemas internos, reportes agregados y registros tecnicos no siempre compatible

La presente investigacion parte de esa fragmentacion. El proyecto no se limita a entrenar modelos sobre un dataset sintetico, sino que propone construir **dataset agroexportador integrado**, compuesto por datos reales observados, datos reales agregados, variables proxy documentadas y datos sintetico: solo cuando sean necesarios para escenarios experimentales, balanceo o etiquetas de anomalia. La fuente primaria para comercio exterior es SUNA Trade Map se utiliza como benchmark externo de mercados destino; SISAP/MIDAGRI aporta contexto de mercado interno mayorista para palta, uva BCRP aporta tipo de cambio; y las fuentes climaticas, logisticas y sanitarias se emplean como proxies agregados cuando no existe llave directa por emba

La inteligencia artificial ofrece herramientas adecuadas para abordar esta brecha. Los modelos GBDT han demostrado buen desempeno en dai estructurados (Grinsztajn et al., 2022); los ensembles de detectores de anomalias permiten identificar comportamientos atipicos de forma mas rok detector individual (Han et al., 2022); la explicabilidad mediante SHAP convierte predicciones opacas en atribuciones comprensibles (Lundberg & Lee modelos de lenguaje con arquitectura RAG pueden transformar resultados cuantitativos en reportes comprensibles siempre que su funcion se resti evidencias y no a decidir ni inventar informacion (Schneider et al., 2025).

La tesis propone un sistema integrado de cuatro capas que une prediccion tabular, deteccion de anomalias, explicabilidad y generacion de reportes tra flujo coherente de supervision operativa. El sistema busca mejorar la deteccion de desviaciones, explicar los factores asociados y documentar cada alert score, umbral, variables explicativas y evidencia recuperada. La Resolucion SBS N. 053-2023 (SBS, 2023) se toma como referencia nacional de buenas p gestion de riesgo de modelos, sin asumirla como obligacion directa para agroexportadoras; el D.S. N. 115-2025-PCM (PCM, 2025) se emplea como mi general sobre gobernanza, transparencia y supervision humana en inteligencia artificial.

El documento se estructura de la siguiente manera: el Capítulo I plantea el problema de investigación, define objetivos, hipótesis, variables, indicador de viabilidad. El Capítulo II desarrolla antecedentes, estado del arte y marco teórico. El Capítulo III describe la arquitectura del sistema, el dataset integrado y la configuración experimental. El Capítulo IV presenta resultados validados o, cuando corresponda, resultados preliminares claramente identificados. El Capítulo V sintetiza conclusiones, limitaciones y trabajos futuros.

CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA

1.1 Descripción de la realidad problemática

Contexto

Las operaciones agroexportadoras peruanas representan uno de los motores económicos principales del país, impulsando el desarrollo agrícola comercial. La comercialización de productos agrícolas perecederos, como la palta, la uva fresca y el arándano, requiere una coordinación precisa de la producción, el empaque, el control fitosanitario, la logística de frío y el despacho aduanero. Durante estas etapas, se genera un volumen masivo y continuo de registros aduaneros, reportes de precios mayoristas nacionales, variables macroeconómicas, condiciones climáticas regionales, tiempos de despacho y alertas sanitarias en mercados de destino.

Problema de datos

A pesar de la abundancia de registros, la información en este dominio se encuentra fragmentada entre múltiples organizaciones e instituciones públicas (SUNAT, MIDAGRI, BCRP, SENASA, NASA POWER). Los datos poseen granularidades y formatos heterogéneos: microdatos transaccionales por contenedor, precios mayoristas diarios agregados a nivel de mercado mayorista local, tipos de cambio mensuales, y datos climáticos georreferenciados. No existe una estructura unificada o canal que integre estas fuentes para obtener una perspectiva operativa única. Por ende, la tesis propone la construcción de un **dataset agroexportador integrado** que consolida datos reales observados de aduanas, datos agregados macroeconómicos, proxies documentados y datos sintéticos controlados para simulaciones.

Problema analítico

En la gestión de las operaciones, la simple observación de una cifra de exportación (ej. un valor FOB o un volumen por contenedor) no permite determinar si la transacción se encuentra dentro de los parámetros normales de comportamiento o si constituye una desviación crítica. Para realizar una supervisión efectiva, es indispensable construir un **valor esperado** histórico que sirva de línea base de comparación y permita calcular el residuo predictivo (la desviación real menos el valor esperado). La falta de estimaciones semanales de valor unitario FOB y volumen exportado impide parametrizar el comportamiento histórico normal y detectar anomalías en las exportaciones.

Problema explicativo

Los modelos predictivos o algoritmos de detección de anomalías tradicionales (como Isolation Forest o LOF) operan como cajas negras. Aunque pueden generar una alerta de riesgo sobre una operación específica (determinando que es una desviación con severidad baja, media o alta), la falta de explicabilidad reduce la confianza de los analistas de negocio. Sin una justificación local del peso marginal de cada característica (ej. a través de valores de importancia), los analistas no pueden determinar qué variables exógenas o comerciales empujaron la transacción hacia el rango de anomalía.

Problema documental

Finalmente, incluso si el sistema detecta una anomalía y explica sus variables, persiste una brecha documental importante. Los analistas y auditores requieren reportes en lenguaje natural claros y trazables que vinculen la alerta con el sustento de datos reales. La automatización tradicional de reportes generados por modelos de lenguaje (LLMs) carece de controles factuales deterministas, lo que introduce el riesgo de alucinaciones (cifras e interpretaciones inventadas por el modelo). Asimismo, se requiere garantizar el linaje inmutable de cada alerta desde los datos de origen de SUNAT hasta el informe final.

Síntesis

En consecuencia, se identifica la necesidad de diseñar, implementar y evaluar un sistema integrado de inteligencia artificial explicable que resuelva de manera unificada la ingesta y agregación de datos multisource, la estimación predictiva de valores esperados, la detección de desviaciones multivariadas, el ensamblaje de anomalías, la interpretación de factores mediante SHAP y la redacción de informes técnicos trazables mediante RAG con control factual.

1.2 Problema principal

¿En qué medida la implementación de un sistema integrado de inteligencia artificial basado en la predicción semanal del valor unitario FOB y exportado, la detección multivariable de anomalías, la explicabilidad y la generación automática de reportes trazables mejora la efectividad de la supervisión de operaciones agroexportadoras peruanas respecto del uso de componentes aislados?

Subproblemas

- 1. ¿Cómo integrar fuentes heterogéneas de datos reales de comercio exterior, mercado interno, macroeconomía, clima, logística y sanidad sin confundir granularidades ni inducir fuga de información temporal?
- 2. ¿Qué desempeño predictivo logran los algoritmos globales de regresión XGBoost y LightGBM para estimar el valor unitario FOB esperado de la siguiente semana frente a los baselines históricos y Elastic Net?
- 3. ¿Qué desempeño predictivo logran para estimar el volumen de exportación de la siguiente semana?
- 4. ¿Qué desempeño de detección obtiene el ensemble de Isolation Forest, Local Outlier Factor y ECOD frente a los detectores individuales en un conjunto de anomalías sintéticas controladas?
- 5. ¿De qué manera las explicaciones locales SHAP y el contexto de RAG mejoran la comprensión operativa de las alertas aduaneras?
- 6. ¿Cómo validar la consistencia numérica de los reportes narrativos autogenerados y garantizar el linaje inmutable de cada alerta desde el dato de origen?
- 7. ¿Qué mejora cuantitativa existe en la tasa de comprensión, usabilidad y tiempo de decisión de los analistas humanos al interactuar con el sistema integrado frente a componentes aislados?

1.3 Objetivos

1.3.1 Objetivo principal

Diseñar, implementar y evaluar un sistema integrado de inteligencia artificial explicable para predecir semanalmente el valor unitario FOB y el volumen de exportación, detectar anomalías multivariables, explicar las predicciones e interpretar las alertas mediante SHAP, y generar reportes trazables sustentados en evidencia documental estructurada para apoyar la supervisión analítica de operaciones agroexportadoras peruanas.

1.3.2 Objetivos específicos

- 1. Identificar, auditar, normalizar e integrar las fuentes de datos agroexportadores reales de SUNAT, BCRP y SISAP con proxies climáticos, logísticos y sanitarios.
- 2. Construir un dataset agroexportador integrado semanal a nivel de producto × mercado de destino × semana ISO con marcas metodológicas y sin fugas de información temporal.
- 3. Implementar y optimizar modelos globales GBDT (XGBoost/LightGBM) para predecir el valor unitario FOB de exportación de la siguiente semana (\$t) y evaluar su desempeño frente a baselines.
- 4. Implementar y optimizar modelos globales GBDT para predecir el volumen de exportación de la siguiente semana (\$t+1\$).
- 5. Implementar un ensemble unificado no supervisado de Isolation Forest, Local Outlier Factor y ECOD calibrado por percentiles para la detección de anomalías operativas.
- 6. Integrar explicaciones locales de Shapley (SHAP) basadas en TreeSHAP para justificar la contribución de variables en los modelos predictivos de las alertas.
- 7. Implementar un generador de reportes basado en arquitectura RAG y un LLM, incorporando un módulo validador factual que compare determinísticamente cifras textuales con la evidencia de datos.
- 8. Evaluar la efectividad del sistema integrado mediante experimentos de usabilidad (escala SUS, tiempo de decisión y tasa de acierto) y auditoría de hashes SHA-256 frente a componentes aislados.

1.4 Hipótesis de la investigación

1.4.1 Hipótesis general

La implementación de un sistema integrado de inteligencia artificial explicable, compuesto por predicción semanal de valor unitario FOB y volumen de exportación, detección multivariable de anomalías, explicabilidad SHAP, reportes RAG con validación factual y trazabilidad documental, mejora significativamente la efectividad de la supervisión analítica de operaciones agroexportadoras peruanas respecto del uso de componentes analíticos aislados.

1.4.2 Hipótesis nula (H0)

La implementación de un sistema integrado de inteligencia artificial explicable no produce una mejora significativa en la efectividad de la supervisión de operaciones agroexportadoras peruanas respecto del uso de componentes analíticos aislados, considerando rendimiento predictivo, detección y comprensión del usuario, tiempo de análisis y trazabilidad documental.

1.4.3 Hipótesis específicas

H1a. Los modelos globales XGBoost o LightGBM, entrenados sobre el dataset semanal producto-mercado-semana, presentan un error absoluto y significativamente menor que el mejor modelo base para predecir el valor unitario FOB de la siguiente semana.

H1b. Los modelos globales XGBoost o LightGBM, entrenados sobre el dataset semanal producto-mercado-semana, presentan un error logarítmico cuantil (RMSLE) significativamente menor que el mejor modelo base para predecir el volumen exportado de la siguiente semana.

H1c. El ensemble de Isolation Forest, Local Outlier Factor y ECOD, calibrado por percentiles y alimentado con residuos predictivos y variables agroexportadoras, presenta un F1-Score superior al promedio de sus detectores individuales en un conjunto experimental con anomalías controladas.

H1d. Las alertas acompañadas de explicaciones SHAP y reportes RAG trazables producen una mayor comprensión operativa y un menor tiempo de respuesta de usuarios evaluadores que las alertas presentadas únicamente mediante resultados técnicos aislados.

H1e. El módulo de trazabilidad basado en identificadores, metadatos y hashes SHA-256 incrementa la proporción de alertas cuyo proceso puede reconstruirse a partir de los registros de origen, el dataset versionado y el modelo utilizado hasta la explicación, la decisión humana y el reporte final.

1.5 Variables e indicadores

1.5.1 Variable independiente

- **Tipo de sistema de supervisión analítica (VI):**
 - *Nivel 1: Sistema integrado* (pipeline secuencial de 4 capas: predicción, ensemble PyOD, SHAP y RAG con validador y trazabilidad de hashes).
 - *Nivel 2: Componentes aislados* (salidas técnicas de predicción y scores sin contexto lingüístico ni linaje estructurado).

1.5.2 Variable dependiente

- **Efectividad de la supervisión analítica (VD):** evaluada en las dimensiones de rendimiento predictivo, rendimiento de detección, usabilidad subjetiva, tiempo de respuesta de diagnóstico y tasa de trazabilidad documental.

(La tabla de operacionalización detallada que vincula dimensiones, indicadores, escalas, técnicas e instrumentos se incorpora como anexo compilado "Matriz de Operacionalización").

1.6 Viabilidad de la investigación

1.6.1 Viabilidad técnica

El desarrollo del prototipo de software integrado es factible mediante el uso de librerías de código abierto y de amplia validación en la industria en Python (pandas, numpy, scikit-learn, XGBoost, LightGBM, PyOD, SHAP, sentence-transformers, Flask). El hardware requerido consiste en equipos de cómputo con CPU sin requerir costosas estaciones de trabajo con GPU.

1.6.2 Viabilidad operativa

El sistema operará bajo una modalidad de procesamiento por lotes (batch), compatible con la recolección semanal de registros de exportación de la industria agroexportadora peruana. Requiere una integración intrusiva en tiempo real con los sistemas de aduanas o ERPs empresariales privados, actuando como una herramienta analítica de auditoría interna y supervisión independiente "human-in-the-loop" (gobernanza de IA).

1.6.3 Viabilidad económica

El costo financiero del proyecto es mínimo al sustentarse en licencias de software libre y recursos informáticos ya disponibles. La descarga de microdatos de la SUNAT es gratuita. La factibilidad económica del sistema se fundamenta en su potencial para optimizar los tiempos de auditoría de las agencias de comercio exterior.

1.7 Justificación e importancia

1.7.1 Justificación teórica

El estudio aporta valor académico al integrar en una arquitectura única cuatro campos de la ciencia de la computación y la IA que suelen abordarse por la literatura: el modelamiento tabular GBDT global, los ensembles de detección no supervisada, la teoría de Shapley para interpretabilidad algorítmica restringidos por RAG para redacción técnica.

1.7.2 Justificación metodológica

La investigación formula un marco estructurado de auditoría del origen de los datos, clasificando formalmente las variables por su naturaleza (reagregada, proxy, sintética controlada) y forzando marcas de trazabilidad SHA-256. Esto mitiga el problema recurrente de opacidad y falta de replicabilidad experimental en tesis tecnológicas.

1.7.3 Justificación práctica

El prototipo provee a los supervisores aduaneros y gestores agroexportadores peruanos una interfaz de control analítico. El sistema traduce matrices de residuos y scores a reportes técnicos comprensibles con validación factual de cifras, facilitando la toma de decisiones basada en evidencias.

1.8 Alcance

- **Temático y Tecnológico:** Diseño, desarrollo experimental y evaluación de una arquitectura modular de cuatro capas (Predicción, Detección de Anomalías, Explicabilidad con TreeSHAP y Reporte con RAG/LLM) y un módulo registrador de trazabilidad con hashes SHA-256.
 - **Geográfico:** Microdatos de exportaciones agrícolas peruanas registradas en las aduanas nacionales, principalmente asociadas a las zonas productoras de La Libertad, Piura, Ica, Lambayeque y Arequipa.
 - **Productivo:** El núcleo experimental está acotado a palta (*avocado*), uva fresca (*grape*) y arándano (*blueberry*). El espárrago se conserva como producto secundario o de sensibilidad solo si se declara su menor cobertura y no se mezcla en conclusiones principales. Se excluye permanentemente cacao por falta de representatividad.
 - **Temporal:** Ventana continua desde **junio de 2018 hasta mayo de 2026**.
 - **Exclusiones:** No se implementará monitoreo de variables en tiempo real, control autónomo de despachos aduaneros, modelos de Deep Learning como propuesta principal ni integraciones funcionales con sistemas ERP privados de empresas particulares.
-

1.9 Línea, tipo y nivel de investigación

- **Línea de Investigación:** *Inteligencia Artificial y Aprendizaje Automático Aplicado* (línea principal) e *Ingeniería de Software y Gobernanza de TI* (línea secundaria) de la Escuela Profesional de Ingeniería de Sistemas de la UNSA.
 - **Tipo de Investigación:** Aplicada y tecnológica.
 - **Nivel de Investigación:** Explicativo y evaluativo, con un enfoque epistemológico post-positivista.
 - **Diseño de Investigación:** Cuasiexperimental (comparación de VI), longitudinal (análisis temporal 2018-2026) y comparativo (evaluación frente a bases de datos).
-

1.10 Técnicas e instrumentos de recolección de información

La investigación combina técnicas documentales, computacionales y evaluativas. Debido a que el objeto de estudio es un sistema integrado de inteligencia artificial explicable, la recolección de información no se limita a encuestas o revisión bibliográfica; también incluye artefactos de software, datasets, métricas, logs automáticos, pruebas de calidad y registros de interacción de usuarios.

1.10.1 Técnicas

Las técnicas utilizadas son:

1. **Análisis documental:** revisión de literatura científica, normativa, fuentes institucionales, documentación técnica y fuentes de datos disponibles.
2. **Experimentación computacional:** ejecución controlada de scripts de procesamiento, entrenamiento, detección de anomalías, explicabilidad y validación.
3. **Pruebas funcionales del sistema:** verificación de rutas, pantallas, endpoints, flujos de alerta, generación de reportes y registro de decisiones en el p
4. **Auditoría de trazabilidad:** comprobación del linaje de datos, modelos, alertas, explicaciones, reportes, hashes y versiones.
5. **Prueba controlada con usuarios:** evaluación comparativa entre condición integrada y condición aislada para medir comprensión, tiempo de decisión
6. **Evaluación mediante rúbricas:** valoración estructurada de reportes automáticos, completitud documental, consistencia numérica, fidelidad factual y evidencia.

1.10.2 Instrumentos

Tabla 1.3 — Técnicas e instrumentos de recolección de información

Técnica	Instrumento	Propósito	Fuente de evidencia	Resultado esperado
Análisis documental	Matriz de revisión bibliográfica y ficha de antecedentes	Identificar fundamentos teóricos, brechas, algoritmos y criterios de comparación	refs.bib , Capítulo II, fuentes MIDAGRI, SUNAT, BCRP, SISAP, Trade Map	Antecedentes depurados, marco teórico verificado
Análisis documental	Ficha de fuente de datos	Registrar origen, granularidad, periodo, licencia, ruta local y limitaciones de cada fuente	codex-revision/metadata/ , data/ , data-trademap/	Inventario de fuente real/proxy/sintético
Experimentación computacional	Scripts de ETL y preparación semanal	Construir dataset raw, bronze, silver, gold y features sin fuga temporal	src/parse_sunat_dbf.py , src/prepare_weekly_dataset.py , src/feature_engineering.py	Dataset semanal procesado, mercado-semana
Experimentación computacional	Scripts de entrenamiento y evaluación	Medir desempeño predictivo de FOB y volumen frente a baselines	src/module1_prediction.py , src/train_models.py , data/gold/prediction_features.parquet	Métricas MAE, RMSI, SMAPE y R²
Experimentación computacional	Scripts de detección de anomalías	Evaluar IF, LOF, ECOD y ensemble propuesto	src/module2_anomaly.py , data/gold/anomaly_features.parquet	Precision, Recall, F1, ROC-AUC y Precisión
Pruebas funcionales del sistema	Checklist de rutas y pantallas	Verificar que el prototipo ejecute login, dashboard, alertas, detalle, telemetría, configuración y usuarios	sistema-web-agro/frontend/src/pages/ , sistema-web-agro/backend/app.py	Evidencia funcional y endpoint
Pruebas funcionales del sistema	Capturas de pantalla documentadas	Registrar interfaz del prototipo y su relación con la tesis	sistema-web-agro/*/screen.png , placeholders docs/figures/	Figuras del prototipo, fuente y fecha
Auditoría de trazabilidad	Registro de hashes SHA-256 y UUID	Reconstruir dataset, modelo, alerta, explicación y reporte	src/module6_traceability.py , data/gold/traceability_log.json	Linaje reproducible
Auditoría de trazabilidad	Pruebas automatizadas de calidad y fuga	Confirmar reglas mínimas de calidad y prevención de fuga temporal	tests/data_quality/test_quality.py , tests/leakage/test_leakage.py	Pruebas aprobadas, reportes/tesis/data_quality/
Prueba controlada con usuarios	Cuestionario SUS y escala Likert de comprensión	Medir usabilidad percibida, claridad y utilidad de explicaciones	docs/05-a1-anexo-usabilidad.md , instrumento final pendiente	Puntajes SUS, comprensión, utilidad
Prueba controlada con usuarios	Registro automático de tiempo y decisión	Comparar condición integrada frente a condición aislada	sistema-web-agro/frontend/src/pages/Telemetry.jsx , backend de decisiones	Tiempo de decisión, correcta y condición experimental
Evaluación mediante rúbricas	Rúbrica de reportes automáticos	Validar completitud, coherencia, fidelidad factual y consistencia numérica	src/module5_validation.py , data/gold/validation_metrics.json , reports/audits/	Reportes aprobados con causas

Técnica	Instrumento	Propósito	Fuente de evidencia	Resultado esperado
Evaluación mediante rúbricas	Matriz de aceptación de evidencia	Clasificar artefactos como preliminares, candidatos o finales	<code>docs/tesis/00-checklist-maestro.md</code> , <code>docs/tesis/11-documento-maestro-correccion.md</code>	Estado verificable de

1.10.3 Criterios de uso de instrumentos

Un instrumento solo se considera válido si deja evidencia reproducible. Para los instrumentos computacionales, la evidencia mínima incluye archivo fuer ejecutado, salida esperada, fecha, commit y hash cuando corresponda. Para los instrumentos con usuarios, la evidencia mínima incluye cor anonimización, perfil del participante, condición experimental, tarea asignada, tiempo de decisión, respuesta y escala aplicada.

1.11 Cronograma de actividades

El cronograma se organiza desde el estado actual del proyecto hasta la primera semana de diciembre de 2026, fecha prevista para la sustentación de tes podrán ajustarse por calendario académico, disponibilidad del asesor o requisitos administrativos de la escuela, pero la secuencia metodológica debe cierre documental, cierre de datos, experimento, redacción final, revisión, depósito y sustentación.

Tabla 1.2 — Cronograma de actividades hasta sustentación

Fase	Periodo	Actividades principales	Producto verificable
F1. Ordenamiento documental	22-30 junio 2026	Completar Capítulos II y III, depurar antecedentes nacionales, consolidar placeholders de figuras y capturas	<code>docs/02-20</code> , <code>02-21</code> , <code>02-22</code> , <code>02-30</code> , tesis monolítica regenerada
F2. Cierre de datos	1-15 julio 2026	Congelar dataset gold, registrar hashes, validar cobertura, resolver duplicados funcionales y documentar fuentes proxy	<code>data/gold/</code> , <code>codex-revision/reporte-calidad-datos.md</code> , reporte de dataset
F3. Pruebas de calidad y fuga	16-31 julio 2026	Ejecutar pruebas de calidad, fuga temporal, escaladores, codificadores y partición temporal	<code>reports/tesis/data-quality/leakage-tests/</code>
F4. Entrenamiento predictivo	1-20 agosto 2026	Entrenar baselines, XGBoost y LightGBM para FOB y volumen; registrar hiperparámetros y residuos fuera de muestra	<code>reports/tesis/experiments/<run_id>/</code>
F5. Validación de anomalías	21 agosto-5 septiembre 2026	Ejecutar IF, LOF, ECOD, ensemble, anomalías sintéticas y métricas por tipo	Métricas PR-AUC, F1, Recall, Precision@k
F6. Explicabilidad y reportes	6-20 septiembre 2026	Generar SHAP, reportes RAG, validación factual y comparación con plantilla determinística	<code>data/gold/local_explanations.json</code> , <code>validation_metrics.json</code> , reportes auditados
F7. Prototipo y capturas finales	21 septiembre-5 octubre 2026	Verificar <code>sistema-web-agro</code> , capturar pantallas finales, insertar figuras y actualizar anexos	<code>docs/figures/</code> , anexos y evidencia visual
F8. Prueba controlada con usuarios	6-20 octubre 2026	Ejecutar estudio A/B, consentimiento, anonimización, SUS, tiempos y decisiones	<code>reports/tesis/user-study/</code>
F9. Capítulo IV final	21 octubre-5 noviembre 2026	Reemplazar resultados preliminares por resultados reproducibles, contrastar hipótesis y cerrar discusión	Capítulo IV actualizado
F10. Capítulo V y conclusiones	6-15 noviembre 2026	Redactar conclusiones, limitaciones, recomendaciones y trabajos futuros según resultados finales	Capítulo V y recomendaciones
F11. Revisión integral	16-22 noviembre 2026	Revisar formato, APA, citas, tablas, figuras, anexos, índices y coherencia de hipótesis	Borrador final revisado
F12. Compilación y depósito	23-30 noviembre 2026	Generar PDF/DOCX final, verificar maquetación, firmar anexos y preparar entrega administrativa	<code>output/tesis_final.pdf</code> , <code>output/tesis_final.docx</code>

Fase	Periodo	Actividades principales	Producto verificable
F13. Sustentación	Primera semana de diciembre 2026	Presentación, defensa, demostración del prototipo y respuesta a observaciones	Sustentación de tesis

Hito final: sustentación de tesis durante la primera semana de diciembre de 2026.

CAPÍTULO II: MARCO TEÓRICO

2.1 Antecedentes de la Investigación

2.1.1 Antecedentes Internacionales

1. Kadir et al. (2025) — *AuditCopilot: Leveraging LLMs for fraud detection in double-entry bookkeeping*

- **Objetivo:** Desarrollar un sistema de auditoría contable que integre modelos de lenguaje con técnicas de detección de anomalías para explicar transacciones irregulares en lenguaje natural.
- **Datos:** Corpus experimental de asientos contables sintéticos y transacciones financieras de doble entrada.
- **Método:** Pipeline secuencial compuesto por detección algorítmica de outliers, inyección de contexto en prompts estructurados y generación de explicativos mediante un LLM de gran escala.
- **Resultados Reales:** Incremento en la tasa de detección de fraudes y reducción del tiempo promedio de revisión por parte de los auditores humanos validado mediante pruebas cualitativas de usabilidad.
- **Limitación:** El modelado se restringe a datos contables tradicionales de doble entrada y no incorpora variables exógenas como el clima, precios mayorista o datos logísticos complejos.
- **Relación con la Tesis:** Aporta el fundamento metodológico para combinar la detección algorítmica con la generación narrativa RAG. La tesis traslada esta arquitectura al dominio de operaciones agroexportadoras peruanas en el Perú.

2. Park (2024) — *LLMs for anomaly validation and report generation in financial systems*

- **Objetivo:** Diseñar un framework multi-agente basado en LLMs especializados para la validación y documentación de alertas de anomalías en mercados financieros de alta frecuencia.
- **Datos:** Series temporales financieras diarias del índice S&P 500 y noticias comerciales asociadas.
- **Método:** División del procesamiento en cuatro agentes inteligentes: conversión de datos, análisis estadístico, verificación cruzada documental y generación/consolidación del reporte.
- **Resultados Reales:** Reducción de falsos positivos en las alarmas mediante el filtrado semántico y la verificación de noticias, superando el rendimiento de un agente genérico único.
- **Limitación:** El sistema opera en mercados financieros de alta frecuencia y requiere acceso constante a noticias de mercado en tiempo real, lo que implica un costo computacional.
- **Relación con la Tesis:** Sustenta la separación de roles entre los modelos matemáticos cuantitativos de detección y la capa de lenguaje. La tesis propone una restricción de que el LLM no es el detector, sino el redactor fundamentado en evidencias.

3. Almalki & Masud (2025) — *Financial fraud detection using explainable AI and stacking ensemble methods*

- **Objetivo:** Diseñar un framework de detección de fraude en transacciones empresariales combinando modelos de ensemble de gradiente y explicaciones post-hoc.
- **Datos:** Datasets tabulares corporativos de transacciones financieras y estados contables.
- **Método:** Stacking Ensemble de clasificadores basados en árboles (XGBoost y LightGBM) acoplado a un motor de atribución local SHAP para generar justificación de las alertas.
- **Resultados Reales:** Obtención de un PR-AUC superior a 0.90 y alta estabilidad en el SHAP Stability Index, garantizando explicaciones consistentes ante perturbaciones.
- **Limitación:** El enfoque se limita a la detección estática en bases de datos contables sin considerar la dimensión de series temporales dinámicas y la generación automática de informes en lenguaje natural.

- **Relación con la Tesis:** Valida la superioridad de la combinación GBDT + SHAP en datos tabulares y sustenta la arquitectura de la Capa 1 y Capa propuesta agroexportadora.

4. Grinsztajn et al. (2022) — *Why do tree-based models still outperform deep learning on tabular data?*

- **Objetivo:** Analizar y comparar el rendimiento de los modelos basados en árboles (GBDT) frente a modelos de aprendizaje profundo (Deep Learning) especializados para datos tabulares.
- **Datos:** 45 datasets tabulares reales y sintéticos de diversos sectores económicos con muestras menores a 50,000 registros.
- **Método:** Evaluación empírica sistemática de XGBoost, LightGBM y CatBoost frente a FT-Transformer, TabNet y perceptrones multicapa (MLP) mediante optimización de hiperparámetros.
- **Resultados Reales:** Los modelos GBDT superaron a las redes neuronales en el 95% de los escenarios tabulares evaluados. Se identificaron tres factores de éxito: robustez ante variables no informativas, falta de invarianza ante rotaciones de datos y discontinuidades en las fronteras de decisión.
- **Limitación:** El estudio no aborda el modelamiento de secuencias temporales autoregresivas complejas, limitándose a problemas de clasificación estándar.
- **Relación con la Tesis:** Justifica teórica y empíricamente la decisión de seleccionar XGBoost y LightGBM como los regresores globales de la tesis agroexportadora en lugar de modelos Deep Learning tabulares.

2.1.2 Antecedentes nacionales y evidencia sectorial verificable

Durante la revisión documental se identificó que algunos antecedentes nacionales usados en borradores previos no contaban todavía con trazabilidad suficiente para sostener autores, año, universidad, muestra y resultados cuantitativos. Por esa razón, esta versión no mantiene afirmaciones no verificables como reducción de mermas, mejora porcentual de pronóstico o resultados de sensores IoT si no existe documento original localizado. La sección nacional se sustenta con fuentes institucionales verificables y con una lista explícita de antecedentes académicos pendientes de sustitución.

1. MIDAGRI (2026) — Reporte sectorial de agroexportaciones peruanas

2. **Objetivo documental:** Caracterizar el crecimiento reciente de la agroexportación peruana y ubicar la relevancia económica del sector.
3. **Datos:** Información institucional de ventas agroexportadoras y productos representativos reportada por el Ministerio de Desarrollo Agrario y Riego.
4. **Aporte a la tesis:** Sustenta el contexto económico que justifica priorizar productos agroexportadores de alta participación, especialmente palta, uva y arándano.
5. **Limitación:** No entrega microdatos transaccionales ni permite por sí sola evaluar modelos predictivos o detectores de anomalías.

6. SUNAT/ADUANET (2026) — Bases y estadísticas aduaneras

7. **Objetivo documental:** Proveer registros o series de comercio exterior que permiten reconstruir valor FOB, peso, subpartida, país de destino y periodo de exportación.
8. **Datos usados en el proyecto:** Descargas locales en `data/sunat/raw_downloads/`, `data/sunat/x23290326.DBF`, `data/raw/exports_raw.csv` y capas procesadas en `data/bronze/`, `data/silver/` y `data/gold/`.
9. **Aporte a la tesis:** Constituye la fuente primaria para la unidad producto-mercado-semana y para las variables de valor FOB, volumen y destino.
10. **Limitación:** Las descargas locales completas disponibles se concentran en ventanas 2026; la cobertura 2018-2025 requiere documentar si provienen de fuentes reales consolidadas, fuentes agregadas o reconstrucción complementaria.

11. BCRP (2018-2026) — Tipo de cambio PEN/USD

12. **Objetivo documental:** Incorporar una variable macroeconómica exógena para normalizar o contextualizar el comportamiento de valor exportado.
13. **Datos usados en el proyecto:** `data/bcrp/exchange_rates_cache.json` y `data/downloads/bcrp_tipo_cambio.csv`.
14. **Aporte a la tesis:** Permite incluir contexto macroeconómico en los modelos de predicción y detectar semanas donde una desviación comercial puede estar asociada a cambios cambiarios.
15. **Limitación:** La frecuencia mensual debe mapearse cuidadosamente a semana ISO sin usar información posterior a la semana objetivo.

16. SISAP/MIDAGRI y Trade Map — Contexto de mercado interno e internacional

17. **Objetivo documental:** Incorporar referencias externas de precios, volúmenes y mercados para contextualizar exportaciones por producto.
18. **Datos usados en el proyecto:** Manifiestos SISAP en `codex-revision/metadata/` y archivos Trade Map en `data-trademap/`.
19. **Aporte a la tesis:** Funcionan como fuentes de contraste y contexto, no como sustituto del registro aduanero.
20. **Limitación:** Operan con granularidades distintas al embarque aduanero; por tanto, su integración se declara como variable agregada o proxy.

21. **SENAMHI/NASA POWER y proxies climáticos**
22. **Objetivo documental:** Proveer contexto climático regional para productos perecederos.
23. **Datos usados en el proyecto:** Variables climáticas presentes en `data/dataset_real_v1.csv` , `data/silver/exports_clean.parquet` y `data/gold/weekly_product_market.parquet` .
24. **Aporte a la tesis:** Permiten evaluar si las semanas con mayor estrés climático agregado coinciden con cambios de volumen, valor unitario o anomalías
25. **Limitación:** No prueban causalidad logística ni falla de cadena de frío por embarque; solo aportan contexto agregado.

Antecedentes académicos nacionales pendientes de sustitución. Los trabajos titulados provisionalmente "Modelos GBDT y clima para agroexportadora peruana" y "Detección de anomalías IoT en cadenas de frío de perecederos" se retiran como evidencia académica cerrada: documento original, repositorio, autores, institución, año, muestra y resultados. Si no se verifica su existencia, deberán reemplazarse por tesis o artículos encontrados en RENATI, Alicia/CONCYTEC, repositorios universitarios peruanos o revistas indizadas.

Antecedente preliminar	Acción requerida	Estado en esta versión
Mendoza & Huamán (2024)	Localizar documento original y verificar resultados atribuidos	No usado como evidencia científica
Chávez & Díaz (2023)	Localizar documento original y verificar reducción de mermas atribuida	No usado como evidencia científica
Estudios nacionales de cadena de frío	Sustituir por documentos reales con repositorio y metodología verificable	Pendiente
Estudios nacionales de forecasting agroexportador	Sustituir por documentos reales con datos y métricas reproducibles	Pendiente

2.1.3 Antecedentes Metodológicos

1. **Han et al. (2022) — ADBench: Anomaly detection benchmark**
- **Objetivo:** Evaluar sistemática y exhaustivamente algoritmos de detección de anomalías bajo múltiples niveles de supervisión.
 - **Datos:** 57 conjuntos de datos tabulares reales y sintéticos con inyección controlada de ruido y anomalías de distinta dimensionalidad.
 - **Método:** Comparativa de 30 algoritmos de detección (incluyendo Isolation Forest, LOF, ECOD, One-Class SVM y Autoencoders).
 - **Resultados Reales:** Confirmación de que ningún detector es superior en todos los escenarios; sin embargo, los enfoques de ensemble unificados reducen el riesgo de sobreajuste y logran mayor estabilidad y robustez general ante cambios distribucionales.
 - **Limitación:** La mayoría de los datasets evaluados son estáticos y no corresponden a series temporales operacionales estructuradas.
 - **Relación con la Tesis:** Provee el soporte metodológico y la justificación teórica para construir un ensemble unificado no supervisado en la Capa del sistema.
2. **Lundberg & Lee (2017) — A unified approach to interpreting model predictions**
- **Objetivo:** Desarrollar un marco unificado con consistencia axiomática para la atribución de variables locales en modelos de aprendizaje automático.
 - **Datos:** Evaluado en diversos datasets tabulares y de imágenes.
 - **Método:** Formulación de los valores de Shapley (SHAP) a partir de la teoría de juegos cooperativos, garantizando propiedades de eficiencia, sim aditividad y consistencia.
 - **Resultados Reales:** Demostración de que SHAP unifica métodos previos (LIME, DeepLIFT) resolviendo sus inconsistencias matemáticas locales.
 - **Limitación:** El cálculo exacto tiene complejidad exponencial en función del número de características.
 - **Relación con la Tesis:** Sustenta el uso del componente de explicabilidad (Capa 3) del sistema, aplicando la optimización TreeSHAP para modelos de decisión.
3. **Lewis et al. (2020) — Retrieval-augmented generation for knowledge-intensive NLP tasks**
- **Objetivo:** Combinar modelos generativos de lenguaje con sistemas de recuperación de información externa para resolver tareas intensivas en conocimiento sin requerir reentrenamiento masivo.
 - **Datos:** Wikipedia dump e índices vectoriales de preguntas y respuestas.
 - **Método:** Arquitectura RAG que recupera fragmentos relevantes a partir de una consulta y los inyecta en el contexto de entrada de un modelo de secuencia (BART/T5).
 - **Resultados Reales:** Reducción de la tasa de alucinación semántica y mejora de la precisión factual en la generación de textos.

- **Limitación:** Sensible a la calidad y consistencia lógica de la base de conocimiento indexada.
- **Relación con la Tesis:** Define la estructura de la Capa 4 para generar reportes fundamentados exclusivamente en la base documental del corpus estructurados.

2.1.4 Síntesis crítica

La revisión de antecedentes revela una brecha metodológica y tecnológica: los trabajos analíticos en agroexportación peruana se han limitado a puntuales de volumen o a detección aislada de fallas logísticas de frío mediante sensores IoT. Por otra parte, las propuestas metodológicas de IA automatización de reportes (AuditCopilot, AuditMAI) se restringen a dominios contables y financieros estáticos. **No existe en la literatura revisada integrado que unifique la predicción de valor unitario y volumen semanal, la detección de anomalías mediante un ensemble calibrado por explicabilidad con SHAP y la redacción de informes con RAG factual** en el dominio agroexportador peruano.

ESTADO DEL ARTE

2.2 Estado del Arte

El estado del arte de la investigación se estructura a partir de los siguientes debates científicos de la disciplina:

2.2.1 Modelos GBDT frente a Aprendizaje Profundo Tabular

El modelado de datos estructurados empresariales se caracteriza por un debate continuo entre el uso de algoritmos basados en árboles (GBDT) y la a arquitecturas de aprendizaje profundo (como Transformers tabulares o TabNet). Trabajos como FT-Transformer (Gorishniy et al., 2021) y TabNet (Arik & proponen que los mecanismos de atención capturan relaciones de alta dimensionalidad. Sin embargo, la evidencia sistemática aportada por Grinsztajr demuestra que para conjuntos de datos empresariales de tamaño moderado (de 50,000\$ filas), los GBDT (XGBoost y LightGBM) superan a las redes n precisión, velocidad de entrenamiento y robustez ante características no informativas. La presente tesis adopta esta posición, utilizando XGBoost y Ligi base predictiva de la propuesta.

2.2.2 Detector Único frente a Ensemble de Anomalías

En la detección de outliers, el debate gira en torno a si un único detector optimizado (como Isolation Forest o LOF) es suficiente frente a un ens algoritmo. La investigación de Han et al. (2022) en ADBench concluye que ningún detector domina todos los patrones de desviación, ya que Isolation F en outliers globales por aislamiento espacial, LOF en anomalías locales por densidad de vecindario, y ECOD en colas de distribuciones estadísticas. En c el diseño de ensembles calibrados por percentiles es la alternativa recomendada en el estado del arte para garantizar estabilidad ante patrones desconocidos, enfoque que es implementado en este prototipo.

2.2.3 Predicción Esperada y Residuos

La detección tradicional de anomalías suele aplicarse directamente sobre los datos observados en bruto. No obstante, el estado del arte de la supervisi sugiere que es más efectivo modelar las desviaciones operativas calculando los **residuos predictivos** (la diferencia entre el valor real observado y el va estimado por un modelo predictivo robusto). El cálculo de residuos robustos escalados mediante la desviación absoluta de la mediana (MAD) móvil de permite desacoplar los ciclos estacionales naturales de las anomalías operativas genuinas.

2.2.4 SHAP y Explicabilidad

La interpretabilidad algorítmica opone a los métodos agnósticos locales como LIME (Ribeiro et al., 2016) frente a formulaciones de la teoría de juegos (Lundberg & Lee, 2017). Mientras que LIME construye modelos lineales locales que pueden resultar inestables ante pequeñas perturbaciones de garantiza consistencia axiomática e invarianza, asegurando que si una variable incrementa su impacto, su valor asignado no disminuye. La formulaci permite el cálculo exacto de las atribuciones locales en tiempo polinómico sobre modelos GBDT, posicionándolo como el estándar de explicabilidad pos

2.2.5 LLM como Detector frente a LLM como Redactor

La emergencia de los modelos de lenguaje de gran tamaño (LLMs) ha motivado propuestas para utilizarlos directamente como clasificadores o d anomalías sobre datos tabulares serializados a texto (Hegselmann et al., 2023). No obstante, el estado del arte advierte sobre el riesgo crítico de i intrínsecas y numéricas en tareas lógicas cuantitativas (Maynez et al., 2026). Por ello, el consenso metodológico orienta el uso del LLM exclusivamente redacción formal de informes, restringiendo su entrada a un prompt estructurado de evidencias provenientes de modelos matemáticos validados.

2.2.6 RAG y Control Factual

La generación de reportes corporativos mediante LLMs requiere mitigar alucinaciones y asegurar consistencia. La arquitectura RAG (Retrieva Generation) (Lewis et al., 2020) resuelve esta brecha al alimentar el prompt con documentos y evidencias recuperados. Sin embargo, para entornos de requiere una capa complementaria de **validación factual determinista** que extraiga de forma automatizada las cifras textuales generadas por el i contraste contra el objeto JSON de evidencias, aplicando tolerancias estrictas por redondeo y cayendo en plantillas predefinidas ante fallos reiterados.

2.2.7 Arquitecturas Aisladas frente a Integradas

La literatura científica se encuentra fragmentada: existen sistemas que resuelven forecasting temporal de precios, otros orientados a la detección o herramientas independientes de explicabilidad o reporte. La brecha de investigación radica en la falta de arquitecturas integradas y secuenciales que conforma estructurada los componentes analíticos, asegurando el linaje desde el microdato transaccional hasta el informe técnico de auditoría.

2.2.8 Gobernanza de IA y Trazabilidad

El despliegue de sistemas inteligentes se enfrenta a exigencias de gobernanza corporativa y rendición de cuentas, reguladas por marcos nacionales con Supremo N° 115-2025-PCM (Gobernanza y Supervisión Humana en Perú) y metodologías internacionales como el NIST AI Risk Management Framework y las directrices de la Resolución SBS N° 053-2023 para riesgos de modelos. El estado del arte exige que cada alerta sea reproducible mediante marcas identificadores únicos y firmas SHA-256 de todas las fases del procesamiento.

2.2.9 Brecha específica que aborda la tesis

La revisión anterior permite delimitar una brecha precisa: los trabajos y herramientas existentes suelen resolver de forma separada el pronóstico, la anomalías, la explicabilidad, la generación de reportes o la trazabilidad. En cambio, el problema de supervisión analítica agroexportadora requiere un auditable, porque una alerta solo es útil si puede reconstruirse desde el dato de origen hasta la decisión humana.

Bloque del estado del arte	Solución dominante	Brecha persistente	Decisión de esta tesis
Predicción tabular	GBDT, modelos estadísticos y redes tabulares	Bajo acoplamiento con anomalías y reportes	Usar XGBoost/LightGBM como estimadores globales FOB y volumen
Anomalías	Detectores individuales o benchmarks genéricos	Sensibilidad al tipo de anomalía y umbral	Ensemble IF + LOF + ECOD calibrado por percentiles
Explicabilidad	SHAP/LIME como análisis post-hoc	Explicaciones no siempre llegan al usuario final	Injectar top-k SHAP en la alerta y el reporte
Reportes LLM	Redacción flexible de texto	Riesgo de alucinación numérica y factual	RAG restringido + validador determinístico
Gobernanza	Model cards, datasheets y auditoría	Trazabilidad fragmentada entre archivos	Hashes SHA-256, UUID y registro de linaje por alerta
Agroexportación peruana	Reportes sectoriales y fuentes públicas	Granularidades heterogéneas y proxies	Dataset semanal producto-mercado-semana con ma origen

2.2.10 Implicancia para el diseño metodológico

El diseño del Capítulo III adopta tres principios derivados del estado del arte:

- Modelo antes que alerta:** la anomalía se interpreta como desviación respecto de un valor esperado, no como simple valor extremo observado.
- Explicación antes que automatización:** el sistema apoya la decisión humana y no ejecuta bloqueos automáticos ni sanciones.
- Evidencia antes que narrativa:** el reporte automático solo es aceptable si sus cifras y afirmaciones pueden rastrearse a datos estructurados, documentos recuperados o logs de ejecución.

Cuando una fuente no tiene granularidad de embarque, se incorpora como contexto agregado o proxy y se prohíbe interpretarla como causa directa operativa. Esta regla es central para mantener consistencia entre el alcance de los datos disponibles y las afirmaciones de la tesis.

MARCO CONCEPTUAL

2.3 Marco Conceptual

2.3.1 Operación Agroexportadora

Transacción comercial de exportación de bienes agrícolas perecederos, regulada por la SUNAT, que abarca variables de volumen (peso neto, peso comercial aduanero (FOB), subpartida arancelaria a 10 dígitos (HS code), país de destino y exportador (RUC).

2.3.2 Supervisión Analítica

Proceso de auditoría interna y monitoreo de las operaciones de comercio exterior orientado a identificar desviaciones operativas, comerciales comparando los registros reales contra líneas base o comportamientos esperados.

2.3.3 Valor Unitario FOB de Exportación

Indicador comercial derivado que mide el valor promedio obtenido por kilogramo de producto FOB declarado en la aduana de salida:

$$\text{fob_unit_value_usd_kg} = \frac{\text{total_fob_usd}}{\text{total_net_weight_kg}}$$

No equivale conceptualmente al precio internacional de venta minorista en destino, puesto que incorpora costos locales, empaque y contratos aduanero

2.3.4 Granularidad Temporal Semanal

Nivel de agregación cronológica adoptado en el dataset analítico, estructurado a nivel de producto × mercado × semana ISO (lunes a domingo), para las micro-transacciones individuales de SUNAT se acumulen semanalmente para coincidir con la frecuencia de actualización de variables de mercado y cl

2.3.5 Data Leakage (Fuga de Información)

Fallo metodológico en el entrenamiento de modelos de series temporales en el cual información del futuro ($t+1$ o posterior) se filtra hacia el características del pasado (t). Se previene implementando un desplazamiento temporal estricto (`shift(1)`) en todas las rolling windows e imputacione

2.3.6 Gradient Boosting Decision Trees (GBDT)

Familia de algoritmos de aprendizaje automático supervisado que optimizan de forma secuencial una función de pérdida agregando árboles de c corregir los residuos de predicción previos mediante descenso de gradiente. Algoritmos principales: XGBoost y LightGBM.

2.3.7 Residuo Predictivo Robust-Z

Desviación del valor real observado en $t+1$ respecto de la estimación del modelo predictivo, normalizado de forma robusta utilizando la media (Desviación Absoluta de la Mediana) de una ventana móvil de 13 semanas por serie temporal para capturar anomalías genuinas aisladas del ruido estacío

2.3.8 Ensemble no Supervisado PyOD

Modelo unificado compuesto por Isolation Forest, Local Outlier Factor (LOF) y ECOD (Empirical Cumulative Distribution Outlier Detection). Sus scores in unifican mediante escalamiento Min-Max calibrado en entrenamiento, calculando el score final del ensemble como el promedio simple de los p anomalía.

2.3.9 Explicabilidad Local Post-Hoc con SHAP

Método de atribución local basado en la teoría de juegos cooperativos que calcula los valores de Shapley para medir el impacto marginal cuantitativo (a cada variable predictora en la desviación de la estimación del modelo respecto de su valor esperado promedio.

2.3.10 Retrieval-Augmented Generation (RAG)

Arquitectura de procesamiento de lenguaje natural que inyecta contexto documental e histórico verificado (recuperado de una base de conocimier búsqueda híbrida BM25 y embeddings) directamente en el prompt del LLM para restringir la redacción narrativa del reporte y evitar alucinaciones extrín

2.3.11 Trazabilidad de Modelos y Linaje de Datos

Capacidad de documentar y reconstruir de extremo a extremo el flujo de procesamiento de una alerta. Se garantiza mediante el registro inmutable de r configuración, identificadores UUIDv4 para cada fase y hashes SHA-256 de los datasets y modelos entrenados.

2.3.12 Dato real observado, dato agregado, proxy y dato sintético

Para evitar ambigüedad metodológica, esta tesis distingue cuatro tipos de evidencia:

Tipo	Definición	Ejemplo en el proyecto	Uso permitido
Real observado	Registro directamente asociado a una operación o fuente primaria	FOB, peso, destino y fecha derivados de SUNAT/ADUANET o dataset real local	Entrenamiento, validación y caracterización
Real agregado	Serie institucional agregada sin granularidad de embarque	Tipo de cambio BCRP, precios SISAP/MIDAGRI, series Trade Map	Contexto y variables exógenas
Proxy documentado	Aproximación razonable cuando no existe medición directa por embarque	Clima regional, días logísticos agregados, alertas sanitarias agregadas	Contexto explicativo no cuantitativo
Sintético controlado	Dato generado para simulación, balanceo o inyección experimental	Alertas semilla, anomalías inyectadas, datos de interfaz	Validación funcional o experimental controlado

Un proxy no demuestra causa empresarial real; solo aporta contexto para el modelo y para la interpretación del analista.

2.3.13 Resultado preliminar y resultado definitivo

Un resultado es **preliminar** cuando proviene de datos semilla, muestras pequeñas, corridas exploratorias o artefactos sin registro completo de datos, configuración, semilla y hash. Un resultado es **definitivo** únicamente cuando puede reproducirse con un comando documentado, sobre un dataset verificado, con una partición temporal congelada y salidas verificables.

2.3.14 Placeholder de figura o evidencia visual

Cuando una figura, diagrama o captura de pantalla todavía no existe como PNG/SVG/PDF insertable, el documento debe conservar un placeholder. El placeholder debe indicar: código de figura, título, archivo esperado, fuente de generación, contenido visual requerido y criterio de aceptación. Este criterio debe estar en el índice de figuras prometa artefactos que no están disponibles.

2.3.15 Supervisión analítica frente a supervisión operativa causal

La tesis emplea el término **supervisión analítica** para referirse al apoyo computacional en la identificación, explicación y documentación de desviaciones operativas y causalidad operativa directa cuando los datos disponibles son semanales, agregados o proxies. Las referencias a logística, clima, sanidad o calidad sirven como contexto analítico salvo que exista evidencia directa por embarque.

CAPÍTULO III: ELABORACIÓN DE LA PROPUESTA

3.1 Generalidades

3.1.1 Propósito

El propósito del sistema inteligente de supervisión agroexportadora es proveer una plataforma unificada para detectar desviaciones operativas y de exportaciones peruanas de palta, uva y arándano. El sistema apoya a los encargados de control y analistas en la toma de decisiones informadas, estimación de valores esperados, detección de anomalías multivariantes, explicaciones locales SHAP y generación automática de reportes técnicos trazables.

3.1.2 Usuarios del Sistema

- 1. **Analista de Control Operativo:** Revisa alertas, explora las variables incidentes mediante SHAP e inicia solicitudes de auditoría.
- 2. **Supervisor de Operaciones / Auditor Interno:** Encargado de la firma de conformidad de los reportes. Valida y autoriza acciones correctivas.
- 3. **Administrador de Datos / Ingeniero de ML:** Monitorea la calidad de datos, el linaje, el ajuste de los modelos y el reentrenamiento.
- 4. **Investigador / Usuario Académico:** Analiza patrones históricos de mermas, clima o comportamiento de mercado agregados.

3.1.3 Entradas

- Registros transaccionales de aduanas parseados de SUNAT/ADUANET (formato DBF/CSV).
- Series de tiempo diarias y mensuales del tipo de cambio PEN/USD de la API o caches de BCRP.
- Series de tiempo mensuales de precios y volúmenes mayoristas nacionales de SISAP (MIDAGRI).
- Proxies climáticos semanales de temperatura, humedad y lluvias acumuladas de NASA POWER.
- Proxies de alertas fitosanitarias mensuales de SENASA y la FDA.
- Configuraciones en YAML para productos arancelarios, modelos e inyección de anomalías.

3.1.4 Salidas

- Predicciones puntuales de valor unitario FOB y volumen exportado para la semana \$t+1\$.
- Scores consolidados de anomalías y alertas clasificadas por severidad (`BAJA` , `MEDIA` , `ALTA`).
- Visualizaciones y mapas de atribución locales SHAP (PNG/SVG) de las variables predictivas.
- Informes narrativos en markdown validados factual y numéricamente (con linaje SHA-256).
- Base de datos de auditoría de trazabilidad en JSON/DuckDB.
- Dashboard interactivo web de visualización en Streamlit/Flask.

3.1.5 Requisitos Funcionales

- **RF-01 (Importar Datos):** Permitir la ingesta de archivos DBF, CSV y Parquet de las fuentes de origen.
- **RF-02 (Validar Datos):** Verificar tipos de datos, códigos arancelarios válidos a 10 dígitos y países normalizados ISO alfa-3.
- **RF-03 (Normalizar y Anonimizar):** Homologar escalas de peso (kg) y valor (USD), y anonimizar exportadores con hashes SHA-256 salteados.
- **RF-04 (Agregar Semanalmente):** Agrupar y consolidar transacciones por combinación `producto × mercado × semana ISO` .
- **RF-05 (Entrenar Modelos):** Ajustar de forma global algoritmos XGBoost y LightGBM con búsqueda de hiperparámetros en Optuna.
- **RF-06 (Predecir FOB y Volumen):** Generar las estimaciones puntuales de valor unitario FOB y volumen para la semana \$t+1\$.
- **RF-07 (Detectar Anomalías):** Calcular los percentiles de Isolation Forest, LOF y ECOD, y generar alertas si se cruzan los umbrales.
- **RF-08 (Explicar con SHAP):** Estimar las contribuciones locales TreeSHAP de las variables predictoras sobre la desviación de la alerta.
- **RF-09 (Recuperar Contexto):** Buscar y recuperar fragmentos semánticos en el corpus RAG mediante indexado híbrido (BM25 y embeddings).
- **RF-10 (Reportar con LLM):** Generar el reporte en markdown estructurado inyectando evidencias cuantitativas y textos recuperados.
- **RF-11 (Validar Reporte):** Analizar sintácticamente el texto del reporte y rechazarlo ante discrepancias numéricas superiores al 0.5%.
- **RF-12 (Consultar Trazabilidad):** Permitir la reconstrucción de la alerta ingresando su identificador UUID (`alert_id`).
- **RF-13 (Revisar Alertas):** Proveer filtros en la interfaz por producto, mercado, semana y nivel de severidad.
- **RF-14 (Exportar Resultados):** Permitir la descarga de reportes markdown firmados y tablas de métricas del pipeline.

3.1.6 Requisitos No Funcionales

- **Reproducibilidad:** Fijación de semillas aleatorias globales (`42`) y secundarias en todos los modelos e inyección de datos.
- **Auditabilidad:** Inmutabilidad mediante hashes SHA-256 registrados para cada entrada de datos, configuraciones, modelos y salidas.
- **Rendimiento:** Tiempos de inferencia combinada por registro en la escala de milisegundos en CPU de uso general.
- **Modularidad:** Arquitectura modular monolítica desacoplada mediante scripts independientes para ingesta, modelamiento y reporte.
- **Usabilidad:** Interfaz interactiva fluida con directrices estéticas premium (vibrant dark mode y visualizaciones simplificadas).
- **Privacidad:** Anonimización irreversible de los identificadores comerciales de exportadores.

3.1.7 Restricciones

- **Procesamiento por Lotes (Batch):** El sistema está acotado a ejecuciones programadas semanales, excluyendo telemetría en tiempo real.
- **Soporte Consultivo:** El sistema provee soporte a la decisión humana, no autoriza bloqueos automáticos en aduanas ni reemplaza firmas.
- **Variables Proxies:** Variables críticas como mermas, costos logísticos o riesgos sanitarios se declaran conceptualmente como estimaciones o proxies, mediciones directas.

3.1.8 Principios de Diseño

- 1. **Separación de Responsabilidades:** Desacoplamiento estricto del cálculo cuantitativo frente a la redacción narrativa del LLM.
- 2. **Evidencia Primero:** El prompt del modelo de lenguaje se restringe exclusivamente a las evidencias cuantitativas inyectadas.
- 3. **Human-in-the-Loop:** Cada alerta y reporte requiere revisión y firma del supervisor humano antes de su registro oficial.
- 4. **Trazabilidad:** Cada elemento del sistema hereda y propaga el linaje de identificadores y hashes.
- 5. **Control Factual:** Rechazo sistemático de reportes con discrepancias numéricas.
- 6. **Mínimo Privilegio:** Restricción de permisos y control de acceso local a los datos brutos de aduana.

3.1.9 Tecnologías Implementadas

- *Lenguaje de programación:* Python (versión 3.11.x).
- *Análisis y manipulación de datos:* Pandas, Numpy, PyArrow (formato Parquet).
- *Algoritmos de ML y Anomalías:* XGBoost, LightGBM, PyOD (Isolation Forest, LOF, ECOD), Scikit-Learn, Optuna.
- *Explicabilidad:* SHAP (TreeSHAP).
- *RAG e Indexado:* Rank-BM25, Sentence-Transformers (`paraphrase-multilingual-MiniLM-L12-v2`).
- *Servicios y Dashboard:* Flask / Streamlit, Jinja2, HTML5/CSS3 (estilo premium).
- *Persistencia:* Parquet para almacenamiento analítico y archivos JSON para trazabilidad y configuraciones.

3.1.10 Arquitectura de Componentes




Figura 3.1 — Arquitectura lógica del sistema integrado.

Estado: placeholder de figura pendiente.

Archivo esperado: `docs/figures/figura_3_1_arquitectura_logica.svg` y copia PNG en `docs/figures/figura_3_1_arquitectura_logica.png`.

Fuente de generación: bloque Mermaid anterior o diagrama equivalente generado desde `src/module1_prediction.py` a `src/module6_traceability.py` y `agro/backend/app.py`.

Contenido visual requerido: cinco capas diferenciadas: datos/ETL, modelado predictivo, anomalías, explicabilidad/RAG-validación y dashboard/trazal mostrar entradas, salidas, módulos y relación de linaje.

Criterio de aceptación: la figura debe renderizarse sin código Mermaid visible en el PDF final, tener título, fuente "Elaboración propia" y coincidir con la del repositorio.

3.2 Esquema de la Propuesta

3.2.1 Flujo General de Datos

```
sequenceDiagram
    autonumber
    participant SUNAT as SUNAT aduanas
    participant ETL as ETL & Agregación
    participant Models as Predicción & Residuos
    participant PyOD as Ensemble Outliers
    participant SHAP as TreeSHAP
    participant RAG as RAG & LLM
    participant Val as Validador Factual
    participant Log as Traceability Log

    SUNAT->>ETL: Enviar registros transaccionales
    ETL->>ETL: Agrupar por producto-mercado-semana ISO
    ETL->>Models: Dataset gold e ingeniería de lags
    Models->>Models: Entrenar XGBoost/LightGBM global
    Models->>PyOD: Residuos robustos y características
    PyOD->>PyOD: Calcular percentiles consolidados
    PyOD->>SHAP: Gatillar alerta (score >= 0.95)
    SHAP->>SHAP: Calcular contribución local de variables
    SHAP->>RAG: Enviar evidencia (valores, SHAP, metadatos)
    RAG->>RAG: Recuperar documentos contextuales
    RAG->>RAG: Redactar reporte en markdown
    RAG->>Val: Enviar reporte de revisión
    alt Reporte válido (error <= 0.5%)
        Val->>Log: Guardar reporte y registrar hash SHA-256
    else Reporte inválido (error > 0.5%)
        Val->>RAG: Solicitar corrección (máx 1 intento)
        alt Corrección fallida
            Val->>Log: Generar reporte determinista con TemplateProvider y registrar
        end
    end
    Log->>Log: Retornar alert_id y confirmar trazabilidad
```

Figura 3.2 — Flujo temporal de datos, predicción, alerta y reporte.

Estado: placeholder de figura pendiente.

Archivo esperado: `docs/figures/figura_3_2_flujo_temporal.svg` y copia PNG en `docs/figures/figura_3_2_flujo_temporal.png`.

Fuente de generación: bloque Mermaid anterior, scripts `src/prepare_weekly_dataset.py`, `src/feature_engineering.py`, `src/module1_preparation.py`, `src/module2_anomaly.py`, `src/module4_rag.py` y `src/module6_traceability.py`.

Contenido visual requerido: secuencia desde registros SUNAT/ADUANET hasta dataset gold, predicción, residuo, score ensemble, explicación SHAP, validación factual y log de trazabilidad.

Criterio de aceptación: debe distinguir explícitamente información disponible en semana `t` frente al objetivo `t+1`, para evidenciar prevención de fuga.

3.2.2 Esquema y Capas de Datos

- **Raw:** Datos crudos originales descargados sin procesar (formatos DBF de SUNAT y CSVs de SISAP/BCRP).
- **Bronze:** Transformación inicial uno-a-uno a formato estructurado de alto rendimiento (Parquet) sin alterar campos.
- **Silver:** Limpieza de nulos, homologación de códigos arancelarios a 10 dígitos, normalización de países ISO alfa-3, y anonimización de exportadores criptográficos. Exclusión sistemática de cacao.
- **Gold:** Cuadrícula temporal de agregación semanal de combinación única `product_code`, `market_aggregated`, `week_start`. Generación de lags, rolling características cíclicas calendario.

3.2.3 Unidad de Análisis

- Definición metodológica única y obligatoria: la combinación de **producto × mercado de destino × semana ISO** iniciada en la fecha `week_start`.
- Unidad de registro en los archivos analíticos de entrada a los modelos: cada fila describe el comportamiento acumulado de una subpartida arancelaria mercado específico durante una semana ISO (lunes a domingo).

3.2.4 Variables Objetivo

- **FOB Unitario Promedio Semanal (\$t+1\$):**
$$\text{\$Y}_{\{\text{FOB}\}}(t+1) = \frac{\sum \text{\text{FOB_USD}}_{\{t+1\}}}{\sum \text{\text{Net_Weight_kg}}_{\{\$ \$\}}}$$
- **Volumen Neto Semanal (\$t+1\$):**
$$\text{\$Y}_{\{\text{Vol}\}}(t+1) = \sum \text{\text{Net_Weight_kg}}_{\{t+1\}}_{\{\$ \$\}}$$

3.2.5 Integración de Fuentes Exógenas

- *Tipo de cambio (BCRP):* Mapeado semanalmente a través del mes de la fecha `week_start`.
- *Precios internos (SISAP):* Incorporados semanalmente mediante correspondencia de producto.
- *Clima regional (NASA):* Agregado semanalmente y desplazado en una semana (`lag1`) para representar la información disponible al cierre de la semana de predicción.

3.2.6 Ingeniería de Características (Prevención de Data Leakage)

Todas las variables de predicción correspondientes a estadísticas móviles (`rolling mean`, `rolling std`, `rolling mad`) y variaciones porcentuales desplazando los datos observados en una semana (`shift(1)`). Esto asegura que ninguna información correspondiente a la semana \$t+1\$ o posterior conjunto de entrenamiento de la semana \$t\$.

3.2.7 Modelamiento Predictivo Global

Se entrena un único modelo global de regresión multivariable (un modelo para valor unitario FOB y otro para volumen) para todos los productos seleccionados, incorporando las características categóricas codificadas mediante One-Hot Encoding. La optimización de hiperparámetros se realiza med sobre el split de validación temporal.

3.2.8 Cálculo de Residuos Robustos

Los detectores de anomalías se alimentan de los residuos de predicción fuera de muestra (predicciones OOF generadas mediante validación temporal) residuo se escala mediante robust-z score móvil:

$$\text{\$ residual_robust_z} = \frac{\text{\text{residuo}}(t) - \text{\text{mediana}}(\text{\text{residuos}}_{\{t-13..t-1\}})}{\text{\text{MAD}}(\text{\text{residuos}}_{\{\$ \$\}})}$$

3.2.9 Ensemble de Anomalías y Percentiles

Las puntuaciones crudas de Isolation Forest, LOF y ECOD se calibran en la distribución del conjunto de entrenamiento para transformarlas a percentiles el rango \$[0, 1]\$. El ensemble consolida las puntuaciones promediándolas y gatilla la alerta si se supera el percentil 95.

3.2.10 Explicabilidad SHAP y Atribución local

TreeSHAP se aplica sobre los regresores globales de GBDT entrenados para calcular las contribuciones marginales locales de cada característica. El siste top-5 de variables que empujaron positivamente la predicción esperada y el top-5 que la redujeron, inyectándolos en el prompt de la alerta.

3.2.11 RAG con Validador Factual

El motor RAG recupera información metodológica y limitaciones del corpus documental de `knowledge_base/`. El LLM recibe las evidencias de la alerta reporte técnico. El validador determinista realiza un análisis numérico mediante expresiones regulares, comparando los números del reporte contra entrada, cayendo en `TemplateProvider` ante discrepancias persistentes.

3.2.12 Trazabilidad de Auditoría

```
classDiagram
    class IngestionRun {
        +String ingestion_run_id
        +String dataset_version_id
        +String sunat_source_hash
        +DateTime timestamp
    }
    class ModelRun {
        +String model_version_id
        +String dataset_version_id
    }
```

```

+String model_parameters_hash
+Float mae_fob_val
+Float rmsle_vol_val
}
class AlertLog {
+String alert_id
+String model_version_id
+String product_code
+String market_aggregated
+DateTime week_start
+Float ensemble_score
+String severity
}
class ExplanationLog {
+String explanation_id
+String alert_id
+List top_k_shap_variables
+String shap_plot_path
}
class ReportLog {
+String report_id
+String alert_id
+String explanation_id
+String report_text_hash
+Boolean is_factual_valid
+String template_used
}

IngestionRun --> ModelRun : "alimenta"
ModelRun --> AlertLog : "evalúa y detecta"
AlertLog --> ExplanationLog : "explica"
ExplanationLog --> ReportLog : "documenta"

```

Figura 3.3 — Modelo lógico de trazabilidad de alerta, explicación y reporte.

Estado: placeholder de figura pendiente.

Archivo esperado: docs/figures/figura_3_3_trazabilidad.svg y copia PNG en docs/figures/figura_3_3_trazabilidad.png .

Fuente de generación: bloque Mermaid anterior, src/module6_traceability.py , data/gold/traceability_log.json y modelos del prototipo en agro/backend/models.py .

Contenido visual requerido: entidades IngestionRun , ModelRun , AlertLog , ExplanationLog y ReportLog , con campos mínimos de ID, hash, fecha, dat y artefacto.

Criterio de aceptación: debe permitir reconstruir visualmente qué hash conecta dataset, modelo, alerta, explicación y reporte.

3.2.13 Seguridad y Privacidad

El sistema opera localmente y no expone datos aduaneros crudos al exterior. Los identificadores fiscales (RUC) y nombres de las empresas exp anonimizan de manera irreversible mediante algoritmo criptográfico SHA-256 con sal fija:

$$\text{exporter_hash} = \text{SHA256}(\text{RUC} + \text{salt_salt_42})$$

Las claves de API de los LLMs se cargan mediante variables de entorno estrictamente privadas en el archivo .env .

3.2.14 Esquema de Despliegue Local

```

graph LR
  subgraph Servidor_Local [Servidor Local / Entorno Virtual]
    A[SQLite / DuckDB Metadata] <--> B[FastAPI Backend / App Logic]
    C[Parquet/JSON Gold Store] <--> B
    D[Model Binaries .joblib] --> B
    B <--> E[Streamlit / Flask Dashboard]
  end

  subgraph Clientes [Clientes de Red Local]
    E <--> F[Navegador Analista]
    E <--> G[Navegador Supervisor]
  end

```

3.3 Obtención y Preparación de Datos

La preparación de datos se organiza como un flujo reproducible por capas. Esta estructura evita mezclar archivos crudos, datos intermedio experimentales y evidencias finales. La unidad de análisis se mantiene constante en todo el proceso: producto agroexportador, mercado de destino y ser

3.3.1 Fuentes de datos y estado de uso

Fuente	Ruta o evidencia	Uso en la tesis	Estado
Dataset real local	data/dataset_real_v1.csv	Base experimental inicial de exportaciones y proxies	Disponible; requiere declarar como real/proxy/sintética
SUNAT/ADUANET	data/sunat/raw_downloads/ , data/sunat/x23290326.DBF	Fuente primaria aduanera y validación de estructura	Parcial; descargas locales concernientes a 2026
Trade Map	data-trademap/*.xls	Contraste externo por producto y mercado	Disponible como benchmark agroexportador
BCRP	data/bcrp/exchange_rates_cache.json , data/downloads/bcrp_tipo_cambio.csv	Tipo de cambio PEN/USD	Disponible
SISAP/MIDAGRI	codex-revision/metadata/sisap_*	Contexto de precio/volumen mayorista interno	Disponible como dato agregado
NASA POWER / clima	Variables climáticas integradas en silver/gold	Contexto climático regional	Disponible como proxy
Dataset analítico gold	data/gold/weekly_product_market.parquet	Unidad producto-mercado-semana	Disponible, preliminar
Prototipo funcional	sistema-web-agro/backend/init_db.py	Datos semilla para validar interfaz y telemetría	Implementado como prototipo

Los datos semilla del prototipo no sustituyen al dataset final de investigación. Se usan para demostrar integración funcional de backend, frontend, explicaciones, reportes y telemetría. Los resultados finales deberán provenir del dataset semanal reproducible y documentado.

3.3.2 Inventario reproducible de archivos principales

Capa	Archivo	Filas x columnas	Hash SHA-256	Uso
Raw local	data/raw/exports_raw.csv	40,672 x 21	64a7dd130cbe2ba79cee04fe8e391d64a81d18cb6a0cbdb4d84e7d27fbd7bea3	Base de datos inicial
Dataset real v1	data/dataset_real_v1.csv	40,672 x 21	64a7dd130cbe2ba79cee04fe8e391d64a81d18cb6a0cbdb4d84e7d27fbd7bea3	Base de datos experimental local
Bronze	data/bronze/exports_raw.parquet	40,672 x 21	66c4464cd87a6d4238a793ccb693d5afe1be704e1556d49e3bad8540bb2b2c9c	Conversion de estructura
Silver	data/silver/exports_clean.parquet	40,293 x 24	ba98a37a9f3c9c7cf36baff8af8e1b61837cd237817b6e441d2bfb9f839e4eb3	Limpieza y normalización
Gold	data/gold/weekly_product_market.parquet	8,340 x 27	4b9d0ea84880dc46192806125896707aec8274d51f5c05c8e5d1ebb5350edac3	Agregación y procesamiento semanal
Features predictivas	data/gold/prediction_features.parquet	8,340 x 139	e343829f19fc26b1cd153e18fcb70808b9713c82c4b37ea86fe8395c8c607773	Entrenamiento de modelos de Machine Learning
Features anomalías	data/gold/anomaly_features.parquet	8,340 x 170	f3fa9e7868e2432df240ad932daff0bfb99d54e825fc5967f991b125412c26	Detección de Outliers (IF/LOF, etc.)

Comando de verificación: `.\.venv\Scripts\python.exe -c "<script de lectura pandas y hash SHA-256>"`.

Salida esperada: dimensiones y hashes iguales a la tabla anterior. Si algún hash cambia, debe generarse nueva versión de dataset y actualizar los report

3.3.3 Capas de procesamiento

Capa	Descripción	Evidencia esperada
Raw	Archivos originales sin transformación metodológica	Hash de origen, fecha de descarga, ruta cruda
Bronze	Conversión estructural a formatos tabulares/parquet	Script de extracción y conteo de registros
Silver	Limpieza, normalización, homologación y anonimización	Diccionario de datos y reporte de calidad
Gold	Agregación semanal por producto-mercado-semana	Dataset final, hash, versión y pruebas
Features	Variables predictivas, rezagos y ventanas móviles	Matriz de entrenamiento y prueba de fuga
Evidence	Métricas, residuos, alertas, explicaciones y reportes	Artefactos en <code>reports/tesis/</code>

3.3.4 Caracterización del dataset semanal gold

Indicador	Valor observado	Evidencia
Filas gold	8,340	<code>data/gold/weekly_product_market.parquet</code>
Columnas gold	27	<code>data/gold/weekly_product_market.parquet</code>
Productos	4 (<code>avocado</code> , <code>blueberry</code> , <code>esparrago</code> , <code>grape</code>)	Conteo pandas
Mercados agregados	10	Conteo pandas
Series producto-mercado	20	Conteo pandas
Semanas ISO	417	<code>week_start</code>
Periodo semanal	2018-06-04 a 2026-05-25	<code>week_start</code>
Filas avocado	2,502	Conteo por <code>product_code</code>
Filas blueberry	2,502	Conteo por <code>product_code</code>
Filas grape	2,502	Conteo por <code>product_code</code>
Filas esparrago	834	Conteo por <code>product_code</code>

Criterio metodológico sobre espárrago: aunque existe en la base gold, se mantiene como producto secundario o de sensibilidad. El núcleo defendible se concentra en palta, uva y arándano; espárrago no debe mezclarse en conclusiones principales salvo que se declare explícitamente su cobe

3.3.5 Calidad, registros eliminados y límites de datos

El reporte `codex-revision/reporte-calidad-datos.md` registra 40,293 filas válidas post-validación y 4 filas rechazadas. También identifica 4,933 duplicado potenciales usando producto, fecha, exportador, destino, volumen y precio. Estos duplicados no deben eliminarse automáticamente sin revisar si múltiples operaciones similares o registros repetidos.

Control	Resultado actual	Acción documental
Cacao	Excluido	Mantener exclusión
Palta, uva, arándano	Presentes	Núcleo del estudio
Espárrago	Presente con menor cobertura	Mantener como secundario

Control	Resultado actual	Acción documental
Rechazados	4 filas	Documentar archivo de rechazados
Duplicados exactos	0	Sin acción
Duplicados funcionales	4,933	Revisar antes de cierre final
<code>fob_unit_value_usd_kg</code> faltante en gold	91.46%	No usar como métrica final sin imputación/criterio formal

3.3.6 Controles de calidad temporal

Para prevenir fuga de información, las variables predictivas solo deben utilizar información disponible antes de la semana objetivo. Los rezagos, med desviaciones móviles se calculan con desplazamiento explícito de una semana. Los escaladores, codificadores y selectores de características se ajustar con el conjunto de entrenamiento. La partición temporal se congela antes de entrenar los modelos definitivos.

Control	Regla de aceptación	Estado actual
Rezagos y ventanas	Toda ventana móvil usa <code>shift(1)</code> antes del objetivo	Parcial, requiere prueba automatizada final
Escaladores/codificadores	Ajuste solo en entrenamiento	Pendiente de evidencia definitiva
Selección de características	Sin acceso al conjunto de prueba	Pendiente
Predicciones fuera de muestra	Residuos generados con validación temporal	Pendiente para dataset final
Reporte de fuga	Guardar en <code>reports/tesis/data-quality/leakage-tests/</code>	Pendiente si no existe ejecución

Comando de prueba esperado: `.\.venv\Scripts\python.exe -m pytest tests/leakage/test_leakage.py .`

Salida esperada: pruebas aprobadas y reporte copiado a `reports/tesis/data-quality/leakage-tests/` con fecha, commit y hash. Si el reporte no existe queda pendiente.

3.3.7 Registro de artefactos experimentales

Cada corrida experimental debe registrar identificador único, commit, dataset, semilla, configuración, hiperparámetros, entorno, métricas globales, producto, predicciones, residuos y hashes de salida. Hasta que esos campos existan, el artefacto se clasifica como preliminar o pendiente, no como defin

3.4 Diseño e Implementación del Prototipo

El prototipo funcional se encuentra en `sistema-web-agro/`. Su propósito es demostrar la integración de los componentes de supervisión aduanera con no cerrar por sí solo la validación estadística final de la tesis.

3.4.1 Estructura técnica del prototipo

Componente	Ruta	Función	Estad
Backend Flask	<code>sistema-web-agro/backend/app.py</code>	API de alertas, configuración, telemetría y reportes	Imple
Modelos de datos	<code>sistema-web-agro/backend/models.py</code>	Entidades de alerta, decisión, usuario y documentos	Imple
Semilla de base	<code>sistema-web-agro/backend/init_db.py</code>	Carga de datos de prueba y configuración inicial	Imple
Frontend React	<code>sistema-web-agro/frontend/src/</code>	Interfaz de auditoría, detalle, telemetría e integridad	Imple
Despliegue local	<code>sistema-web-agro/docker-compose.yml</code> , <code>run.ps1</code>	Orquestación local del prototipo	Imple
Evidencia visual	<code>sistema-web-agro/*/screen.png</code>	Capturas de pantallas funcionales	Dispo

3.4.2 Vistas funcionales del prototipo

El prototipo incluye vistas para autenticación, panel del auditor, gestión de alertas, detalle de operación con IA explicable, historial, telemetría, exploración de datos, configuración de modelo y control de usuarios. La vista de detalle de alerta concentra la integración de predicción, score explicable SHAP, reporte RAG y decisión humana.

Vista	Ruta esperada	Evidencia
Login	/login	frontend/src/pages/Login.jsx
Dashboard	/dashboard	frontend/src/pages/Dashboard.jsx
Alertas	/alerts	frontend/src/pages/Alerts.jsx
Detalle de alerta	/alerts/:id	frontend/src/pages/Detail.jsx , AuditDetail.jsx
Historial	/history	frontend/src/pages/History.jsx
Telemetría	/telemetry	frontend/src/pages/Telemetry.jsx
Integridad	/integrity	frontend/src/pages/Integrity.jsx
Datos/RAG	/data	frontend/src/pages/Data.jsx
Configuración	/config	frontend/src/pages/Config.jsx
Usuarios	/users	frontend/src/pages/Users.jsx

3.4.3 Placeholders de capturas del prototipo

Las capturas de pantalla no deben sustituir evidencia funcional ni resultados experimentales. Se usan para documentar la interfaz del prototipo. Cuando todavía no esté incorporada al PDF final, se registra el placeholder siguiente:

Figura	Pantalla	Archivo esperado	Fuente actual	Contenido que debe mostrar
Figura 4.1	Detalle de alerta IA explicable	docs/figures/figura_4_1_detalle_alerta.png	sistema-web-agro/detalle_de_operaci_n_ia_explicable_esp/screen.png	Datos DAM, FOB esperado, score, SHAP, reporte RAG y decisión humana
Figura 4.2	Consola de telemetría	docs/figures/figura_4_2_telemetria.png	sistema-web-agro/experimental_telemetry_console/screen.png o monitor_de_telemetr_a_y_equidad_esp/screen.png	Condiciones A/B, tiempo de decisión, comprensión y métricas agregadas
Figura 4.3	Bandeja de alertas	docs/figures/figura_4_3_bandeja_alertas.png	sistema-web-agro/alerts_management_inbox/screen.png	Lista filtrable de alertas, estados, severidad y producto
Figura 4.4	Configuración de modelo	docs/figures/figura_4_4_configuracion_modelo.png	sistema-web-agro/model_configuration_terminal/screen.png	Pesos IF/LOF/ECOD, umbral y parámetros editables

Figura	Pantalla	Archivo esperado	Fuente actual	Contenido que debe mostrar
Figura 4.5	Explorador de datos y RAG	docs/figures/figura_4_5_explorador_datos.png	sistema-web-agro/data_explorer_load_center/screen.png	Carga o exploración de datos, biblioteca documental y estado de indexación

Criterio de aceptación de capturas: cada imagen debe tener resolución legible, título, fuente "captura del prototipo sistema-web-agro ", fecha de generación del componente React correspondiente. Si la captura se usa en Capítulo IV, debe corresponder a la versión del commit documentado.

3.4.4 Algoritmos propuestos e implementación vinculada

Módulo	Algoritmo o técnica	Función	Evidencia
Predicción	XGBoost/LightGBM, GBDT	Estimar FOB unitario y volumen esperado	src/module1_prediction.py , prototipo
Detección de anomalías	Isolation Forest, LOF, ECOD	Calcular score anómalo individual y ensemble	src/module2_anomaly.py , backend/api
Explicabilidad	TreeSHAP/SHAP	Atribuir variables que impulsan el riesgo	src/module3_shap.py , vista de detalle
Reportes automáticos	RAG con recuperación documental y plantilla determinística	Generar narrativa técnica anclada a evidencia	src/module4_rag.py , src/module5_validation.py
Validación factual	Reglas determinísticas y comparación numérica	Rechazar cifras no sustentadas	src/module5_validation.py
Trazabilidad	Hashes, IDs, logs y relaciones alerta-decisión	Auditar evidencia de extremo a extremo	src/module6_traceability.py , mode backend

En el estado actual, el prototipo respalda la arquitectura, las rutas funcionales, la telemetría y la experiencia de auditoría. La validación cuantitativa de condicionada al dataset semanal final, a las pruebas de fuga de información y a los experimentos formales.

3.5 Diseño Experimental y Validación

La validación se plantea en cinco bloques: rendimiento predictivo y detección, explicabilidad, calidad de reportes, usabilidad y trazabilidad. Cada uno producir evidencia reproducible antes de ser incorporado como resultado definitivo en el Capítulo IV.

3.5.1 Validación de predicción y anomalías

La comparación principal evalúa el ensemble IF + LOF + ECOD frente a detectores individuales y baselines. Las métricas previstas son Precision, Recall, ROC-AUC y Precision@k. Cuando se usen anomalías sintéticas, se debe registrar tipo, magnitud, proporción de inyección y etiqueta generada.

3.5.1.1 Partición temporal propuesta

La partición se define por fecha y no por muestreo aleatorio, debido a la naturaleza longitudinal del problema.

Conjunto	Periodo propuesto	Uso	Regla
Entrenamiento	2018-06-04 a 2024-12-30	Ajustar modelos, codificadores y escaladores	Puede usarse para Optuna y calibración interna
Validación	2025-01-06 a 2025-12-29	Selección de hiperparámetros y umbrales	No se mezcla con test
Prueba	2026-01-05 a 2026-05-25	Evaluación final preliminar	Solo inferencia fuera de muestra

Si la distribución real por producto no permite sostener estas ventanas para todas las series, debe usarse una validación walk-forward por serie con las mínimas documentadas. En ese caso, la tesis debe reportar cuántas series quedaron excluidas y por qué.

3.5.1.2 Estrategia walk-forward

Parámetro	Valor metodológico
Unidad de ventana	Semana ISO
Horizonte	1 semana (<code>t+1</code>)
Ventana inicial mínima	104 semanas por serie cuando exista cobertura
Paso	1 semana o bloque mensual, según costo computacional
Salida	Predicción, residuo y error por semana fuera de muestra
Evidencia	<code>reports/tesis/experiments/<run_id>/predictions_oos.parquet</code>

3.5.1.3 Baselines predictivos

Objetivo	Baseline	Descripción	Métrica principal
FOB unitario	Último valor observado	<code>y_hat(t+1)=y(t)</code>	MAE
FOB unitario	Mediana móvil 4 semanas	Mediana de semanas disponibles hasta <code>t</code>	MAE
FOB unitario	Mediana móvil 13 semanas	Baseline robusto estacional corto	MAE
FOB unitario	Elastic Net	Modelo lineal regularizado	MAE/RMSE
Volumen	Último valor observado	Persistencia temporal	RMSLE
Volumen	Mediana móvil 4/13 semanas	Baseline robusto	RMSLE
Volumen	Baseline estacional	Misma semana del año anterior si existe	RMSLE

3.5.1.4 Modelos propuestos e hiperparámetros

Modelo	Hiperparámetros a registrar	Selección
XGBoost	<code>n_estimators</code> , <code>max_depth</code> , <code>learning_rate</code> , <code>subsample</code> , <code>colsample_bytree</code> , <code>reg_lambda</code> , <code>reg_alpha</code>	Optuna o grid reducido sobre validación temporal
LightGBM	<code>num_leaves</code> , <code>max_depth</code> , <code>learning_rate</code> , <code>feature_fraction</code> , <code>bagging_fraction</code> , <code>lambda_l1</code> , <code>lambda_l2</code>	Optuna o grid reducido sobre validación temporal
Elastic Net	<code>alpha</code> , <code>l1_ratio</code>	Validación temporal
IF/LOF/ECOD	<code>contamination</code> , vecinos LOF, semilla y umbral percentílico	Calibración en entrenamiento/validación

Semilla base: `42` . Toda corrida debe registrar semilla global, semilla de modelo y versión de librerías.

3.5.1.5 Métricas por objetivo

Bloque	Métricas	Nivel de reporte
FOB	MAE, RMSE, MAPE/SMAPE, R ²	Global, producto y mercado principal
Volumen	RMSLE, MAE, RMSE, SMAPE, R ²	Global, producto y mercado principal
Anomalías	Precision, Recall, F1, PR-AUC, ROC-AUC, Precision@k	Global, tipo de anomalía y producto

Bloque	Métricas	Nivel de reporte
Eficiencia	Tiempo de entrenamiento e inferencia	Por modelo
Estabilidad	Intervalo de confianza por bootstrap temporal	Por métrica principal

3.5.1.6 Protocolo de anomalías sintéticas

Tipo	Inyección	Magnitud sugerida	Etiqueta
Precio/FOB	Multiplicar FOB unitario o precio por factor atípico	±20% a ±60%	precio
Volumen	Alterar total_net_weight_kg o volumen semanal	±30% a ±80%	volumen
Clima/contexto	Perturbar temperatura o precipitación proxy	Percentiles 95-99	clima
Logística	Aumentar días logísticos proxy	Percentiles 95-99	logístico
Calidad/sanidad	Alterar merma o cumplimiento proxy	Regla documentada	calidad

La proporción de inyección no debe superar el 5% del conjunto evaluado sin justificarlo. Deben ejecutarse al menos tres repeticiones con semillas c quieren reportar intervalos de confianza.

3.5.2 Validación de explicabilidad

SHAP se evalúa por cobertura top-k, estabilidad de atribuciones, coherencia con variables disponibles y claridad para el auditor. Las atribuciones se inter contribuciones del modelo, no como causalidad empresarial.

Indicador	Definición	Evidencia esperada
Cobertura top-k	Porcentaje de alertas con top-5 variables explicativas	data/gold/local_explanations.json
Estabilidad	Variación del ranking SHAP entre corridas equivalentes	Reporte de estabilidad
Coherencia	Variables explicativas existen en matriz de features	Validación de columnas
Tiempo de cálculo	Milisegundos por explicación	Log de inferencia
Visualización	Gráficos bar/beeswarm exportados	src/static/images/shap_*.png

Placeholders de figuras SHAP.

Figura	Archivo actual o esperado	Descripción
Figura 4.6	src/static/images/shap_price_bar.png	Importancia global para predicción de precio/FOB
Figura 4.7	src/static/images/shap_volume_bar.png	Importancia global para predicción de volumen
Figura 4.8	src/static/images/shap_price_beeswarm.png	Distribución de efectos SHAP para precio/FOB
Figura 4.9	src/static/images/shap_volume_beeswarm.png	Distribución de efectos SHAP para volumen

3.5.3 Validación de reportes automáticos

Los reportes se validan con una rúbrica de completitud, coherencia, fidelidad factual y consistencia numérica. Cada cifra citada en el reporte debe existir estructurada. Si el reporte RAG no supera la validación, se registra rechazo y se genera una versión determinística.

Criterio	Métrica	Fuente
Completitud	Porcentaje de campos obligatorios presentes	data/gold/validation_metrics.json

Criterio	Métrica	Fuente
Fidelidad factual	Proporción de cifras coincidentes con evidencia	data/gold/validation_metrics.json
Rechazo controlado	Reportes no aprobados por validador	reports/audits/
Comparación determinística	RAG frente a plantilla	Reporte de validación
Recuperación documental	Documentos usados por reporte	Log RAG

En el estado actual, `data/gold/validation_metrics.json` registra 5 reportes evaluados y 0 reportes válidos. Por tanto, el módulo queda documentado como pero no aprobado para resultados definitivos hasta corregir las discrepancias numéricas.

3.5.4 Evaluación controlada con usuarios

El estudio de usabilidad compara una condición integrada, con SHAP y RAG visibles, frente a una condición aislada, sin explicaciones avanzadas. Las tiempo de análisis, decisión registrada, comprensión percibida y utilidad. Hasta contar con participantes reales y consentimiento documentado, permanece como diseño experimental y no como resultado concluyente.

Elemento	Diseño mínimo
Participantes	Definir perfil, experiencia y número mínimo antes de ejecutar
Condiciones	A: integrado con SHAP/RAG; B: aislado sin SHAP/RAG
Tareas	Casos equivalentes por producto y severidad
Orden	Contrabalanceado para reducir aprendizaje
Métricas	Tiempo, decisión correcta, Likert de comprensión, SUS, utilidad
Prueba estadística	Mann-Whitney U o Welch según normalidad y tamaño muestral
Evidencia	Consentimiento, datos anonimizados y script de análisis

Placeholder de instrumento: el formulario final de consentimiento y encuesta SUS debe guardarse como `reports/tesis/user-study/instrumento_usabilidad/docs/tesis/anexos/instrumento_usabilidad.md`. Si no existe, la evaluación con usuarios permanece pendiente.

3.5.5 Puertas de control

Puerta	Criterio	Estado actual
A. Datos	Dataset semanal reproducible, documentado, versionado y sin duplicidad de clave	Parcial
B. Implementación	Cada módulo con ruta, entrada, salida, configuración, prueba y evidencia	Parcialmente aprobado por proto
C. Experimento	Split temporal, métricas, semillas y criterios congelados	Pendiente
D. Capítulo III	Arquitectura e implementación documentadas sin resultados finales	En desarrollo
E. Capítulo IV preliminar	Resultados reproducibles y claramente marcados como preliminares o definitivos	Parcial

3.5.6 Checklist verificable de cierre del Capítulo III

ID	Actividad	Archivo fuente	Comando	Salida esperada	Estad
C3-DATA-01	Verificar hashes de datasets	data/raw , data/gold	Script pandas + SHA-256	Hashes iguales a Tabla 3.3.2	Parcial

ID	Actividad	Archivo fuente	Comando	Salida esperada	Estado
C3-DATA-02	Ejecutar pruebas de calidad	tests/data_quality/test_quality.py	.\.venv\Scripts\python.exe -m pytest tests/data_quality/test_quality.py	Tests aprobados	Pen con
C3-LEAK-01	Ejecutar prueba de fuga temporal	tests/leakage/test_leakage.py	.\.venv\Scripts\python.exe -m pytest tests/leakage/test_leakage.py	Tests aprobados y reporte en reports/tesis/data-quality/leakage-tests/	Pen
C3-EXP-01	Registrar experimento	src/train_models.py	.\.venv\Scripts\python.exe src/train_models.py	run_id , métricas, predicciones y residuos	Par
C3-SHAP-01	Generar explicabilidad	src/module3_shap.py	Script de SHAP	JSON + PNG/SVG	Par
C3-RAG-01	Validar reportes	src/module5_validation.py	Tests/report validation	Reportes válidos o rechazados documentados	Par actu apr
C3-FIG-01	Renderizar figuras Mermaid	docs/02-30-capitulo3.md	Mermaid CLI o equivalente	Figuras 3.1-3.3 PNG/SVG	Pen
C3-UI-01	Insertar capturas del prototipo	sistema-web-agro/*/screen.png	Copia a docs/figures/	Figuras 4.1-4.5 con título y fuente	Pen

CAPÍTULO IV — RESULTADOS Y DISCUSIÓN

Estado del capítulo: avance parcial verificable al 22 de junio de 2026. Este capítulo documenta el estado funcional del prototipo y los resultados disponibles. Las métricas derivadas de datos semilla se presentan como validación de flujo, no como resultados definitivos de la investigación.

4.1 Estado de Implementación del Prototipo

El prototipo funcional se ubica en `sistema-web-agro/` y permite validar la integración de las capas principales de la propuesta: autenticación de usuarios, operativo, gestión de alertas, detalle de operación con IA explicable, telemetría experimental, métricas de integridad, explorador de datos, configuración y administración de usuarios.

4.1.1 Alcance verificable

Bloque	Evidencia principal	Estado
Backend/API	sistema-web-agro/backend/app.py , models.py , init_db.py	Implementado para prototipo
Frontend	sistema-web-agro/frontend/src/pages/	Implementado
Despliegue local	sistema-web-agro/docker-compose.yml , run.ps1	Implementado, sujeto a verificación de entorno
Pantallas y flujo	sistema-web-agro/*/screen.png , frontend/src/pages/*.jsx	Disponible
Datos semilla	sistema-web-agro/backend/init_db.py , DATOS_PRUEBA.txt	Disponible para validación funcional
Dataset final de tesis	data/gold/ , reports/tesis/	Parcial o pendiente según evidencia

4.1.2 Reglas de interpretación

Los resultados de este capítulo se clasifican en tres niveles:

1. **Implementado:** existe ruta real, código o artefacto verificable.

- 2. **Preliminar:** existe salida funcional o dato semilla, pero aún no constituye evidencia final.
- 3. **Pendiente:** requiere dataset final, experimento formal, prueba automatizada o validación documental adicional.

Esta separación evita presentar como definitivos los resultados generados con datos de prueba. La evidencia definitiva deberá registrar fecha, con configuración, semilla, entorno, hash de salida y procedimiento de reproducción.

4.1.3 Algoritmos integrados en el avance actual

Capa	Algoritmo/técnica	Uso en el prototipo y tesis	Estado
Predicción	XGBoost/LightGBM, GBDT	Estimar valor FOB o volumen esperado	Parcial: implementado en scripts/prototipo, pendiente va
Anomalías	Isolation Forest, LOF, ECOD	Calcular score individual y score ensemble	Parcial: funcional con datos semilla
Explicabilidad	SHAP/TreeSHAP	Mostrar contribuciones locales por variable	Parcial: funcional con evidencia semilla
Reportes	RAG y plantilla determinística	Generar reporte técnico anclado a documentos	Parcial: motor funcional, validador formal pendiente
Trazabilidad	IDs, hashes, logs, relaciones alerta-decisión	Reconstruir el flujo de evidencia	Parcial: flujo implementado, auditoría final pendiente

4.1.4 Estado frente a las puertas de control

Puerta	Estado al punto actual	Observación
A. Datos	Parcial	Falta congelar dataset semanal final y reporte de fuga de información
B. Implementación	Parcialmente aprobada	El prototipo respalda rutas, pantallas y flujo operativo
C. Experimento	Pendiente	Faltan partición temporal congelada, semillas, métricas definitivas y protocolos corridos
D. Capítulo III	En avance	La arquitectura e implementación ya están documentadas de forma ampliada
E. Capítulo IV preliminar	Parcial	Solo deben incluirse resultados marcados como preliminares o pendientes

Las secciones siguientes desarrollan los resultados preliminares disponibles y dejan explícito qué evidencia todavía debe completarse.

4.2 Resultados Cuantitativos: Predicción y Detección — VD1

Estado: preliminar. Las cifras disponibles provienen de datos semilla del prototipo (`sistema-web-agro/backend/init_db.py`) y sirven para validar el flujo no para aceptar o rechazar hipótesis definitivas.

4.2.1 Condiciones de reproducibilidad

Evidencia	Archivo	Estado
Dataset semilla	<code>sistema-web-agro/backend/init_db.py</code>	Disponible
Datos de prueba documentados	<code>sistema-web-agro/backend/DATOS_PRUEBA.txt</code>	Disponible
Código backend	<code>sistema-web-agro/backend/app.py</code>	Disponible
Dataset semanal final	<code>data/gold/weekly_product_market.parquet</code>	Parcial/pendiente de validación final
Prueba de fuga temporal	<code>reports/tesis/data-quality/leakage-tests/</code>	Pendiente si no existe ejecución
Registro experimental completo	<code>reports/tesis/experiments/</code>	Pendiente

4.2.2 Tabla 4.1 — Rendimiento de detección en validación semilla

Método	N	PR-AUC	ROC-AUC	F1	Precisión	Recall	Clasificació
Isolation Forest	40	0.79	0.84	0.80	0.78	0.82	Preliminar
LOF	40	0.75	0.80	0.76	0.74	0.79	Preliminar
ECOD	40	0.72	0.76	0.73	0.71	0.76	Preliminar
Ensemble IF + LOF	40	0.82	0.87	0.83	0.81	0.85	Preliminar
Ensemble IF + LOF + ECOD	40	0.85	0.90	0.86	0.83	0.89	Preliminar

Estas cifras permiten verificar que el pipeline produce métricas y compara detectores, pero no sustituyen el experimento final con dataset versiona temporal congelada y residuos fuera de muestra.

4.2.3 Tabla 4.2 — Recall por tipo de anomalía

Tipo de anomalía	Origen de etiqueta	Recall ensemble	Recall IForest	Estado
Precio/FOB desviado	Regla proxy en semilla	0.91	0.84	Prelimir
Volumen inconsistente	Regla proxy en semilla	0.87	0.79	Prelimir
Temperatura contenedor	Regla proxy en semilla	0.84	0.76	Prelimir
Retraso logístico	Regla proxy en semilla	0.88	0.81	Prelimir

4.2.4 Tabla 4.3 — Predicción FOB en validación semilla

Métrica	XGBoost	Regresión lineal baseline	Estado
MAE (USD)	8,340	14,820	Preliminar
RMSE (USD)	12,150	21,340	Preliminar
R²	0.87	0.71	Preliminar
MAPE	6.9%	12.3%	Preliminar

4.2.5 Evidencia faltante para resultado definitivo

- Congelar dataset semanal final con hash y versión.
- Ejecutar partición temporal sin fuga de información.
- Generar predicciones y residuos fuera de muestra.
- Registrar hiperparámetros, semilla, entorno y tiempo de entrenamiento.
- Guardar métricas globales y por producto.
- Clasificar cada salida como experimental, candidata o final.

Hasta completar esos puntos, VD1 queda en estado preliminar.

4.3 Explicabilidad Local y Reportes Automáticos — VD2, VD3

Estado: parcial verificable. El prototipo muestra explicaciones y reportes para datos semilla; la validación factual completa y la comparación formal co determinística quedan pendientes hasta ejecutar el protocolo definitivo.

4.3.1 Explicabilidad local con SHAP — VD2

El sistema utiliza explicabilidad local para que el auditor observe qué variables empujan el riesgo estimado en una alerta. En la propuesta metodológica se vincula con `src/module3_shap.py` ; en el prototipo funcional se evidencia en la vista de detalle de alerta de `sistema-web-agro/frontend/src/pages/AuditDetail.jsx` .

Tabla 4.4 — Atribuciones SHAP promedio en datos semilla

Variable	SHAP promedio	Dirección	Interpretación operacional
valor_fob_declarado	+0.4231	Aumenta riesgo	Desviación del valor FOB frente a referencia esperada
temperatura_contenedor_c	+0.2184	Aumenta riesgo	Posible deterioro o condición logística atípica
dias_retraso_logistico	+0.1562	Aumenta riesgo	Retraso asociado a mayor incertidumbre operativa
peso_netto_kg	-0.0891	Reduce riesgo	Consistencia entre volumen y valor declarado

Estos valores se interpretan como contribuciones del modelo, no como causalidad. La validación definitiva debe guardar top-k de variables por alerta, e la explicación, tiempo de cálculo y hash del modelo usado.

4.3.2 Reportes RAG — VD3

El prototipo contempla generación de reportes técnicos con recuperación documental y respaldo de citas. La tesis propone que cada reporte sea validad determinísticas antes de incorporarse como evidencia.

Tabla 4.5 — Rúbrica requerida para reportes automáticos

Criterio	Verificación requerida	Estado
Compleitud	Score, FOB esperado, variables SHAP y recomendación presentes	Parcial
Coherencia	El reporte no contradice los datos de la alerta	Pendiente de validador formal
Fidelidad factual	Cada cifra existe en evidencia estructurada	Pendiente
Consistencia numérica	Diferencia numérica dentro del umbral definido	Pendiente
Trazabilidad documental	Citas o documentos recuperados guardados con ID	Parcial

4.3.3 Tabla 4.6 — Documentos recuperados en muestras semilla

Tipo de alerta	Documento 1	Documento 2	Documento 3	Estado
Palta, FOB bajo, temperatura alta	FDA-1	SENASA-2	LEY_IA-3	Prelimin
Uva, retraso logístico	SENASA-2	FDA-1	LEY_IA-3	Prelimin
Arándano, score alto	FDA-1	LEY_IA-3	SENASA-2	Prelimin

4.3.4 Evidencia faltante para cierre de VD2 y VD3

- Guardar cada explicación SHAP con `alert_id` , `model_version_id` , fecha, commit y hash.
- Validar que los valores SHAP correspondan al modelo entrenado para esa ejecución.
- Guardar prompt, modelo, parámetros y documentos recuperados.
- Registrar reportes rechazados por el validador factual.
- Comparar reporte RAG contra plantilla determinística.
- Marcar afirmaciones no sustentadas y excluirlas del borrador final.

Hasta completar esos puntos, VD2 y VD3 quedan como avances funcionales, no como resultados finales.

4.4 Usabilidad y Trazabilidad — VD4, VD5

Estado: diseño experimental y validación funcional parcial. El prototipo registra decisiones y tiempos con datos semilla, pero el experimento con us permanece pendiente.

4.4.1 Diseño del estudio de usabilidad — VD4

El estudio compara dos condiciones:

- **Condición A integrada:** el auditor observa datos de la operación, predicción, score de anomalía, explicación SHAP y reporte RAG.
- **Condición B aislada:** el auditor observa datos de la operación, predicción y score, sin explicación SHAP ni reporte RAG.

Las variables dependientes son tiempo de análisis, decisión registrada, comprensión percibida, utilidad percibida y exactitud de la decisión frente a una referencia.

Requisito	Estado
Cantidad y perfil de participantes	Pendiente
Consentimiento informado y anonimización	Pendiente
Tareas equivalentes por condición	Pendiente
Contrabalanceo del orden	Pendiente
Prueba estadística definida	Pendiente
Registro de decisiones y tiempos	Implementado en prototipo

4.4.2 Telemetría semilla

El prototipo registra decisiones de auditoría mediante el flujo de adjudicación de alertas. Esta evidencia valida captura de datos, no desempeño humano

Tabla 4.7 — Telemetría semilla de validación de flujo

Alerta	Auditor	Condición	Decisión	Comprensión
AL-2026-0009	auditor1	Integrado	Anomalía confirmada	5/5
AL-2026-0006	auditor1	Aislado	Falsa alarma	3/5
AL-2026-0005	auditor2	Integrado	Requiere inspección	4/5
AL-2026-0004	auditor2	Aislado	Falsa alarma	2/5

Con N=2 por condición no corresponde afirmar significancia estadística. Los datos solo indican que la plataforma puede capturar tiempos, decisiones y comprensión.

4.4.3 Trazabilidad — VD5

La trazabilidad se evalúa verificando que cada alerta pueda reconstruirse desde entrada, predicción, score, explicación, reporte, decisión humana y registro

Tabla 4.8 — Campos de trazabilidad esperados

Campo	Evidencia	Estado
ID de alerta	Registro de alerta	Disponible en prototipo
Score de anomalía	Resultado del ensemble	Disponible en prototipo
FOB esperado vs declarado	Salida predictiva	Disponible en prototipo

Campo	Evidencia	Estado
Valores SHAP	Detalle de explicación	Parcial
Reporte generado	Reporte RAG o plantilla	Parcial
Documentos recuperados	IDs/citas del RAG	Parcial
Decisión humana	Registro de adjudicación	Disponible en prototipo
Timestamp	Registro de decisión	Disponible en prototipo
Hash de artefactos	Control de auditoría	Pendiente para cierre final

4.4.4 Evidencia faltante

- Ejecutar el experimento con participantes reales.
- Registrar consentimiento, perfil y anonimización.
- Guardar datos crudos de usabilidad fuera de rutas de referencia pública si contienen información sensible.
- Ejecutar prueba estadística definida.
- Generar reporte de trazabilidad con hash de artefactos y commit.

Hasta completar el estudio, VD4 se mantiene pendiente y VD5 queda parcialmente respaldada por el prototipo.

4.5 Discusion y Cruce Comparativo

4.5.1 Proposito de la discusion

La discusion triangula cuatro bloques: literatura revisada, hipotesis del Capitulo I, variables operacionalizadas y evidencia generada por el pipeline. S explicar los resultados sin convertir correlaciones, scores o valores SHAP en afirmaciones causales.

4.5.2 Cruce 1 - Resultados propios versus literatura comparable

Atributo	Esta tesis	Literatura comparable	Lectura esperada
Prediccion tabular	XGBoost/LightGBM	GBDT en fraude, auditoria y agroexportacion	Comparar cobertura y estabilidad, no valores absolutos entre
Deteccion de anomalias	Isolation Forest, LOF, ECOD	ADBench/PyOD	Justificar ensemble si mejora o estabiliza resultados.
Explicabilidad	SHAP/TreeSHAP	XAI tabular	Evaluar claridad y consistencia, no causalidad.
Reporte tecnico	RAG/LLM restringido	LLMs para auditoria/reportes	Evaluar fidelidad a evidencia y trazabilidad.
Dominio	Agroexportacion peruana	Finanzas, auditoria, agroclima	Declarar limites de comparabilidad.

4.5.3 Cruce 2 - Contraste de hipotesis

Hipotesis	Evidencia requerida
H1a	MAE de XGBoost/LightGBM para valor unitario FOB semanal frente al mejor modelo base, usando dataset producto-mercado-semana y particion temporal.
H1b	RMSLE de XGBoost/LightGBM para volumen exportado semanal frente al mejor modelo base, usando dataset producto-mercado-semana y particion temporal.
H1c	F1-Score del ensemble IF + LOF + ECOD calibrado por percentiles frente al promedio de detectores individuales en anomalias controladas.
H1d	Diferencia de comprension operativa y tiempo de analisis entre alertas con SHAP/RAG trazable y alertas tecnicas aisladas.

Hipotesis	Evidencia requerida
H1e	Proporcion de alertas reconstruibles desde registros de origen, dataset versionado y modelo hasta explicacion, decision humana y reporte.
H0	Ausencia de mejora significativa del sistema integrado en rendimiento, deteccion, comprension, tiempo de analisis y trazabilidad.
H1 general	Mejora conjunta de la supervision analitica por integrar prediccion, anomalias, explicabilidad, reportes validados y trazabilidad.

La decision puede ser: aceptar, rechazar o inconclusa. Toda decision debe estar vinculada al reporte de entrenamiento o de usabilidad correspondiente.

4.5.4 Cruce 3 - Variables operacionalizadas versus indicadores observados

Variable	Indicador	Valor observado	Cumple
VD1 rendimiento	PR-AUC, F1, precision, recall	pendiente	pendiente
VD2 explicabilidad	Cobertura top-k, estabilidad, claridad	pendiente	pendiente
VD3 reportes	Rubrica, consistencia numerica, evidencia	pendiente	pendiente
VD4 decision	Tiempo, comprension, decision correcta	pendiente	pendiente
VD5 trazabilidad	Campos completos por alerta	pendiente	pendiente

4.5.5 Cruce 4 - Gobernanza, componente y metrica

Principio	Componente	Metrica
Transparencia	Datasheet, Model Cards, logs	Cobertura de metadatos.
Explicabilidad	SHAP/TreeSHAP	VD2.
Supervision humana	Protocolo de usabilidad y revision	VD4.
Gestion de riesgo	Validacion temporal y umbrales	VD1.
Anti-alucinacion	RAG anclado a evidencia	VD3.
Trazabilidad	Registro de alerta end-to-end	VD5.

4.5.6 Cruce 5 - Errores por tipo de anomalia

Tipo de anomalia	Posible mecanismo de fallo	Mejora candidata
precio	Estacionalidad o mercado destino no capturado.	Media movil por producto-destino.
volumen	Campanas pico confundidas con outliers.	Variables de campana y calendario.
clima	Proxy regional demasiado agregado.	Mayor granularidad geografica.
logistica	Falta de llave directa puerto-embarque.	Agregacion puerto-mes documentada.
sanidad/calidad	Alertas agregadas sin trazabilidad por embarque.	Mantener como contexto, no etiqueta directa.

4.5.7 Interpretacion conjunta

La contribucion esperada no es solo mejorar una metrica aislada, sino demostrar que la integracion de prediccion, deteccion, explicabilidad y reporte capacidad de supervision operativa trazable. Si los resultados finales no sostienen una hipotesis, la tesis debe reportarlo como hallazgo metodologico discusion sin forzar la narrativa.

4.6 Limitaciones de los Resultados

Los resultados finales deberán interpretarse considerando:

1. **Naturaleza integrada del dataset:** el dataset combina datos reales observados, datos reales agregados, proxies y datos sintéticos controlados. Cada granularidad y alcance distintos.
2. **Etiquetas de anomalía:** cuando `etiqueta_anomalia` derive de reglas o inyección sintética, la evaluación mide detección de desviaciones definidas pero no necesariamente incidentes reales confirmados por empresa.
3. **SISAP/MIDAGRI:** aporta contexto de mercado interno mayorista y no debe interpretarse como exportación.
4. **Fuentes sanitarias y logísticas:** pueden operar como contexto agregado si no existe llave directa por embarque.
5. **SHAP:** entrega atribuciones del modelo, no causalidad.
6. **RAG/LLM:** mejora la redacción y trazabilidad del reporte, pero requiere validación contra evidencias y supervisión humana.
7. **Usabilidad:** si el estudio usa muestra pequeña, sus conclusiones deben presentarse como piloto especializado.

4.7 Síntesis del Capítulo IV

La síntesis final se completará cuando existan resultados integrados verificables:

1. El ensemble IF + LOF + ECOD *supera/no supera* al detector individual en VD1.
2. SHAP *mejora/no mejora* la comprensión y trazabilidad explicativa en VD2.
3. RAG anclado *mejora/no mejora* la calidad documental en VD3.
4. El sistema integrado *reduce/no reduce* el tiempo-a-decisión en VD4.
5. La trazabilidad documental alcanza *pendiente%* de alertas completas en VD5.
6. Las limitaciones por proxies, granularidad y datos sintéticos controlados quedan documentadas para evitar sobreinterpretación.

Hasta completar esos puntos, el capítulo se considera una estructura de resultados, no una afirmación empírica final.

CAPÍTULO V: CONCLUSIONES Y TRABAJOS FUTUROS

Pendiente: Capítulo V — depende de los resultados del Capítulo IV

5.1 Conclusiones

(Esqueleto para la síntesis final: el sistema integrado logró los objetivos propuestos, manteniendo el balance entre vanguardia tecnológica y rigor conclusión sobre el gap cerrado, métricas alcanzadas vs. objetivos, validación de hipótesis H1a–H1e, aporte al contexto regulatorio peruano).

5.2 Limitaciones de la Investigación

(Abordar: limitaciones del dataset agroexportador integrado; diferencias de granularidad entre datos reales observados, datos agregados, proxies y datos controlados; dependencia de la calidad de datos documentada en Datasheets for Datasets (Gebru et al., 2021); deuda técnica de mantenimiento del pipeline (Sculley et al., 2015); limitaciones del tamaño de la muestra en la evaluación de comprensión; restricciones de los LLMs actuales en precisión de cálculos (Maynez et al., 2026)).

5.3 Trabajos Futuros

(Propuestas: integración de GraphRAG para recuperación semántica más rica sobre conocimiento agroexportador; extensión del ensemble con ECC Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica) (Li et al., 2022) y modelos de concept drift parciales en stream; exploración de Chronos (Ansari et al., 2024) para forecasting de horizonte largo; prueba piloto en una empresa agroexportadora peruana; evaluación de sesgos y limitaciones según Datasheets for Datasets (Gebru et al., 2021)).

CRONOGRAMA DE ACTIVIDADES

Pendiente: conclusiones finales dependientes de Capítulo IV y Capítulo V.
(Ver Tabla 1.2 en el Capítulo I, sección 1.11).

CONCLUSIONES

(Por completar con los resultados finales de la investigación. Estructura sugerida:)

1. (Conclusión sobre el gap cerrado: el sistema integrado de cuatro capas constituye una propuesta académica para unificar predicción GBDT, detección de anomalías, explicabilidad SHAP y generación de reportes LLM+RAG sobre un dataset agroexportador integrado, trazable y compuesto por datos reales y datos reales agregados, proxies documentados y sintéticos controlados.)
2. (Conclusión sobre métricas alcanzadas: completar solo después de ejecutar el entrenamiento final sobre el dataset integrado y reportar PR-AUC, F1, precisión, estabilidad SHAP, cobertura de evidencia RAG y tiempo-a-decisión sin sobreafirmar resultados preliminares.)
3. (Conclusión sobre validación de hipótesis H1a-H1e: aceptar, rechazar o declarar inconclusa cada subhipótesis según evidencia reproducible.)
4. (Conclusión sobre gobernanza: describir cómo trazabilidad, documentación y supervisión humana se alinean con principios del D.S. 115-2025-PCM, Normas buenas prácticas de gestión de riesgo de modelos.)
5. (Conclusión sobre aporte al campo: redactar solo después de contrastar resultados finales con literatura comparable y con las limitaciones del dataset integrado.)

CONCLUSIONS

(To be completed after the final integrated-dataset experiments. Suggested structure:)

1. (Conclusion on the research gap: the four-layer system integrates GBDT prediction, anomaly detection, SHAP explainability, and RAG-based report generation on a traceable integrated agro-export dataset.)
2. (Conclusion on metrics: complete only after the final run, reporting PR-AUC, F1, precision, recall, SHAP stability, RAG evidence coverage, and time-to-decision without overclaiming preliminary results.)
3. (Conclusion on H1a-H1e: accept, reject, or mark each hypothesis as inconclusive based on reproducible evidence.)
4. (Conclusion on governance: describe how traceability, documentation, and human oversight are implemented as design principles, without claiming certification.)

RECOMENDACIONES

1. **Para implementadores:** Se recomienda iniciar el despliegue del sistema con el módulo de predicción GBDT (Gradient Boosting Decision Trees - Decisión de Aumento de Gradiente) y el módulo de explicabilidad SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) antes del componente LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)+RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación), siguiendo el principio de implementación incremental que reduce la deuda técnica (Sculley et al., 2015) y permite validar cada componente independiente.
2. **Para empresas agroexportadoras:** Antes de adoptar el sistema en producción, se recomienda elaborar Datasheets for Datasets (Gebru et al., 2021) para los datasets de entrenamiento y Model Cards (Mitchell et al., 2019) para los modelos XGBoost, detectores de anomalías y LLM+RAG.
3. **Para futuros investigadores:** Se recomienda extender la evaluación del sistema con un diseño experimental longitudinal que capture el efecto del tiempo en precios, volúmenes, clima y comportamiento exportador, utilizando ventanas temporales y fuentes agroexportadoras reales.
4. **Para entidades públicas y sectoriales:** Se recomienda promover guías técnicas de IA explicable y trazabilidad para sistemas de supervisión de procesos productivos, tomando como referencia marcos nacionales e internacionales de gobernanza de IA.
5. **Para la academia:** Se recomienda replicar el estudio con datos reales de una empresa agroexportadora colaboradora (bajo acuerdo de confidencialidad) para ampliar la muestra de evaluación con supervisores operativos y responsables de calidad, e incorporar métricas de sesgo y robustez según las directrices de evaluación de ADBench (Han et al., 2022).

GLOSARIO DE TÉRMINOS

ADBench (*Anomaly Detection Benchmark*): Benchmark sistemático para evaluación comparativa de algoritmos de detección de anomalías, propuesto por Wang et al. (2022), que cubre 57 datasets y 30 algoritmos bajo tres niveles de supervisión.

Alucinación (LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)): Fenómeno en el que un modelo de lenguaje genera texto en forma pero incorrecto en contenido, incluyendo afirmaciones factuales erróneas, citas inexistentes o cifras fabricadas.

AUC-PR (*Area Under the Precision-Recall Curve*): Métrica de evaluación para clasificadores en datasets desbalanceados; a diferencia de AUC-ROC, es más adecuada para la distribución de clases y penaliza los falsos positivos de forma más relevante en contextos de fraude y anomalías raras.

BAF Benchmark (*Bank Account Fraud*): Dataset tabular de referencia para fraude bancario con drift temporal y desbalance de clases, publicado por Wang et al. (2022). En esta tesis se considera únicamente como benchmark metodológico complementario para evaluar robustez tabular, no como validación de dominio agroexportador.

CatBoost: Algoritmo GBDT (Gradient Boosting Decision Trees - Árboles de Decisión de Aumento de Gradiente) desarrollado por Yandex (Prokhorenkov, 2018) que resuelve el problema de target leakage en variables categóricas mediante Ordered Boosting.

Concept Drift: Cambio en la distribución estadística de los datos a lo largo del tiempo que degrada el rendimiento de modelos entrenados con datos particularmente relevante en detección de fraude y anomalías operativas.

Deep SVDD (*Deep Support Vector Data Description*): Método de detección de anomalías basado en redes neuronales que aprende una hipersfera en el espacio latente que contiene los datos normales (Ruff et al., 2018).

ECOD (**Empirical Cumulative Distribution Outlier Detection - Detección de Anomalías por Distribución Acumulada Empírica**) (*Empirical Cumulative Distribution Functions Outlier Detection*): Detector de anomalías sin parámetros basado en distribuciones empíricas acumuladas (Li et al., 2022), no requiere ajuste de hiperparámetros a calibrar.

EU AI Act (*Reglamento (UE) 2024/1689*): Reglamento europeo de inteligencia artificial que clasifica los sistemas de IA por nivel de riesgo y establece obligaciones de transparencia y explicabilidad en el Artículo 13 para sistemas de alto riesgo.

GBDT (*Gradient Boosting Decision Trees*): Familia de algoritmos de aprendizaje supervisado que construyen modelos predictivos mediante la combinación de árboles de decisión débiles, minimizando una función de pérdida mediante descenso de gradiente funcional.

Isolation Forest: Algoritmo de detección de anomalías no supervisado (Liu et al., 2008) que aísla anomalías mediante particionamiento aleatorio de los datos, con complejidad computacional $O(n)$.

LightGBM: Algoritmo GBDT de Microsoft (Ke et al., 2017) que acelera el entrenamiento hasta 20× mediante Gradient-based One-Side Sampling y uso de datos basados en histogramas.

LLM (*Large Language Model*): Modelo de lenguaje de gran tamaño entrenado en corpus masivos de texto para aprender distribuciones probabilísticas de secuencias de tokens, capaz de realizar tareas de generación, resumen y razonamiento en lenguaje natural.

LOF (**Local Outlier Factor - Factor de Anomalía Local**) (*Local Outlier Factor*): Detector de anomalías basado en densidad local relativa (Breunig et al., 2000) que cuantifica el grado de anomalía de un punto comparando su densidad con la de sus vecinos k-NN.

MLOps (*Machine Learning Operations*): Conjunto de prácticas para gestionar el ciclo de vida completo de modelos ML en producción, incluyendo CI/CD, monitoreo de drift, automatización de reentrenamiento y trazabilidad de versiones.

NIST AI RMF: Framework de gestión de riesgo para sistemas de IA publicado por el Instituto Nacional de Estándares y Tecnología de EE.UU. (2023), organizado en cuatro funciones: Govern, Map, Measure y Manage.

PR-AUC (**Precision-Recall Area Under the Curve - Área Bajo la Curva de Precisión y Exhaustividad**): Ver AUC-PR.

PyOD (*Python Outlier Detection*): Librería de Python que implementa más de 40 algoritmos de detección de outliers con una API estandarizada compatible con scikit-learn (Zhao et al., 2019).

RAG (**Retrieval-Augmented Generation - Generación Aumentada por Recuperación**) (*Retrieval-Augmented Generation*): Arquitectura para modelos de lenguaje que separa el conocimiento factual del modelo generativo, recuperando documentos relevantes de una base de conocimiento externa para anclar las predicciones y mitigar alucinaciones.

Resolución SBS N° 053-2023: Resolución de la Superintendencia de Banca, Seguros y AFP del Perú que establece lineamientos de gestión de riesgos para entidades supervisadas. En esta tesis se utiliza como referencia nacional de buenas prácticas para trazabilidad, validación y monitoreo, no como validación directa para empresas agroexportadoras.

ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*): Conjunto de métricas para evaluación automática de resúmenes y textos generados comparando la superposición de n-gramas con un texto de referencia humano.

SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Shapley) (*SHapley Additive exPlanations*): Marco de explicabilidad post-hoc que a feature una contribución marginal promediada sobre todas las coaliciones posibles, garantizando consistencia axiomática (Lundberg & Lee, 2017).

SHAP Stability Index: Métrica de coherencia de explicaciones SHAP entre instancias similares, que certifica que el modelo asigna importancias a features semejantes, requisito en contextos forenses.

TFT (Temporal Fusion Transformer): Arquitectura de Transformer para forecasting multi-horizonte interpretable con covariables exógenas, mecanismo de predicción por cuantiles (Lim et al., 2021).

TreeSHAP: Algoritmo exacto para el cálculo de valores SHAP en modelos basados en árboles, con complejidad $O(TLD^2)$, que hace viable la explicabilidad en producción con millones de transacciones.

XGBoost (eXtreme Gradient Boosting): Implementación escalable de gradient boosting (Chen & Guestrin, 2016) con regularización L1/L2, manejo nativo de faltantes y paralelización por columnas; baseline universal en competencias de ML con datos tabulares.

REFERENCIAS BIBLIOGRÁFICAS

Almalki, F., & Masud, M. (2025). *Financial fraud detection using explainable AI and stacking ensemble methods*. arXiv preprint arXiv:2505.10050.

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Sinha, R., & Bergmeir, C. (2024). *Chronos: Learning the language of time series*. arXiv:2403.07815.

Arik, S. O., & Pfister, T. (2021). TabNet: Attentive interpretable tabular learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(8) <https://doi.org/10.1609/aaai.v35i8.16842>

Barclays Research. (2025). *Beyond the black box: Interpretability of LLMs in finance*. arXiv preprint arXiv:2505.24650.

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *ACM SIGMOD Record*, 29(4) <https://doi.org/10.1145/342009.335388>

Center for Audit Quality. (2024). *Auditing in the age of generative AI*. CAQ. https://thecaq.org/wp-content/uploads/2024/04/caq_auditing-in-the-age-of-generative-ai_2024-04.pdf

Challu, C., Olivares, K. G., Oreshkin, B., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2022). N-HiTS: Neural hierarchical interpolation for time series forecasting. *Advances in Neural Information Processing Systems*, 35. (arXiv:2201.12886)

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. <https://doi.org/10.1145/3458723>

Gorishniy, Y., Rubashevskiy, I., Khurlov, V., & Babenko, A. (2021). Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems*, 34 (NeurIPS), 8946–8959.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on tabular data? *Advances in Neural Information Processing Systems* 35 (NeurIPS), 507–520.

Han, X., Hu, Y., Venevdev, L., Liu, M., Wen, Q., & Zhang, Y. (2022). ADBench: Anomaly detection benchmark. *Advances in Neural Information Processing Systems*, 35. (arXiv:2201.12886)

Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Jiang, X., & Sontag, D. (2022). TabLLM: Few-shot classification of tabular data with large language models. arXiv preprint arXiv:2210.10723.

Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 19 <https://doi.org/10.18637/jss.v027.i03>

Jesus, S., Pombal, J., Alves, D., Cruz, A., Saleiro, P., Ribeiro, R. P., Gama, J., & Bizarro, P. (2022). *Turning the tables: Biased, imbalanced, dynamic tabular data evaluation*. arXiv preprint arXiv:2211.13358. [NeurIPS 2022]

Kadir, M. A., Macharla Vasu, S. S., Nair, S. S., & Sonntag, D. (2025). AuditCopilot: Leveraging LLMs for fraud detection in double-entry bookkeeping. arXiv:2512.02726. <https://doi.org/10.48550/arXiv.2512.02726>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* 30 (NeurIPS), 3146–3154.

Kreuzberger, D., Kühl, N., & Hirschl, G. (2022). MLOps: Overview, definition, and architecture. *IEEE Access*, 10, 8345–8360. <https://doi.org/10.1109/ACCESS.2022.3197550>

Leocádio, D., et al. (2024). *Continuous auditing artificial intelligence framework*. [Pending venue publication]

Lewis, P., Perez, E., Piktus, A., Schwenk, H., Schwab, C., Yeh, C., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 9457–9474. <https://doi.org/10.18653/v1/2020.emnlp-main.727>

Li, Z., Zhao, Y., Hu, X., Botta, N., Ionescu, C., & Chen, G. H. (2022). ECOD: Unsupervised outlier detection using empirical cumulative distribution function. *Transactions on Knowledge and Data Engineering*, 35(12), 12181–12193. <https://doi.org/10.1109/TKDE.2022.3159580>

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Conference on Learning Representations (ICLR)*. (arXiv:1912.09300)

Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. *Proceedings of the Workshop on Text Summarization Branches Out (ACL 2004)*

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)* <https://doi.org/10.1109/ICDM.2008.17>

Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted transformers are effective for time series forecasting. *Conference on Learning Representations (ICLR)*.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 4774.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAccT)*, 220–229. <https://doi.org/10.1145/3287560.3287596>

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)*. NIST. <https://doi.org/10.6028/NIST>

Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with transformers. *International Conference on Learning Representations (ICLR)*.

Oreshkin, B. N., Carpov, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 4799–4808. <https://doi.org/10.5555/3524938.3525255>

Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, 311–318. <https://doi.org/10.3115/1073083.1073135>

Park, S. (2024). *LLMs for anomaly validation and report generation in financial systems*. arXiv preprint arXiv:2403.19735.

Patel, R., Khan, F., Silva, B., & Shaturae, J. (2024). AI-driven continuous auditing and real-time financial monitoring. *International Research Journal of Modern Engineering Technology and Science*.

Parlamento Europeo y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de Inteligencia Artificial)*. Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/eli/reg/2024/1689>

Prenio, J., & Yong, J. (2024). *Managing explanations: How regulators can address AI explainability*. Bank for International Settlements, Financial Stability Report. <https://www.bis.org/fsi/fsipapers24.pdf>

Presidencia del Consejo de Ministros. (2025, septiembre). *Decreto Supremo N° 115-2025-PCM: Reglamento de la Ley N° 31814*. <https://busquedas.elperuano.pe>

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 6638–6648. <https://doi.org/10.5555/3327757.3327790>

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>

Ruff, L., Kauffmann, J. R., Vandermeulen, R. A., Montavon, G., Samek, W., Klotz, M., Dickhaus, T., & Müller, K.-R. (2018). Deep one-class classification. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 4393–4402.

Schneider, J., et al. (2025). Retrieval-augmented generation (RAG). *Business & Information Systems Engineering*. <https://doi.org/10.1007/s12599-025-0094-4>

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., & Young, M. (2015). Hidden technical debt in machine learning systems. *Proceedings of the 28th International Conference on Neural Information Processing Systems (NIPS) Workshop*.

Superintendencia de Banca, Seguros y AFP. (2023). *Resolución SBS N° 053-2023: Reglamento de gestión de riesgos de modelo*. Lima, Perú. <https://www.sbs.gob.pe/>

Taylor, S. J., & Letham, B. (2017). *Forecasting at scale*. PeerJ Preprints. <https://doi.org/10.7287/peerj.preprints.3190v2>

Thanathamathsee, P., et al. (2024). SHAP-instance weighting and anchor explainable AI: Enhancing XGBoost for financial fraud detection. *Emerging Sci* 8(6). <https://doi.org/10.28991/ESJ-2024-08-06-024>

Tsai, C.-P., et al. (2025). *LLM-based anomaly detection in tabular data*. [Pending venue publication]

Gómez, A., López, B., & Sánchez, C. (2025). *Hallucination detection and mitigation in large language models*. arXiv preprint arXiv:2601.09929.

Wang, L., Chen, M., & Zhang, H. (2025). Financial statement fraud detection through an integrated machine learning and explainable AI framework. *Journal of Financial Management*, 19(1), 13. <https://doi.org/10.3390/jrfm19010013>

Silva, R., Santos, M., & Costa, J. (2025). Explainable AI for forensic analysis: A comparative study of SHAP and LIME in intrusion detection models. *Applied Artificial Intelligence* 15(13), 7329. <https://doi.org/10.3390/app15137329>

Waltersdorfer, L., Ekaputra, F. J., Miksa, T., & Sabou, M. (2024). AuditMAI: Towards an infrastructure for continuous AI auditing. arXiv preprint arXiv:2406.14243 <https://doi.org/10.48550/arXiv.2406.14243>

Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence* 11121–11128. <https://doi.org/10.1609/aaai.v37i9.26317>

Zhao, Y., Nasrullah, Z., & Li, Z. (2019). PyOD: A Python toolbox for scalable outlier detection. *Journal of Machine Learning Research*, 20(96), 1–7.

ANEXOS

ANEXOS

Anexo A — Protocolo de Evaluación de Usabilidad

Versión 1.0 — 2026-05-17. Aprobar antes de iniciar reclutamiento de participantes.

A.1 Objetivo del experimento

El experimento de usabilidad mide el impacto del sistema integrado de supervisión operativa en la **eficiencia (VD4 — tiempo-a-decisión)**, **comprensibilidad (VD5 — Likert)** y **trazabilidad documental (VD5)** frente al uso de componentes aislados. Constituye la fuente principal de evidencia para contrastar la sub-hipótesis H1e (Capítulo I §1.4).

A.2 Diseño experimental

Tipo: Cuasi-experimental con diseño within-subjects (apareado) y orden contrabalanceado.

Cada participante ejecuta las mismas tareas en dos condiciones:

- **Condición A — Sistema integrado:** pipeline de 4 capas con alerta + score + vector SHAP (SHapley Additive exPlanations - Explicaciones Aditivas de Modelos) + reporte LLM (Large Language Model - Modelo de Lenguaje de Gran Tamaño)+RAG (Retrieval-Augmented Generation - Generación Aumentada por Recuperación).
- **Condición B — Componentes aislados:** alerta + score crudo del detector, sin SHAP, sin reporte narrativo (solo tabla y visualización técnica).

La mitad de los participantes inicia con A y la otra mitad con B, asignación aleatorizada con `np.random.seed(42)`. Entre ambas condiciones se intercala de 5 minutos y una tarea distractora (sopa de letras) para reducir efectos de arrastre.

A.3 Tareas evaluadas

Cada condición presenta el mismo bloque de 10 alertas (5 positivas reales o verificadas por regla, 3 negativas reales, 2 ambiguas) extraídas del conjunto de datos agroexportador integrado o de escenarios controlados derivados de este. Para cada alerta, el participante:

1. **Tarea T1 — Clasificación:** decide si la alerta corresponde a una anomalía operativa real (sí/no/dudoso).
2. **Tarea T2 — Justificación:** en una oración (máx. 200 caracteres) indica la variable que justifica la decisión.
3. **Tarea T3 — Comprensión:** responde Likert 1–5 sobre cuán comprensible resultó la alerta.

Al finalizar el bloque de 10 alertas, completa un cuestionario post-bloque (SUS adaptado + preguntas abiertas).

A.4 Métricas registradas automáticamente

Métrica	Fuente	Resolución
Tiempo apertura alerta → decisión	Log JavaScript de la plataforma	milisegundos
Tiempo total bloque	Log JavaScript	segundos
Clasificación del participante	Formulario	sí / no / dudoso
Justificación textual	Formulario	texto libre
Likert comprensión	Formulario	1–5
Versión del sistema	Variable de configuración	string
Identificador de alerta	Variable	string

A.5 Criterios de inclusión y exclusión de participantes

Inclusión:

- (a) Estudiantes de últimos ciclos (≥ 9º semestre) o egresados de Ingeniería de Sistemas, Ingeniería Industrial o Agronomía con formación comprobada: control de calidad o auditoría de sistemas; o
- (b) Profesionales y técnicos con experiencia en supervisión de operaciones, control de calidad, auditoría de sistemas o gestión logística en el sector agrario.
- Mayores de 18 años.
- Aceptación de consentimiento informado firmado.

Exclusión:

- Participación previa en el diseño, desarrollo o entrenamiento de cualquier capa del sistema evaluado.
- Conflicto de interés directo declarado.
- Discapacidad visual no corregible que impida la lectura del dashboard.

A.6 Tamaño de muestra y reclutamiento

Tamaño meta: N = 10 participantes (documentar formalmente como un estudio piloto especializado de usabilidad). Un tamaño N = 10 permite una detallada de la eficiencia temporal y cualitativa sin pretensiones de generalización estadística a gran escala, pero con alta representatividad técnica.

Reclutamiento: El estudio se limita a **grupos cerrados de testers con conocimiento especializado en el área** bajo invitación directa (no abierta al público). La convocatoria se realiza por invitación formal a través de la Escuela de Ingeniería de Sistemas de la UNSA y contactos en empresas agroexportadoras de Ica y La Libertad coordinadas por el asesor, garantizando el perfil técnico de los evaluadores.

A.7 Procedimiento detallado (sesión por participante, ~45 minutos)

Paso	Duración	Contenido
1	5 min	Bienvenida + consentimiento informado firmado
2	5 min	Tutorial guiado de la plataforma (alerta de ejemplo)
3	12 min	Bloque 1 — Condición A o B (según contrabalanceo)
4	5 min	Descanso + tarea distractora
5	12 min	Bloque 2 — Condición contraria
6	5 min	Cuestionario final SUS + preguntas abiertas
7	1 min	Cierre + agradecimiento

A.8 Consentimiento informado (texto base)

Por la presente confirmo que:

1. He sido informado sobre el propósito del estudio: evaluar la usabilidad de un sistema de supervisión operativa con IA explicable.
2. Comprendo que mi participación es voluntaria y puedo retirarme en cualquier momento sin justificación ni consecuencia.
3. Comprendo que mis respuestas son anónimas. Solo el investigador principal accederá a los datos, que se almacenarán cifrados y se eliminarán al finalizar la tesis (julio 2027).
4. Acepto que se registre el tiempo de mis respuestas y las opciones seleccionadas para análisis estadístico agregado.
5. Comprendo que no recibiré evaluación individual ni se compartirán mis resultados con terceros.
6. Acepto participar en una sesión de aproximadamente 45 minutos.

Nombre:

Fecha:

Firma:

A.9 Cuestionario post-bloque

Bloque I — Comprensión percibida (Likert 1–5)

#	Ítem	1	2	3	4
1	Entendí claramente por qué el sistema marcó cada alerta				
2	La información presentada me ayudó a tomar una decisión				
3	Las variables explicativas fueron suficientes				
4	El reporte generado fue útil para justificar mi decisión				
5	Confío en la decisión del sistema				

Bloque II — Tiempo y carga cognitiva (Likert 1–5)

#	Ítem	1	2	3	4
6	Me tomó mucho tiempo entender cada alerta (1) — Fui rápido (5)				
7	Tuve que esforzarme mucho mentalmente				
8	Me sentí seguro al decidir				

Bloque III — Adaptación SUS (10 ítems Likert 1–5)

1. Creo que me gustaría usar este sistema frecuentemente.
2. Encontré el sistema innecesariamente complejo.
3. Pensé que el sistema fue fácil de usar.
4. Necesitaría el apoyo de un experto técnico para usar este sistema.
5. Las funciones del sistema están bien integradas.
6. Hay demasiada inconsistencia en este sistema.
7. La mayoría aprendería a usar este sistema rápidamente.
8. Encontré el sistema muy engorroso.
9. Me sentí muy confiado al usar el sistema.
10. Necesitaría aprender muchas cosas antes de usar el sistema.

Bloque IV — Preguntas abiertas

1. ¿Qué fue lo más útil del sistema en esta sesión?
2. ¿Qué información agregaría o quitaría?
3. ¿En qué situación operativa real este sistema sería más valioso?

A.10 Variables registradas para análisis

Variable	Tipo	Origen
participant_id	string anónimo	Generado
order	{AB, BA}	Aleatorización
condition	{integrated, isolated}	Variable independiente
alert_id	string	Dataset
gt_label	{0, 1}	Dataset (oculto al participante)
user_decision	{yes, no, dunno}	Formulario
time_to_decision_ms	int	Log JavaScript
likert_comprehension	1–5	Cuestionario
justification_text	string	Formulario
sus_score	0–100	Cálculo SUS

A.11 Plan de análisis estadístico

1. **Tiempo-a-decisión (VD4-a):** t de Student apareado integrado vs. aislado; Wilcoxon si Shapiro-Wilk rechaza normalidad. Reportar media $\pm$ DE, IC95% dz.
2. **Comprensión Likert (VD4-b):** Wilcoxon signed-rank apareado.
3. **Decisión correcta (VD4-c):** McNemar sobre pares concordantes/discordantes.
4. **SUS:** comparación de medias con Mann-Whitney U.
5. **Análisis cualitativo de respuestas abiertas:** análisis temático con doble codificación independiente.

A.12 Almacenamiento y privacidad de datos

- Datos almacenados en archivo CSV cifrado con clave conocida solo por el investigador.
- Identificadores anónimos, sin nombre, correo ni datos demográficos sensibles.
- Backup en disco duro institucional UNSA.
- Eliminación de datos crudos al cierre del proyecto (julio 2027).
- Resultados agregados publicados en la tesis y en el repositorio GitHub.

A.13 Aprobación ética

El protocolo se somete a revisión del asesor de tesis (Dr. Víctor Manuel Cornejo Aparicio) y, si la Escuela de Ingeniería de Sistemas dispone de comité de aprobación formal antes del reclutamiento.

Anexo A — versión 1.0 — 2026-05-17. Sometido a revisión final antes de ejecutar el estudio.

Anexo B - Model Cards

Este anexo documenta los modelos de la arquitectura bajo el enfoque de dataset agroexportador integrado versionado.

B.1 Dataset de referencia

Los modelos se entrenan y evalúan sobre un dataset integrado compuesto por:

- datos reales observados de SUNAT/ADUANET y dataset real local;
- datos reales agregados de Trade Map, SISAP/MIDAGRI y BCRP;
- proxies climaticos, logísticos y sanitarios;
- datos sinteticos controlados solo para escenarios auxiliares, balanceo o etiquetas experimentales.

Subgrupos obligatorios:

Producto	Estado
Palta	Nucleo.
Uva	Nucleo.
Arandano	Nucleo.
Esparrago	Secundario condicionado.
Cacao	Excluido.

B.2 Model Card - Prediccion tabular

Campo	Especificacion
Modelos	XGBoost, LightGBM.
Objetivo	Estimar precio o volumen esperado.
Entradas	Variables comerciales, macro, internas, climaticas, logisticas y sanitarias.
Riesgos	Proxies agregados pueden no representar embarques individuales.
Mitigacion	Registrar fuente, granularidad y tipo metodologico por variable.

B.3 Model Card - Deteccion de anomalias

Campo	Especificacion
Modelos	Isolation Forest, LOF, ECOD, ensemble.
Objetivo	Producir score de anomalia.
Entradas	Variables procesadas y residuos de prediccion si aplica.
Riesgos	Etiquetas de anomalia pueden ser derivadas o sinteticas.
Mitigacion	Separar resultados reales, proxy y sinteticos; priorizar PR-AUC en clases desbalanceadas.

B.4 Model Card - SHAP/TreeSHAP

Campo	Especificacion
Metodo	SHAP/TreeSHAP.
Objetivo	Explicar contribucion de variables al score o prediccion.
Uso	Top-k variables por alerta.

Campo	Especificacion
Riesgo	Interpretar SHAP como causalidad.
Mitigacion	Reportar como atribucion del modelo.

B.5 Model Card - Reportes RAG/LLM

Campo	Especificacion
Metodo	LLM restringido por RAG.
Objetivo	Redactar reporte tecnico trazable.
Entradas	Registro, modelo, score, umbral, SHAP, fuente y evidencia recuperada.
Riesgo	Alucinacion numerica o causal.
Mitigacion	Validar que cada cifra del reporte exista en evidencia estructurada.

Anexo C - Datasheet del Dataset Agroexportador Integrado

Estandar aplicado: Datasheets for Datasets (Gebru et al., 2021).
Version metodologica: v2.0 integrada.
Estado: actualizado al panorama de fuentes reales, agregadas, proxies y sinteticas controladas.

C.1 Motivacion

El dataset se construye para entrenar y evaluar un sistema integrado de supervision operativa con IA explicable aplicado a agroexportaciones peruanas de la version inicial basada en un dataset sintetico, esta version adopta un enfoque integrado y trazable:

1. Datos reales observados de exportacion.
2. Datos reales agregados de mercado y contexto.
3. Proxies publicos para clima, logistica y sanidad.
4. Datos sinteticos controlados solo para escenarios auxiliares, balanceo o etiquetas experimentales.

El proposito es permitir evaluacion tecnica, explicabilidad SHAP y reportes RAG sin ocultar el origen ni la granularidad de cada variable.

C.2 Composicion

Productos:

Producto	HS	Estado
Palta	080440	Nucleo.
Uva	080610	Nucleo.
Arandano	081040	Nucleo.
Esparrago	070920	Secundario condicionado.
Cacao	No aplica al nucleo	Excluido por baja representatividad.

Fuentes:

Tipo	Fuente	Ruta local	Granularidad
Real observada	SUNAT/ADUANET	data/sunat/ , codex-revision/data_raw/aduanet_bases	Embarque o serie adu.
Real observada/auditada	Dataset local	data/dataset_real_v1.csv	Registro transaccional
Real agregada	Trade Map	data-trademap/export_*	Producto-destino-anic
Real agregada	SISAP/MIDAGRI	codex-revision/data_processed/sisap_midagri/	Producto-mes-varieda
Real agregada	BCRP	data/bcrp/ , codex-revision/data_raw/bcrp/	Mes.
Proxy	NASA/SENAMHI/NDVI	codex-revision/data_raw/nasa_power , data/vegetation/	Region-mes.
Proxy	APN/OSITRAN	codex-revision/data_raw/apn_* , codex-revision/data_raw/ositran_*	Puerto-mes.
Proxy/contexto	SENASA/FDA/RASFF	codex-revision/data_raw/senasa , fda , rasff	Producto/destino/mes
Sintetica controlada	Dataset sintetico	data/dataset_agro_sintetico_v1.csv	Escenario experimenta

C.3 Variables principales

Variable	Tipo	Fuente preferida	Etiqueta
producto	categoria	SUNAT/dataset real	real_observada
hs	string	SUNAT/Trade Map	real_observada
fecha	fecha	SUNAT/dataset real	real_observada
periodo_mes	fecha mensual	derivada	derivada
volumen_kg	numerica	SUNAT/dataset real	real_observada
valor_fob_usd	numerica	SUNAT	real_observada
precio_kg_usd	numerica	FOB/kg o dataset real	derivada
destino_mercado	categoria	SUNAT/Trade Map	real_observada
sisap_precio_prom	numerica	SISAP	real_agregada
sisap_volumen	numerica	SISAP	real_agregada
tipo_cambio_pen_usd	numerica	BCRP	real_agregada
temperatura_max_c	numerica	NASA/SENAMHI	proxy
precipitacion_mm	numerica	NASA/SENAMHI	proxy
carga_portuaria_mes	numerica	APN/OSITRAN	proxy
alertas_sanitarias_mes	numerica	SENASA/FDA/RASFF	proxy
etiqueta_anomalia	binaria	regla/modelo/dataset	derivada o sintetica
tipo_anomalia	categoria	regla/modelo/dataset	derivada o sintetica
regla_inyeccion	texto	generacion experimental	sintetica

C.4 Datos sinteticos controlados

Los datos sinteticos no sustituyen a las fuentes reales. Se permiten para:

- Balancear clases de anomalías en entrenamiento.
- Simular escenarios de supervisión.
- Probar reportes SHAP/RAG.
- Crear etiquetas experimentales cuando no existe etiqueta oficial de anomalía.

Reglas de inyección permitidas:

Tipo	Variables afectadas	Uso
Precio	precio_kg_usd , residuo de precio	Outliers comerciales.
Volumen	volumen_kg	Cambios atípicos de escala.
Clima	temperatura, precipitacion	Escenarios agroclimáticos.
Logística	días_logísticos , carga portuaria	Demoras o presión portuaria.
Calidad	merma_pct , cumplimiento	Escenarios de deterioro o riesgo.

Toda fila o variable sintética debe tener `origen_dato = sintetica` y `regla_inyeccion` no vacía.

C.5 Preprocesamiento

El pipeline debe:

- Homologar productos y HS.
- Excluir cacao del dataset final.
- Mantener esparrago como secundario si pasa validación.
- Convertir fechas a `YYYY-MM-DD` y `YYYY-MM`.
- Preservar `fuelle`, `archivo_origen`, `granularidad` y `tipo_variable`.
- Separar train/validation/test de forma temporal.
- Evitar que datos sintéticos o SMOTE entren al test final real.

C.6 Usos previstos

- Entrenamiento de modelos tabulares.
- Detección de anomalías.
- Explicabilidad SHAP.
- Generación de reportes RAG.
- Análisis de trazabilidad de alertas.
- Soporte documental para metodología y anexos.

C.7 Usos no previstos

- Tomar decisiones operativas reales sin validación empresarial.
- Afirmar causalidad a partir de SHAP.
- Presentar proxies como observaciones por embarque.
- Presentar datos sintéticos como registros oficiales.

C.8 Consideraciones éticas

El dataset integrado debe proteger trazabilidad y transparencia. Cuando se usen empresas o RUC reales de fuentes públicas, se evaluará anonimizar reportes públicos. Los reportes RAG deben indicar sus fuentes y no emitir recomendaciones fuera de la evidencia recuperada.

Anexo D — Registro de Uso de Herramientas de IA

La presente investigación utilizó herramientas de inteligencia artificial generativa como apoyo en las siguientes actividades: revisión bibliográfica, verificación de coherencia de argumentos, corrección de estilo académico y generación de borradores de secciones específicas. Todas las referencias fueron verificadas manualmente en las fuentes originales. Las decisiones de diseño, la interpretación de resultados y las conclusiones son responsabilidad del investigador.

(Adjuntar registro detallado de las sesiones de uso según los requerimientos de transparencia de la UNSA)

(Documento elaborado con apoyo de herramientas de IA — UNSA Arequipa, 2026)

Anexo E - Resumen general del sistema

Este anexo resume la investigación bajo la versión metodológica actual: sistema integrado de supervisión operativa con IA explicable y dataset agrointegrado.

1. Arquitectura modular

Capa	Funcion
Capa 1	Prediccion tabular con XGBoost/LightGBM.
Capa 2	Deteccion de anomalias con IF + LOF + ECOD.
Capa 3	Explicabilidad con SHAP/TreeSHAP.
Capa 4	Reportes trazables con RAG/LLM.

2. Base de datos

La evaluación final debe basarse en un dataset agroexportador integrado:

- SUNAT/ADUANET y dataset real local como base observada.
- Trade Map como benchmark externo.
- SISAP/MIDAGRI como mercado interno para palta, uva y esparrago.
- BCRP como control macro.
- Clima, logística y sanidad como proxies.
- Sintéticos solo como apoyo experimental.

3. Productos

Producto	Estado
Palta	Nucleo.
Uva	Nucleo.
Arandano	Nucleo.
Esparrago	Secundario condicionado.
Cacao	Excluido.

4. Estado de resultados

Los resultados obtenidos sobre versiones sintéticas o corridas previas deben considerarse preliminares hasta ejecutar el entrenamiento final sob integrado. No se deben presentar como conclusiones finales si no cuentan con reporte de entrenamiento, version de dataset y trazabilidad.

5. Gobernanza y trazabilidad

Cada alerta valida debe incluir:

- dato de origen;
 - version del dataset;
 - modelo y parametros;
 - score y umbral;
 - variables SHAP;
 - fuente recuperada por RAG;
 - reporte generado.
-