

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA
FACULTAD DE INGENIERÍA DE PRODUCCIÓN Y SERVICIOS
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



TESIS
Título de la tesis

Presentado por el bachiller:
Nombres y Apellidos
Para optar el título profesional de
Ingeniero de Sistemas

Asesor:
Dr. Víctor Manuel Cornejo Aparicio

Arequipa – Perú
2026

DEDICATORIA

AGRADECIMIENTOS

PRESENTACIÓN

RESUMEN

Palabras Clave:

ABSTRACT

Key Word:

ÍNDICE DE CONTENIDOS

DEDICATORIA	II
AGRADECIMIENTOS	III
PRESENTACIÓN	IV
RESUMEN	V
ABSTRACT	VI
ÍNDICE DE CONTENIDOS	VII
ÍNDICE DE FIGURAS	X
ÍNDICE DE TABLAS	XI
ÍNDICE DE FORMULAS	XII
INTRODUCCIÓN	XIII
CAPÍTULO I : PLANTEAMIENTO DEL PROBLEMA	1
1.1. Descripción de la Realidad Problemática	1
1.2. Problema principal.	1
1.3. Objetivos	1
1.3.1. Objetivo principal	1
1.3.2. Objetivos específicos	1
1.4. Hipótesis de la investigación.	1
1.5. Variables e Indicadores	1
1.5.1. Variable Independiente	1
1.5.2. Variable Dependiente	1
1.6. Viabilidad de la investigación.	1
1.6.1. Viabilidad técnica	1
1.6.2. Viabilidad operativa.	1
1.6.3. Viabilidad económica.	1
1.7. Justificación e Importancia de la Investigación.	1
	7

1.7.1.	Justificación	1
1.7.2.	Importancia.	2
1.8.	Alcance	2
1.9.	Línea, Tipo y Nivel de la investigación	2
1.9.1.	Línea de la investigación.	2
1.9.2.	Tipo de la investigación.	2
1.9.3.	Nivel de la investigación.	2
1.10.	Técnicas e Instrumentos de Recolección de Información	2
1.10.1.	Técnicas.	2
1.10.2.	Instrumentos.	2
CAPÍTULO II: MARCO TEÓRICO		3
2.1.	Antecedentes de la Investigación	3
2.2.	Estado del Arte	3
2.3.	Marco Conceptual	3
CAPÍTULO III : ELABORACIÓN DE LA PROPUESTA		4
3.1.	Generalidades.	4
3.2.	Esquema de la propuesta	4
3.3.		4
3.4.		4
3.5.		4
CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS		5
4.1.		5
4.2.		5
CONCLUSIONES		6
CONCLUSIONS		7
RECOMENDACIONES		8
GLOSARIO DE TÉRMINOS		9

REFERENCIAS BIBLIOGRÁFICAS	10
ANEXOS	11

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

ÍNDICE DE FORMULAS

INTRODUCCIÓN

CAPÍTULO I : PLANTEAMIENTO DEL PROBLEMA

- 1.1. Descripción de la Realidad Problemática**
- 1.2. Problema principal.**
- 1.3. Objetivos**
 - 1.3.1. Objetivo principal**
 - 1.3.2. Objetivos específicos**
- 1.4. Hipótesis de la investigación.**
- 1.5. Variables e Indicadores**
 - 1.5.1. Variable Independiente**
 - 1.5.2. Variable Dependiente**
- 1.6. Viabilidad de la investigación.**
 - 1.6.1. Viabilidad técnica**
 - 1.6.2. Viabilidad operativa.**
 - 1.6.3. Viabilidad económica.**
- 1.7. Justificación e Importancia de la Investigación.**
 - 1.7.1. Justificación**
 - A. Teórica**
 - B. Económica**

C. Social

1.7.2. Importancia.

1.8. Alcance

1.9. Línea, Tipo y Nivel de la investigación

1.9.1. Línea de la investigación.

1.9.2. Tipo de la investigación.

1.9.3. Nivel de la investigación.

1.10. Técnicas e Instrumentos de Recolección de Información

Técnica	Instrumento	Propósito

1.11. Cronograma

CAPÍTULO II: MARCO TEÓRICO

2.1. Antecedentes de la Investigación

El desarrollo de sistemas de predicción, detección de anomalías y generación de reportes en entornos empresariales ha evolucionado significativamente en los últimos años, impulsado por avances en aprendizaje automático, modelado de series temporales y el uso emergente de modelos de lenguaje.

En el ámbito de los datos tabulares, diversos estudios han demostrado que los métodos basados en Gradient Boosting Decision Trees (GBDT) continúan siendo altamente competitivos. El modelo XGBoost introdujo mejoras significativas en escalabilidad y rendimiento para grandes volúmenes de datos estructurados [1], mientras que LightGBM optimizó el proceso de entrenamiento mediante técnicas como histogram-based learning y reducción de dimensionalidad [2]. Por su parte, CatBoost resolvió de manera eficiente el tratamiento de variables categóricas mediante codificación ordenada, evitando problemas de target leakage [3]. Investigaciones más recientes han evaluado modelos profundos para datos tabulares, concluyendo que arquitecturas como FT-Transformer pueden ser competitivas, aunque no superan consistentemente a los métodos basados en árboles en todos los escenarios [4].

En el campo del modelado de series temporales, los enfoques tradicionales continúan siendo relevantes. El método AutoARIMA permite la selección automática de modelos estadísticos adecuados para forecasting [6], mientras que Prophet facilita la modelación de estacionalidades y tendencias en entornos empresariales [7]. Sin embargo, modelos más recientes como N-BEATS [8], N-HiTS [9] y Temporal Fusion Transformers [10] han demostrado mejoras en la predicción multi-horizonte y la incorporación de variables exógenas, lo cual resulta relevante para sistemas que requieren proyecciones complejas.

En cuanto a la detección de anomalías, el algoritmo Isolation Forest ha sido ampliamente adoptado debido a su eficiencia y capacidad para detectar valores atípicos sin supervisión [11]. Métodos clásicos como Local Outlier Factor (LOF) permiten identificar anomalías basadas en densidad local [12], mientras que enfoques más recientes como Deep SVDD extienden el problema a representaciones profundas [13]. No obstante, estudios comparativos como ADBench evidencian que no existe un algoritmo universalmente superior, y que el rendimiento depende del tipo de anomalía, la calidad de los datos y el nivel de supervisión disponible [14].

En el contexto específico de fraude y auditoría, la literatura reciente destaca desafíos recurrentes como el desbalance extremo de clases, el concept drift y la necesidad de interpretabilidad en los modelos [16]. Asimismo, se ha identificado una transición hacia sistemas de auditoría continua apoyados en inteligencia artificial, capaces de monitorear operaciones en tiempo real y detectar irregularidades de manera proactiva [17]. En este sentido, el uso de datasets sintéticos como el Bank Account Fraud Benchmark ha permitido simular condiciones reales de fraude, incluyendo sesgos y dinámica temporal [15].

De manera complementaria, el uso de modelos de lenguaje (LLMs) ha comenzado a integrarse en tareas de análisis y detección de anomalías. Investigaciones recientes exploran su aplicación en datos tabulares [18] y en auditoría contable mediante sistemas como AuditCopilot, los cuales combinan detección automatizada con generación de explicaciones en lenguaje natural [19]. Sin embargo, estos enfoques aún se consideran complementarios a los modelos tradicionales, especialmente en tareas críticas donde la trazabilidad y la precisión son fundamentales.

Finalmente, el desarrollo de estos sistemas requiere considerar aspectos de gobernanza y calidad, alineados con marcos como el AI Risk Management Framework del NIST [20], así como prácticas de documentación como Datasheets for Datasets [22] y Model Cards [23], que permiten garantizar transparencia, reproducibilidad y control del sesgo en los modelos.

En conjunto, estos antecedentes evidencian que la tendencia actual no se orienta hacia el uso de un único modelo, sino hacia arquitecturas híbridas que integran predicción, detección de anomalías y explicabilidad, soportadas por prácticas de MLOps y evaluación rigurosa. Este enfoque resulta particularmente relevante en entornos empresariales donde la toma de decisiones depende de la confiabilidad y trazabilidad de los resultados.

2.2. Estado del Arte

Autor(es)	Año	Aporte
Autor(es)	Año	Aporte
T. Chen y C. Guestrin	2016	Proponen XGBoost , un modelo de boosting optimizado para datos tabulares, destacando por su escalabilidad y rendimiento en problemas estructurados.

G. Ke et al.	2017	Desarrollan LightGBM , mejorando eficiencia en entrenamiento mediante histogramas y reducción de complejidad computacional.
L. Prokhorenkova et al.	2018	Introducen CatBoost , optimizado para variables categóricas y evitando fuga de información (<i>target leakage</i>).
R. J. Hyndman y Y. Khandakar	2008	Presentan AutoARIMA , método automático para selección de modelos de series temporales.
S. J. Taylor y B. Letham	2017	Proponen Prophet , modelo robusto para forecasting con estacionalidad y tendencia en entornos empresariales.
B. N. Oreshkin et al.	2020	Desarrollan N-BEATS , modelo profundo para series temporales con alta precisión en predicción.
C. Challu et al.	2023	Proponen N-HiTS , arquitectura optimizada para forecasting en horizontes largos.
B. Lim et al.	2021	Introducen Temporal Fusion Transformer (TFT) , modelo interpretable para predicción multi-horizonte.
F. T. Liu et al.	2008	Proponen Isolation Forest , algoritmo eficiente para detección de anomalías sin supervisión.
M. M. Breunig et al.	2000	Introducen LOF , método basado en densidad para detección de outliers locales.
L. Ruff et al.	2018	Presentan Deep SVDD , enfoque profundo para detección de anomalías en espacios complejos.

S. Han et al.	2022	Desarrollan ADBench , benchmark para evaluar algoritmos de detección de anomalías bajo distintos escenarios.
S. Jesus et al.	2022	Proponen Bank Account Fraud Benchmark , dataset realista para evaluación de fraude financiero.
S. Jesus et al.	2025	Realizan revisión sistemática sobre detección de fraude , identificando desafíos como desbalance y drift.
D. Leocádio et al.	2024	Proponen marco conceptual de auditoría con IA , enfocándose en monitoreo continuo y soporte a decisiones.
C.-P. Tsai et al.	2025	Exploran uso de LLMs en detección de anomalías tabulares , ampliando enfoques tradicionales.
M. A. Kadir et al.	2025	Proponen AuditCopilot , integrando LLMs en auditoría contable con generación de explicaciones.
NIST	2023	Define AI Risk Management Framework , estableciendo lineamientos de gobernanza, confiabilidad y riesgo.
T. Gebru et al.	2021	Introducen Datasheets for Datasets , enfoque para documentar datasets y mejorar transparencia.
M. Mitchell et al.	2019	Proponen Model Cards , documentación estructurada para modelos de ML.

2.3. Marco Conceptual

El marco conceptual del presente estudio se sustenta en los principios del aprendizaje automático, análisis de datos y sistemas inteligentes aplicados a entornos empresariales. Se abordan los conceptos clave necesarios para

comprender el diseño de un sistema híbrido orientado a la predicción, detección de anomalías y generación de reportes.

2.3.1 Reconocimiento de patrones

El reconocimiento de patrones es un campo fundamental dentro de la inteligencia artificial que se encarga de identificar regularidades, estructuras o relaciones en los datos. Este proceso permite transformar datos crudos en información útil mediante la identificación de tendencias y comportamientos recurrentes.

En el contexto del aprendizaje automático, el reconocimiento de patrones se realiza a través de modelos que aprenden funciones a partir de datos históricos, permitiendo generalizar hacia nuevos datos no observados. Este proceso es la base para tareas como clasificación, regresión y detección de anomalías [16].

2.3.2 Aprendizaje automático (Machine Learning)

El aprendizaje automático es una disciplina que permite a los sistemas mejorar su desempeño mediante la experiencia, es decir, a través del análisis de datos. Se clasifica en tres tipos principales:

Aprendizaje supervisado: Utiliza datos etiquetados para entrenar modelos predictivos.

Aprendizaje no supervisado: Identifica patrones sin necesidad de etiquetas.

Aprendizaje semi-supervisado: Combina ambos enfoques cuando las etiquetas son limitadas.

Estos enfoques son ampliamente utilizados en aplicaciones empresariales como análisis de clientes, predicción de demanda y detección de fraude [16].

2.3.3 Modelos basados en árboles y Gradient Boosting

Los modelos basados en árboles de decisión son ampliamente utilizados en datos tabulares debido a su interpretabilidad y capacidad para manejar relaciones no lineales. El enfoque de Gradient Boosting combina múltiples árboles débiles para construir un modelo robusto mediante optimización iterativa.

Algoritmos como XGBoost, LightGBM y CatBoost han demostrado alto rendimiento en problemas de predicción estructurada, mejorando aspectos como eficiencia computacional, manejo de datos categóricos y escalabilidad [1]–[3].

2.3.4 Datos tabulares en sistemas empresariales

Los datos tabulares representan la forma más común de almacenamiento en sistemas empresariales, donde cada fila corresponde a una instancia y cada

columna a una variable. Este tipo de datos se encuentra en sistemas como ERP, CRM y bases de datos financieras.

Estudios recientes indican que los modelos basados en árboles siguen siendo una referencia sólida para este tipo de datos, incluso frente a modelos profundos más complejos [4].

2.3.5 Series temporales y predicción

Las series temporales son secuencias de datos ordenadas en el tiempo, utilizadas para analizar tendencias, estacionalidad y comportamiento dinámico. El objetivo principal es predecir valores futuros a partir de datos históricos.

Modelos clásicos como ARIMA permiten capturar relaciones lineales [6], mientras que modelos modernos como Prophet facilitan el modelado de tendencias y estacionalidad [7]. En paralelo, arquitecturas profundas como N-BEATS, N-HiTS y TFT han demostrado mejoras en predicción multi-horizonte y manejo de variables externas [8]–[10].

2.3.6 Detección de anomalías

La detección de anomalías consiste en identificar observaciones que se desvían significativamente del comportamiento esperado. Este proceso es clave en aplicaciones como fraude, monitoreo y auditoría.

El algoritmo Isolation Forest permite detectar anomalías mediante la partición aleatoria del espacio de datos [11], mientras que LOF se basa en la densidad local [12]. En escenarios más complejos, se emplean enfoques profundos como Deep SVDD [13]. Sin embargo, la literatura evidencia que la efectividad depende del contexto y tipo de datos [14].

2.3.7 Detección de fraude y auditoría inteligente

Los sistemas modernos de detección de fraude combinan modelos predictivos, detección de anomalías y reglas de negocio. Estos sistemas enfrentan desafíos como el desbalance de clases y la variabilidad temporal de los datos.

Investigaciones recientes destacan la necesidad de arquitecturas híbridas que integren múltiples enfoques para mejorar la precisión y robustez del sistema [16], [17]. Además, el uso de datasets sintéticos permite simular escenarios reales y evaluar el desempeño de los modelos [15].

2.3.8 Modelos de lenguaje (LLMs) y generación de reportes

Los modelos de lenguaje de gran escala (LLMs) permiten generar texto en lenguaje natural a partir de datos estructurados. En sistemas empresariales, se utilizan para transformar resultados analíticos en reportes comprensibles para usuarios no técnicos.

Sin embargo, su uso debe ser complementario a modelos determinísticos, debido a limitaciones en precisión y trazabilidad [18], [19].

2.3.9 Gobernanza y calidad en sistemas de IA

El desarrollo de sistemas de inteligencia artificial requiere garantizar confiabilidad, transparencia y control del riesgo. El marco de gestión de riesgos del NIST proporciona lineamientos para asegurar estos aspectos [20].

Asimismo, prácticas como Datasheets for Datasets y Model Cards permiten documentar datasets y modelos, mejorando la reproducibilidad y reduciendo sesgos [22], [23]

CAPÍTULO III : ELABORACIÓN DE LA PROPUESTA

3.1. Generalidades.

3.2. Esquema de la propuesta

3.3.

3.4.

3.5.

CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS

4.1.

4.2.

CONCLUSIONES

- 1.
- 2.
- 3.
- 4.
- 5.

CONCLUSIONS

First.

Second.

Third.

Quarter.

Fifth.

RECOMENDACIONES

- 1.
- 2.
- 3.
- 4.
- 5.

GLOSARIO DE TÉRMINOS

REFERENCIAS BIBLIOGRÁFICAS

Pérez, Juan (2017) kxzbvjv lzkxcnzjc

[1] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD), pp. 785–794, 2016.

DOI: <https://doi.org/10.1145/2939672.2939785>

[2] G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," Advances in Neural Information Processing Systems (NeurIPS), 2017.

DOI: <https://doi.org/10.5555/3295222.3295232>

[3] L. Prokhorenkova et al., "CatBoost: unbiased boosting with categorical features," Advances in Neural Information Processing Systems (NeurIPS), 2018.

DOI: <https://doi.org/10.5555/3327757.3327770>

[4] Y. Gorishniy et al., "Revisiting Deep Learning Models for Tabular Data," NeurIPS, 2021.

DOI: <https://doi.org/10.48550/arXiv.2106.11959>

[5] S. Ö. Arik and T. Pfister, "TabNet: Attentive Interpretable Tabular Learning," AAAI, 2021.

DOI: <https://doi.org/10.1609/aaai.v35i8.16826>

[6] R. J. Hyndman and Y. Khandakar, "Automatic Time Series Forecasting," Journal of Statistical Software, vol. 27, no. 3, 2008.

DOI: <https://doi.org/10.18637/jss.v027.i03>

[7] S. J. Taylor and B. Letham, "Forecasting at Scale," The American Statistician, 2017.

DOI: <https://doi.org/10.1080/00031305.2017.1380080>

[8] B. N. Oreshkin et al., "N-BEATS: Neural Basis Expansion Analysis," ICLR, 2020.

DOI: <https://doi.org/10.48550/arXiv.1905.10437>

[9] C. Challu et al., "N-HiTS: Neural Hierarchical Interpolation," AAAI, 2023.

DOI: <https://doi.org/10.1609/aaai.v37i6.25854>

[10] B. Lim et al., "Temporal Fusion Transformers," International Journal of Forecasting, 2021.

DOI: <https://doi.org/10.1016/j.ijforecast.2021.03.012>

[11] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation Forest," IEEE ICDM, 2008.

DOI: <https://doi.org/10.1109/ICDM.2008.17>

[12] M. M. Breunig et al., "LOF: Identifying Density-Based Local Outliers," SIGMOD, 2000.

DOI: <https://doi.org/10.1145/342009.335388>

- [13] L. Ruff et al., “Deep One-Class Classification,” ICML, 2018.
DOI: <https://doi.org/10.48550/arXiv.1802.06360>
- [14] S. Han et al., “ADBench: Anomaly Detection Benchmark,” NeurIPS Datasets, 2022.
DOI: <https://doi.org/10.48550/arXiv.2206.09426>
- [15] S. Jesus et al., “Bank Account Fraud Benchmark,” NeurIPS, 2022.
DOI: <https://doi.org/10.48550/arXiv.2204.13733>
- [16] S. Jesus et al., “Machine Learning for Fraud Detection: A Systematic Literature Review,” Applied Sciences, 2025.
DOI: <https://doi.org/10.3390/app15063000>
- [17] D. Leocádio et al., “Artificial Intelligence in Auditing,” Administrative Sciences, 2024.
DOI: <https://doi.org/10.3390/admsci14010012>
- [18] C.-P. Tsai et al., “Large Language Models for Tabular Anomaly Detection,” ICLR, 2025.
DOI: <https://doi.org/10.48550/arXiv.2402.XXXX>
- (Nota: preprint → DOI tipo arXiv, confirmar versión final)
- [19] M. A. Kadir et al., “AuditCopilot: Leveraging LLMs for Fraud Detection,” 2025.
DOI: <https://doi.org/10.48550/arXiv.XXXX>
- (Nota: preprint → requiere validación final)
- [20] NIST, “AI Risk Management Framework 1.0,” 2023.
DOI: No disponible (documento estándar, no paper científico)
- [21] European Union, “AI Act (Regulation EU 2024/1689),” 2024.
DOI: No disponible (regulación legal)
- [22] T. Gebru et al., “Datasheets for Datasets,” Communications of the ACM, 2021.
DOI: <https://doi.org/10.1145/3458723>
- [23] M. Mitchell et al., “Model Cards for Model Reporting,” FAT Conference*, 2019.
DOI: <https://doi.org/10.1145/3287560.3287596>
- [24] A. Paszke et al., “PyTorch: An Imperative Style,” NeurIPS, 2019.
DOI: <https://doi.org/10.48550/arXiv.1912.01703>
- [25] A. Ratner et al., “Snorkel: Rapid Training Data Creation,” VLDB, 2017.
DOI: <https://doi.org/10.14778/3157794.3157797>

ANEXOS