

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA
FACULTAD DE INGENIERÍA DE PRODUCCIÓN Y SERVICIOS
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



TESIS
Título de la tesis

Presentado por el bachiller:
yoset cozco mauri
Para optar el título profesional de
Ingeniero de Sistemas

Asesor:
Karim Guevara

Arequipa – Perú
2026

DEDICATORIA

AGRADECIMIENTOS

PRESENTACIÓN

RESUMEN

Palabras Clave:

ABSTRACT

Key Word:

ÍNDICE DE CONTENIDOS

DEDICATORIA	II
AGRADECIMIENTOS	III
PRESENTACIÓN	IV
RESUMEN	V
ABSTRACT	VI
ÍNDICE DE CONTENIDOS	VII
ÍNDICE DE FIGURAS	X
ÍNDICE DE TABLAS	XI
ÍNDICE DE FORMULAS	XII
INTRODUCCIÓN	XIII
CAPÍTULO I : PLANTEAMIENTO DEL PROBLEMA	1
1.1. Descripción de la Realidad Problemática	1
1.2. Problema principal.	1
1.3. Objetivos	1
1.3.1. Objetivo principal	1
1.3.2. Objetivos específicos	1
1.4. Hipótesis de la investigación.	1
1.5. Variables e Indicadores	1
1.5.1. Variable Independiente	1
1.5.2. Variable Dependiente	1
1.6. Viabilidad de la investigación.	1
1.6.1. Viabilidad técnica	1
1.6.2. Viabilidad operativa.	1
1.6.3. Viabilidad económica.	1
1.7. Justificación e Importancia de la Investigación.	1
	7

1.7.1.	Justificación	1
1.7.2.	Importancia.	2
1.8.	Alcance	2
1.9.	Línea, Tipo y Nivel de la investigación	2
1.9.1.	Línea de la investigación.	2
1.9.2.	Tipo de la investigación.	2
1.9.3.	Nivel de la investigación.	2
1.10.	Técnicas e Instrumentos de Recolección de Información	2
1.10.1.	Técnicas.	2
1.10.2.	Instrumentos.	2
CAPÍTULO II: MARCO TEÓRICO		3
2.1.	Antecedentes de la Investigación	3
2.2.	Estado del Arte	3
2.3.	Marco Conceptual	3
CAPÍTULO III : ELABORACIÓN DE LA PROPUESTA		4
3.1.	Generalidades.	4
3.2.	Esquema de la propuesta	4
3.3.		4
3.4.		4
3.5.		4
CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS		5
4.1.		5
4.2.		5
CONCLUSIONES		6
CONCLUSIONS		7
RECOMENDACIONES		8
GLOSARIO DE TÉRMINOS		9

REFERENCIAS BIBLIOGRÁFICAS	10
ANEXOS	11

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

ÍNDICE DE FORMULAS

INTRODUCCIÓN

CAPÍTULO I :

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

El sector agroexportador peruano desarrolla operaciones comerciales caracterizadas por la movilización continua de productos agrícolas hacia diferentes mercados internacionales. Estas operaciones generan registros relacionados con fechas de exportación, productos, mercados de destino, valores FOB, pesos netos, cantidad de operaciones, participación por destino y otras variables comerciales que permiten analizar el comportamiento de las exportaciones a lo largo del tiempo.

A estos registros se pueden incorporar variables contextuales provenientes de fuentes oficiales, tales como información de mercados mayoristas, indicadores macroeconómicos y, cuando exista una correspondencia geográfica y temporal válida, datos climáticos, logísticos o sanitarios agregados. Sin embargo, estas fuentes presentan diferencias de estructura, periodicidad, unidad de medida y nivel de agregación, lo que dificulta su integración dentro de un mismo proceso analítico.

Los registros de comercio exterior pueden encontrarse a nivel de declaración o transacción diaria, mientras que las variables macroeconómicas pueden tener frecuencia mensual y otras fuentes contextuales pueden publicarse con periodicidad diaria, semanal o mensual. La integración incorrecta de estas granularidades puede producir duplicidades, asociaciones no justificadas o fuga de información, afectando la validez de los modelos desarrollados.

Además de la fragmentación de fuentes, existe una dificultad analítica para determinar cuándo un valor observado debe considerarse inusual. Por ejemplo, un incremento del valor FOB total o una reducción del volumen exportado no representan necesariamente una anomalía, debido a que pueden corresponder a comportamientos estacionales, cambios de mercado, variaciones en la composición de los destinos o modificaciones propias de una campaña agroexportadora.

Por esta razón, la supervisión analítica no debe limitarse a observar los valores registrados. Es necesario estimar previamente cuál era el comportamiento esperado para un producto y mercado determinados. La diferencia entre el valor observado y el valor esperado permite calcular residuos predictivos que, combinados con indicadores históricos y técnicas de detección multivariable, pueden servir para identificar operaciones o periodos que requieren revisión.

En la presente investigación se consideran dos indicadores principales. El primero es el valor unitario FOB, expresado en dólares

estadounidenses por kilogramo, calculado como la relación entre el valor FOB total y el peso neto exportado. El segundo es el volumen exportado, expresado en kilogramos. Ambos indicadores serán analizados con frecuencia semanal y bajo una unidad de análisis definida por la combinación de producto, mercado de destino y semana.

La predicción de estos indicadores permitirá estimar el valor unitario FOB y el volumen esperado para la siguiente semana. Posteriormente, los residuos obtenidos al comparar los valores esperados con los observados serán incorporados a un conjunto de variables para la detección de anomalías mediante Isolation Forest, Local Outlier Factor y ECOD.

Sin embargo, una puntuación de anomalía no es suficiente para apoyar la supervisión. Los usuarios necesitan comprender qué indicadores presentaron desviaciones, cómo se comparan con el comportamiento histórico y qué variables influyeron en las predicciones. Los modelos de aprendizaje automático pueden producir resultados técnicamente adecuados, pero su uso aislado dificulta interpretar las alertas y verificar el proceso que condujo a su generación.

La explicabilidad mediante SHAP permite interpretar las predicciones generadas por modelos basados en árboles, como XGBoost y LightGBM. Estas explicaciones muestran la contribución de las características utilizadas para elevar o reducir el valor esperado. No obstante, SHAP no establece relaciones causales ni explica directamente el score combinado de todos los detectores no supervisados. Por ello, la interpretación de una alerta debe combinar valores SHAP, residuos predictivos, desviaciones históricas y puntuaciones individuales de los detectores.

Otro problema corresponde a la documentación de las alertas. Cuando los resultados de los modelos, las explicaciones y las fuentes se procesan por separado, resulta difícil reconstruir qué registros, versiones de datos, parámetros y evidencias originaron un reporte. Esta situación limita la auditabilidad y reduce la confianza en el sistema.

Los modelos de lenguaje pueden facilitar la transformación de resultados técnicos en reportes comprensibles. Sin embargo, su uso libre puede introducir cifras, causas o conclusiones no sustentadas. Por esta razón, la generación de reportes debe restringirse a evidencias estructuradas, documentos recuperados y valores verificados mediante controles determinísticos.

En consecuencia, se identifica la necesidad de diseñar e implementar un sistema integrado que articule la recolección y normalización de datos, la predicción del valor unitario FOB y del volumen exportado, la detección multivariable de anomalías, la explicabilidad de las predicciones, la generación controlada de reportes y la trazabilidad completa del proceso.

La investigación se concentrará en palta, uva fresca y arándano. La unidad de análisis será producto por mercado de destino por semana, y el horizonte predictivo será de una semana. El sistema será evaluado como prototipo experimental y no como una solución conectada en tiempo real con los sistemas internos de una empresa agroexportadora.

1.2. Problema principal.

¿En qué medida la implementación de un sistema integrado de inteligencia artificial basado en la predicción semanal del valor unitario FOB y del volumen exportado, la detección multivariable de anomalías, la explicabilidad y la generación automática de reportes trazables mejora la efectividad de la supervisión analítica de operaciones agroexportadoras peruanas respecto del uso de componentes analíticos aislados?

Problemas identificados

1. ¿Cómo integrar registros de comercio exterior y variables contextuales con diferentes estructuras, periodicidades y granularidades dentro de un conjunto de datos semanal trazable?
2. ¿Qué desempeño presentan XGBoost y LightGBM para predecir el valor unitario FOB de la siguiente semana en comparación con modelos base?
3. ¿Qué desempeño presentan XGBoost y LightGBM para predecir el volumen exportado de la siguiente semana en comparación con modelos base?
4. ¿En qué medida la combinación de Isolation Forest, Local Outlier Factor y ECOD permite detectar anomalías multivariables sobre los indicadores y residuos predictivos?
5. ¿Cómo pueden las explicaciones SHAP, los residuos y las desviaciones históricas facilitar la interpretación de las alertas generadas?
6. ¿Cómo generar reportes automáticos sustentados en evidencias estructuradas sin incorporar cifras o afirmaciones no verificables?
7. ¿En qué medida el sistema integrado mejora la comprensión, el tiempo de análisis y la trazabilidad respecto de la presentación aislada de resultados técnicos?

1.3. Objetivos

1.3.1. Objetivo principal

Diseñar, implementar y evaluar un sistema integrado de inteligencia artificial explicable para predecir semanalmente el valor unitario FOB y el volumen exportado, detectar anomalías multivariables, contextualizar las alertas y generar reportes

trazables que apoyen la supervisión analítica de operaciones agroexportadoras peruanas.

1.3.2. Objetivos específicos

1. Identificar, auditar, normalizar e integrar las fuentes de datos de comercio exterior y las variables contextuales seleccionadas, documentando su procedencia, granularidad, cobertura y calidad.
2. Construir un conjunto de datos analítico semanal cuya unidad de análisis corresponda a producto, mercado de destino y semana para palta, uva fresca y arándano.
3. Implementar y evaluar modelos XGBoost y LightGBM para predecir el valor unitario FOB por kilogramo de la siguiente semana.
4. Implementar y evaluar modelos XGBoost y LightGBM para predecir el volumen exportado de la siguiente semana.
5. Implementar un enfoque de detección multivariable de anomalías mediante Isolation Forest, Local Outlier Factor y ECOD, utilizando variables comerciales, temporales y residuos predictivos fuera de muestra.
6. Incorporar explicaciones globales y locales mediante SHAP para interpretar las predicciones y complementar la contextualización de las alertas.
7. Desarrollar un componente de generación automática de reportes mediante recuperación aumentada por información y un modelo de lenguaje, aplicando validación numérica y factual.
8. Evaluar el desempeño predictivo, la capacidad de detección, la comprensión de las alertas, la calidad de los reportes, el tiempo de análisis y la trazabilidad del sistema.

1.4. Hipótesis de la investigación.

1.4.1 Hipotesis general

La implementación de un sistema integrado de inteligencia artificial mejora significativamente la efectividad de la supervisión analítica de operaciones agroexportadoras respecto del uso de componentes analíticos aislados.

1.4.2 Hipótesis Nula (H0)

La implementación de un sistema integrado de inteligencia artificial no produce una mejora significativa en la efectividad de la supervisión analítica de operaciones agroexportadoras respecto del uso de componentes analíticos aislados.

1.4.2 Hipótesis específicas

H1a. Los modelos XGBoost o LightGBM presentan un error absoluto medio significativamente menor que el mejor modelo base para predecir el valor unitario FOB de la siguiente semana.

H1b. Los modelos XGBoost o LightGBM presentan un error logarítmico cuadrático medio significativamente menor que el mejor modelo base para predecir el volumen exportado de la siguiente semana.

H1c. El ensemble de Isolation Forest, Local Outlier Factor y ECOD presenta un F1-Score superior al promedio de sus detectores individuales en un conjunto experimental con anomalías controladas.

H1d. Las alertas acompañadas de explicaciones y reportes trazables producen una mayor comprensión y un menor tiempo de análisis que las alertas presentadas únicamente mediante resultados técnicos aislados.

H1e. El sistema integrado incrementa la proporción de alertas cuyo proceso puede reconstruirse desde los registros de origen hasta el reporte final.

1.5. Variables e Indicadores

1.5.1. Variable Independiente

La variable independiente es el tipo de sistema utilizado para la supervisión analítica de las operaciones agroexportadoras.

Esta variable presenta dos modalidades:

1. Componentes analíticos aislados.
2. Sistema integrado de inteligencia artificial.

En la primera modalidad, las predicciones, puntuaciones de anomalía, explicaciones y reportes son presentados de forma independiente o requieren documentación manual. En la segunda modalidad, los componentes intercambian evidencias estructuradas dentro de un flujo trazable.

Tabla 1

Operacionalización de la variable independiente

Variable	Modalidad	Definición operacional	Indicadores
Tipo de sistema de supervisión analítica	Componentes aislados	Predicciones, scores y resultados presentados sin	Número de componentes integrados, disponibilidad de

		integración estructurada de explicación, reporte y linaje	explicación, disponibilidad de reporte automático y nivel de trazabilidad
Tipo de sistema de supervisión analítica	Sistema integrado	Flujo articulado de datos, predicción, anomalías, SHAP, reporte y trazabilidad	Integración de módulos, evidencia estructurada, validación factual y reconstrucción de alertas

1.5.2. Variable Dependiente

La variable dependiente es la efectividad de la supervisión analítica de operaciones agroexportadoras.

Se define como el nivel de desempeño alcanzado por el sistema para estimar indicadores esperados, identificar desviaciones, facilitar la comprensión de las alertas, reducir el tiempo de análisis, documentar los resultados y reconstruir el origen de cada reporte.

Tabla 2

Operacionalización de la variable dependiente

Variable	Indicadores	Unidad o escala	Técnica	Instrumento
Predicción del valor unitario FOB	MAE, RMSE, SMAPE y R^2	USD/kg, porcentaje y coeficiente	Experimentación computacional	Protocolo experimental y registro de métricas
Predicción del volumen	RMSLE, MAE, RMSE, SMAPE y R^2	Logaritmo, kilogramos, porcentaje y coeficiente	Experimentación computacional	Protocolo experimental y registro de métricas
Detección de	Precision, Recall, F1,	Razón de 0 a 1	Experimentación	Dataset de

anomalías	PR-AUC, ROC-AUC y Precision @k		controlada	anomalías controlada s y matriz de resultados
Efectividad Comprensi ón de alertas	Respuesta s correctas, claridad y utilidad percibida	Porcentaje y escala Likert	Prueba con usuarios	uestionari o y rúbrica
Calidad de reportes	Completitu d, coherencia , fidelidad factual y consistenc ia numérica	Rúbrica de 1 a 5 y porcentaje	Evaluación documenta l	Rúbrica y validador automátic o

1.6. Viabilidad de la investigación.

La viabilidad de la investigación se fundamenta en la disponibilidad de registros de comercio exterior, herramientas de código abierto y recursos computacionales suficientes para desarrollar y evaluar un prototipo experimental.

1.6.1. Viabilidad técnica

El sistema será implementado utilizando Python y bibliotecas de aprendizaje automático, procesamiento de datos, explicabilidad y recuperación de información. La arquitectura se diseñará de forma modular para separar la ingesta, validación, transformación, entrenamiento, detección, explicación, generación de reportes y trazabilidad.

SUNAT o ADUANET constituirán la fuente principal para calcular el valor unitario FOB y el volumen exportado. Otras fuentes podrán incorporarse como contexto cuando presenten cobertura, correspondencia temporal y reglas de integración suficientemente documentadas.

Las diferencias de granularidad serán atendidas mediante una agregación semanal. La unidad final de análisis será producto por mercado de destino por semana. Las características temporales serán construidas utilizando exclusivamente información disponible

antes del periodo objetivo, con el propósito de evitar fuga de información.

Los experimentos podrán ejecutarse en un equipo convencional con procesamiento mediante CPU. No se requiere una infraestructura distribuida ni una unidad de procesamiento gráfico de alto rendimiento para los modelos seleccionados.

El número definitivo de registros válidos, la cobertura por producto y la cobertura por fuente serán consignados después de concluir la auditoría del dataset. No se presentará una cantidad de registros como definitiva sin el correspondiente reporte de calidad.

Las variables de merma, días logísticos, costos privados o cumplimiento por embarque no serán utilizadas como variables reales cuando no exista una fuente directa que las respalde. Los escenarios sintéticos serán utilizados únicamente para evaluar anomalías controladas y no para completar el dataset histórico.

1.6.2. Viabilidad operativa

La propuesta será evaluada como prototipo experimental y no requerirá integración con sistemas ERP, sensores o plataformas productivas de empresas reales.

La evaluación se organizará en experimentos para medir:

1. Predicción del valor unitario FOB.
2. Predicción del volumen.
3. Detección de anomalías.
4. Estabilidad e interpretación de explicaciones.
5. Calidad, trazabilidad y utilidad de los reportes.

La evaluación con personas se realizará mediante un diseño controlado que compare dos condiciones: resultados técnicos aislados y sistema integrado. Se registrarán el tiempo de análisis, las respuestas correctas, la claridad y la utilidad percibida.

La realización de pruebas con usuarios dependerá de la disponibilidad de participantes y de la aplicación de un protocolo de consentimiento y anonimización. La tesis no afirmará que la evaluación fue realizada hasta disponer de sus evidencias.

1.6.3. Viabilidad económica.

La investigación utilizará principalmente herramientas de código abierto, datos públicos y recursos computacionales disponibles. No se requiere

la adquisición de licencias empresariales, sensores, servidores especializados ni integración productiva.

El presupuesto debe considerar:

Recurso	Condición
Equipo de cómputo	Recurso disponible
Software de desarrollo	Código abierto
Almacenamiento	Local o servicio de bajo costo
Servicio de modelo de lenguaje	Opcional; debe existir alternativa local o por plantilla
Internet	Recurso necesario para consulta y descarga
Documentación e impresión	Costo administrativo
Contingencia	Reserva para servicios menores

El beneficio económico será planteado como impacto potencial relacionado con una reducción del tiempo de análisis y una mejor documentación de las alertas. No se afirmará una reducción real de pérdidas empresariales porque dicho efecto no forma parte de la evaluación experimental.

1.7. Justificación e Importancia de la Investigación.

1.7.1. Justificación

A. Teórica

La presente investigación se justifica teóricamente al proponer y validar un framework de integración conceptual para la supervisión operativa que unifica cuatro áreas de la inteligencia artificial tradicionalmente aisladas en la literatura: (1) predicción supervisada en datos estructurados mediante árboles de decisión optimizados (XGBoost y LightGBM); (2) detección de anomalías no supervisada en entornos multidimensionales mediante un ensemble unificado probabilísticamente (PyOD); (3) explicabilidad local post-hoc basada en la teoría de juegos cooperativos (SHAP); y (4) generación narrativa en lenguaje natural mediante modelos de lenguaje acotados por contexto (RAG).

El principal aporte teórico radica en resolver el problema del acoplamiento débil entre modelos predictivos y modelos generativos, aportando una metodología formal para mitigar el riesgo de alucinación numérica del LLM al forzarlo a operar sobre un espacio de representación cerrado estructurado por scores y vectores de importancia SHAP. Esto contribuye a la teoría de sistemas inteligentes orientados a la auditoría continua, demostrando cómo la explicabilidad matemática puede ser convertida en una interfaz narrativa útil para la supervisión humana, en concordancia con los principios de gobernanza algorítmica.

B. Económica

Desde el punto de vista económico, el sector agroexportador peruano constituye una de las columnas vertebrales de la economía nacional, con transacciones que superan los USD 15,000 millones anuales (MIDAGRI, 2026). No obstante, la variabilidad del precio FOB por kilogramo, el descalibrado estacional y las ineficiencias logísticas en puertos representan un riesgo constante para la rentabilidad de las organizaciones. Un solo día de retraso logístico o una desviación en la cadena de frío de productos altamente perecederos (como la palta, uva y arándano) puede reducir la vida útil del cultivo en destino hasta en un 15%, generando reclamos de calidad que deprecian el valor comercial del embarque hasta en un 30%.

Esta investigación se justifica económicamente al dotar a las empresas de una herramienta de detección temprana que identifica desviaciones operativas y de precios en los registros aduaneros y contextuales antes de que se consoliden pérdidas irreparables. Al automatizar la documentación y explicación de anomalías, el sistema reduce el costo de auditoría operativa interna de horas a segundos, protegiendo los márgenes de ganancia de los exportadores peruanos frente a la volatilidad internacional.

C. Social

Socialmente, la agricultura de exportación representa la mayor fuente de empleo formal, directo y descentralizado en las regiones del Perú, albergando a más de un millón de trabajadores en la costa y valles andinos (con especial concentración en La Libertad, Piura, Ica y Arequipa). La estabilidad laboral y el ingreso de miles de familias dependen directamente de la competitividad y la continuidad de los flujos de exportación de las empresas del sector.

Las crisis operativas no detectadas a tiempo o los rechazos fitosanitarios masivos en aduanas extranjeras provocan suspensiones de contratos y despidos masivos en las plantas de empaque y campos de cultivo. Al optimizar y dar visibilidad

a la cadena de valor operativa mediante la detección de anomalías, esta tesis contribuye indirectamente a la protección del empleo agrario formal y a la reducción de la vulnerabilidad económica de las comunidades rurales peruanas, promoviendo el desarrollo regional sostenible.

1.7.2. Importancia.

La importancia práctica de esta investigación radica en entregar un prototipo auditable y trazable alineado con los desafíos de gobernanza de la inteligencia artificial en el Perú. Bajo el marco regulatorio del Decreto Supremo N.º 115-2025-PCM y el estándar internacional del NIST AI Risk Management Framework, los sistemas basados en IA aplicados a la toma de decisiones críticas deben ser transparentes, seguros y explicables para el usuario. Esta tesis rompe con el paradigma de los modelos predictivos tipo "caja negra" al traducir puntuaciones numéricas abstractas y vectores multidimensionales SHAP en reportes narrativos en lenguaje natural de alta fidelidad factual.

La solución es de suma importancia para analistas logísticos, supervisores de operaciones, gerentes de calidad y auditores de TI, puesto que les permite entender instantáneamente qué factores determinan una alerta operativa (por ejemplo, si el desvío es causado por anomalía de volumen o por variables climatológicas extremas) y rastrear la evidencia de vuelta a las bases de datos originales de SUNAT o MIDAGRI. Esto no solo acelera la velocidad de reacción corporativa, sino que democratiza el acceso a la IA para profesionales sin conocimientos en ciencia de datos, garantizando una supervisión humana efectiva y responsable sobre la tecnología.

1.8. Alcance

Alcance temático

La investigación comprende:

- integración y normalización de datos;
- construcción de un dataset semanal;
- predicción de valor unitario FOB;
- predicción de volumen;
- cálculo de residuos;
- detección de anomalías;
- explicabilidad;
- generación de reportes;
- validación factual;
- trazabilidad.'

Alcance productivo

Se consideran exclusivamente:

1. Palta.
2. Uva fresca.
3. Arándano.

El espárrago, cacao y otros productos quedan fuera de la evaluación principal.

Alcance geográfico

La investigación utiliza operaciones de exportación registradas en el Perú.

No se realizará una delimitación por departamento de producción mientras no exista un campo confiable que identifique el origen productivo. La aduana, el puerto o el domicilio del exportador no serán considerados equivalentes al lugar de producción.

Alcance temporal

La ventana prevista comprende desde junio de 2018 hasta mayo de 2026. La cobertura real será documentada por producto y fuente después de la auditoría de los archivos.

1.9. Línea, Tipo y Nivel de la investigación

1.9.1. Línea de la investigación.

La investigación se adscribirá a la línea oficial de la Escuela Profesional de Ingeniería de Sistemas relacionada con inteligencia artificial, ciencia de datos o computación aplicada.

La temática secundaria se relaciona con ingeniería de software, trazabilidad y gobernanza de sistemas inteligentes.

1.9.2. Tipo de la investigación.

La investigación es aplicada porque utiliza métodos y tecnologías existentes para atender un problema concreto de integración, análisis y documentación de datos agroexportadores.

Asimismo, es tecnológica porque comprende el diseño, implementación y evaluación de un artefacto de software funcional.

El enfoque es cuantitativo, debido a que el desempeño se evaluará mediante métricas numéricas, tiempos, proporciones y pruebas estadísticas.

1.9.3. Nivel de la investigación.

La investigación presenta un nivel explicativo-evaluativo.

Es explicativa porque analiza el efecto del sistema integrado sobre la comprensión, el tiempo de análisis y la trazabilidad.

Es evaluativa porque compara modelos, detectores y condiciones de uso mediante experimentos controlados.

El diseño es cuasiexperimental, longitudinal y comparativo:

- cuasiexperimental por la comparación de condiciones sin asignación aleatoria completa de una población empresarial;
- longitudinal por el uso de datos ordenados temporalmente;
- comparativo por la evaluación de modelos base, modelos GBDT, detectores individuales y sistema integrado.

1.10. Técnicas e Instrumentos de Recolección de Información

- Análisis documental.
- Experimentación computacional.
- Pruebas funcionales del sistema.
- Auditoría de trazabilidad.
- Prueba controlada con usuarios.
- Evaluación mediante rúbricas.

Técnica	Instrumento	Propósito

1.11. Cronograma

primera semana de diciembre

CAPÍTULO II: MARCO TEÓRICO

2.1. Antecedentes de la Investigación

El desarrollo de sistemas de predicción, detección de anomalías y generación de reportes en entornos financieros empresariales ha seguido una trayectoria de especialización creciente en los últimos años, marcada por tres tendencias paralelas: el auge de los modelos basados en árboles de decisión para datos tabulares, la proliferación de benchmarks sistemáticos de evaluación, y la emergencia de los modelos de lenguaje como capa de interpretación en sistemas analíticos. Los antecedentes que se presentan a continuación son trabajos seleccionados por su proximidad temática y metodológica con la propuesta de esta investigación.

2.1.1 Kadir et al. (2025)

Kadir et al. (2025), en el estudio AuditCopilot: Large Language Models in Accounting Audit, desarrollaron una propuesta orientada a la automatización de auditorías contables mediante la integración de modelos de lenguaje de gran escala con técnicas de detección de anomalías sobre registros financieros. La investigación plantea un pipeline compuesto por detección supervisada de irregularidades en asientos contables, interpretación contextual mediante LLMs especializados en terminología contable y generación automática de explicaciones narrativas dirigidas a auditores.

Los resultados mostraron mejoras en la identificación de irregularidades y reducción del tiempo de revisión frente a procesos manuales tradicionales. Además, las explicaciones generadas fueron valoradas positivamente por especialistas del dominio. Sin embargo, el estudio no reporta métricas comparables con benchmarks públicos ni evalúa aspectos de gobernanza regulatoria o control explícito de alucinaciones. Este antecedente resulta relevante para la presente investigación porque valida el uso de LLMs como capa de interpretación y generación de reportes automatizados, aunque no incorpora predicción tabular, forecasting temporal ni mecanismos formales de trazabilidad regulatoria.

2.1.2 Park (2024)

Park (2024), en la investigación Enhancing Anomaly Detection in Financial Markets with an LLM-Based Multi-Agent Framework, propuso una arquitectura basada en agentes especializados para mejorar la validación de anomalías en mercados financieros. El sistema distribuye funciones entre múltiples agentes encargados de transformar datos estructurados, analizar patrones temporales, validar señales y consolidar reportes finales.

Los experimentos realizados sobre datos del índice bursátil S&P 500 mostraron una mejora en la tasa de verdaderos positivos y una reducción de falsos positivos respecto a enfoques basados en un único LLM. Los resultados demuestran que la especialización funcional mejora la robustez analítica. Este trabajo aporta evidencia para utilizar LLMs como capa interpretativa sobre modelos cuantitativos, aunque su aplicación se limita a mercados financieros y no contempla entornos empresariales operativos con necesidades de trazabilidad y auditoría interna.

2.1.3 Mongolia et al. (2025)

Mongolia et al. (2025), en el estudio Financial Statement Fraud Detection through an Integrated Machine Learning and Explainable AI Framework, desarrollaron un framework de detección de fraude financiero basado en técnicas de ensamble y explicabilidad. La propuesta integra modelos XGBoost, LightGBM y CatBoost dentro de una arquitectura Stacking Ensemble, complementada con explicabilidad mediante SHAP.

Los resultados reportaron un PR-AUC de 0.93 y un F1-Score de 0.83, superando arquitecturas de Deep Learning sobre el mismo conjunto de datos. Además, el índice de estabilidad SHAP evidenció consistencia forense en las explicaciones generadas. Este antecedente respalda directamente la decisión de utilizar modelos GBDT como núcleo predictivo en esta investigación. No obstante, su alcance se limita a clasificación supervisada de fraude y no integra forecasting, detección no supervisada ni generación automática de reportes.

2.1.4 Han et al. (2022)

Han et al. (2022), mediante el estudio ADBench: Anomaly Detection Benchmark, presentaron uno de los benchmarks más completos para evaluación de algoritmos de detección de anomalías. La investigación evaluó 30 algoritmos sobre 57 datasets pertenecientes a diferentes dominios, incluyendo finanzas, medicina, industria y ciberseguridad.

Los resultados evidenciaron que no existe un único algoritmo universalmente superior, sino que el rendimiento depende de la distribución de los datos y del tipo de anomalía analizada. Asimismo, se observó que los enfoques ensamble superan consistentemente a detectores individuales en escenarios de alta variabilidad. Este antecedente justifica metodológicamente la implementación de múltiples detectores de anomalías dentro de la presente investigación.

2.1.5 Grinsztajn et al. (2022)

Grinsztajn et al. (2022), en Why do Tree-Based Models Still Outperform Deep Learning on Tabular Data?, analizaron comparativamente el rendimiento de modelos basados en árboles frente a arquitecturas de

Deep Learning en datos tabulares. La evaluación incluyó 45 datasets públicos y modelos como Gradient Boosting, Random Forest, MLP, TabNet y FT-Transformer.

Los resultados demostraron que los modelos basados en árboles superan a los modelos de Deep Learning en aproximadamente el 95% de los datasets con menos de 50,000 registros. Los autores concluyen que la estructura de los datos tabulares favorece a los métodos GBDT en escenarios empresariales de tamaño mediano. Este antecedente sustenta bibliográficamente la elección de modelos GBDT como backbone predictivo de esta tesis.

2.1.6 Lim et al. (2021)

Lim et al. (2021), en Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting, propusieron una arquitectura Transformer especializada en predicción temporal interpretable. El modelo integra mecanismos de atención, selección de variables y análisis de covariables estáticas y dinámicas para realizar forecasting multi-horizonte.

Los resultados evidenciaron mejoras respecto a LSTM y otros modelos de series temporales en distintos datasets reales. Además, los mecanismos de atención facilitaron la interpretabilidad del proceso predictivo. Este antecedente resulta relevante para la presente investigación, ya que respalda la incorporación de módulos de forecasting interpretable para anticipar comportamientos operativos y riesgos futuros.

2.1.7 Zhao et al. (2019)

Zhao et al. (2019), en el estudio PyOD: A Python Toolbox for Scalable Outlier Detection, desarrollaron una librería especializada para detección de anomalías que integra más de 40 algoritmos bajo una API unificada compatible con scikit-learn.

La propuesta permitió estandarizar experimentos de detección de outliers y facilitar la reproducibilidad en investigación aplicada. La librería ha sido ampliamente adoptada en entornos académicos e industriales y fue utilizada posteriormente como base experimental en benchmarks como ADBench. Este antecedente resulta importante para esta tesis porque proporciona la base técnica para implementar y comparar múltiples detectores de anomalías dentro de un pipeline experimental reproducible.

2.2. Estado del Arte

La revisión del estado del arte permitió identificar cinco líneas de discusión predominantes dentro de la literatura científica vinculada al

diseño de sistemas inteligentes para predicción, detección de anomalías, explicabilidad y generación automatizada de reportes en entornos empresariales. El análisis de estas líneas permite contextualizar la propuesta de investigación y fundamentar técnicamente las decisiones metodológicas adoptadas.

2.2.1 Modelos basados en árboles frente a Deep Learning en datos tabulares

El análisis de datos tabulares ha seguido una evolución distinta a otras áreas de la inteligencia artificial, como la visión computacional o el procesamiento del lenguaje natural. En este tipo de datos, los modelos basados en árboles continúan mostrando ventajas competitivas en términos de robustez, interpretabilidad y desempeño predictivo.

XGBoost, propuesto por Tianqi Chen y Carlos Guestrin en 2016, introdujo un enfoque escalable de gradient boosting con mecanismos de regularización y manejo eficiente de valores faltantes. Posteriormente, LightGBM y CatBoost ampliaron estas capacidades mediante mejoras en velocidad de entrenamiento y tratamiento de variables categóricas.

En contraste, arquitecturas recientes como FT-Transformer y TabNet buscaron adaptar redes profundas a datos estructurados. No obstante, Grinsztajn et al. (2022) demostraron, sobre múltiples datasets públicos, que los modelos GBDT mantienen un rendimiento superior en la mayoría de escenarios empresariales con volúmenes medianos de datos.

Considerando que las empresas agroexportadoras trabajan principalmente con información estructurada asociada a producción, inventario, costos y calidad, la evidencia revisada respalda el uso de modelos basados en árboles como núcleo predictivo de la presente investigación.

2.2.2 Detectores individuales frente a enfoques ensemble para anomalías

La detección de anomalías ha evolucionado desde algoritmos clásicos basados en densidad o proximidad hasta enfoques híbridos y arquitecturas profundas capaces de modelar comportamientos complejos.

Entre los algoritmos más representativos destacan Isolation Forest, LOF y Deep SVDD, ampliamente utilizados en escenarios no supervisados. Sin embargo, estudios comparativos recientes como ADBench, desarrollado por Han et al. (2022), evidencian que ningún detector individual mantiene un desempeño consistentemente superior en todos los dominios de aplicación.

Los resultados sugieren que la efectividad depende de factores como la distribución de los datos, el tipo de anomalía y la disponibilidad de

etiquetas. Esta variabilidad resulta especialmente relevante en operaciones agroexportadoras, donde pueden coexistir anomalías relacionadas con producción, logística, inventario o control de calidad.

A partir de esta evidencia, la presente investigación adopta una estrategia basada en múltiples detectores, buscando mejorar la robustez y reducir la dependencia de un único algoritmo.

2.2.3 Modelos de lenguaje en análisis empresarial

La aparición de los modelos de lenguaje de gran escala ha abierto nuevas posibilidades en sistemas inteligentes orientados al análisis empresarial. Algunas investigaciones han explorado su uso directo en tareas de clasificación o detección, mientras que otras los emplean como mecanismos de interpretación y generación de reportes.

Trabajos recientes como TabLLM y la arquitectura multiagente propuesta por Park (2024) muestran resultados prometedores en tareas de análisis automatizado. No obstante, diversos estudios también reportan limitaciones importantes, especialmente relacionadas con errores numéricos, generación de información no verificable y falta de consistencia en contextos críticos.

En entornos empresariales, donde una interpretación incorrecta puede impactar procesos operativos o decisiones estratégicas, estas limitaciones deben ser consideradas cuidadosamente.

Por ello, en esta investigación los modelos de lenguaje no serán utilizados como mecanismo principal de detección, sino como una capa orientada a traducir resultados técnicos en reportes comprensibles y auditables para los responsables de la operación.

2.2.4 Integración de componentes analíticos

La literatura revisada muestra que muchas soluciones actuales abordan de forma aislada componentes específicos del proceso analítico, tales como predicción, forecasting, detección de anomalías o generación automatizada de reportes.

Aunque estos enfoques han demostrado utilidad en contextos particulares, la separación entre componentes limita la trazabilidad, dificulta la auditoría y reduce la capacidad de tomar decisiones basadas en información integrada.

En el sector agroexportador, donde la operación depende simultáneamente de variables relacionadas con producción, clima, costos, inventario, transporte y calidad, la integración de estos módulos representa una necesidad estratégica.

En función de esta brecha identificada, la propuesta de esta tesis plantea una arquitectura modular que permita conectar predicción, detección, explicabilidad y generación de reportes dentro de un mismo flujo operacional.

2.2.5 Gobernanza, explicabilidad y cumplimiento

La incorporación de inteligencia artificial en procesos empresariales ha incrementado la necesidad de establecer mecanismos de gobernanza, trazabilidad y explicabilidad que permitan garantizar la confiabilidad de los sistemas automatizados.

Organizaciones como el National Institute of Standards and Technology han desarrollado marcos de referencia orientados a la gestión responsable de sistemas inteligentes, promoviendo principios asociados con transparencia, confiabilidad y auditoría.

En el contexto peruano, aunque la regulación específica sobre inteligencia artificial aún se encuentra en proceso de consolidación, las organizaciones enfrentan una creciente necesidad de fortalecer sus mecanismos de control interno y gestión de riesgos tecnológicos.

En sectores como el agroexportador, donde la trazabilidad de procesos y el cumplimiento de estándares internacionales constituyen factores estratégicos, la interpretabilidad de las decisiones algorítmicas adquiere una importancia fundamental.

En ese contexto, la presente investigación incorpora técnicas de explicabilidad como SHAP, con el propósito de fortalecer la transparencia del sistema y facilitar procesos de supervisión, validación y auditoría.

A partir del análisis de la literatura científica, se identifica una brecha de investigación relacionada con la ausencia de propuestas que integren, dentro de una misma arquitectura operacional orientada al sector agroexportador, modelos predictivos para datos tabulares, técnicas de predicción de series temporales, detección de anomalías basada en métodos de ensamble, mecanismos de explicabilidad y generación automatizada de reportes. Esta brecha constituye el espacio de investigación abordado en la presente tesis.

Autor(es)	Año	Aporte relevante para la investigación
T. Chen y C. Guestrin	2016	Propusieron XGBoost , algoritmo de gradient boosting optimizado para datos tabulares, ampliamente adoptado por su escalabilidad, manejo de datos faltantes y alto rendimiento en entornos empresariales.

G. Ke et al.	2017	Desarrollaron LightGBM, arquitectura basada en histogramas que reduce costos computacionales y acelera el entrenamiento sobre grandes volúmenes de datos estructurados.
L. Prokhorenkova et al.	2018	Introdujeron CatBoost, modelo optimizado para variables categóricas que evita target leakage, especialmente útil en dominios empresariales con atributos categóricos complejos.
Y. Gorishniy et al.	2021	Presentaron FT-Transformer, una de las primeras arquitecturas Transformer adaptadas a datos tabulares para comparar Deep Learning frente a modelos GBDT.
S. Lundberg y S.-I. Lee	2017	Propusieron SHAP , método de explicabilidad basado en teoría de juegos que permite interpretar la contribución individual de cada variable en una predicción.
M. Ribeiro et al.	2016	Desarrollaron LIME, técnica de explicabilidad local orientada a interpretar decisiones individuales de modelos de aprendizaje automático.
R. J. Hyndman y Y. Khandakar	2008	Propusieron AutoARIMA, método automatizado para selección óptima de modelos de series temporales.
S. J. Taylor y B. Letham	2017	Desarrollaron Prophet, modelo robusto para forecasting empresarial con componentes de tendencia y estacionalidad.
B. Lim et al.	2021	Introdujeron Temporal Fusion Transformer, arquitectura interpretable para forecasting multi-horizonte con selección automática de variables relevantes.
F. T. Liu et al.	2008	Propusieron Isolation Forest , algoritmo eficiente de detección de anomalías en escenarios no supervisados.
M. M. Breunig et al.	2000	Introdujeron LOF, método basado en densidad local para detección de outliers en patrones heterogéneos.
L. Ruff et al.	2018	Presentaron Deep SVDD, arquitectura profunda para detección de anomalías en espacios no lineales.
S. Han et al.	2022	Desarrollaron ADBench, benchmark de referencia para evaluación comparativa de algoritmos de detección de anomalías.

M. A. Kadir et al.	2025	Propusieron AuditCopilot, integrando LLMs para interpretación de resultados y generación de reportes automatizados en auditoría.
T. Gebru et al.	2021	Introdujeron el enfoque <i>Datasheets for Datasets</i> , orientado a mejorar transparencia y documentación de datasets.
NIST	2023	Publicó el marco de gestión de riesgos en IA, estableciendo lineamientos de gobernanza, trazabilidad y confiabilidad en sistemas inteligentes.

CAPÍTULO III : ELABORACIÓN DE LA PROPUESTA

3.1. Generalidades.

La propuesta consiste en el desarrollo de un sistema integrado de inteligencia artificial explicable para apoyar la supervisión analítica de operaciones agroexportadoras peruanas.

El sistema recibirá registros de exportación y variables contextuales, realizará procesos de validación y normalización, construirá un dataset semanal, generará predicciones del valor unitario FOB y del volumen, detectará desviaciones multivariantes, elaborará explicaciones y producirá reportes trazables.

La unidad de análisis será la combinación de producto, mercado de destino y semana. Los productos comprendidos serán palta, uva fresca y arándano. El horizonte predictivo será de una semana.

Los usuarios previstos son:

- analistas de datos;
- supervisores de operaciones;
- responsables de control;
- auditores de tecnologías de información;
- investigadores;
- administradores del sistema.

Las entradas principales serán:

- registros de exportación;
- catálogos de productos y destinos;
- variables macroeconómicas;
- variables contextuales con cobertura válida;
- archivos de configuración;
- documentos metodológicos para recuperación.

Las salidas principales serán:

- predicción del valor unitario FOB;

- predicción del volumen;
- residuos predictivos;
- puntuación de cada detector;
- score combinado;
- nivel de severidad;
- explicación local;
- reporte validado;
- registro de trazabilidad.

El sistema se desarrollará bajo los principios de modularidad, reproducibilidad, explicabilidad, validación de evidencia, supervisión humana y separación de responsabilidades.

La propuesta no contempla monitoreo en tiempo real, integración directa con ERP, decisiones automáticas, identificación causal de riesgos ni sustitución del criterio humano.

3.2. Esquema de la propuesta

El esquema general comprende las siguientes etapas:

Fuentes de datos → Ingesta → Validación → Normalización → Agregación semanal → Ingeniería de características → Predicción → Residuos → Detección de anomalías → Explicabilidad → Recuperación de evidencia → Generación del reporte → Validación → Trazabilidad

3.3. Capa de datos

Los archivos originales serán conservados sin modificaciones en una zona raw. Posteriormente serán convertidos a una estructura tabular normalizada.

La arquitectura considerará:

- raw: archivos originales;
- bronze: archivos estructurados sin transformación analítica;
- silver: datos limpios y normalizados;
- gold: dataset semanal, características y variables objetivo.

Cada archivo y dataset contará con identificador, fecha de procesamiento, cantidad de registros y hash.

3.4.

3.5. enviar al correo electronico karim

CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS

4.1.

4.2.

CONCLUSIONES

- 1.
- 2.
- 3.
- 4.
- 5.

CONCLUSIONS

First.

Second.

Third.

Quarter.

Fifth.

RECOMENDACIONES

- 1.
- 2.
- 3.
- 4.
- 5.

GLOSARIO DE TÉRMINOS

REFERENCIAS BIBLIOGRÁFICAS

- Almalki, F., & Masud, M. (2025). Financial fraud detection using explainable AI and stacking ensemble methods. arXiv preprint arXiv:2505.10050.
- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Sinha, R., & Bergmeir, C. (2024). Chronos: Learning the language of time series. arXiv preprint arXiv:2403.07815.
- Arik, S. O., & Pfister, T. (2021). TabNet: Attentive interpretable tabular learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(8), 6679–6687. <https://doi.org/10.1609/aaai.v35i8.16842>
- Barclays Research. (2025). Beyond the black box: Interpretability of LLMs in finance. arXiv preprint arXiv:2505.24650.
- Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *ACM SIGMOD Record*, 29(2), 93–104. <https://doi.org/10.1145/342009.335388>
- Center for Audit Quality. (2024). Auditing in the age of generative AI. CAQ. https://thecaq.org/wp-content/uploads/2024/04/caq_auditing-in-the-age-of-generative-ai__2024-04.pdf
- Challu, C., Olivares, K. G., Oreshkin, B., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2022). N-HiTS: Neural hierarchical interpolation for time series forecasting. *Advances in Neural Information Processing Systems*, 35. (arXiv:2201.12886)
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. <https://doi.org/10.1145/3458723>
- Gorishniy, Y., Rubashevskiy, I., Khrulkov, V., & Babenko, A. (2021). Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 8946–8959.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on tabular data? *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 507–520.
- Han, X., Hu, Y., Venevdev, L., Liu, M., Wen, Q., & Zhang, Y. (2022). ADBench: Anomaly detection benchmark. *Advances in Neural Information Processing Systems*, 35.

Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Jiang, X., & Sontag, D. (2022). TabLLM: Few-shot classification of tabular data with large language models. arXiv preprint arXiv:2210.10723.

Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 27(3), 1–22. <https://doi.org/10.18637/jss.v027.i03>

Jesus, S., Pombal, J., Alves, D., Cruz, A., Saleiro, P., Ribeiro, R. P., Gama, J., & Bizarro, P. (2022). Turning the tables: Biased, imbalanced, dynamic tabular datasets for ML evaluation. arXiv preprint arXiv:2211.13358. [NeurIPS 2022]

Kadir, M. A., Macharla Vasu, S. S., Nair, S. S., & Sonntag, D. (2025). AuditCopilot: Leveraging LLMs for fraud detection in double-entry bookkeeping. arXiv preprint arXiv:2512.02726. <https://doi.org/10.48550/arXiv.2512.02726>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* 30 (NeurIPS), 3146–3154.

Kreuzberger, D., Kühl, N., & Hirschl, G. (2022). MLOps: Overview, definition, and architecture. *IEEE Access*, 10, 86995–87010. <https://doi.org/10.1109/ACCESS.2022.3197550>

Leocádio, D., et al. (2024). Continuous auditing artificial intelligence framework. [Pending venue publication]

Lewis, P., Perez, E., Piktus, A., Schwenk, H., Schwab, C., Yeh, C., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 9457–9474. <https://doi.org/10.18653/v1/2020.emnlp-main.727>

Li, Z., Zhao, Y., Hu, X., Botta, N., Ionescu, C., & Chen, G. H. (2022). ECOD: Unsupervised outlier detection using empirical cumulative distribution functions. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12181–12193. <https://doi.org/10.1109/TKDE.2022.3159580>

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Conference on Learning Representations (ICLR)*. (arXiv:1912.09300)

Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. *Proceedings of the Workshop on Text Summarization Branches Out (ACL 2004)*, 74–81.

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>

Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted transformers are effective for time series forecasting. International Conference on Learning Representations (ICLR).

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems 30 (NeurIPS), 4765–4774.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency (FAccT), 220–229. <https://doi.org/10.1145/3287560.3287596>

National Institute of Standards and Technology. (2023). Artificial intelligence risk management framework (AI RMF 1.0). NIST. <https://doi.org/10.6028/NIST.AI.600-1>

Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with transformers. International Conference on Learning Representations (ICLR).

Oreshkin, B. N., Carpio, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. Proceedings of the 37th International Conference on Machine Learning (ICML), 4799–4808. <https://doi.org/10.5555/3524938.3525255>

Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL), 311–318. <https://doi.org/10.3115/1073083.1073135>

Park, S. (2024). LLMs for anomaly validation and report generation in financial systems. arXiv preprint arXiv:2403.19735.

Patel, R., Khan, F., Silva, B., & Shaturaev, J. (2024). AI-driven continuous auditing and real-time financial monitoring. International Research Journal of Modernization in Engineering Technology and Science.

Parlamento Europeo y Consejo de la Unión Europea. (2024). Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de Inteligencia Artificial). Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/eli/reg/2024/1689>

Prenio, J., & Yong, J. (2024). Managing explanations: How regulators can address AI explainability. Bank for International Settlements, Financial Stability Institute. <https://www.bis.org/fsi/fsipapers24.pdf>

Presidencia del Consejo de Ministros. (2025, septiembre). Decreto Supremo N° 115-2025-PCM: Reglamento de la Ley N° 31814. Lima, Perú. <https://busquedas.elperuano.pe>

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems* 31 (NeurIPS), 6638–6648. <https://doi.org/10.5555/3327757.3327790>

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>

Ruff, L., Kauffmann, J. R., Vandermeulen, R. A., Montavon, G., Samek, W., Kloft, M., Dickhaus, T., & Müller, K.-R. (2018). Deep one-class classification. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 4393–4402.

Schneider, J., et al. (2025). Retrieval-augmented generation (RAG). *Business & Information Systems Engineering*. <https://doi.org/10.1007/s12599-025-00945-3>

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., & Young, M. (2015). Hidden technical debt in machine learning systems. *Proceedings of the 28th International Conference on Neural Information Processing Systems (NIPS) Workshop*.

Superintendencia de Banca, Seguros y AFP. (2023). Resolución SBS N° 053-2023: Reglamento de gestión de riesgos de modelo. Lima, Perú. <https://www.sbs.gob.pe>

Taylor, S. J., & Letham, B. (2017). Forecasting at scale. *PeerJ Preprints*. <https://doi.org/10.7287/peerj.preprints.3190v2>

Thanathamath, P., et al. (2024). SHAP-instance weighting and anchor explainable AI: Enhancing XGBoost for financial fraud detection. *Emerging Science Journal*, 8(6). <https://doi.org/10.28991/ESJ-2024-08-06-024>

Tsai, C.-P., et al. (2025). LLM-based anomaly detection in tabular data. [Pending venue publication]

Varios autores. (2025). Hallucination detection and mitigation in large language models. *arXiv preprint arXiv:2601.09929*.

Varios autores. (2025). Financial statement fraud detection through an integrated machine learning and explainable AI framework. *Journal of Risk and Financial Management*, 19(1), 13. <https://doi.org/10.3390/jrfm19010013>

Varios autores. (2025). Explainable AI for forensic analysis: A comparative study of SHAP and LIME in intrusion detection models. *Applied Sciences*, 15(13), 7329. <https://doi.org/10.3390/app15137329>

Waltersdorfer, L., Ekaputra, F. J., Miksa, T., & Sabou, M. (2024). AuditMAI: Towards an infrastructure for continuous AI auditing. arXiv preprint arXiv:2406.14243. <https://doi.org/10.48550/arXiv.2406.14243>

Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? Proceedings of the AAAI Conference on Artificial Intelligence, 37(9), 11121–11128. <https://doi.org/10.1609/aaai.v37i9.26317>

Zhao, Y., Nasrullah, Z., & Li, Z. (2019). PyOD: A Python toolbox for scalable outlier detection. Journal of Machine Learning Research, 20(96), 1–7.

ANEXOS