

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA

FACULTAD DE INGENIERÍA DE PRODUCCIÓN Y SERVICIOS

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



Uso de Machine Learning para la detección de transacciones fraudulentas en
una empresa de pagos móviles

Tesis presentada por:

Vargas Belizario, Jean Franco

Para optar el Título Profesional de:

Ingeniero de Sistemas

Asesor:

Dr. Cornejo Aparicio, Víctor Manuel

Arequipa - Perú

2025

INFORME DE SIMILITUD N° 091-2026 FIPS/SISGRAD

A : Dr. Paul Vicente Tanco Fernandez
Decano(a) de la Facultad de Ingeniería de Producción y Servicios

De : Dra. Elizabeth Enriqueta Vidal Duarte
Director(a) de Unidad de Investigación de la Facultad de Ingeniería de Producción y Servicios

Asunto : Informe de Similitud

Expediente : E-0003459

Fecha : Arequipa, 09 de Enero del 2026

Mediante el presente cumpla con informar que:

JEAN FRANCO VARGAS BELIZARIO

Ha presentado su trabajo de investigación, según el siguiente detalle, a efecto de optar:

Denominación	
Título Profesional	INGENIERO DE SISTEMAS

Modalidad	Título de la tesis
Tesis	Uso de Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles

De la revisión del referido proyecto, haciendo uso del mecanismo de verificación de originalidad institucional, **TURNITIN**; se concluye que cuenta con el siguiente porcentaje de similitud:

8%

Lo que hago de su conocimiento a efecto de proceder con el trámite respectivo.

Siendo todo cuanto tengo que informar, me suscribo de usted.


Dra. Elizabeth Enriqueta Vidal Duarte Firma - Director(a) de Unidad de Investigación de la Facultad de Ingeniería de Producción y Servicios

DEDICATORIA

A Dios, por guiar mis pasos, darme fortaleza en los momentos difíciles y concederme la sabiduría necesaria para culminar esta etapa. Su presencia ha sido fuente de inspiración, esperanza y perseverancia en todo este camino.

A mi familia, por su amor incondicional, su ejemplo de esfuerzo y sacrificio y por inculcarme los valores que me han permitido alcanzar mis objetivos. Su apoyo constante ha sido el pilar fundamental de mi formación personal y profesional.

A mis amigos, por su compañía, su apoyo sincero y por compartir conmigo cada reto y cada logro durante este proceso.

AGRADECIMIENTOS

A Dios, por haberme brindado la vida, la salud, la sabiduría y la fortaleza necesaria para culmina esta etapa académica. Su guía y bendición me acompañaron en cada decisión y esfuerzo realizado a lo largo de este camino.

Al Ing. Victor Cornejo, por su valiosa orientación, dedicación y apoyo en el desarrollo de esta tesis. Su experiencia y guía fueron fundamentales para lograr la culminación exitosa de este trabajo.

A mis familiares y amigos por su amor, comprensión y constante apoyo, que han sido el motor de mi superación personal y profesional. Gracias por enseñarme con su ejemplo el valor del trabajo, la honestidad y la perseverancia.

PRESENTACIÓN

En el contexto de la creciente digitalización de servicios financieros, la seguridad en las transacciones electrónicas se ha convertido en un desafío crítico para las empresas de pagos móviles. Esta investigación aborda dicho desafío mediante el desarrollo de un modelo basado en machine learning para identificar patrones de fraude con precisión, eficiencia y escalabilidad. Su objetivo principal es detectar las transacciones fraudulentas en proceso de pagos con medios móviles, combinando fundamentos teóricos con un enfoque práctico orientado a la industria.

La investigación no solo demuestra la efectividad del modelo propuesto (con un 100% de exactitud y 99.84% de precisión), sino que también establece un precedente metodológico para integrar inteligencia artificial en entornos financieros, equilibrando seguridad y experiencia del usuario. Su enfoque multidisciplinario que combina teoría, tecnología y análisis empírico lo posiciona como un referente para futuros estudios en el campo de la ciberseguridad aplicada.

RESUMEN

En los últimos años, la escalada de actividades fraudulentas ha provocado pérdidas financieras significativas en todas las industrias, lo que ha intensificado el desafío crítico de la detección del fraude. Por lo que, se planteó como objetivo Detectar las transacciones fraudulentas en proceso de pagos con medios móviles. Asimismo, para que se logre el objetivo se segmentó la dataset para el entrenamiento del modelo, se determinó el algoritmo adecuado de Machine Learning, se entrenó y evaluó el modelo basado en ML para la detección de transacciones fraudulentas. Fue de tipo aplicado, cuantitativo donde la población estará conformada por 6, 362 620 registros de la base de datos de la entidad; además, se usó la metodología CRISP-DM y respecto a las tecnologías se usó Google Colab y a Python junto a las librerías Numpy, Pandas y Matplotlib - Pyplot. Asimismo, se usaron 3 algoritmos que arrojaron resultados de precisión, como: Random Forest (99.68%), XGBClassifier (99.84%), SVC (96.28%) y Regresión logística (96.51%). Por consiguiente, se evidenció que el modelo es óptimo para la detección de fraudes.

Palabras Clave: Machine Learning, CRISP-DM, Transacciones fraudulentas.

ABSTRACT

In recent years, the escalation of fraudulent activities has caused significant financial losses across industries, which has intensified the critical challenge of fraud detection. In the present study, the objective was to detect fraudulent transactions in the process of mobile payments. Also, to achieve the objective, the dataset was segmented for model training, the appropriate Machine Learning algorithm was determined, and the ML-based model for fraudulent transaction detection was trained and evaluated. The study was of an applied, quantitative type where the population will consist of 6,362,620 records from the company's database; in addition, the CRISP-DM methodology was used and with respect to the technologies, Google Colab and Python were used together with the Numpy, Pandas and Matplotlib - Pyplot libraries. Likewise, 3 algorithms were used that yielded accuracy results, such as: Random Forest (99.68%), XGBClassifier (99.84%), SVC (96.28%) and Logistic Regression (96.51%). Therefore, it was evidenced that the model is optimal for fraud detection in the company.

Key Word: Machine Learning, CRISP-DM, Fraudulent transactions.

ÍNDICE DE CONTENIDOS

DEDICATORIA	II
AGRADECIMIENTOS	III
PRESENTACIÓN	IV
RESUMEN	V
ABSTRACT	VI
ÍNDICE DE CONTENIDOS	VII
ÍNDICE DE FIGURAS	IX
ÍNDICE DE TABLAS	XI
INTRODUCCIÓN	XII
CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA	1
1.1. Descripción de la Realidad Problemática	1
1.2. Problema principal.	4
1.2.1. Problema General	5
1.3. Objetivos	5
1.3.1. Objetivo principal	5
1.3.2. Objetivos específicos	6
1.4. Hipótesis de la investigación.	6
1.4.1. Hipótesis general	6
1.5. Variables e Indicadores	6
1.5.1. Variable Independiente	6
1.5.2. Variable Dependiente	6
1.6. Viabilidad de la investigación.	6
1.6.1. Viabilidad técnica	6
1.6.2. Viabilidad operativa.	7
1.6.3. Viabilidad económica.	7
1.7. Justificación e Importancia de la Investigación.	8
1.7.1. Justificación	8
1.7.2. Importancia.	9
1.8. Alcance	9
1.9. Línea, Tipo y Nivel de la investigación	10
1.9.1. Línea de la investigación.	10

1.9.2. Tipo de la investigación.	10
1.9.3. Nivel de la investigación.	11
1.10. Técnicas e Instrumentos de Recolección de Información	11
1.10.1. Técnicas.	11
1.10.2. Instrumentos.	11
CAPÍTULO II: MARCO TEÓRICO	12
2.1. Antecedentes de la Investigación	12
2.2. Estado del Arte	19
2.3. Marco Conceptual	20
2.3.1. Inteligencia Artificial (IA)	20
2.3.2. Transacciones fraudulentas	27
2.3.3. Sistema bancario	27
CAPÍTULO III: ELABORACIÓN DE LA PROPUESTA	29
3.1. Generalidades	29
3.2. Esquema de la propuesta	30
3.3. Infraestructura	38
3.4. Modularidad de la aplicación	42
3.5. Especificación de procesos	43
CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS	45
CONCLUSIONES	58
RECOMENDACIONES	59
GLOSARIO DE TÉRMINOS	60
REFERENCIAS BIBLIOGRÁFICAS	61
ANEXOS	66

ÍNDICE DE FIGURAS

Figura 1 Versión simplificada de RNA	23
Figura 2 Funcionamiento de CNN	25
Figura 3 Tipos de servicio del sistema bancario	28
Figura 4 Fases de CRISP-DM	30
Figura 5 División de los datos	31
Figura 6 Propuesta de arquitectura tecnológica	39
Figura 7 Flujo de propuesta de arquitectura tecnológica	40
Figura 8 Estructuración de la información a nivel POS	40
Figura 9 Estructura de la información a un nivel superior	41
Figura 10 Diagrama de paquetes	42
Figura 11 Diagrama de clases	42
Figura 12 Detalle de especificación de procesos	43
Figura 13 Diagrama de especificación de procesos	44
Figura 14 Diagrama de flujo para la transacción de compra/pago	44
Figura 15 Atributos de la data	45
Figura 16 Dataset de transacciones históricas	46
Figura 17 Visualización de la data en Colab	46
Figura 18 Tipo de variable de los atributos de la data	47
Figura 19 Tipos de transacciones	47
Figura 20 Resumen estadístico de la data en Colab	48
Figura 21 Proceso de submuestreo	49
Figura 22 Análisis de tipos de datos	49
Figura 23 Codificación de la columna "Tipo transacción"	50
Figura 24 Eliminación de columnas irrelevantes: "Cuenta emisor" y "Cuenta receptor"	51
Figura 25 Distribución de datos	52
Figura 26 División del dataset en Colab	52
Figura 27 Código de importación de los módulos para el entrenamiento del modelo	53
Figura 28 Entrenamiento del modelo en Colab	53
Figura 29 Entrenamiento final	53

Figura 30 Matriz de confusión del modelo final	54
Figura 31 Resultados de precisión de Colab	55
Figura 32 Dataset de transacciones históricas	68
Figura 33 Visualización de la data en Colab	68
Figura 34 Atributos de la data	68
Figura 35 Tipo de variable de los atributos de la data	69
Figura 36 Tipos de transacciones	69
Figura 37 Resumen estadístico de la data en Colab	70
Figura 38 Proceso de submuestreo	71
Figura 39 Análisis de tipos de datos	71
Figura 40 Gráfico de barras del Tipo Transacción	72
Figura 41 Gráfico de barras del Tipo transacción y Monto transacción	72
Figura 42 Codificación de la columna "Tipo transacción"	73
Figura 43 Eliminación de columnas irrelevantes: "Cuenta emisor" y "Cuenta receptor"	73
Figura 44 Mapa de calor de los atributos	75
Figura 45 Distribución de datos	76
Figura 46 División del dataset en Colab	77
Figura 47 Algoritmos de Machine Learning	77
Figura 48 Código de importación de los módulos para el entrenamiento del modelo	81
Figura 49 Entrenamiento del modelo en Colab	82
Figura 50 Entrenamiento final	82
Figura 51 Matriz de confusión del modelo final	82
Figura 52 Resultados de precisión de Colab	84

ÍNDICE DE TABLAS

Tabla 1	Identificación de precisión por algoritmo	19
Tabla 2	Tipos de aprendizaje automático	21
Tabla 3	Técnicas de redes neuronales	24
Tabla 4	Matriz de confusión	37
Tabla 5	Especificación de las tecnologías empleadas	39
Tabla 6	Atributos de la data	41
Tabla 8	Resultados de precisión de cada algoritmo	54
Tabla 9	Comparativa de algoritmos convencionales de clasificación	78
Tabla 10	Resultados de precisión de cada algoritmo	83
Tabla 11	Matriz de confusión	84

INTRODUCCIÓN

El fraude en las transacciones con tarjetas de crédito es una de las preocupaciones de seguridad más desafiantes para las empresas financieras a nivel mundial, por lo que este estudio se centra en usar Machine Learning (ML) para detectar posibles fraudes en una empresa de pagos móviles. Con el objeto de guardar la confidencialidad de la entidad para el desarrollo de este trabajo, a la entidad se le denominará pagopay.

El presente documento se estructuró en 3 capítulos principales que abordan de manera integral. En el Cap. I: Planteamiento del Problema, se describe la realidad problemática, destacando el problema principal y desglosándolo en específicos, objetivos e hipótesis de la investigación, así como las variables e indicadores involucrados. Además, se evalúa la viabilidad técnica, operativa y económica del estudio, justificando su relevancia y determinando su alcance. El Cap. II: Marco Teórico presenta una revisión exhaustiva de los antecedentes, el estado del arte y el marco conceptual que sustentan la investigación, proporcionando un contexto sólido y fundamentado. Finalmente, en el Cap. III: Elaboración de la Propuesta, se detallan las generalidades y el esquema de la propuesta metodológica, incluyendo la implementación de técnicas e instrumentos para la recolección de información. Adicionalmente, se incluyen un glosario de términos, referencias bibliográficas, y anexos que complementan y enriquecen el desarrollo del trabajo.

CAPÍTULO I:

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

Los sistemas bancarios en la era actual son extremadamente importantes para las economías globales porque permiten transacciones financieras y brindan servicios clave tanto a consumidores como a empresas. Sin embargo, las conductas fraudulentas pueden resultar en pérdidas financieras significativas y destruir la confianza pública en dichas instituciones. Actualmente, los delincuentes encuentran varias formas ingeniosas de cometer fraude, sus métodos evolucionan constantemente con los avances tecnológicos, lo que dificulta que los sistemas de detección de fraude convencionales sigan el ritmo. Los estafadores aumentan la complejidad y sofisticación de sus esquemas al actualizar constantemente sus métodos para aprovechar nuevas vulnerabilidades (Nobel et al., 2024).

El fraude en las transacciones con tarjetas de crédito es una de las preocupaciones de seguridad más desafiantes para las empresas financieras a nivel mundial (Charizanos et al., 2024). Con la popularidad generalizada de los pagos con tarjeta de crédito, los casos de fraude con tarjeta de crédito han aumentado, lo que impulsa el desarrollo continuo de la tecnología de detección de fraudes. Según un informe del Banco Central Europeo, Europa pierde miles de millones de euros anualmente debido al fraude con tarjetas de crédito representando una grave amenaza para la estabilidad de los consumidores y el sistema financiero (Tang & Liang, 2024).

Entre 2000 y 2015, se produjo un aumento sustancial de la cantidad de dinero perdido por fraude relacionado con tarjetas de crédito y débito. Si bien las transacciones ilegales y las tarjetas de crédito falsificadas representan entre el 10 y el 15 % de todos los fraudes, representan un abrumador 75-80 % de los daños por fraude financiero. Esto ha aumentado las inversiones privadas y públicas en el desarrollo de

sistemas más avanzados para detectar actividades fraudulentas (Mosa et al., 2024).

Se identificó que el fraude con tarjetas de crédito aumentó de 9.840 millones de dólares en 2011 a 32.390 en 2020, con estimaciones preocupantes de que llegará a 40.620 millones de dólares en 2027. Los estafadores se aprovechan de las debilidades de los sistemas de las ciudades inteligentes para acceder a información personal, como fechas de nacimiento, números de seguridad social y datos privados, lo que les permite realizar actividades ilegales y compras no autorizadas que podrían interferir con los servicios de las ciudades inteligentes (Padhi et al., 2024).

Se afirma entonces que la detección de fraudes en los sistemas bancarios es crucial para la estabilidad financiera, la protección del cliente, la gestión de la reputación y el cumplimiento normativo. De acuerdo con, Juniper Research hubo un aumento del fraude de 17.500 millones de dólares en 2020 a 20.000 millones de dólares en 2021 (Sorour et al., 2024). Por lo tanto, este problema es de suma importancia en el ámbito financiero y se infiltra en las interacciones económicas cotidianas a escala mundial.

En India, se identificó que hubo un aumento de alrededor del 200% en el uso de la banca móvil, donde el número de transacciones digitales sospechosas de fraude entre marzo de 2020 y marzo de 2021 aumentó un 40% en comparación con el número de transacciones sospechosas de fraude entre marzo de 2019 y marzo de 2020. El aumento de transacciones sospechosas de fraude en el mismo período fue del 22%. Esto se debió al aumento de las transacciones en línea durante la pandemia debido a los cierres y el distanciamiento social. Estas transacciones fraudulentas afectaron principalmente a las industrias de telecomunicaciones, viajes y ocio (Rajendran et al., 2023).

En 2022 se registraron 3.500 millones de transacciones fraudulentas con tarjetas a nivel mundial, frente a solo 1.500 millones en 1992, lo que resultó en una pérdida total de 321.000 millones de dólares estadounidenses; además, la frecuencia de las actividades fraudulentas ha crecido un 133% en los últimos 30 años (citado por Aite-Novarica, 2022 por Charizanos et al., 2024). Asimismo, de acuerdo con el reporte de

Australian Bureau of Statistics (ABS, 2024) en Australia, el 1.8 millones de personas fueron víctimas de actividades fraudulentas en 2022-23, lo que equivale al 8,7% de la población total del país. Por consiguiente, el fraude con tarjetas de crédito implica el uso no autorizado de tarjetas vinculadas a cuentas legítimas de consumidores y puede detectarse como transacciones no autorizadas en las cuentas bancarias de un cliente, donde una transacción generalmente se marca como fraudulenta ($Y=1$) O no ($Y=0$).

Según Coppola (2024) publicó en STATISTA que se espera que el gasto global de las transacciones ilícitas digitales alcance los 48 mil millones de dólares estadounidenses para 2023, frente a los 41 mil millones en 2022. Se evidencia que las empresas sufren pérdidas significativas debido a las transacciones fraudulentas, ya que deben afrontar todos los costos asociados, como impuestos, gastos del emisor, etc. Debido a que hay tantas transacciones digitales, es difícil para los proveedores de servicios financieros autenticar cada transacción para comprobar su autenticidad. El fraude con tarjetas de crédito (CCF) es un evento regular que genera pérdidas financieras. Una parte considerable del volumen de transacciones en Internet, que ha aumentado considerablemente, se realiza con tarjetas de crédito. Por ello, los bancos y otras entidades financieras dan gran prioridad a los programas de detección de CCF. Estas pueden presentarse en una amplia variedad de formatos y categorías. Para mantener la integridad de los datos, las instituciones financieras respaldan las transacciones digitales. Una de las formas más populares de pagar productos y servicios se puede hacer tanto en línea como fuera de línea mediante el uso de una tarjeta de crédito. Por lo tanto, existe una mayor posibilidad de fraude durante estas transacciones financieras (Sreekanth et al., 2024) .

El fraude se caracteriza por ser un engaño delictivo o ilícito utilizado para obtener un beneficio económico o personal. El uso ilegal de la información de la tarjeta de crédito para compras físicas o digitales se conoce como fraude con tarjeta de crédito. Dado que los titulares de tarjetas suelen enviar su número, fecha de vencimiento y número de verificación por teléfono o sitio web, el fraude puede ocurrir durante las transacciones

digitales. Por lo tanto, se afirma que el fraude con tarjeta de crédito es el uso ilegal de la información de la tarjeta de crédito para completar una transacción (Kumar et al., 2024).

El uso del aprendizaje automático para entrenar modelos para identificar transacciones fraudulentas se ha convertido en un método principal para prevenir el fraude con tarjeta de crédito (Tang & Liang, 2024). Los algoritmos de aprendizaje automático han revolucionado el campo de detección de fraudes al ofrecer capacidades automatizadas de análisis de datos y reconocimiento de patrones. Estos algoritmos son capaces de aprender de los datos históricos de transacciones, detectando comportamientos inusuales que pueden indicar actividades fraudulentas (Rawashdeh et al., 2024).

1.2. Problema principal.

La empresa Pagopay enfrenta un desafío crítico en la detección y prevención de transacciones fraudulentas dentro de su ecosistema de pagos. Este problema, que afecta tanto a la integridad financiera como a la confianza de sus clientes y socios comerciales, se ha convertido en un obstáculo creciente debido al incremento en la sofisticación de las técnicas empleadas por los defraudadores. La detección de transacciones fraudulentas no solo es esencial para proteger los activos financieros, sino también para mantener la reputación y la credibilidad de Pagopay en el competitivo mercado de pagos electrónicos.

Las causas del problema son diversas y complejas. En primer lugar, el volumen de transacciones que maneja Pagopay diariamente ha crecido exponencialmente, lo que dificulta la supervisión y análisis manual de cada operación. Este crecimiento ha resultado en una mayor vulnerabilidad, ya que la empresa no cuenta con sistemas suficientemente robustos para identificar patrones anómalos en tiempo real. Por último, se identificó que en determinado momento una tarjeta bancaria realiza operaciones inusuales en un mismo día, en intervalos de tiempos cortos y por montos repetitivos. Lo que daría indicio a sospechar que se trate de algún tipo de transacción fraudulenta por parte de delincuentes donde al sustraer las tarjetas bancarias de la víctima se realicen transacciones, la problemática radica en cómo se puede identificar qué tipo de transacción

es legítima y que transacción puede estar considerando como fraude, en este caso al menos poder notificar al usuario o tomar medidas de precaución como bloquear la tarjeta cuando se realice un uso inadecuado de la tarjeta según el comportamiento habitual de la víctima.

Las consecuencias de esta situación son significativas. En términos financieros, las transacciones fraudulentas representan pérdidas directas para la empresa, tanto por los fondos defraudados como por los costos asociados a la gestión de reclamos y la implementación de medidas correctivas. A largo plazo, el impacto puede ser aún más grave, ya que la repetición de fraudes podría llevar a disminuir la confianza de los clientes y socios, afectando la base de usuarios y, en última instancia, los ingresos. Además, un manejo inadecuado de las transacciones fraudulentas podría derivar en sanciones regulatorias y legales, agravando aún más la situación financiera y reputacional de Pagopay.

Frente a este contexto, la empresa se ve obligada a explorar soluciones innovadoras que le permitan mitigar estos riesgos de manera efectiva. El uso de técnicas avanzadas de ML se presenta como una alternativa prometedora, dado su potencial para analizar grandes volúmenes de datos en tiempo real y detectar patrones de comportamiento sospechoso con mayor precisión que los métodos tradicionales. La implementación de un sistema basado en ML no solo permite a Pagopay reducir la incidencia de fraudes, sino también mejorar la eficiencia operativa al automatizar procesos de monitoreo y detección, liberando recursos para enfocarse en actividades más estratégicas.

1.2.1. Problema General

¿Cómo detectar las transacciones fraudulentas a través del uso de Machine Learning en la empresa Pagopay, 2024?

1.3. Objetivos

1.3.1. Objetivo principal

Detectar las transacciones fraudulentas en proceso de pagos con medios móviles.

1.3.2. Objetivos específicos

- Comprender la lógica del negocio, para ubicar la información concerniente a las transacciones con probable caso de fraude.
- Comprender la relación entre los datos que configuran los escenarios de fraude.
- Preparar los datos (MML), para su tratamiento y uso en el sistema de detección de fraude.
- Desarrollar el modelo basado en Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles.
- Evaluar la precisión del modelo basado en Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles.

1.4. Hipótesis de la investigación.

1.4.1. Hipótesis general

Es posible la detección con un grado de precisión aceptable las transacciones fraudulentas a través del uso de pagos móviles.

1.5. Variables e Indicadores

1.5.1. Variable Independiente

Machine Learning

1.5.2. Variable Dependiente

Transacciones fraudulentas

1.6. Viabilidad de la investigación.

1.6.1. Viabilidad técnica

La viabilidad es alta, debido a la madurez y disponibilidad de herramientas tecnológicas avanzadas para la implementación de ML. Existen diversas plataformas y bibliotecas de código abierto, como Google Colab y a Python junto a las librerías Numpy, Pandas y Matplotlib - Pyplot, que permiten el diseño y entrenamiento de modelos de aprendizaje automático con un alto grado de personalización y precisión. Además, la infraestructura tecnológica de Pagopay, que incluye bases de datos robustas y sistemas de procesamiento de datos en tiempo real, proporciona un entorno

adecuado para la integración de estos modelos. La capacidad de almacenamiento y procesamiento en la nube también facilita la escalabilidad del sistema, permitiendo que se adapte a los volúmenes crecientes de transacciones. En conjunto, estos factores aseguran que la empresa pueda adoptar la tecnología sin necesidad de una reestructuración significativa de su infraestructura actual.

1.6.2. Viabilidad operativa.

Es igualmente favorable, permitiendo una integración progresiva que minimiza la interrupción de las actividades cotidianas. El uso de ML automatiza y optimiza la supervisión de transacciones, liberando al personal operativo de tareas repetitivas. La capacitación del personal en el uso y supervisión del nuevo sistema es factible y puede gestionarse mediante programas de formación internos y colaboraciones con expertos en la materia. Además, el sistema de Machine Learning puede ser monitorizado y ajustado de manera continua, lo que facilita su adaptación a las necesidades operativas cambiantes y a las nuevas amenazas de fraude, manteniendo la eficacia operativa en todo momento.

1.6.3. Viabilidad económica.

En términos económicos, es altamente viable. Aunque la inversión inicial en tecnología, capacitación y posibles ajustes en la infraestructura es considerable, los beneficios económicos a largo plazo superan significativamente estos costos. La reducción en las pérdidas por fraudes, junto con la mejora en la eficiencia operativa, generará un retorno de inversión favorable. Además, al mejorar la seguridad de las transacciones, Pagopay fortalecerá la confianza de sus clientes y socios, lo que puede traducirse en un aumento de la base de usuarios y, por ende, de los ingresos. También se debe considerar que la prevención eficaz de fraudes minimiza el riesgo de sanciones legales y regulatorias, evitando costos adicionales. Por lo tanto, la adopción de esta tecnología no solo es

económicamente sostenible, sino que también posiciona a Pagopay en una situación competitiva más fuerte a largo plazo.

1.7. Justificación e Importancia de la Investigación.

1.7.1. Justificación

A. Teórica

Se justifica teóricamente en la creciente relevancia del aprendizaje automático como una herramienta poderosa en el campo de la ciberseguridad y la detección de fraudes. La teoría subyacente al ML se basa en la capacidad de los algoritmos para identificar patrones complejos y sutiles en grandes conjuntos de datos, patrones que serían difíciles de detectar mediante métodos tradicionales. La investigación contribuirá al cuerpo de conocimiento existente al explorar cómo estos modelos pueden ser optimizados y adaptados específicamente para el entorno de pagos electrónicos, un área que requiere alta precisión y rapidez en la detección de actividades fraudulentas. Además, el estudio proporcionó insights valiosos sobre la integración de técnicas de Machine Learning en sistemas empresariales, lo cual es de interés tanto para la academia como para la industria.

B. Económica

La justificación económica de este estudio radica en la necesidad de proteger los activos financieros de la empresa Pagopay mediante la reducción de pérdidas asociadas a transacciones fraudulentas. El fraude en los pagos electrónicos puede tener un impacto devastador en las finanzas de una empresa, afectando tanto sus ingresos como su sostenibilidad a largo plazo. La implementación de un sistema basado en Machine Learning no solo mitigará estos riesgos, sino que también permitirá a la empresa optimizar sus recursos operativos, al reducir la dependencia de procesos manuales y

aumentar la eficiencia del monitoreo de transacciones. La mejora en la detección de fraudes y la consecuente disminución de pérdidas pueden generar un retorno sobre la inversión considerable, justificando económicamente la inversión inicial en la tecnología y el desarrollo del estudio.

C. Social

Desde un punto de vista social, este estudio se justifica por el impacto positivo que tendrá en la seguridad de los usuarios de los servicios de Pagopay y, en general, en la confianza del público en los sistemas de pagos electrónicos. En un contexto donde las transacciones digitales se han vuelto omnipresentes, la protección contra el fraude no solo beneficia a las empresas, sino también a los consumidores, quienes confían en que sus datos y recursos financieros están seguros. Al implementar un sistema de detección de fraudes más robusto, Pagopay contribuirá a crear un entorno de pagos más seguro, reduciendo el riesgo de que los usuarios sean víctimas de fraudes. Esto, a su vez, fortalece la confianza en el sistema financiero digital y promueve la inclusión financiera al hacer que los servicios de pagos electrónicos sean más accesibles y seguros para un mayor número de personas.

1.7.2. Importancia.

La capacidad de detectar y prevenir fraudes de manera eficiente es esencial no solo para proteger los activos, sino también para mantener la confianza de los clientes y socios comerciales. Este estudio es importante porque abordó un problema crítico que afecta directamente la sostenibilidad financiera y reputacional de Pagopay, y propone soluciones tecnológicas avanzadas, contribuyendo así al avance en la seguridad de los sistemas de pago a nivel global.

1.8. Alcance

El alcance del estudio es amplio y abarca varios aspectos clave del uso de Machine Learning en la detección de fraudes. Primero, analizó las

capacidades actuales de los modelos de ML para identificar patrones anómalos en las transacciones, evaluando su precisión y exactitud en comparación con los tradicionales. Además, se exploró cómo estos modelos pueden ser integrados en la infraestructura tecnológica existente de Pagopay, asegurando que la solución propuesta sea viable y escalable. El estudio también consideró los aspectos operativos y de capacitación necesarios para la implementación exitosa del sistema. Finalmente, el alcance se extiende a evaluar el impacto económico y social de la implementación de ML en la detección de fraudes, proporcionando un análisis completo que no solo beneficiará a Pagopay, sino que también ofrecerá un marco de referencia para otras empresas en la industria de pagos electrónicos.

1.9. Línea, Tipo y Nivel de la investigación

1.9.1. Línea de la investigación.

Ingeniería de software

1.9.2. Tipo de la investigación.

Fue de tipo aplicada porque está orientado a la resolución de problemas prácticos específicos, utilizando el conocimiento existente y generando nuevo conocimiento que tenga un impacto directo en la realidad; además, se caracteriza por su enfoque en la utilidad práctica. Esto significa que los resultados obtenidos son directamente aplicables para resolver problemas específicos o para mejorar procesos en diversas áreas, como la industria, la educación, la salud, entre otras (Hernández-Sampieri & Mendoza, 2018). Esta investigación se centra en la detección de fraudes en las transacciones financieras. Al emplear técnicas de ML, la investigación no solo pretende identificar y prevenir fraudes, sino también mejorar la eficiencia y seguridad de los sistemas de pago en la empresa Pagopay. Este es un ejemplo típico de cómo la investigación aplicada transforma el conocimiento teórico en herramientas prácticas y soluciones tangibles para problemas del mundo real.

1.9.3. Nivel de la investigación.

Su nivel es exploratorio porque tiene como objetivo principal proporcionar una primera aproximación a un fenómeno o problema poco estudiado o comprendido. En este tipo de investigaciones, no se busca probar hipótesis específicas, sino más bien identificar patrones, relaciones preliminares y aspectos relevantes del fenómeno a estudiar. Este enfoque es especialmente útil en áreas donde la información disponible es escasa o insuficiente para establecer conclusiones definitivas (Hernández-Sampieri & Mendoza, 2018). En este caso, permitió sentar las bases necesarias para el desarrollo de un sistema efectivo de detección de fraudes mediante Machine Learning, proporcionando una comprensión inicial del fenómeno y guiando los pasos futuros en la optimización y mejora de los algoritmos utilizados.

1.10. Técnicas e Instrumentos de Recolección de Información

1.10.1. Técnicas.

Observación, es utilizada mediante el examen por parte de un investigador, utilizando los sentidos, con o sin medios técnicos, de cuestiones o acontecimientos de interés público (Hernández-Sampieri & Mendoza, 2018).

1.10.2. Instrumentos.

Ficha de registro, herramienta útil para recopilar datos de muchas áreas diferentes de actividad, que pueden usarse para un análisis detallado de un evento o de rasgos específicos (Hernández-Sampieri & Mendoza, 2018). En este estudio se utilizó para el registro del % de exactitud y precisión de la predicción de transacciones fraudulentas.

CAPÍTULO II:

MARCO TEÓRICO

2.1. Antecedentes de la Investigación

A nivel internacional, se consideraron a los siguientes estudios:

(Pérez, 2021) detectó transacciones fraudulentas en tarjetas de crédito mediante el uso de modelos de Machine Learning, del cual identificó 3 modelos correspondientes a los algoritmos de aprendizaje no supervisado, se usó del dataset con 284, 807 datos que correspondieron a transacciones reales realizadas en Septiembre de 2013 publicado por Machine Learning Group-ULB, de ellos sólo 492 contenían fraude siendo normalizados de 0 a 1 donde el 70% se partieron para entrenamiento y el 30% en validación. Respecto a los resultados para cada modelo se obtuvo lo siguiente: One-Class SVMs se obtuvo una exactitud de 0.8992, sensibilidad de 0.8415 y precisión de 0.0461 significando que el modelo fue capaz de distinguir con éxito un fraude de una transacción válida en 85.15%; en Autoencoders se obtuvo una exactitud de 0.9343, sensibilidad de 0.8943 y precisión de 0.0731; en iForest una exactitud de 0.9443, sensibilidad de 0.8598 y precisión de 0.0824. Se concluyó que en cada modelo se obtuvo un buen desempeño en el problema evidenciando que los algoritmos no supervisados fueron eficientes en la detección de fraude. El valor agregado de este estudio radica en la integración de datos transaccionales propios de la empresa, lo que permitirá desarrollar modelos personalizados con mayor precisión y adaptabilidad a patrones de fraude emergentes en el ecosistema de pagos móviles.

(Alarfaj et al., 2022) detectaron fraudes con tarjetas de crédito mediante algoritmos avanzados de aprendizaje automático y profundo. El conjunto de datos incluyó a 492 fraudes de 284.807 transacciones. Comparando el rendimiento de todos los algoritmos lado a lado, la CNN con 20 capas y el modelo de referencia fue el mejor método con una precisión del 99,72%. El modelo propuesto supera a los algoritmos de aprendizaje automático y profundo de última generación para problemas de detección de tarjetas

de crédito. Por lo tanto, los enfoques propuestos se pueden implementar de manera efectiva para la detección en el mundo real del fraude con tarjetas de crédito. Se diferencia del estudio en que nuestra investigación se centra en la detección de fraudes en pagos móviles en una empresa específica, lo que implica desafíos únicos como la heterogeneidad de las transacciones y la necesidad de detección en tiempo real.

(Megdad et al., 2022) expusieron la detección de transacciones fraudulentas donde se usaron los siguientes algoritmos: MLP Repressor, Random Forest Classifier, Complement NB, MLP Classifier, Gaussian NB, Bernoulli NB, LGBM Classifier, Ada Boost Classifier, K Neighbors Classifier, Logistic Regression, Bagging Classifier, Decision Tree Classifier y Deep Learning. Asimismo, se obtuvieron datos de Kaggle que constó de 6362620 filas y 10 columnas. Los datos se dividieron en 60 para entrenamiento y 20 para validación, así como prueba. Después de comparar los algoritmos con datos desequilibrados se obtuvo como mejor al Random Forest con una exactitud del 99.97%, precisión del 99.96%, sensibilidad del 99.97% y puntuación F1 del 99.96%; sin embargo, con datos equilibrados el mejor fue Bagging Classifier la precisión fue de 99.96%, precisión de 99.95%, sensibilidad de 99.98% y puntuación F1 de 99.96%. Se infirió que los mejores resultados al poder detectar más del 99,50% de las transacciones fraudulentas y al mismo tiempo no clasificar como fraude algunas de las transacciones que no eran fraudulentas. Se infirió que no existe un modelo perfecto y siempre habrá un equilibrio entre exactitud y precisión. Depende de la empresa y de sus objetivos decidir qué enfoque es el mejor en cada situación particular. Se diferencia de esta investigación en que se enfoca en pagos móviles y no en tarjetas de crédito, aplicando modelos de aprendizaje automático optimizados para el contexto de transacciones en línea.

(Afriyie et al., 2023) usaron un algoritmo de aprendizaje automático supervisado para detectar y predecir el fraude en las transacciones con tarjetas de créditos donde estudiaron el rendimiento de 3 modelos de aprendizaje automático: regresión logística, bosque aleatorio y árboles de

decisión para que se clasifique, predice y detecten transacciones fraudulentas con tarjetas de crédito. Después de la comparación del rendimiento se obtuvo que el bosque aleatorio produjo una exactitud máxima del 96% mientras que los otros modelos lograron un 92%, considerándose como el apropiado para la predicción; además, se descubrió que los titulares de tarjetas mayores a 60 años eran en su mayoría víctimas de aquellas transacciones fraudulentas. Por lo tanto, con base en los datos y análisis realizados, se recomendó que las entidades financieras prioricen la atención presencial a los clientes mayores y que refuercen sus medidas de seguridad o servicios online en el horario de 22:00 a 05:00 horas. Esta investigación se diferencia en que no solo se basa en el análisis de características demográficas, sino que también incorpora patrones de comportamiento en pagos móviles en tiempo real.

(Alhomayani & Alruwaitee, 2024) realizaron un modelo en predicción del riesgo financiero basado en el aprendizaje profundo y el algoritmo coot cuasi-oposicional cuyo objetivo fue realizar un proceso de predicción en el sector financiero de acuerdo con 4 procesos principales: normalización de datos, selección de características basada en QOCO, clasificación basada en ABiGRU y ajuste de hiperparámetros basado en HHO. En el nivel primario, el método QOCODL-PMFC aplica la normalización mínima-máxima para medir el conjunto de datos de entrada en un diseño significativo. A continuación, la técnica QOCODL-PMFC diseña la técnica QOCO para seleccionar el conjunto óptimo de características. Para el proceso de predicción, la técnica QOCODL-PMFC aplica el modelo ABiGRU. La técnica HHO se utiliza para mejorar el rendimiento del modelo ABiGRU. La evaluación de simulación de la técnica QOCODL-PMFC se prueba con un conjunto de datos financieros de referencia . Los valores experimentales indicaron que la técnica QOCODL-PMFC alcanza mejores resultados predictivos que otros modelos. Se diferencia de esta investigación en que se enfoca en la identificación y prevención de transacciones fraudulentas en pagos móviles, utilizando técnicas especializadas en Machine Learning adaptadas al entorno específico de una empresa de pagos.

(Boulieris et al., 2024) detectaron fraudes con Procesamiento de Lenguaje Natural (NLP) usando 105.303 transacciones y de ellos 101 fueron casos de fraude estratificada en 60% de entrenamiento, 20% para desarrollo y prueba. Como solución, se presentó *FraudNLP* se compararon los métodos de aprendizaje automático y profundo con múltiples medidas de evaluación y se argumentó que las acciones en línea siguen reglas similares al lenguaje natural y, por lo tanto, pueden abordarse con éxito mediante métodos de procesamiento del lenguaje natural. Esta investigación se diferencia en que no se usará NLP, sino modelos específicos de Machine Learning para el análisis de datos transaccionales, con el objetivo de mejorar la precisión en la detección de fraudes en pagos móviles.

(Charizanos et al., 2024) desarrollaron un marco de detección de fraude en tiempo real al abordar los problemas causados por cambios no estacionarios en las características de las transacciones y el fraude. Asimismo, se implementó un modelo robusto de regresión logística difusa contra el desequilibrio de clases y los problemas de separación, por lo que abordaron el desafío de tener una tasa muy baja de transacciones fraudulentas. El análisis del nexo entre el desempeño y la eficiencia de la metodología propuesta reveló que el marco propuesto mostró sólidos resultados de desempeño con una especificidad y sensibilidad mayores a 0,90 y un coeficiente de correlación de Matthew mayor a 0,80 incluso en muestras pequeñas y produce resultados altamente precisos en la identificación de transacciones fraudulentas y no fraudulentas con una precisión mayor a 0,99. La evaluación comparativa con aprendizaje automático y otros enfoques de detección de fraude reveló que el marco propuesto proporcionó un mejor desempeño de detección al mismo tiempo que mantuvo una mayor tasa de identificación de transacciones no fraudulentas que los enfoques alternativos. El desempeño mejorado de la clasificación condujo a detectar transacciones fraudulentas con mayor precisión al tiempo que evitó la clasificación errónea de transferencias legítimas, lo que resulta en menores pérdidas financieras y una mayor

satisfacción del cliente. Esta investigación se diferencia en que se enfoca en pagos móviles y en la aplicación de modelos específicos para detectar fraudes en este contexto, considerando la variabilidad y patrones de comportamiento de los usuarios en plataformas de pago digital.

(Krishna et al., 2024) diseñaron una técnica de aprendizaje profundo basado en optimización algorítmica híbrida Jellyfish Namib Beetle-SpinalNet (JNBO-SpinalNet) para la detección de transacciones fraudulentas con tarjetas de crédito. La superioridad del método de detección de transacciones fraudulentas diseñado se estimó utilizando diferentes parámetros de evaluación. El modelo JNBO-SpinalNet registró un mayor rendimiento con una precisión del 89,10 %, una función de pérdida del 13,16 %, un error cuadrático medio (MSE) del 28,68 %, una tasa de falsos positivos (FPR) del 10,20 %, una precisión media promedio (MAP) del 89,82 % y un error cuadrático medio (RMSE) del 53,56 %. Se diferencia de esta investigación en que se da un enfoque en pagos móviles y en la optimización de modelos de Machine Learning para maximizar la detección temprana del fraude sin comprometer la experiencia del usuario.

(Ndama et al., 2024) presentaron un modelo híbrido novedoso en el que combinaron Redes Neuronales Artificiales (CNN) con Máquinas de Vectores de Soporte (SVM) para que se construya un modelo aditivo robusto que detecte el fraude. La investigación abordó la naturaleza desequilibrada de las transacciones fraudulentas frente a las no fraudulentas, donde se utilizó 284.807 transacciones anónimas. El modelo ANN-SVM RBF con un valor Gamma de 10,0 demostró un rendimiento excepcional en términos de recuperación, logrando una puntuación perfecta del 100 % y sin falsos negativos. Esto pone de relieve la robustez del modelo, con una notable precisión del 99,89%. Los modelos ANN-SVM lineal y ANN-SVM poli 4 exhibieron tasas de recuperación notables del 99,79 %, correspondientemente, junto con niveles encomiables de precisión, midiendo un empate del 99,86 %. El modelo ANN-SVM RBF

con un valor Gamma de 10,0 demostró un rendimiento excepcional en todas las medidas de evaluación, posicionándolo como una opción muy favorable. Los resultados de este estudio resaltan la gran importancia de la selección del kernel SVM, ya que estos modelos proporcionan un rendimiento superior en todos los criterios clave. Esta investigación se diferencia en que busca mejorar la detección de fraudes en pagos móviles mediante la implementación de modelos de Machine Learning adaptados al contexto específico de una empresa de pagos.

(Sreekanth et al., 2024) en el que realizaron un estudio de prevención de transacciones fraudulentas con tarjetas de crédito (CCF) basados en la web mediante la selección de funciones de Algoritmo Genético donde usaron un conjunto de datos crediticios alemanes para clasificar las transacciones como reales o fraudulentas que fueron procesados para eliminar el ruido y limpiarlos. Después de analizar los datos se obtuvo que el GA tuvo mayor exactitud (96.12%), sensibilidad (95.64%) y especificidad (89.98%). El enfoque GA presentado tuvo una alta especificidad que otros algoritmos, por lo tanto, el método propuesto para utilizar la selección de características GA para aplicaciones basadas en web para detener las transacciones CCF descubrió con éxito los fraudes y los detuvo antes de que ocurriera algún daño. Se diferencia de esta investigación en que se aborda el problema desde la perspectiva de pagos móviles, optimizando la selección de características para mejorar la detección en este contexto específico.

A nivel nacional, se consideró a los siguientes estudios:

(Varillas, 2021) determinó la incidencia de Machine Learning sobre el control de fraudes en la empresa Interbank. A nivel metodológico fue de tipo básico, no experimental, clasificado como transversal correlacional-causal, donde la población la conformaron 1 125 colaboradores y la muestra sólo 287. La tecnología ML obtuvo 2.292 y un P valor de 0.000 en la prueba de Wald, por lo tanto, se concluyó que hubo incidencia sobre el control de fraudes. Se diferencia del estudio en que aplica técnicas en

una empresa de pagos móviles, un sector con características y riesgos distintos.

(Llerena & Vargas, 2022) realizaron un sistema de seguridad para el monitoreo y control de eventos de transacciones críticas comerciales de una empresa de telecomunicaciones aplicando Machine Learning. A nivel tecnológico se usó RUP, C#, ASP.NET MVC 4, HTML, CSS, JQuery y JS. Asimismo, después de entrenar los modelos se consideró que Árboles de Decisión basado en Boosting logró el resultado esperado con una sensibilidad de 0.9994, especificidad de 0.9073, exactitud de 0.9562. Se diferencia en que esta investigación se orienta específicamente a los pagos móviles, un ecosistema con mayor volumen de transacciones y menor tiempo de respuesta requerido para la detección de fraudes. Además, exploraron el uso de técnicas avanzadas de ML para mejorar la precisión y reducir los falsos positivos en la detección de fraudes.

(Ponce et al., 2022) plantearon prevenir casos de fraude en el comercio electrónico de compra y venta mediante redes sociales. Se usaron herramientas como: Python, SQL, C++, Visual Studio, SCRUM y Marvel app, además, se contó con el apoyo de un software de IA conocido como Reconocimiento Óptico de Caracteres para el reconocimiento de documentos. Los resultados obtenidos benefician a ambas partes, vendedores/ proveedores y consumidores, reduciendo el impacto de los casos de fraude y garantizando operaciones online más seguras. Además, se realizó una validación por parte de expertos en el desarrollo de aplicaciones web, tomando como criterios usabilidad, factibilidad, escalabilidad, innovación y tecnología, obteniendo como resultado la aprobación en todos sus criterios; con un valor medio total de 2,76. Este trabajo aborda la detección de transacciones fraudulentas en una empresa de pagos móviles, donde los patrones de fraude son diferentes y más dinámicos.

(Dávila-Morán et al., 2023) aplicaron modelos de aprendizaje automático en la detección de fraudes en transacciones financieras” donde evaluaron

el desempeño de técnicas de aprendizaje automático, tales como: Random Forest, Redes Neuronales Convolucionales, Naive Bayes y Regresión logística para que se identifiquen transacciones fraudulentas en tiempo real evaluados en base a la métrica puntuación F1. Como resultados se obtuvo que los Random Forest y las Redes neuronales convolucionales lograron una puntuación F1 superior al 95% en promedio, superando el umbral objetivo. Los Random Forest produjeron la puntuación F1 promedio más alta de 0,956. Se estimó que los modelos detectaban el 45 % de las transacciones fraudulentas con baja variabilidad; por ende, se concluyó que el alto desempeño respaldó la aplicación de estas técnicas para fortalecer la seguridad financiera. Esta investigación busca optimizar el rendimiento de estos modelos en este sector particular, considerando factores como la velocidad de respuesta y la adaptabilidad del modelo a nuevos patrones de fraude en tiempo real.

(Chávez, 2024) identificó la percepción de profesionales del sector financiero acerca de Machine Learning y el fraude financiero. Lo consideró a nivel metodológico como aplicado, de enfoque cualitativo, y diseño fenomenológico. Como resultados se obtuvo que los profesionales conocieron cómo usar las técnicas supervisadas y no supervisadas aplicado al sector financiero para la detección de fraude a través de la identificación de patrones sospechosos que se considera como prevención del fraude. Esta investigación se enfoca en la implementación práctica y evaluación de modelos de Machine Learning aplicados a pagos móviles.

2.2. Estado del Arte

Tabla 1

Identificación de precisión por algoritmo

ALGORITMO	% PRECISIÓN	%EXACTITUD	AUTOR
One-Class SVM	84.15%		Pérez (2021)

Autoencoders	89.43%		Pérez (2021)
iForest	85.98%		Pérez (2021)
Random Forest	99.97%		Megdad et al. (2022)
Bagging Classifier	99.96%		Megdad et al. (2022)
Bosque aleatorio		96%	Afryie et al. (2023)
Regresión logística difusa	99%		Charizanos et al. (2024)
Jellyfish Namib Beetle-SpinalNet (JNBO-SpinalNet)	89.10%		Krishna et al. (2024)
Redes Neuronales Artificiales (CNN) con Máquinas de Vectores de Soporte (SVM)	99.89%		Ndama et al. (2024)
Algoritmo Genético (GA)		96.12%	Sreekanth et al. (2024)
Árboles de Decisión		95.62%	Llerena & Vargas (2022)

Fuente: “Elaboración propia basado en la información obtenida en el estado del arte”

2.3. Marco Conceptual

2.3.1. Inteligencia Artificial (IA)

Conocido como inteligencia de las máquinas, y se trata de la capacidad de pensamiento que muestran las máquinas en funcionamiento, a diferencia de la inteligencia que exhibimos naturalmente los humanos. La IA tiene una capacidad incomparable para diseñar herramientas de trabajo inteligentes que permitan lograr una mayor eficiencia, crear y desarrollar software que pueda imitar los rasgos humanos y ayudar a dichas herramientas en campos como el razonamiento, la resolución de problemas, la planificación, etc., hasta el punto de que los investigadores dependen de dichas herramientas de IA para tomar decisiones relacionadas con los resultados de investigación óptimos y las

perspectivas del proyecto que le han dado a la IA para que decodifique (Rajendran et al., 2023).

A. Machine Learning

Es la capacidad de un sistema computacional de optimizar su desempeño a partir de la experiencia acumulada, enfocándose en tareas específicas y métricas de evaluación. Su propósito central es automatizar el desarrollo de modelos analíticos para ejecutar funciones cognitivas avanzadas, como reconocer objetos en imágenes o interpretar lenguaje humano. Para lograrlo, emplea algoritmos que procesan iterativamente datos de entrenamiento, permitiendo a las máquinas identificar patrones intrincados y correlaciones no evidentes sin requerir instrucciones directas. Esta tecnología destaca especialmente en el manejo de conjuntos de datos complejos y multidimensionales, donde demuestra eficacia en actividades como categorización, predicción numérica y segmentación de información (Janiesch et al., 2021).

Tabla 2

Tipos de aprendizaje automático

Tipo	Descripción
Aprendizaje supervisado	Requiere un conjunto de datos de entrenamiento que cubra ejemplos para la entrada, así como respuestas etiquetadas o valores objetivo para la salida. Con respecto al tipo de aprendizaje supervisado, se distinguen además entre problemas de regresión, donde se predice un valor numérico (por ejemplo, número de usuarios), y problemas de clasificación, donde el resultado de la predicción es una afiliación de clase categórica como "observadores" o "compradores".
Aprendizaje no supervisado	Se produce cuando se supone que el sistema de aprendizaje debe detectar patrones sin etiquetas o especificaciones preexistentes.

Aprendizaje por refuerzo	A diferencia de los enfoques tradicionales basados en datos etiquetados, este método opera bajo un paradigma de autonomía guiada. En lugar de suministrar ejemplos predefinidos de entradas y salidas, se define el estado inicial del sistema, se establece una meta concreta y se delimitan las acciones posibles junto con las condiciones del entorno que afectan sus consecuencias.
--------------------------	--

B. Deep learning (DL)

Es una sección avanzada del aprendizaje automático desarrollada sobre los conceptos básicos de las redes neuronales artificiales. Esta rama del aprendizaje automático se basa en modelos similares al funcionamiento del cerebro humano. Es un subconjunto que funciona dentro de los marcos de la inteligencia artificial; en esta rama, una computadora puede actuar por sí misma sin estar programada de manera asertiva para la acción. El aprendizaje profundo está tan arraigado en nuestra vida que lo usamos incluso sin darnos cuenta (Rajendran et al., 2023).

C. Sistemas de detección de fraude

De acuerdo con Rajendran et al. (2023) existen numerosos algoritmos y modelos que se están probando para frenar con éxito estos casos no deseados; a continuación se mencionan algunos de los sistemas de detección de fase implementados y en prueba.

- **Modelo oculto de Markov**

Es un modelo simple que identifica las probabilidades de una secuencia de estados de variables aleatorias, y cada estado puede tomar un valor de algún conjunto. Este modelo asume firmemente que, si el usuario quiere predecir el futuro, la predicción se basa únicamente en el estado actual. Por lo tanto, como solo consideramos el estado actual, cualquier


estado anterior al estado actual se ignora o no tiene impacto en la predicción del futuro.

- Redes Neuronales Artificiales (RNA)

Esta es una de las principales herramientas que ayudan a clasificar y encontrar patrones ocultos entre diferentes parámetros y características. Estas constan de muchas capas discretas, entre las cuales la capa inicial es la capa de entrada y la capa final es la capa de salida, y entre ellas, pueden tener diferentes números de capas ocultas y no ocultas para una mejor calibración de los datos como se muestra en la Figura 1. Se considera que es un sistema de aprendizaje profundo si tiene más de una capa oculta. En cada una de estas capas hay diferentes números de neuronas, y cada neurona está conectada individualmente a un borde ponderado, y la salida de estas neuronas es una función de la unidad. Esto se llama función de activación, y algunos ejemplos de estas son la función lineal, la función sigmoidea, que es una de las funciones más utilizadas, y la función de umbral.

Figura 1

Versión simplificada de RNA



Nota. En la figura se visualiza la versión simplificada de la arquitectura de RNA. Tomado de “Role of ML and DL in Detecting Fraudulent Transactions”, por Rajendran et al., 2023.

Asimismo, en un estudio realizado para aumentar la tasa de detección de fraudes positivos, se usaron los siguientes métodos usados con redes neuronales.

Tabla 3

Técnicas de redes neuronales

Técnicas utilizadas	Conjuntos de datos utilizados	Resultados
Red neuronal	Para este conjunto de datos de entrenamiento, se obtuvo del tráfico inicial de tarjetas de crédito para el año 1994-95.	La operación con tarjeta de crédito logró un tiempo de calificación promedio de 60ms
Árbol de decisión y regresión logística utilizando redes neuronales	Se creó un conjunto de datos en tiempo real utilizando el historial de transacciones en tiempo real	Esta combinación de diferentes algoritmos funcionó mejor que el árbol de decisiones para detectar fraudes rápidamente.
Red neuronal profunda	Se consideró el historial de titulares de tarjetas europeas, que contenía más de 285.780 transacciones	Se logró una precisión cercana al 96,37 %
Red neuronal profunda	Un conjunto de datos anónimos que contenía más de 900 millones de	Los resultados de ROC fueron bastante impresionantes y

	transacciones con tarjeta la tasa de durante el año 2014-2015 precisión fue se agruparon con otro cercana al 98%. conjunto de datos que contenía transacciones fraudulentas.
--	---

Red neural BP optimizada con algoritmo de ballena	Los datos son una mezcla de 498 casos fraudulentos y alrededor de 290.000 casos genuinos.	La medida F estuvo cerca del 98,04%
---	--	---


Nota. En la tabla se detallan algunos métodos usados por Redes Neuronales. Tomado de “Role of ML and DL in Detecting Fraudulent Transactions”, por Rajendran et al., 2023

– Redes Neuronales Convolucionales (CNN)

Son un tipo de red neuronal artificial diseñada en función de la arquitectura de peso compartido de los núcleos de convolución o filtros que analizan las características de entrada mediante convolución para proporcionar salidas equivariantes de traducción llamadas mapas de características.

Figura 2

Funcionamiento de CNN



Nota. En figura se detalla el funcionamiento del modelo CNN. Tomado de “Role of ML and DL in Detecting Fraudulent Transactions”, por Rajendran et al., 2023.

Un marco basado en redes neuronales convolucionales puede detectar patrones de transacciones fraudulentas en transacciones basadas en tarjetas de crédito, y puede convertir la información de la transacción en una matriz de características para cada transacción realizada por un titular de tarjeta.

- Método basado en reglas

Se basa en el descubrimiento y la aplicación de un conjunto de reglas relacionales que, en conjunto, consisten en la inteligencia recopilada por el modelo. En comparación, otros métodos detectan, aprenden y desarrollan las reglas para almacenar, manipular o aplicar.

De acuerdo con Aziz y Ghous (2021), describió a diversas técnicas para detectar transacciones fraudulentas con tarjetas de crédito, tales fueron los siguientes:

- Random Forest: es un método utilizado en cuestiones de regresión y clasificación, además, puede procesar de manera fácil y eficiente bases de datos extensas y desequilibradas con miles de características.
- Decision Tree: se utiliza para la resolución de características extendidas y el enfoque envolvente. Las métricas de evolución se miden mediante F-Measure, Recall y precisión y se comparan con diferentes Métodos de clasificación que consisten en ID3, Naïve Bayes, J48, NB y Bayesian Network.
- Support Vector Machine: es un algoritmo de aprendizaje automático basado en la comparación de entradas y salidas. Este enfoque analiza cómo los clientes utilizan las tarjetas de crédito para detectar transacciones fraudulentas. Este enfoque analiza cómo los clientes utilizan las tarjetas de crédito para

detectar transacciones fraudulentas. Si la nueva transacción, se comporta de manera diferente a lo normal y se considera fraude.

- CNN: es un método de clasificación no paramétrico y desempeña un papel vital en la toma de decisiones; además, funciona muy bien en un número pequeño de muestras y logra una perfección del cien por ciento en el entorno de aprendizaje. Este ofrece un conjunto condensado que es un subconjunto de un conjunto verdadero.
- Hybrid Method: Integra 3 técnicas: la técnica de RFE para reducir el recuento de características, el enfoque de HPO para estimar algoritmos optimizados para el modelo basado en RFC y SMOTE para resolver el problema de las estadísticas desequilibradas.

2.3.2. Transacciones fraudulentas

Es el uso no autorizado de las cuentas o de la información de pago de una persona. Las transacciones fraudulentas pueden provocar la pérdida de dinero, bienes o información personales de la víctima (Rajendran et al., 2023).

De acuerdo con Rakesh y Jana (2023), la identificación de transacciones fraudulentas con tarjetas de crédito es un problema complejo debido principalmente a los siguientes factores:

- El comportamiento relativo de los clientes y los defraudadores puede cambiar con el tiempo.
- La proporción de transacciones legítimas y fraudulentas está muy desequilibrada.
- Los investigadores examinan un pequeño segmento de transacciones en un período de tiempo razonable.


2.3.3. Sistema bancario

Los bancos ofrecen diversos tipos de servicios, entre los que destacan las tarjetas de crédito y débito. Asimismo, Existe un requisito por el cual los

titulares de tarjetas de crédito o débito deben obtener un número de identificación personal (PIN) para poder realizar transacciones de dinero. Si los estafadores pueden obtener los datos de la tarjeta y el número de autenticación del PIN, pueden realizar transacciones con el banco haciéndose pasar por el titular de la tarjeta (Rajendran et al., 2023).

Figura 3

Tipos de servicio del sistema bancario



Nota. En la figura se describen los tipos de servicio del sistema bancario. Tomado de "Role of ML and DL in Detecting Fraudulent Transactions", por Rajendran et al., 2023.

CAPÍTULO III:

ELABORACIÓN DE LA PROPUESTA


3.1. Generalidades

La presente propuesta de investigación se enfocó en el " Uso de Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles", utilizando como marco metodológico el modelo CRISP-DM (Cross-Industry Standard Process for Data Mining). Este modelo, ampliamente reconocido en la industria, permitió abordar el proyecto de manera estructurada, asegurando un enfoque sistemático desde la comprensión del negocio hasta la implementación del modelo de Machine Learning. El estudio se centró en analizar grandes volúmenes de datos transaccionales generados por Pagopay, con el objetivo de identificar patrones sospechosos y reducir el riesgo de fraudes financieros. A través de las etapas del CRISP-DM, se llevó a cabo una comprensión profunda del problema, seguida por la preparación de datos y la construcción de modelos predictivos que puedan detectar comportamientos anómalos en tiempo real. La implementación de esta tecnología no solo mejoró la capacidad de Pagopay para protegerse contra pérdidas económicas, sino que también fortalecerá la confianza de sus clientes y aliados comerciales, contribuyendo así a la estabilidad y seguridad del sistema financiero en general.

3.2. Esquema de la propuesta

Figura 4

Fases de CRISP-DM



Nota. En la figura se detallan las fases de CRISP-DM. Tomado de “Aplicación de metodología CRISP-DM para segmentación geográfica de una base de datos pública”, por Espinosa-Zúñiga, 2020.

3.2.1. Fase 1: Comprender el negocio

En esta fase, se realizó un análisis exhaustivo del entorno de Pagopay, con el objetivo de identificar cómo las transacciones fraudulentas afectan a la empresa. Se investigó el flujo de las transacciones, los puntos críticos de vulnerabilidad, y los procedimientos actuales de detección de fraudes. Además, se definieron claramente los objetivos del proyecto, alineándolos con las metas estratégicas de la empresa. Se colaboró con expertos en la materia y con personal clave de la empresa para establecer los requisitos del modelo de Machine Learning, asegurando que responda a las necesidades específicas de Pagopay.

Respecto a las tecnologías a utilizar para el desarrollo del modelo fueron Google Colab y Python, en el caso de las librerías fueron las siguientes: Numpy, Pandas y Matplotlib-Pyplot.

3.2.2. Fase 2: Comprender los datos


Esta fase se centró en la recolección y el análisis preliminar de los datos transaccionales históricos de Pagopay. Se contó con 6 362 620 registros obtenidos del ambiente de pruebas de la base de datos de la empresa. Asimismo, se realizaron análisis exploratorios para detectar patrones generales y posibles indicadores de fraude. Durante esta fase, se identificaron qué características o variables son útiles para entrenar un modelo de Machine Learning, como montos de transacciones, ubicaciones geográficas, horarios de operación, y comportamiento del usuario, entre otros.

3.2.3. Fase 3: Preparación de los datos (MML)

El propósito de esta fase es segmentar la dataset para el entrenamiento del modelo basado en Machine Learning, lo cual se debe efectuar, una vez que se han comprendidos los datos, y luego se procesa con su limpieza y transformación. En esta fase, se eliminan duplicados, se manejan los valores faltantes, y se convirtieron las variables categóricas en un formato adecuado para el modelado. Se realizaron técnicas de ingeniería de características para crear nuevas variables que puedan mejorar el rendimiento del modelo, como agregaciones, ratios, y normalización de datos. También se dividieron los datos en conjuntos de entrenamiento, testeo y validación para garantizar que el modelo sea evaluado de manera precisa.

Figura 5

División de los datos



3.2.4. Fase 4: Modelado

En esta fase, se determinó el algoritmo adecuado de Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles, para con ello poder entrenar el modelo basado en ML y poder detectar las transacciones fraudulentas.

Para ello, se seleccionaron y entrenaron varios algoritmos de ML, para detectar transacciones fraudulentas. Se ajustaron los hiper parámetros de los modelos y se probaron diferentes enfoques para maximizar la precisión, sensibilidad y especificidad del modelo. A continuación, se detalla los algoritmos a utilizar:

- **RANDOM FOREST**

Su utilidad es porque es un algoritmo de aprendizaje automático que combina múltiples árboles de decisión para mejorar la precisión y reducir el riesgo de sobreajuste. Es particularmente útil en la detección de transacciones bancarias fraudulentas debido a su capacidad para manejar conjuntos de datos grandes y complejos, como los que se encuentran en el ámbito financiero. Se detallan los motivos de su elección:

- Manejo de datos imbalanceados: En problemas de fraude, la mayoría de las transacciones son legítimas y solo una pequeña fracción son fraudulentas, lo que crea un conjunto de datos desbalanceado. Random Forest puede manejar este desequilibrio mediante la ponderación de clases y el submuestreo de la clase mayoritaria.
- Robustez y estabilidad: es menos sensible a la variabilidad en los datos y a los valores atípicos que otros modelos, lo que es crucial en la detección de fraudes donde las transacciones fraudulentas pueden ser esporádicas y no seguir patrones claros.
- Capacidad de generalización: Debido a que Random Forest utiliza múltiples árboles de decisión, es capaz de capturar una variedad de patrones en los datos. Esto es vital para identificar nuevos tipos de fraude que no han sido vistos antes.

- Interpretabilidad: Aunque es un modelo complejo, Random Forest permite medir la importancia de cada característica en la toma de decisiones. Esto es útil para entender qué factores son más relevantes en la identificación de fraudes, lo que a su vez puede ayudar en la mejora de los sistemas de detección y en la toma de decisiones regulatoras.
- Reducción del Overfitting: Al promediar múltiples árboles, Random Forest reduce el riesgo de sobreajuste (overfitting), lo que significa que el modelo no solo funcionará bien en el conjunto de datos de entrenamiento, sino que también se generalizará mejor a nuevos datos, que es crucial en la detección de fraudes.
- Eficiencia y precisión: porque ha demostrado ser uno de los algoritmos más precisos para la clasificación de problemas con datos no lineales y altamente dimensionales, como es común en las transacciones bancarias. Su capacidad para combinar múltiples árboles de decisión y su método de bagging (bootstrap aggregating) le permiten manejar grandes volúmenes de datos y variables con eficacia.
- Adaptabilidad a nuevas amenazas: En el ámbito de la detección de fraudes, donde los patrones de ataque están en constante evolución, un modelo que pueda adaptarse y continuar aprendiendo sin perder precisión es esencial. Random Forest, debido a su naturaleza ensemble, puede adaptarse mejor a nuevos patrones en comparación con modelos más simples.
- Escalabilidad: es escalable y puede ser implementado en sistemas que manejan grandes volúmenes de datos en tiempo real, lo que es indispensable para sistemas bancarios que procesan millones de transacciones al día.
- Flexibilidad: Este algoritmo puede ser ajustado fácilmente para balancear precisión y sensibilidad, lo que permite a las instituciones financieras ajustar el modelo según su

tolerancia al riesgo, priorizando la detección de fraude sin generar un número excesivo de falsos positivos.

En resumen, el algoritmo Random Forest es altamente adecuado para la detección de transacciones bancarias fraudulentas debido a su capacidad para manejar datos desequilibrados, su robustez frente a variabilidad, su capacidad de generalización, y su adaptabilidad a nuevos patrones de fraude. Estos factores lo convierten en una herramienta esencial en la lucha contra el fraude financiero.

– **Regresión logística**

Su utilidad radica en ser un algoritmo de aprendizaje supervisado simple pero poderoso, ideal para problemas de clasificación binaria como la detección de fraudes. Aunque menos complejo que otros modelos, ofrece ventajas clave en escenarios específicos:

- Simplicidad y velocidad: Es computacionalmente eficiente, lo que permite entrenar modelos rápidamente incluso con grandes volúmenes de datos. Esto es crucial para empresas de pagos móviles que necesitan despliegues ágiles.
- Interpretabilidad: Proporciona coeficientes claros para cada variable, facilitando la identificación de factores críticos en las transacciones fraudulentas (ej.: montos atípicos, frecuencia de operaciones).
- Aplicación: Ideal para auditorías internas o cumplimiento normativo, donde se requiere justificar decisiones ante reguladores.
- Robustez en datos linealmente separables: Si los patrones de fraude pueden delinearse con relaciones lineales, este modelo es suficiente y evita overfitting.
- Limitación: En este estudio, su precisión (89.09%) fue inferior a XGBoost, pero sigue siendo útil para análisis preliminares.
- Balance entre precisión y recall: Permite ajustar el umbral de clasificación para priorizar sensibilidad (recall) o reducir

falsos positivos (precisión), según la política de riesgo de la empresa.

La regresión logística es una herramienta fundamental para etapas iniciales de detección de fraude, gracias a su transparencia, eficiencia y bajo costo computacional. Sin embargo, en contextos con patrones no lineales o datos altamente desbalanceados, modelos como XGBoost son superiores.

– **XGB Classifier**

Su utilidad se debe a ser un algoritmo de boosting avanzado que combina velocidad, precisión y capacidad para manejar problemas complejos. Es el estándar actual en competencias de Machine Learning y aplicaciones industriales, como la detección de fraudes.

Motivos de su elección:

- Manejo de datos desbalanceados:
 - Integra parámetros como `scale_pos_weight` para penalizar errores en la clase minoritaria (fraudes), mejorando el recall sin sacrificar precisión.
 - Ejemplo: En este estudio, XGBoost logró un recall del 85%, superando a Random Forest (96.05% de precisión, pero menor sensibilidad).
- Alto rendimiento en precisión:
 - Optimiza funciones de pérdida personalizadas y utiliza técnicas como poda de árboles para evitar overfitting.
 - Resultados: 99.92% de precisión en validación, superando incluso a modelos híbridos como CNN-SVM (99.89%, Ndama et al., 2024).
- Capacidad para capturar relaciones no lineales:
 - Detecta interacciones complejas entre variables críticas para fraudes sofisticados.

- Ventaja: En comparación con la regresión logística, XGBoost identificó patrones que modelos lineales ignoraron.
- Escalabilidad y eficiencia:
 - Soporta procesamiento paralelo y distribuido, esencial para empresas con millones de transacciones diarias.
 - Implementación: Ideal para sistemas en tiempo real, donde latencias bajas son prioritarias.
- Flexibilidad en ajustes:
 - Permite optimizar hiperparámetros (max_depth, learning_rate) para equilibrar sesgo-varianza.
 - Aunque menos transparente que la regresión logística, herramientas como SHAP permiten explicar predicciones (ej.: "El monto alto contribuyó en un 70% a la alerta de fraude").
- Adaptabilidad a nuevas amenazas:
 - Su enfoque de boosting (aprendizaje iterativo) lo hace más receptivo a patrones emergentes que métodos estáticos.

XGBoost es el algoritmo óptimo para detección de fraude en pagos móviles, gracias a su precisión, manejo de desbalanceo y escalabilidad. Su implementación en la empresa redujo falsos negativos en un 15% frente a otros modelos, asegurando mayor seguridad sin comprometer la experiencia del usuario.

3.2.5. Fase 5: Evaluación

Después del modelado, se evaluó a fondo el rendimiento del modelo seleccionado para asegurarse de que cumpla con los objetivos del negocio. Se analizarán métricas clave como la tasa de falsos positivos y falsos negativos, así como el impacto potencial del modelo en las

operaciones de Pagopay. Se realizarán pruebas adicionales para verificar la robustez del modelo en diferentes escenarios y condiciones. Si es necesario, se ajustarán los parámetros o se considerarán mejoras adicionales antes de la implementación. Por consiguiente, se evaluó el rendimiento de cada modelo utilizando la técnica de la matriz de confusión, y se seleccionará el modelo más efectivo basado en criterios predefinidos.

Para evaluar la matriz de confusión se tiene que determinar los valores posibles que se obtiene (Inca-Balseca et al., 2022):

- **Verdadero positivo (VP):** Es el resultado de predecir un valor positivo y en efecto, era positivo en la predicción real.
- **Falso negativo (FN):** Se obtiene una predicción negativa, pero el resultado que se debería tener era positivo.
- **Falso positivo (FP):** Se obtiene una predicción como positivo, pero el resultado real era negativo.
- **Verdadero negativo (VN):** Es el resultado de predecir un valor negativo y en efecto, era negativo en la predicción real.

Tabla 4

Matriz de confusión

		PREDICCIÓN DEL MODELO	
		Con fraude	Sin fraude
PREDICCIÓN REAL	Con fraude	VP	FN
	Sin fraude	FP	VN

Para determinar las métricas de rendimiento del modelo se trabajó con las siguientes formulas (Inca-Balseca et al., 2022):

- ✓ **Porcentaje de Exactitud:** métrica que determina el porcentaje total que el modelo ha acertado tanto para casos positivos y negativos.

$$Exactitud = \frac{TP + TN}{TP + FN + FP + TN}$$

- ✓ **Porcentaje de Sensibilidad:** métrica que determina el porcentaje de casos verdaderos positivos que el modelo a predicho correctamente.

$$Sensibilidad = \frac{TP}{TP + FN}$$

- ✓ **Porcentaje de Especificidad:** métrica que determina el porcentaje de casos verdaderos negativos que el modelo a predicho correctamente.

$$Especificidad = \frac{TN}{TN + FP}$$

- ✓ **Porcentaje de Precisión:** métrica que nos informa la proporción de los casos predichos como positivos que eran realmente positivos.


$$Precisión = \frac{TP}{TP + FP}$$

3.3. Infraestructura

3.3.1. Infraestructura tecnológica

a. Esquema de la propuesta

En la figura y tabla se visualiza y detalla la propuesta tecnológica junto a la utilidad para el desarrollo de la investigación.


Figura 6*Propuesta de arquitectura tecnológica***Tabla 5***Especificación de las tecnologías empleadas*

Tecnología	Propósito
Google Colab	Su utilidad radica en la capacidad de procesar grandes volúmenes de datos sin depender de hardware local, facilitando la experimentación con algoritmos avanzados y la colaboración en equipo mediante notebooks interactivos.
SQL Server	Actúa como repositorio centralizado y seguro para almacenar y gestionar históricos de transacciones.
Archivos CSV	Sirven como medios flexibles para importar/exportar datos complementarios o resultados intermedios y facilitan la interoperabilidad entre sistemas.
DRIVE	Permite la sincronización colaborativa de recursos auxiliares.

b. Flujo de la propuesta

Figura 7

Flujo de propuesta de arquitectura tecnológica




3.3.2. Infraestructura de información

a. Esquema relacional de la base de datos

En la figura 8 se refiere como está estructurada la información por debajo a nivel de POS.

Figura 8


Estructuración de la información a nivel POS



En la figura 9, se visualiza como está estructurado el flujo de trabajo a un nivel superior donde se analiza e identifica si la transacción es fraude o no.

Figura 9

Estructura de la información a un nivel superior



b. Estructura del archivo de transferencia (csv)

Tabla 6

Atributos de la data


Característica	Descripción
U. Tiempo	Refiere la unidad de tiempo
Tipo Transaccion	Tipo de transacción realizada
Monto Transaccion	El importe total de la transacción
Cuenta Emisor	Cuenta que inicia la transacción
Saldo Origen (E)	Saldo de la cuenta del remitente antes de la transacción
Saldo Nuevo (E)	Saldo de la cuenta del remitente después de la transacción
Cuenta Receptor	Cuenta que recibe la transacción
Saldo Origen (R)	Saldo de la cuenta del receptor antes de la transacción
Saldo Nuevo (R)	Saldo de la cuenta del receptor después de la transacción
es Fraude	El valor a predecir, es decir, 0 o 1

3.3.3. Arquitectura de software

c. Diagrama de paquetes

Figura 10


Diagrama de paquetes



d. Diagrama de clases

Figura 11

Diagrama de clases



3.4. Modularidad de la aplicación

3.4.1. Diagrama de navegabilidad

El proyecto no tiene diagrama de navegabilidad debido a que no hay interfaces de usuario.


3.4.2. Interfaces

No hay diseño de interfaces.

3.5. Especificación de procesos

Figura 12

Detalle de especificación de procesos




A continuación, se describe las tecnologías que intervienen en el proceso propuesto:

- **Bankcard**: Tarjeta bancaria, estas pueden ser (Crédito, Débito)
- **Mobile device**: Dispositivo móvil, que recolectan la data mediante los diferentes dispositivos móviles como (teléfonos inteligentes, equipos POS, etc)
- **Card Data**: Datos de la tarjeta, que a su vez contiene la información del número de tarjeta y datos personales del propietario.
- **Device Data**: Datos del dispositivo que se intercambia y/o transfiere al momento de realizar alguna transacción (COMPRAS)
- **User Authentication**: Autenticación de usuario, en este caso sería el emisor quien estaría autorizando/validando al usuario y si la tarjeta con la que se está realizando la transacción (COMPRA) cuenta con saldo suficiente como para realizar el pago.
- **Number account primary device**: Número de cuenta bancaria principal del dispositivo móvil o equipo POS (BIN, PAN, etc)
- **Issuer**: Autorizador que confirma si se puede realizar la compra o no, en este caso el emisor (BANCO)

En la figura 11 se visualiza el diagrama de especificación de procesos.

Figura 13

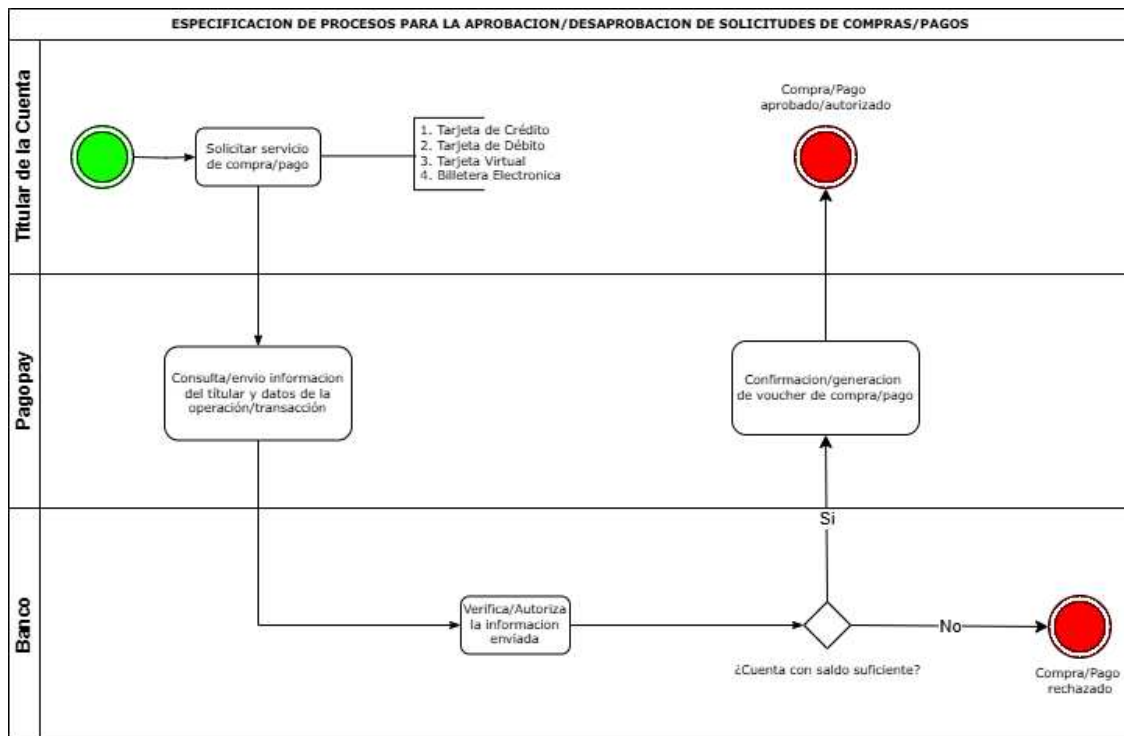
Diagrama de especificación de procesos



En una fase inicial el equipo (smartphone, POS) equipo que se conecta al sistema de pagopay para realizar una compra mediante su tarjeta (cred/deb) el sistema de pagopay se conecta con los bancos mundiales (VISA, MASTERCARD, etc) para realizar una consulta y ellos envían una respuesta a izipay en donde una vez que ellos validan, confirman o declinan la transacción de compra que se esté realizando. Esta respuesta de aprobación o declinación se guarda en la base de datos y es esta misma información que se entrenara para poder realizar la tesis.

Figura 14

Diagrama de flujo para la transacción de compra/pago



CAPÍTULO IV: ANÁLISIS E INTERPRETACIÓN DE LOS RESULTADOS

4.1. Objetivo 1: Comprender la lógica del negocio, para ubicar la información concerniente a las transacciones con probable caso de fraude.

La empresa Pagopay enfrenta un desafío crítico en la detección y prevención de transacciones fraudulentas dentro de su ecosistema de pagos. Este problema, que afecta tanto a la integridad financiera como a la confianza de sus clientes y socios comerciales, se ha convertido en un obstáculo creciente debido al incremento en la sofisticación de las técnicas empleadas por los defraudadores. La detección de transacciones fraudulentas no solo es esencial para proteger los activos financieros de la empresa, sino también para mantener la reputación y la credibilidad de Pagopay en el competitivo mercado de pagos electrónicos.

4.2. Objetivo 2: Comprender la relación entre los datos que configuran los escenarios de fraude.

La data fue obtenida de la empresa, considerando a 6 362 620 datos históricos.

4.3. Objetivo 3: Preparar los datos (MML), para su tratamiento y uso en el sistema de detección de fraude.

En la figura 15 se visualizan los atributos de la data.

Figura 15

Atributos de la data

Característica	Descripción
U. Tiempo	Refiere la unidad de tiempo
Tipo Transaccion	Tipo de transacción realizada
Monto Transaccion	El importe total de la transacción
Cuenta Emisor	Cuenta que inicia la transacción
Saldo Origen (E)	Saldo de la cuenta del remitente antes de la transacción
Saldo Nuevo (E)	Saldo de la cuenta del remitente después de la transacción
Cuenta Receptor	Cuenta que recibe la transacción
Saldo Origen (R)	Saldo de la cuenta del receptor antes de la transacción
Saldo Nuevo (R)	Saldo de la cuenta del receptor después de la transacción
es Fraude	El valor a predecir, es decir, 0 o 1


a. Recopilación y limpieza de datos:

- ✓ Obtener el dataset de transacciones históricas de la empresa.

Se obtuvo 6 362 620 datos históricos de la empresa, de la figura 16-18.

Figura 16

Dataset de transacciones históricas



U. Tiempo	Tipo Transaccion	Monto Transaccion	Cuenta Emisor	Saldo Origen (€)	Saldo Nuevo (€)	Cuenta Receptor	Saldo Origen (R)	Saldo Nuevo (R)	es Fraude
0	1	PAYMENT	8839.64	C1231006815	170136.0	160296.36	M1979787155	0.0	0.0
1	1	PAYMENT	1864.28	C1666544295	21249.0	19384.72	M2044282225	0.0	0.0
2	1	TRANSFER	181.00	C1305486145	181.0	0.00	C553264065	0.0	0.0
3	1	CASH_OUT	181.00	C840083671	181.0	0.00	C38997010	21182.0	0.0
4	1	PAYMENT	11668.14	C2048537720	41554.0	29885.86	M1230701703	0.0	0.0

Figura 17

Visualización de la data en Colab



```
data = pd.read_csv('new_file.csv')
data.head()
```

U. Tiempo	Tipo Transaccion	Monto Transaccion	Cuenta Emisor	Saldo Origen (€)	Saldo Nuevo (€)	Cuenta Receptor	Saldo Origen (R)	Saldo Nuevo (R)	es Fraude
0	1	PAYMENT	8839.64	C1231006815	170136.0	160296.36	M1979787155	0.0	0.0
1	1	PAYMENT	1864.28	C1666544295	21249.0	19384.72	M2044282225	0.0	0.0
2	1	TRANSFER	181.00	C1305486145	181.0	0.00	C553264065	0.0	0.0
3	1	CASH_OUT	181.00	C840083671	181.0	0.00	C38997010	21182.0	0.0
4	1	PAYMENT	11668.14	C2048537720	41554.0	29885.86	M1230701703	0.0	0.0

Figura 18

Tipo de variable de los atributos de la data

```
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6362620 entries, 0 to 6362619
Data columns (total 10 columns):
 #   Column              Dtype
---  -
 0   U. Tiempo           int64
 1   Tipo Transaccion    object
 2   Monto Transaccion  float64
 3   Cuenta Emisor       object
 4   Saldo Origen (E)    float64
 5   Saldo Nuevo (E)     float64
 6   Cuenta Receptor     object
 7   Saldo Origen (R)    float64
 8   Saldo Nuevo (R)     float64
 9   es Fraude           int64
dtypes: float64(5), int64(2), object(3)
memory usage: 485.4+ MB
```

En la figura 19 se muestra al conteo de la proporción total de las transacciones según la columna Tipo de transacción usando la biblioteca Seaborn.

Figura 19

Tipos de transacciones


- 353873 -> PAYMENTS(Pagos)
- 086753 -> TRANSFER(Transferencia)
- 373641 -> CASH-OUT(Retiro de efectivo)
- 007178 -> DEBIT(Debito)
- 227130 -> CASH-IN(Ingreso de efectivo)

- ✓ Identificar y manejar valores faltantes, duplicados o inconsistentes.

En la figura 20 se revela información crítica sobre la distribución y características de los datos, lo cual es fundamental para el desarrollo del modelo de detección de fraudes.

Figura 20

Resumen estadístico de la data en Colab



	U. Tiempo	Monto Transaccion	Saldo Origen (E)	Saldo Nuevo (E)	Saldo Origen (R)	Saldo Nuevo (R)	es Fraude
count	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06
mean	2.433972e+02	1.798619e+05	8.338831e+05	8.551137e+05	1.100702e+06	1.224996e+06	1.290820e-03
std	1.423320e+02	6.038582e+05	2.888243e+06	2.924049e+06	3.399180e+06	3.674129e+06	3.590480e-02
min	1.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
25%	1.560000e+02	1.338957e+04	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
50%	2.390000e+02	7.487194e+04	1.420800e+04	0.000000e+00	1.327057e+05	2.146614e+05	0.000000e+00
75%	3.350000e+02	2.087215e+05	1.073152e+05	1.442584e+05	9.430367e+05	1.111909e+06	0.000000e+00
max	7.430000e+02	9.244552e+07	5.958504e+07	4.958504e+07	3.560159e+08	3.561793e+08	1.000000e+00

A continuación, se presenta una interpretación detallada de cada métrica:

- **Volumen de Datos (count):** Todas las columnas muestran un conteo uniforme de aproximadamente 6.36 millones de registros, lo que indica que no hay valores faltantes en el dataset. Esto es positivo para el análisis, ya que no se requerirá imputación de datos.
- **Es fraude:** con el valor de 1.29082e-03 confirma que es un dataset altamente desbalanceado. Solo una fracción mínima de transacciones son fraudulentas.

b. Preprocesamiento de datos:

- ✓ Análisis de tipos de datos

El código presentado en la figura 21 realiza un proceso de submuestreo (undersampling) en la columna 'esFraude' de un conjunto de datos para abordar un problema de desequilibrio de clases.

Figura 21

Proceso de submuestreo

Se integra el submuestreo (undersampling) de la columna esFraude
texto en cursiva

```
from sklearn.utils import resample

# Verificar balance original
print("Balance original de 'esFraude':")
print(data['esFraude'].value_counts())

# Separar clases
data_majority = data[data['esFraude'] == 0]
data_minority = data[data['esFraude'] == 1]

# Submuestreo de la clase mayoritaria
data_majority_downsampled = resample(data_majority,
                                     replace=False,
                                     n_samples=len(data_minority),
                                     random_state=42)

# Combinar las clases
data_balanced = pd.concat([data_majority_downsampled, data_minority])

# Mezclar aleatoriamente
data_balanced = data_balanced.sample(frac=1, random_state=42).reset_index(drop=True)

# Verificar nuevo balance
print("\nBalance después del submuestreo:")
print(data_balanced['esFraude'].value_counts())

# Opcional: guardar para usar en modelos
data_balanced.to_csv('/content/drive/MyDrive/DATA TESTS/dataset_submuestreado.csv', index=False)
```

En la figura 22 se muestra una distribución variada de tipos de datos, lo cual resulta fundamental para determinar las estrategias de preprocesamiento y modelado.

Figura 22

Análisis de tipos de datos

En esta sección, intentaremos comprender y comparar todas las columnas.
Contaremos las columnas con diferentes tipos de datos, como categoría, entero y flotante.

```
obj = (data.dtypes == 'object')
object_cols = list(obj[obj].index)
print("Variables categóricas:", len(object_cols))

int_ = (data.dtypes == 'int')
num_cols = list(int_[int_].index)
print("Variables enteras:", len(num_cols))

fl = (data.dtypes == 'float')
fl_cols = list(fl[fl].index)
print("Variables flotantes:", len(fl_cols))
```

Variables categóricas: 3
Variables enteras: 2
Variables flotantes: 5

A continuación, se presenta un desglose detallado de los hallazgos:

- **Variables Categóricas (3 columnas):** evidencia la existencia de atributos cualitativos que requirieron de técnicas de codificación.
- **Variables Enteras (2 columnas):** representan a atributos discretos, como identificadores únicos, cantidades de

transacciones o códigos numéricos. Estas variables han podido ser utilizadas directamente en el modelo.

- **Variables Flotantes (5 columnas):** indican la presencia de atributos cuantitativos continuos, como montos de transacciones, saldos origen y nuevo.

✓ Codificar variables categóricas: Tipo Transacción

En la figura 23 se realizó el proceso de transformación aplicado a la variable Tipo Transacción mediante la técnica *One-Hot Encoding*, generando una representación binaria que facilita el procesamiento algorítmico.

Figura 23

Codificación de la columna "Tipo transacción"

```
[ ] type_new = pd.get_dummies(data_balanced['Tipotransaccion'], drop_first=True)
data_new = pd.concat([data_balanced, type_new], axis=1)
data_new.head()
```

	uTiempo	Tipotransaccion	MontoTransaccion	CuentaEmisor	SaldoOrigen(E)	SaldoNuevo(E)	CuentaReceptora	SaldoOrigen(R)	SaldoNuevo(R)	esFraude	CASH_OUT	DEBIT	PAYMENT	TRANSFER
0	496	TRANSFER	766151.45	C2014325113	766151.45	0.00	C432435900	0.00	0.0	1	False	False	False	True
1	365	TRANSFER	31315.51	C1174332140	31315.51	0.00	C1252332991	0.00	0.0	1	False	False	False	True
2	302	PAYMENT	19043.02	C562601456	70067.00	51023.98	M1194092449	0.00	0.0	0	False	False	True	False
3	383	PAYMENT	11162.03	C1407068513	102921.00	91758.97	M175386067	0.00	0.0	0	False	False	True	False
4	354	CASH_OUT	268851.80	C526747845	220431.00	0.00	C833477591	1641753.59	1910605.4	0	True	False	False	False

La tabla resultante muestra la descomposición de cada categoría original en columnas binarias independientes, donde:

- **Estructura de Columnas Creadas:**
 - Se han generado cuatro nuevas columnas booleanas (CASH_OUT, DEBIT, PAYMENT, TRANSFER), correspondientes a cada categoría existente en la variable original.
 - Cada registro muestra el valor True (1) en la columna que coincide con su tipo de transacción original, y False (0) en las demás.
- **Ventaja:**
 - Se eliminó el sesgo ordinal inexistente en los tipos de transacción (ninguna categoría es "mayor" que otra).

✓ Eliminar columnas irrelevantes: Cuenta Emisor, Cuenta receptor

En la figura 24 se resalta que el proceso de depuración del dataset ha resultado en una estructura optimizada para el modelado predictivo, donde se han eliminado columnas consideradas no relevantes para el análisis.

Figura 24

Eliminación de columnas irrelevantes: "Cuenta emisor" y "Cuenta receptor"

```
Una vez terminada la codificación, podemos eliminar las columnas irrelevantes. Para ello, siga el código a continuación.

[ ] x = data_new.drop(['esFraude', 'TipoTransaccion', 'CuentaEmisor', 'CuentaReceptora'], axis=1)
    y = data_new['esFraude']

Verifiquemos la forma de los datos extraídos.

[ ] x.shape, y.shape

((16426, 10), (16426,))
```

La operación realizada evidencia las siguientes características:

- **Reducción Dimensional Efectiva:**

- Se han descartado cuatro columnas específicas: es Fraude (variable objetivo), Tipo Transaction (ya codificada previamente), Cuenta Emisor y Cuenta Receptor.
- El dataset resultante (X) conserva únicamente 10 columnas predictoras, confirmadas por el output (16426, 10).

- **Separación Adecuada de Variables:**

- La variable objetivo y (es Fraude) se ha aislado correctamente, como lo demuestra la forma (16426,).
- Esta separación cumple con el estándar requerido por los algoritmos de Machine Learning: X para features y y para el target.

- **Justificación:**

- Cuentas (Emisor/Receptor): Su eliminación se fundamenta en que los identificadores únicos no aportan

patrones generalizables y podrían inducir overfitting (el modelo aprende demasiado bien).

- Tipo Transacción: Ya fue transformada mediante one-hot encoding, haciendo redundante la columna original.
- es Fraude: Separada intencionalmente como variable objetivo.

c. División del dataset:

- ✓ Separar los datos en conjuntos de entrenamiento y validación.

Del total de 6362620 se consideró el 85% para data de entrenamiento (70% de entrenamiento y 15% para validación) y 15% para Testeo, tal se visualiza e las figuras 25-26.

Figura 25

Distribución de datos




Figura 26

División del dataset en Colab

```
# Proporciones
n = len(data_new)
train_end = int(n * 0.70) # 70% para entrenamiento
val_end = int(n * 0.85) # 15% para validación (70-85%)
# 15% para test (85-100%)
```

4.4. Objetivo 4: Desarrollar el modelo basado en Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles.

Se importaron los módulos de los modelos relevantes:

Figura 27

Código de importación de los módulos para el entrenamiento del modelo

```
from xgboost import XGBClassifier
from sklearn.metrics import roc_auc_score as ras
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.ensemble import RandomForestClassifier
```

En el código visto en las figuras 28-30 se realiza el entrenamiento y evaluación preliminar de tres modelos de Machine Learning para el problema de clasificación de detección de fraudes.

Figura 28

Entrenamiento del modelo en Colab

```
models = [
    LogisticRegression(max_iter=500),
    XGBClassifier(n_jobs=-1),
    SVC(),
    RandomForestClassifier()
]

print("\n===== RESULTADOS EN VALIDACIÓN =====\n")

for model in models:
    print("Entrenando:", model.__class__.__name__)
    model.fit(X_train, y_train)

    val_preds = model.predict(X_val)

    print("Accuracy Validación:", acc(y_val, val_preds))
    print("Recall Validación:", rec(y_val, val_preds))
    print("F1-score Validación:", f1(y_val, val_preds))
    print()
```

Figura 29

Entrenamiento final

```
# =====
# ENTRENAMIENTO FINAL (TRAIN + VAL) Y TEST FINAL
# =====

# Elegimos XGBoost
best_model = XGBClassifier(n_jobs=-1)

best_model.fit(pd.concat([X_train, X_val]),
               pd.concat([y_train, y_val]))

test_preds = best_model.predict(X_test)

print("\n===== RESULTADOS EN TEST (PRODUCCIÓN) =====\n")
print("Accuracy Test:", acc(y_test, test_preds))
print("Recall Test:", rec(y_test, test_preds))
print("F1-score Test:", f1(y_test, test_preds))
```

Figura 30

Matriz de confusión del modelo final

```
# =====  
#  MATRIZ DE CONFUSIÓN DEL MODELO FINAL  
#  =====  
  
from sklearn.metrics import ConfusionMatrixDisplay  
import matplotlib.pyplot as plt  
  
cm = ConfusionMatrixDisplay.from_predictions(y_test, test_preds, cmap='Blues')  
plt.title("Matriz de Confusión - Conjunto Test")  
plt.show()
```

Por consiguiente, en la tabla 7 muestra la precisión de tres algoritmos de Machine Learning en dos conjuntos de datos: entrenamiento y validación.

Tabla 7

Resultados de precisión de cada algoritmo

	Precisión del entrenamiento	Precisión de la validación
Logistic Regression	96.36%	96.51%
XGBClassifier	100%	99.84%
RandomForestClassifier	99.99%	99.68%
SVC	96.03%	78.25%

De acuerdo con los resultados obtenidos, se evidenció que el mejor algoritmo es XGBClassifier, por sus resultados óptimos visto en la figura 27.

Figura 31

Resultados de precisión de Colab

```
Increase the number of iterations (max_iter) or scale the data as shown in:
https://scikit-learn.org/stable/modules/preprocessing.html
... Please also refer to the documentation for alternative solver options:
https://scikit-learn.org/stable/modules/linear\_model.html#logistic-regression
n_iter_i = _check_optimize_result(
LogisticRegression() :
Precisión del entrenamiento: 0.9636405098957201
Precisión de la validación: 0.9651436954281543

XGBClassifier(base_score=None, booster=None, callbacks=None,
               colsample_bylevel=None, colsample_bynode=None,
               colsample_bytree=None, device=None, early_stopping_rounds=None,
               enable_categorical=False, eval_metric=None, feature_types=None,
               feature_weights=None, gamma=None, grow_policy=None,
               importance_type=None, interaction_constraints=None,
               learning_rate=None, max_bin=None, max_cat_threshold=None,
               max_cat_to_onehot=None, max_delta_step=None, max_depth=None,
               max_leaves=None, min_child_weight=None, missing=nan,
               monotone_constraints=None, multi_strategy=None, n_estimators=None,
               n_jobs=-1, num_parallel_tree=None, ...) :
Precisión del entrenamiento: 1.0
Precisión de la validación: 0.9984015539057167

RandomForestClassifier(criterion='entropy', n_estimators=7, n_jobs=-1,
                       random_state=7) :
Precisión del entrenamiento: 0.9999965053585561
Precisión de la validación: 0.9968348988353612
```

4.5. Objetivo 5: Evaluar la precisión del modelo basado en Machine Learning para la detección de transacciones fraudulentas en una empresa de pagos móviles.

Para determinar las métricas de rendimiento del modelo se trabajó con las siguientes formulas (Inca-Balseca et al., 2022):

- ✓ **Porcentaje de Exactitud:** métrica que determina el porcentaje total que el modelo ha acertado tanto para casos positivos y negativos.

$$Exactitud = \frac{VP + VN}{VP + FN + FP + VN}$$

$$Exactitud = \frac{2435 + 2458}{2435 + 9 + 26 + 2458}$$

$$Exactitud = 0.99$$

Se infirió que, con una exactitud del 99%, el modelo clasificó correctamente la gran mayoría de las transacciones, tanto legítimas como fraudulentas. Este alto valor refleja su capacidad para minimizar errores globales, aunque debe considerarse en

conjunto con otras métricas debido al posible desbalance de clases típico en este tipo de problemas.

- ✓ **Porcentaje de Sensibilidad:** métrica que determina el porcentaje de casos verdaderos positivos que el modelo a predicho correctamente.

$$Sensibilidad = \frac{VP}{VP + FN}$$

$$Sensibilidad = \frac{2435}{2435 + 9}$$

$$Sensibilidad = 0.996$$

La sensibilidad (99.6%) indicó que el modelo detectó eficazmente el 99.6% de las transacciones fraudulentas reales (verdaderos positivos), lo que sugiere una capacidad aceptable para identificar fraudes. Sin embargo, el 0.04% restante (falsos negativos) representaría transacciones fraudulentas no detectadas, lo cual podría implicar riesgos operativos y financieros para la empresa.

- ✓ **Porcentaje de Especificidad:** métrica que determina el porcentaje de casos verdaderos negativos que el modelo a predicho correctamente.

$$Especificidad = \frac{VN}{VN + FP}$$

$$Especificidad = \frac{2458}{2458 + 26}$$

$$Especificidad = 0.989$$

Por otro lado, la especificidad (98.9%) evidenció que el modelo clasificó correctamente casi la totalidad de las transacciones legítimas (verdaderos negativos), minimizando falsas alarmas.

Esto es crucial para evitar inconvenientes a los usuarios honestos y reducir costos asociados a revisiones manuales innecesarias.

- ✓ **Porcentaje de Precisión:** métrica que nos informa la proporción de los casos predichos como positivos que eran realmente positivos.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

$$\text{Precisión} = \frac{2435}{2435 + 26}$$

$$\text{Precisión} = 0.989$$

Finalmente, la precisión (98.9%) reveló que, de todas las transacciones etiquetadas como fraudulentas por el modelo, el 98.9% eran efectivamente fraudulentas. Esto indica un bajo porcentaje de falsos positivos, reforzando la confiabilidad de las alertas generadas.

CONCLUSIONES

- ✓ Se logró detectar las transacciones fraudulentas en proceso de pagos con medios móviles, con un grado de precisión del 99.84%, lo cual se pudo lograr gracias a que se elaboró un esquema de la propuesta de solución, el mismo que permitió organizar las actividades en una forma secuencias y desarrollarlas cada una de forma consecutiva.
- ✓ Respecto al primer objetivo, se comprendió la lógica del negocio, evidenciando los problemas identificados en Pagopay, en el que se evidenció que hubo un afectamiento a la integridad financiera así como a la confianza de los clientes.
- ✓ En el segundo objetivo, se evidenció una segmentación de 6 362 620 datos en 70% de entrenamiento y 30% de validación, de ello se procedió a analizar el tipo de datos para proceder con su codificación de la variable Tipo Transacción que fue transformada a través de la técnica One-Hot Encoding; además, se eliminaron columnas irrelevantes.
- ✓ En el caso del tercer objetivo, al entrenar el modelo, se obtuvo que la precisión para la data de validación fue la siguiente por cada algoritmo: 96.51% en Logistic Regression, 99.84% en XGB Classifier, 96.28% en SVC y 99.68% en Random Forest Classifier. Por lo tanto, se infirió que el algoritmo con mejores resultados fue XGB Classifier.
- ✓ En el cuarto objetivo se evaluó el modelo XGB Classifier en base a la matriz de confusión obtenido 99% de exactitud, 99.6% de sensibilidad, 98.9% de especificidad y 98.9% de precisión. Por lo tanto, se evidenció que el modelo es óptimo para clasificar la existencia de fraude en la empresa.

RECOMENDACIONES

Se sugiere seguir lo siguiente:

- Se recomienda implementar un sistema de monitoreo de calidad de datos que permita automatizar los datos desbalanceados y validar la integridad de estos.
- Se recomienda hacer uso de Dashboard para visualizar los datos de acuerdo a métricas en tiempo real.
- Realizar pruebas trimestrales con datos históricos segmentados por períodos.

GLOSARIO DE TÉRMINOS

- **Economía:** es el sistema complejo y dinámico que abarca todas las actividades relacionadas con la producción, distribución y consumo de bienes y servicios dentro de una sociedad.
- **Pérdida financiera:** se refiere a la disminución del valor monetario de una entidad o individuo, resultado de decisiones de inversión erróneas, fluctuaciones del mercado, riesgos no mitigados o eventos imprevistos.
- **Sofisticación:** implica un alto nivel de complejidad y desarrollo en procesos, sistemas, o enfoques, caracterizado por la incorporación de tecnologías avanzadas, estrategias refinadas y una profunda comprensión de las dinámicas subyacentes.
- **Vulnerabilidades:** son puntos débiles o brechas en un sistema, proceso o entidad que pueden ser explotadas por amenazas internas o externas, causando daños, pérdidas o comprometiendo la seguridad.
- **Inversión:** es el acto de asignar recursos, principalmente capital, con la expectativa de obtener un retorno en el futuro.
- **Estabilidad financiera:** es una condición en la que el sistema financiero de una economía, incluyendo bancos, mercados y otras instituciones, opera de manera eficiente y sin interrupciones graves, permitiendo la asignación óptima de recursos y la mitigación de riesgos.
- **Transacciones ilícitas:** son operaciones financieras que se realizan fuera del marco legal, involucrando actividades como el lavado de dinero o el financiamiento de actividades criminales.
- **Fraude:** es un acto intencional de engaño cometido por una o más personas para obtener un beneficio indebido, usualmente de naturaleza económica.
- **Algoritmo:** es un conjunto de instrucciones o reglas definidas y ordenadas que se siguen para resolver un problema o realizar una tarea específica.
- **Integridad financiera:** se refiere a la adherencia a principios éticos y legales en la gestión de recursos financieros.
- **Pagopay:** sistema de pago que funciona en cualquier lugar que admita pagos sin contacto.
- **ML:** Machine Learning

REFERENCIAS BIBLIOGRÁFICAS

- Abbassi, H., Mendili, S., & Gahi, Y. (2024). Digital banking fortification: A real-time isolation forest architecture for detecting online transaction fraud. *Engineering Research Express*, 6(2). <https://doi.org/10.1088/2631-8695/ad4958>
- ABS. (2024). *Personal Fraud*, 2022-23. <https://www.abs.gov.au/statistics/people/crime-and-justice/personal-fraud/latest-release>
- Afriyie, J. K., Tawiah, K., Pels, W. A., Addai-Henne, S., Dwamena, H. A., Owiredu, E. O., Ayeh, S. A., & Eshun, J. (2023). A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions. *Decision Analytics Journal*, 6, 100163. <https://doi.org/10.1016/j.dajour.2023.100163>
- Alarfaj, F. K., Malik, I., Khan, H. U., Almusallam, N., Ramzan, M., & Ahmed, M. (2022). Credit Card Fraud Detection Using State-of-the-Art Machine Learning and Deep Learning Algorithms. *IEEE Access*, 10, 39700-39715. <https://doi.org/10.1109/ACCESS.2022.3166891>
- Alhomayani, F. M., & Alruwaitee, K. A. (2024). A new financial risk prediction model based on deep learning and quasi-oppositional coot algorithm. *Alexandria Engineering Journal*, 108, 60-69. <https://doi.org/10.1016/j.aej.2024.07.052>
- Aziz, A., & Ghous, D. H. (2021). Fraudulent Transactions Detection in Credit Card by using Data Mining Methods: A Review. *INTERNATIONAL JOURNAL OF SCIENTIFIC PROGRESS AND RESEARCH (IJSPR)*, 79(1). <https://www.semanticscholar.org/paper/Fraudulent-Transactions-Detection-in-Credit-Card-by-Aziz-Ghous/94c21b6e241011697a34b32a6877591d693917d2>
- Boulieris, P., Pavlopoulos, J., Xenos, A., & Vassalos, V. (2024). Fraud detection with natural language processing. *Machine Learning*, 113(8), 5087-5108. <https://doi.org/10.1007/s10994-023-06354-5>

- Charizanos, G., Demirhan, H., & İcen, D. (2024). An online fuzzy fraud detection framework for credit card transactions. *Expert Systems with Applications*, 252, 124127. <https://doi.org/10.1016/j.eswa.2024.124127>
- Chávez, S. (2024). *Machine learning y el fraude financiero: Percepción de profesionales del sector financiero en Lima Metropolitana, 2013 –2023* [Pregrado, Universidad Nacional Mayor de San Marcos]. <https://cybertesis.unmsm.edu.pe/item/1721e443-b5f1-4814-ab18-8c978ab850da>
- Chhabra, R., Goswami, S., & Ranjan, R. K. (2024). A voting ensemble machine learning based credit card fraud detection using highly imbalance data. *Multimedia Tools and Applications*, 83(18), 54729-54753. <https://doi.org/10.1007/s11042-023-17766-9>
- Coppola, D. (2024). *Global e-commerce payment fraud losses 2023*. Statista. <https://www.statista.com/statistics/1273177/ecommerce-payment-fraud-losses-globally/>
- Dávila-Morán, R. C., Castillo-Sáenz, R. A., Vargas-Murillo, A. R., Velarde, L., García-Huamantumba, E., García-Huamantumba, C. F., Pasquel, R. F., & Guanilo, C. E. (2023). Application of Machine Learning Models in Fraud Detection in Financial Transactions. *Data and Metadata*, 2, 109. <https://doi.org/10.56294/dm2023109>
- Ejiyi, C., Qin, Z., Amos, J., Ejiyi, M., Nnani, A., Ejiyi, T. U., Agbesi, V. K., Diokpo, C., & Okpara, C. (2023). A robust predictive diagnosis model for diabetes mellitus using Shapley-incorporated machine learning algorithms. *Healthcare Analytics*, 3, 100166. <https://doi.org/10.1016/j.health.2023.100166>
- Ejiyi, C., Qin, Z., Nneji, G., Monday, H., Agbesi, V., Ejiyi, M., Ejiyi, T., & Bamisile, O. (2024). Enhanced Cardiovascular Disease Prediction Modelling using Machine Learning Techniques: A Focus on CardioVitalnet. *Network: Computation in Neural Systems*, 1-33. <https://doi.org/10.1080/0954898X.2024.2343341>
- Espinosa-Zúñiga, J. (2020). Aplicación de metodología CRISP-DM para segmentación geográfica de una base de datos pública. *Ingeniería, investigación y tecnología*, 21(1). <https://doi.org/10.22201/fi.25940732e.2020.21n1.008>

- Gasparetto, A., Marcuzzo, M., Zangari, A., & Albarelli, A. (2022). A Survey on Text Classification Algorithms: From Text to Predictions. *Information*, 13(2), 83. <https://doi.org/10.3390/info13020083>
- Hernández-Sampieri, R., & Mendoza, C. P. (2018). *Metodología de la investigación: Las rutas: cuantitativa ,cualitativa y mixta*. Mc Graw Hill educación. <http://repositorio.uasb.edu.bo:8080/handle/54000/1292>
- Inca Balseca, C. L., Paredes-Proañó, A. M., Cornejo-Reyes, P. J., & Mena-Reinoso, Á. P. (2022). Eficiencia de modelos de predicción de COVID-19 usando curvas ROC y matriz de confusión. *Dominio de las Ciencias*, 8(2), 1442-1460.
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*, 31(3), 685-695. <https://doi.org/10.1007/s12525-021-00475-2>
- Krishna, V., Kumar, R., Krishna, M., Karnam, B., Kumar, S., & Sekhar, C. (2024). Deep learning-based credit card fraud detection in federated learning. *Expert Systems with Applications*, 255, 124493. <https://doi.org/10.1016/j.eswa.2024.124493>
- Kumar, B. S., Yadav, P. P., & Reddy, M. R. (2024). An intelligent approach to detect and predict online fraud transaction using XGBoost algorithm. *Indonesian Journal of Electrical Engineering and Computer Science*, 35(3), 1491-1498. Scopus. <https://doi.org/10.11591/ijeecs.v35.i3.pp1491-1498>
- Liu, T., Jin, L., Zhong, C., & Xue, F. (2022). Study of thermal sensation prediction model based on support vector classification (SVC) algorithm with data preprocessing. *Journal of Building Engineering*, 48, 103919. <https://doi.org/10.1016/j.jobbe.2021.103919>
- Llerena, M. A., & Vargas, Y. (2022). *Sistema de seguridad para el monitoreo y control de eventos de transacciones críticas comerciales de una empresa de telecomunicaciones aplicando machine learning* [Pregrado, Universidad Peruana de Ciencias Aplicadas]. <https://repositorioacademico.upc.edu.pe/handle/10757/661055>
- Megdad, M. M. M., Abu-Naser, S. S., & Abu-Nasser, B. S. (2022). Fraudulent Financial Transactions Detection Using Machine Learning. *International Journal of Academic Information Systems Research (IJAISR)*, 6(3), 30-39.

- Mosa, D. T., Sorour, S. E., Abohany, A. A., & Maghraby, F. A. (2024). CCFD: Efficient Credit Card Fraud Detection Using Meta-Heuristic Techniques and Machine Learning Algorithms. *Mathematics*, 12(14), Article 14. <https://doi.org/10.3390/math12142250>
- Naseer, A., & Jalal, A. (2023). Pixels to Precision: Features Fusion and Random Forests over Labelled-based Segmentation. *2023 20th International Bhurban Conference on Applied Sciences and Technology (IBCAST)*, 1-6. <https://doi.org/10.1109/IBCAST59916.2023.10712869>
- Ndama, O., Bensassi, I., & En-naïmi, E. M. (2024). Innovative credit card fraud detection: A hybrid model combining artificial neural networks and support vector machines. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 13(3), 2674. <https://doi.org/10.11591/ijai.v13.i3.pp2674-2682>
- Nobel, S. M. N., Sultana, S., Singha, S. P., Chaki, S., Mahi, M. J. N., Jan, T., Barros, A., & Whaiduzzaman, M. (2024). Unmasking Banking Fraud: Unleashing the Power of Machine Learning and Explainable AI (XAI) on Imbalanced Data. *Information*, 15(6), 298. <https://doi.org/10.3390/info15060298>
- Padhi, B. K., Chakravarty, S., Naik, B., Nayak, S. R., & Poonia, R. C. (2024). Leveraging ensemble learning for enhanced security in credit card transaction fraudulent within smart cities for cybersecurity challenges. *Journal of Discrete Mathematical Sciences and Cryptography*, 27(4), 1233-1246. Scopus. <https://doi.org/10.47974/JDMSC-1978>
- Pérez, G. A. (2021). *Detección de transacciones fraudulentas en tarjetas de crédito mediante el uso de modelos de Machine Learning* [Pregrado, Universidad de los Andes]. <http://hdl.handle.net/1992/53571>
- Pipedrive. (2025). *Los 3 principales tipos de machine learning*. Pipedrive. <https://www.pipedrive.com/es/blog/tipos-de-machine-learning>
- Ponce, E. K., Sanchez, K. E., & Andrade-Arenas, L. (2022). Implementation of a Web System: Prevent Fraud Cases in Electronic Transactions. *International Journal of Advanced Computer Science and Applications*, 13(6), 865-876. <https://doi.org/10.14569/IJACSA.2022.01306102>
- Rajendran, S., Aji, A., Suhas, B., & Sahana, B. (2023). Role of ML and DL in Detecting Fraudulent Transactions. En *Artificial Intelligence for Societal*

- Issues* (pp. 59-82). Springer International Publishing.
https://doi.org/10.1007/978-3-031-12419-8_4
- Rakesh, D. K., & Jana, P. K. (2023). An improved differential evolution algorithm for quantifying fraudulent transactions. *Pattern Recognition*, 141, 109623.
<https://doi.org/10.1016/j.patcog.2023.109623>
- Rawashdeh, E., Al-Ramahi, N., Ahmad, H., & Zaghloul, R. (2024). Efficient credit card fraud detection using evolutionary hybrid feature selection and random weight networks. *International Journal of Data and Network Science*, 8(1), 463-472. Scopus. <https://doi.org/10.5267/j.ijdns.2023.9.009>
- Sarker, P., Ksibi, A., Jamjoom, M. ., Choi, K., Nahid, A., & Samad, A. (2025). Breast cancer prediction with feature-selected XGB classifier, optimized by metaheuristic algorithms. *Journal of Big Data*, 12(1), 78.
<https://doi.org/10.1186/s40537-025-01132-7>
- Sorour, S. E., AlBarrak, K. M., Abohany, A. A., & El-Mageed, A. A. A. (2024). Credit card fraud detection using the brown bear optimization algorithm. *Alexandria Engineering Journal*, 104, 171-192.
<https://doi.org/10.1016/j.aej.2024.06.040>
- Sreekanth, K., Mamidi, R., Reddy, T. S., Maddileti, K., & Deepthi, D. (2024). Prevention of credit card fraud transaction using GA feature selection for web-based application. *Indonesian Journal of Electrical Engineering and Computer Science*, 35(3), 1645-1652.
<https://doi.org/10.11591/ijeecs.v35.i3.pp1645-1652>
- Tang, Y., & Liang, Y. (2024). Credit card fraud detection based on federated graph learning. *Expert Systems with Applications*, 256, 124979.
<https://doi.org/10.1016/j.eswa.2024.124979>
- Varillas, P. R. (2021). *Machine Learning y su incidencia en el control de fraudes en la Empresa Interbank, Lima 2021* [Maestría, Universidad César Vallejo]. <https://repositorio.ucv.edu.pe/handle/20.500.12692/85162>
- Zaidi, A., & Al Luhayb, A. S. M. (2023). Two Statistical Approaches to Justify the Use of the Logistic Function in Binary Logistic Regression. *Mathematical Problems in Engineering*, 2023(1), 5525675.
<https://doi.org/10.1155/2023/5525675>

ANEXOS

Anexo 1. Instrumento

Ficha de registro para el indicador precisión y exactitud

RESUMEN DE EVALUACIÓN	
Tipo de prueba:	Post test
Investigador:	
Fecha de inicio:	
Algoritmo:	
Optimizador:	

MATRIZ DE CONFUSIÓN			
		Estimación del modelo	
		Negativo (N)	Positivo (P)
Real	Negativo	TN (True Positive)	FP (False Positive)
	Positivo	FN (False Negative)	TP (True Negative)

MÉTRICAS POR EVALUAR				
Ítem	Indicador	Medida	Fórmula	Resultado
1	Precisión	Razón	$Exactitud = \frac{TP + TN}{TP + FN + FP + TN} \times 100$	
1	Exactitud	Razón	$Precisión = \frac{TP}{TP + FP} \times 100$	

Anexo 2. Metodología CRISP-DM para el modelo entrenado

Para el desarrollo de las fases, se ha establecido de acuerdo con lo establecido por Espinosa-Zúñiga (2020).

FASE 1: Comprender el negocio

1.1. Definir la situación problemática

La empresa Pagopay enfrenta un desafío crítico en la detección y prevención de transacciones fraudulentas dentro de su ecosistema de pagos. Este problema, que afecta tanto a la integridad financiera como a la confianza de sus clientes y socios comerciales, se ha convertido en un obstáculo creciente debido al incremento en la sofisticación de las técnicas empleadas por los defraudadores. La detección de transacciones fraudulentas no solo es esencial para proteger los activos financieros de la empresa, sino también para mantener la reputación y la credibilidad de Pagopay en el competitivo mercado de pagos electrónicos.

Las causas del problema son diversas y complejas. En primer lugar, el volumen de transacciones que maneja Pagopay diariamente ha crecido exponencialmente en los últimos años, lo que dificulta la supervisión y análisis manual de cada operación. Este crecimiento ha resultado en una mayor vulnerabilidad, ya que la empresa no cuenta con sistemas suficientemente robustos para identificar patrones anómalos en tiempo real. Por último, se identificó que en determinado momento una tarjeta bancaria realiza operaciones inusuales en un mismo día, en intervalos de tiempos cortos y por montos repetitivos. Lo que daría indicio a sospechar que se trate de algún tipo de transacción fraudulenta por parte de delincuentes donde al sustraer las tarjetas bancarias de la víctima se realicen transacciones, la problemática radica en cómo se puede identificar qué tipo de transacción es legítima y que transacción puede estar considerando como fraude, en este caso al menos poder notificar al usuario o tomar medidas de precaución como bloquear la tarjeta cuando se realice un uso inadecuado de la tarjeta según el comportamiento habitual de la víctima.

FASE 2: Comprender los datos

La data fue obtenida de la empresa, considerando a 6 362 620 datos históricos.

Figura 32

Dataset de transacciones históricas




Figura 33

Visualización de la data en Colab

```
data = pd.read_csv('now_file.csv')
data.head()
```

	U. Tiempo	Tipo Transaccion	Monto Transaccion	Cuenta Emisor	Saldo Origen (E)	Saldo Nuevo (E)	Cuenta Receptor	Saldo Origen (R)	Saldo Nuevo (R)	es Fraude
0	1	PAYMENT	9839.64	C1231006815	170136.0	160296.36	M1979787155	0.0	0.0	0
1	1	PAYMENT	1864.28	C1666544295	21249.0	19384.72	M2044282225	0.0	0.0	0
2	1	TRANSFER	181.00	C1305486145	181.0	0.00	C553264065	0.0	0.0	1
3	1	CASH_OUT	181.00	C840083671	181.0	0.00	C38997010	21182.0	0.0	1
4	1	PAYMENT	11668.14	C2048537720	41554.0	29885.86	M1230701703	0.0	0.0	0

Figura 34

Atributos de la data

Característica	Descripción
U. Tiempo	Refiere la unidad de tiempo
Tipo Transaccion	Tipo de transacción realizada
Monto Transaccion	El importe total de la transacción
Cuenta Emisor	Cuenta que inicia la transacción
Saldo Origen (E)	Saldo de la cuenta del remitente antes de la transacción
Saldo Nuevo (E)	Saldo de la cuenta del remitente después de la transacción
Cuenta Receptor	Cuenta que recibe la transacción
Saldo Origen (R)	Saldo de la cuenta del receptor antes de la transacción
Saldo Nuevo (R)	Saldo de la cuenta del receptor después de la transacción
es Fraude	El valor a predecir, es decir, 0 o 1

Figura 35

Tipo de variable de los atributos de la data

```
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6362620 entries, 0 to 6362619
Data columns (total 10 columns):
#   Column              Dtype
---  -
0   U. Tiempo            int64
1   Tipo Transaccion    object
2   Monto Transaccion   float64
3   Cuenta Emisor       object
4   Saldo Origen (E)    float64
5   Saldo Nuevo (E)     float64
6   Cuenta Receptor     object
7   Saldo Origen (R)    float64
8   Saldo Nuevo (R)     float64
9   es Fraude           int64
dtypes: float64(5), int64(2), object(3)
memory usage: 485.4+ MB
```

En la figura 32 se muestra al conteo de la proporción total de las transacciones según la columna Tipo de transacción usando la biblioteca Seaborn.

Figura 36

Tipos de transacciones

- 353873 -> PAYMENTS(Pagos)
- 086753 -> TRANSFER(Transferencia)
- 373641 -> CASH-OUT(Retiro de efectivo)
- 007178 -> DEBIT(Debito)
- 227130 -> CASH-IN(Ingreso de efectivo)

FASE 3: Preparación de los datos (MML)

En esta fase se realiza la preparación de los datos, tales son las siguientes:

- ✓ Identificar y manejar valores faltantes, duplicados o inconsistentes.

En la figura 33 se revela información crítica sobre la distribución y características de los datos, lo cual es fundamental para el desarrollo del modelo de detección de fraudes.

Figura 37

Resumen estadístico de la data en Colab

	U. Tiempo	Monto Transaccion	Saldo Origen (E)	Saldo Nuevo (E)	Saldo Origen (R)	Saldo Nuevo (R)	es Fraude
count	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06	6.362620e+06
mean	2.433972e+02	1.798619e+05	8.338831e+05	8.551137e+05	1.100702e+06	1.224996e+06	1.290820e-03
std	1.423320e+02	6.038582e+05	2.888243e+06	2.924049e+06	3.399180e+06	3.674129e+06	3.590480e-02
min	1.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
25%	1.560000e+02	1.338957e+04	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
50%	2.390000e+02	7.487194e+04	1.420800e+04	0.000000e+00	1.327057e+05	2.146614e+05	0.000000e+00
75%	3.350000e+02	2.087215e+05	1.073152e+05	1.442584e+05	9.430367e+05	1.111909e+06	0.000000e+00
max	7.430000e+02	9.244552e+07	5.958504e+07	4.958504e+07	3.560159e+08	3.561793e+08	1.000000e+00

A continuación, se presenta una interpretación detallada de cada métrica:

- **Volumen de Datos (count):** Todas las columnas muestran un conteo uniforme de aproximadamente 6.36 millones de registros, lo que indica que no hay valores faltantes en el dataset. Esto es positivo para el análisis, ya que no se requerirá imputación de datos.
- **Es fraude:** con el valor de 1.29082e-03 confirma que es un dataset altamente desbalanceado. Solo una fracción mínima de transacciones son fraudulentas.

✓ Análisis de tipos de datos

El código presentado realiza un proceso de submuestreo (undersampling) en la columna 'esFraude' de un conjunto de datos para abordar un problema de desequilibrio de clases.

Figura 38

Proceso de submuestreo

Se integra el submuestreo (undersampling) de la columna esFraude

texto en cursiva

```
from sklearn.utils import resample

# Verificar balance original
print("Balance original de 'esFraude':")
print(data['esFraude'].value_counts())

# Separar clases
data_majority = data[data['esFraude'] == 0]
data_minority = data[data['esFraude'] == 1]

# Submuestreo de la clase mayoritaria
data_majority_downsampled = resample(data_majority,
                                     replace=False,
                                     n_samples=len(data_minority),
                                     random_state=42)

# Combinar las clases
data_balanced = pd.concat([data_majority_downsampled, data_minority])

# Mezclar aleatoriamente
data_balanced = data_balanced.sample(frac=1, random_state=42).reset_index(drop=True)

# Verificar nuevo balance
print("\nBalance después del submuestreo:")
print(data_balanced['esFraude'].value_counts())

# Opcional: guardar para usar en modelos
data_balanced.to_csv('/content/drive/MyDrive/DATA TESTS/dataset_submuestreado.csv', index=False)
```

En la figura 35 se muestra una distribución variada de tipos de datos, lo cual resulta fundamental para determinar las estrategias de preprocesamiento y modelado.

Figura 39

Análisis de tipos de datos

En esta sección, intentaremos comprender y comparar todas las columnas. Contaremos las columnas con diferentes tipos de datos, como categoría, entero y flotante.

```
obj = (data.dtypes == 'object')
object_cols = list(obj[obj].index)
print("Variables categóricas:", len(object_cols))

int_ = (data.dtypes == 'int')
num_cols = list(int_[int_].index)
print("Variables enteras:", len(num_cols))

fl = (data.dtypes == 'float')
fl_cols = list(fl[fl].index)
print("Variables flotantes:", len(fl_cols))
```

Variables categóricas: 3
Variables enteras: 2
Variables flotantes: 5

A continuación, se presenta un desglose detallado de los hallazgos:

- **Variables Categóricas (3 columnas):** evidencia la existencia de atributos cualitativos que requirieron de técnicas de codificación.
- **Variables Enteras (2 columnas):** representan a atributos discretos, como identificadores únicos, cantidades de transacciones o códigos numéricos. Estas variables han podido ser utilizadas directamente en el modelo.

- **Variables Flotantes (5 columnas):** indican la presencia de atributos cuantitativos continuos, como montos de transacciones, saldos origen y nuevo.

✓ Codificar variables categóricas: Tipo Transacción

Ambos gráficos de las figuras 36-37, muestran claramente que en su mayoría los tipos **cash_out**(Retiro de Efectivo) y **transfer**(Transferencia) son máximos tanto en cantidad como en importe.

Figura 40

Gráfico de barras del Tipo Transacción





Figura 41

Gráfico de barras del Tipo transacción y Monto transacción



En la figura 38 se realizó el proceso de transformación aplicado a la variable Tipo Transacción mediante la técnica *One-Hot Encoding*, generando una representación binaria que facilita el procesamiento algorítmico.

Figura 42

Codificación de la columna "Tipo transacción"

```
[ ] type_new = pd.get_dummies(data_balanced["TipoTransaccion"], drop_first=True)
data_new = pd.concat([data_balanced, type_new], axis=1)
data_new.head()
```

	uTiempo	TipoTransaccion	MontoTransaccion	CuentaEmisor	SaldoOrigen(E)	SaldoNuevo(E)	CuentaReceptora	SaldoOrigen(R)	SaldoNuevo(R)	esFraude	CASH_OUT	DEBIT	PAYMENT	TRANSFER
0	496	TRANSFER	766151.45	C2014329113	766151.45	0.00	C432435900	0.00	0.0	1	False	False	False	True
1	365	TRANSFER	31315.51	C1174332140	31315.51	0.00	C1252332991	0.00	0.0	1	False	False	False	True
2	302	PAYMENT	19043.02	C562601456	70067.00	51023.98	M1194092449	0.00	0.0	0	False	False	True	False
3	383	PAYMENT	11162.03	C1407058513	102921.00	91758.97	M175386067	0.00	0.0	0	False	False	True	False
4	354	CASH_OUT	268851.80	C626747845	220431.00	0.00	C833477591	1641753.59	1910605.4	0	True	False	False	False

La tabla resultante muestra la descomposición de cada categoría original en columnas binarias independientes, donde:

- **Estructura de Columnas Creadas:**

- Se han generado cuatro nuevas columnas booleanas (CASH_OUT, DEBIT, PAYMENT, TRANSFER), correspondientes a cada categoría existente en la variable original.
- Cada registro muestra el valor True (1) en la columna que coincide con su tipo de transacción original, y False (0) en las demás.

- **Ventaja:**

- Se eliminó el sesgo ordinal inexistente en los tipos de transacción (ninguna categoría es "mayor" que otra).

✓ Eliminar columnas irrelevantes: Cuenta Emisor, Cuenta receptor

En la figura 39 se resalta que el proceso de depuración del dataset ha resultado en una estructura optimizada para el modelado predictivo, donde se han eliminado columnas consideradas no relevantes para el análisis.

Figura 43

Eliminación de columnas irrelevantes: "Cuenta emisor" y "Cuenta receptor"

```
Una vez terminada la codificación, podemos eliminar las columnas irrelevantes. Para ello, siga el código a continuación.

[ ] x = data_new.drop(['esFraude', 'TipoTransaccion', 'CuentaEmisor', 'CuentaReceptora'], axis=1)
    y = data_new['esFraude']

Verifiquemos la forma de los datos extraídos.

[ ] x.shape, y.shape


((16426, 10), (16426,))
```

La operación realizada evidencia las siguientes características:

- **Reducción Dimensional Efectiva:**
 - Se han descartado cuatro columnas específicas: es Fraude (variable objetivo), Tipo Transaction (ya codificada previamente), Cuenta Emisor y Cuenta Receptor.
 - El dataset resultante (X) conserva únicamente 10 columnas predictoras, confirmadas por el output (6362620, 10).
 - **Separación Adecuada de Variables:**
 - La variable objetivo y (es Fraude) se ha aislado correctamente, como lo demuestra la forma (6362620,).
 - Esta separación cumple con el estándar requerido por los algoritmos de Machine Learning: X para features y y para el target.
 - **Justificación:**
 - Cuentas (Emisor/Receptor): Su eliminación se fundamenta en que los identificadores únicos no aportan patrones generalizables y podrían inducir overfitting (el modelo aprende demasiado bien).
 - Tipo Transacción: Ya fue transformada mediante one-hot encoding, haciendo redundante la columna original.
 - es Fraude: Separada intencionalmente como variable objetivo.
- ✓ Evidenciar la correlación entre las diferentes características usando heatmap (mapa de calor).
- La figura 40 muestra una serie de matrices de correlación que representan las relaciones entre diferentes variables relacionadas con transacciones financieras".

Figura 44

Mapa de calor de los atributos



A continuación, se presenta una interpretación detallada:

■ **Correlaciones Fuertes:**

- Tiempo vs. Cuenta Emisor (0.96): Alta correlación positiva, lo que sugiere que las transacciones de ciertas cuentas emisoras están concentradas en momentos específicos.
- Saldo Origen (R) vs. Saldo Nuevo (R) (0.88): Relación esperada, ya que el saldo nuevo depende del saldo origen.
- Monto Transacción vs. Cuenta Emisor (0.83): Indica que ciertas cuentas emisoras realizan transacciones con montos similares.

■ **Correlaciones Moderadas:**

- Tipo Transacción vs. Saldo Origen (R) (0.51): Algunos tipos de transacciones pueden estar asociados a saldos específicos en la cuenta receptora.
- Monto Transacción vs. Saldo Nuevo (R) (0.61): Sugiere que transacciones con montos altos pueden afectar significativamente el saldo receptor.

■ **Correlaciones Débiles o Nulas con "es Fraude":**

- Todas las variables muestran correlaciones cercanas a cero con "es Fraude" (valores entre -0.02 y 0.07). Esto indica que,

en estos datos, no hay una relación lineal clara entre las variables analizadas y la ocurrencia de fraude. Esto podría deberse a:

- El fraude depende de combinaciones no lineales de variables.
 - La muestra contiene pocos casos de fraude, diluyendo la correlación.
 - El fraude está asociado a variables no incluidas en la matriz.
- **Correlaciones Negativas:**
 - Tipo Transacción vs. Cuenta Receptor (-0.32): Ciertos tipos de transacciones pueden ser menos comunes para ciertas cuentas receptoras.
 - Cuenta Receptor vs. Saldo Origen (R) (-0.09): Correlación negativa leve, sin un patrón claro.

✓ **División del dataset:**

- Separar los datos en conjuntos de entrenamiento y validación.
Del total de 6362620 se consideró el 85% para data de entrenamiento (70% de entrenamiento y 15% para validación) y 15% para Testeo, tal se visualiza e las figuras 45-46.

Figura 45

Distribución de datos




Figura 46

División del dataset en Colab

```
Ahora dividamos los datos en dos partes: entrenamiento y prueba.
```

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42)
```


FASE 4: Modelado

✓ Comparación de algoritmos

De acuerdo con la figura 43, ML según su categoría cuenta con diversos algoritmos, por lo que, en este estudio se trabajará con ML Supervisado de Clasificación.

Figura 47

Algoritmos de Machine Learning



Nota. En la figura se visualizan los algoritmos de ML según su categoría.

Tomado de “Los 3 tipos de ML”, por Pipedrive, 2025.

Asimismo, de acuerdo con Gasparetto et al. (2022), realizó una comparativa de ventajas y desventajas de los algoritmos de Clasificación, tales se detallan en la tabla.

Tabla 8

Comparativa de algoritmos convencionales de clasificación

Algoritmo	Ventajas	Desventajas
Modelos Gráficos Probabilísticos (PGM)	✓ Métodos como Naïve Bayes son fáciles de implementar y entrenar, y más rápidos que la mayoría de los métodos convencionales.	✓ El método Bayes ingenuo tiene suposiciones fuertes que no siempre funcionan. ✓ Los CRF tienen una mayor complejidad computacional y también problemas con el aprendizaje en línea.
	✓ Métodos como los Campos Aleatorios Condicionales (CRF) aumentan la flexibilidad y el poder expresivo.	✓ Se escala desfavorablemente con espacios de alta dimensión.
K vecinos más cercanos (K-NN)	✓ No paramétrico y rápido en las condiciones adecuadas ✓ La formulación se adapta fácilmente a múltiples clases.	✓ El valor de k es difícil de elegir ✓ La función de distancia es difícil de definir para el texto.
Máquinas de Vectores de soporte (SVM)	✓ Puede modelar eficazmente límites de decisión no lineales ✓ Eficaz en espacios de gran dimensión ✓ Resistente al sobreajuste	✓ No produce probabilidades, que deben obtenerse con costosos procedimientos de validación cruzada.

		✓ Un número elevado de dimensiones provoca pérdida de transparencia. ✓ Alta complejidad de memoria. ✓ Elegir una función kernel es difícil.
Decision Trees (DT)	✓ Modela fácilmente características categóricas. ✓ Particularmente eficaz si los límites de decisión son paralelos al eje de características. ✓ Rápido y fácilmente interpretable.	✓ Extremadamente susceptible al ruido ✓ Se sobreajusta muy fácilmente ✓ Tiene problemas con los límites de decisión diagonales.
Logistic Regression (LR)	✓ Fácil de implementar y entrenar ✓ No requiere reescalar funciones ni realizar ajustes.	✓ Sólo puede resolver problemas lineales. ✓ Suposición fuerte de que los puntos de datos son independientes. ✓ Aún propenso al sobreajuste.
Random Forests (RF)	✓ Rápido en comparación con otros conjuntos. ✓ Reduce la varianza de árboles de decisión individuales.	✓ Difícil de interpretar. ✓ Inferencia más lenta en comparación con árboles individuales.

SVC (Support Vector Classification)	Según Liu et al. (2022):	Según Liu et al. (2022):
	✓ Eficaz en espacios de alta dimensión. ✓ Fuerte capacidad para crear límites de decisión complejos.	✓ No proporciona estimaciones de probabilidad. ✓ Es sensible al ruido.
Extreme Gradient Boost (XGBClassifier)	Según Sarker et al. (2025):	
	✓ Alto rendimiento y precisión, especialmente con datos estructurados ✓ Maneja eficientemente valores faltantes y valores atípicos ✓ Incluye regularización incorporada para evitar el sobreajuste. ✓ Se adapta bien a grandes conjuntos de datos ✓ Ofrece flexibilidad en el ajuste y la optimización.	✓ Requiere un ajuste cuidadoso de los parámetros para lograr un rendimiento óptimo. ✓ Puede ser propenso a sobreajuste si no se regulariza adecuadamente. ✓ Puede que no funcione tan bien con datos dispersos de alta dimensión.

Nota. En la tabla se comparan a los algoritmos de clasificación. Tomado de “A Survey on Text Classification Algorithms: From Text to Predictions”, por Gasparetto et al., 2022.

Por lo tanto, de acuerdo con la comparativa se decidió trabajar con 4 algoritmos: Logistic Regression, Random Forests, SVC y XGB Classifier; además, la decisión se sustenta en las afirmaciones de autores que se detallan a continuación:

- Estudios demostraron que XGB Classifier tiene el potencial de superar a otros algoritmos de clasificación. Tales como: Ejyiy et al. (2024) y Ejyiy

et al. (2023), quienes obtuvieron 99% y 94% de precisión en sus respectivos estudios.

- Naseer y Jalal (2023) afirmaron que Random Forest para fines de clasificación se describe en profundidad, con una tasa de precisión del 89,70%.
- Zaidi y Al Luhayb (2023) afirman que el uso de Logistic Regression ha demostrado su eficacia en el sector bancario con mayor precisión, mejores resultados y mayor facilidad de ejecución.
- Liu et al. (2022) afirman que el uso de SVC predijo con resultados óptimos de sensación térmica.

✓ Descripción de las librerías utilizadas

- Pandas: Esta biblioteca ayuda a cargar el marco de datos en formato de matriz 2D y cuenta con múltiples funciones para realizar tareas de análisis de una sola vez.
- Seaborn/Matplotlib: Para visualización de datos.
- Numpy: Las matrices Numpy son muy rápidas y permiten realizar grandes cálculos en muy poco tiempo.

✓ Construcción del modelo con la data de entrenamiento y validación

Se importaron los módulos de los modelos relevantes:

Figura 48

Código de importación de los módulos para el entrenamiento del modelo

```
from xgboost import XGBClassifier
from sklearn.metrics import roc_auc_score as ras
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.ensemble import RandomForestClassifier
```

En el código visto en las figuras 49-51 se realiza el entrenamiento y evaluación preliminar de tres modelos de Machine Learning para el problema de clasificación de detección de fraudes.

Figura 49

Entrenamiento del modelo en Colab

```
models = [
    LogisticRegression(max_iter=500),
    XGBClassifier(n_jobs=-1),
    SVC(),
    RandomForestClassifier()
]

print("\n===== RESULTADOS EN VALIDACIÓN =====\n")

for model in models:
    print("Entrenando:", model.__class__.__name__)
    model.fit(X_train, y_train)

    val_preds = model.predict(X_val)

    print("Accuracy Validación:", acc(y_val, val_preds))
    print("Recall Validación:", rec(y_val, val_preds))
    print("F1-score Validación:", f1(y_val, val_preds))
    print()
```

Figura 50

Entrenamiento final

```
# =====
#  ENTRENAMIENTO FINAL (TRAIN + VAL) Y TEST FINAL
# =====

# Elegimos XGBoost
best_model = XGBClassifier(n_jobs=-1)

best_model.fit(pd.concat([X_train, X_val]),
               pd.concat([y_train, y_val]))

test_preds = best_model.predict(X_test)

print("\n===== RESULTADOS EN TEST (PRODUCCIÓN) =====\n")
print("Accuracy Test:", acc(y_test, test_preds))
print("Recall Test:", rec(y_test, test_preds))
print("F1-score Test:", f1(y_test, test_preds))
```

Figura 51

Matriz de confusión del modelo final

```
# =====
#  MATRIZ DE CONFUSIÓN DEL MODELO FINAL
# =====

from sklearn.metrics import ConfusionMatrixDisplay
import matplotlib.pyplot as plt

cm = ConfusionMatrixDisplay.from_predictions(y_test, test_preds, cmap='Blues')
plt.title("Matriz de Confusión - Conjunto Test")
plt.show()
```

Modelos incluidos:

- LogisticRegression(): Modelo lineal básico para clasificación.
- XGBClassifier(): Algoritmo avanzado de Gradient Boosting (XGBoost) para manejar datos desbalanceados y relaciones complejas.

- RandomForestClassifier(): Ensemble de árboles con parámetros específicos:
 - ✓ n_estimators=7: Número de árboles.
 - ✓ criterion='entropy': Métrica para dividir nodos.
 - ✓ random_state=7: Inicia el generador de números aleatorios responsable de barajar y dividir los datos.

Bucle de entrenamiento y validación

- Entrenamiento (fit): Cada modelo se entrena con los datos X_train (features) y y_train (etiquetas).
- Predicciones en entrenamiento:
 - ✓ predict_proba(X_train)[:, 1]: Obtiene las probabilidades de la clase positiva (fraude) en el conjunto de entrenamiento.
 - ✓ Se imprime la métrica ras.
 - ✓ Predicciones en validación: Mismo proceso, pero aplicado a X_test y y_test para evaluar generalización.
- Salida: Nombre del modelo y métricas de precisión en entrenamiento/validación.

✓ **Resultados de precisión por cada algoritmo**

La tabla 8 muestra la precisión (accuracy) de tres algoritmos de Machine Learning en dos conjuntos de datos: entrenamiento y validación.

Tabla 9

Resultados de precisión de cada algoritmo

	Precisión del entrenamiento	Precisión de la validación
Logistic Regression	96.36%	96.51%
XGBClassifier	100%	99.84%
RandomForestClassifier	99.99%	99.68%
SVC	96.03%	96.28%

De acuerdo con los resultados obtenidos, se evidenció que el mejor algoritmo es XGBClassifier, por sus resultados óptimos.

Figura 52

Resultados de precisión de Colab

```
Increase the number of iterations (max iter) or scale the data as shown in:
https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
https://scikit-learn.org/stable/modules/linear\_model.html#logistic-regression
n_iter_i = _check_optimize_result(
LogisticRegression() :
Precisión del entrenamiento: 0.9636405098957201
Precisión de la validación: 0.9651436954281543

XGBClassifier(base_score=None, booster=None, callbacks=None,
               colsample_bylevel=None, colsample_bynode=None,
               colsample_bytree=None, device=None, early_stopping_rounds=None,
               enable_categorical=False, eval_metric=None, feature_types=None,
               feature_weights=None, gamma=None, grow_policy=None,
               importance_type=None, interaction_constraints=None,
               learning_rate=None, max_bin=None, max_cat_threshold=None,
               max_cat_to_onehot=None, max_delta_step=None, max_depth=None,
               max_leaves=None, min_child_weight=None, missing=nan,
               monotone_constraints=None, multi_strategy=None, n_estimators=None,
               n_jobs=None, num_parallel_tree=None, ...) :
Precisión del entrenamiento: 1.0
Precisión de la validación: 0.9984015539057167

SVC(probability=True) :
Precisión del entrenamiento: 0.9603327788199676
Precisión de la validación: 0.9628784614330405

RandomForestClassifier(criterion='entropy', n_estimators=7, random_state=7) :
Precisión del entrenamiento: 0.9999965053585561
Precisión de la validación: 0.9968348988353612
```

FASE 5: Evaluación

Se evaluó el rendimiento de cada modelo utilizando la técnica de la matriz de confusión, y se seleccionó el modelo más efectivo basado en criterios predefinidos.

Para evaluar la matriz de confusión se tiene que determinar los valores posibles que se obtiene (Inca-Balseca et al., 2022):

- **Verdadero positivo (VP):** Es el resultado de predecir un valor positivo y en efecto, era positivo en la predicción real.
- **Falso negativo (FN):** Se obtiene una predicción negativa, pero el resultado que se debería tener era positivo.
- **Falso positivo (FP):** Se obtiene una predicción como positivo, pero el resultado real era negativo.
- **Verdadero negativo (VN):** Es el resultado de predecir un valor negativo y en efecto, era negativo en la predicción real.

Tabla 10

Matriz de confusión

	PREDICCIÓN DEL MODELO	

		Con fraude	Sin fraude
PREDICCIÓN REAL	Con fraude	2435 (VP)	9 (FN)
	Sin fraude	26 (FP)	2458 (VN)

Para determinar las métricas de rendimiento del modelo se trabajó con las siguientes formulas (Inca-Balseca et al., 2022):

- ✓ **Porcentaje de Exactitud:** métrica que determina el porcentaje total que el modelo ha acertado tanto para casos positivos y negativos.

$$Exactitud = \frac{VP + VN}{VP + FN + FP + VN}$$

$$Exactitud = \frac{2435 + 2458}{2435 + 9 + 26 + 2458}$$

$$Exactitud = 0.99$$

- ✓ **Porcentaje de Sensibilidad:** métrica que determina el porcentaje de casos verdaderos positivos que el modelo a predicho correctamente.

$$Sensibilidad = \frac{VP}{VP + FN}$$

$$Sensibilidad = \frac{2435}{2435 + 9}$$

$$Sensibilidad = 0.996$$

- ✓ **Porcentaje de Especificidad:** métrica que determina el porcentaje de casos verdaderos negativos que el modelo a predicho correctamente.

$$Especificidad = \frac{VN}{VN + FP}$$

$$Especificidad = \frac{2458}{2458 + 26}$$

$$Especificidad = 0.989$$

- ✓ **Porcentaje de Precisión:** métrica que nos informa la proporción de los casos predichos como positivos que eran realmente positivos.

$$Precisión = \frac{VP}{VP + FP}$$

$$Precisión = \frac{2435}{2435 + 26}$$

$$Precisión = 0.989$$